

自适应加权贝叶斯物理信息神经网络 用于多任务多尺度的正向和逆向问题 *

Sarah Perez¹, Suryanarayana Maddu^{2,3,4,5,6}, Ivo F. Sbalzarini^{2,3,4,5} and Philippe Poncet¹

¹Universite de Pau et des Pays de l' Adour, E2S UPPA, CNRS, LMAP UMR CNRS-UPPA 5142, Pau, France.

²Technische Universität Dresden, Faculty of Computer Science, Nöthnitzer Str. 46, 01062 Dresden, Germany.

³Max Planck Institute of Molecular Cell Biology and Genetics, Pfotenhauerstr. 108, 01307 Dresden, Germany.

⁴Center for Systems Biology Dresden, Pfotenhauerstr. 108, 01307 Dresden, Germany.

⁵Center for Scalable Data Analytics and Artificial Intelligence (ScaDS.AI), Dresden/Leipzig, Germany.

⁶Center for Computational Biology, Flatiron Institute, 162 5th Avenue, New York NY 10010, USA.

2026 年 2 月 26 日

摘要

在本文中，我们提出了一种用于贝叶斯物理信息神经网络（BPINNs）自动自适应加权的新方法，并证明该方法能够稳健地解决多目标和多尺度问题。BPINNs 是一种广泛应用于数据同化的框架，结合了不确定性量化（UQ）和偏微分方程（PDE）的约束。BPINNs 目标分布项的相对权重与各学习任务的内在不确定性直接相关。然而，这些权重通常是事先手动设定的，这可能导致病态行为、稳定性问题以及任务间的冲突，这些问题阻碍了 BPINNs 在具有多尺度动力学的逆问题中的应用。

本加权策略通过考虑目标后验分布的多任务性质，自动调整权重。我们展示了该方法如何纠正 BPINNs 的失败模式，并实现对最优帕累托前沿的高效探索。这带来了 BPINNs 训练的更好收敛性和稳定性，同时减少了采样偏差。此外，确定的权重还包含了任务不确定性的信息，反映了数据中的噪声水平和 PDE 模型的适用性。

我们通过 Sobolev 训练中的数值实验进行了验证，并将结果与解析的 ϵ -最优基线进行了比较，同时还在一个多尺度 Lokta-Volterra 逆问题中进行了测试。最终，我们将该框架应用于图像修复任务和一个逆问题，涉及复杂几何中不可压缩流的潜在场恢复。

关键词: 哈密顿蒙特卡洛，不确定性量化，多目标训练，自适应权重学习，人工智能，贝叶斯物理信息神经网络。

1 引言

直接数值模拟依赖于适当的数学模型，这些模型源自物理原理，用以概念化现实世界的行为并理解复杂现象。实验数据主要用于参数识别和事后模型验证。然而，许多现实世界的应用特征在于

*预印本提交。

缺乏预测性的物理模型，尤其是在生命科学领域。因此，基于数据驱动的物理模型推断作为这些应用的补充方法逐渐兴起 [27]。同样的情况也适用于依赖数据同化和逆向建模的应用，例如地球科学领域。这确立了数据驱动模型作为科学应用中理论驱动模型的补充手段。

根据可用数据的数量，可以选择多种数据驱动建模策略。最近发布的一篇综述文章 [13] 介绍了数据驱动建模的最新进展及尚存挑战，应用重点集中在多孔介质研究。该综述涵盖了从利用稀疏回归进行模型推断的方法 [8, 14, 45, 26]，即从数据中推断部分微分方程（PDE）模型的符号结构，到基于观察到的动力学外推的无方程预测模型 [34, 53, 28]。因此，模型推断方法既适用于基于物理的场景，也适用于无方程的场景。

一种结合这两种场景的流行框架是物理信息神经网络（Physics Informed Neural Networks, PINNs）[40]。它们将潜在稀疏且带噪声的数据与物理原理（如守恒定律）相结合，这些物理原理以数学方程的形式表达。这些方程对神经网络进行正则化，同时网络权重 $\theta \in \mathbb{R}^d$ 和未知的方程系数 $\Sigma \in \mathbb{R}^p$ 从数据中推断。这使得 PINNs 能够作为替代模型使用，例如在流体力学中 [33, 49, 37]。总体而言，PINNs 为纯数据驱动方法提供了有效的替代方案，因为物理正则化可以弥补高保真数据的不足 [22, 31]。

尽管 PINNs 有效且多功能，但其正确使用较为困难，因为它们容易出现多种训练不稳定性。这是因为其训练过程等价于对联合参数集 $\Theta = \{\theta, \Sigma\}$ 进行加权多目标优化问题，

$$\hat{\Theta} = \arg \min_{\Theta} \sum_{k=0}^K \lambda_k \mathcal{L}_k(\Theta), \quad (1)$$

其中损失函数的每个项 $\mathcal{L}_k(\Theta)$ 对应一个不同的推断任务。对于典型的 PINNs，这些任务包括：数据拟合、PDE 残差最小化、边界与初始条件匹配，以及额外的物理约束，例如学习场的散度为零。该多任务学习问题的正确训练依赖于损失项权重 λ_k 的合理设置 [29]。权重选择不当可能导致优化偏差 [39]、任务特定梯度消失 [46, 10] 或灾难性遗忘 [29]。然而，自动优化损失权重并非易事，尤其是在高度非线性和多尺度问题中。

PINNs 权重调节问题广为人知，已有多种潜在解决方案被提出以平衡各目标 [9, 55, 56, 29]。这些方法提供了客观优化不同任务的准则，并实现对最优 Pareto 前沿的良好探索 [43]。虽然这提高了可靠性，减少了优化偏差，但关于预测置信度、噪声估计和模型适宜性仍存在若干问题 [15, 31, 60]。这些问题促使对不确定性量化（UQ）的需求，以确保推断的可信度，从而将 PINNs 扩展为贝叶斯推断形式的 BPINNs [59, 21]。然而，如何将成功的 PINN 加权策略适应于 BPINNs 并与 UQ 集成仍是未解决的问题。

BPINNs 通过提供预测的后验分布估计（也称为贝叶斯模型平均 [57]）实现了 UQ 的集成，这基于马尔可夫链蒙特卡洛（MCMC）采样。BPINNs 中最流行的 MCMC 方法之一是哈密顿蒙特卡洛（Hamiltonian Monte Carlo, HMC），它为高维具有平滑（物理）动力学的问题提供了特别高效的采样器 [4]。尽管 HMC 已被证明对 BPINNs 更高效，但其形式中势能与 PINN 的代价函数相关。PINN 的多目标损失函数直接转化为 BPINN 采样的多势能，因此也面临避免偏差和高效探索 Pareto 前沿的同样困难。

这往往导致 HMC 在 BPINN 训练过程中无法正确探索 Pareto 前沿。高维 Pareto 前沿的高效探索对于包含 UQ 的多任务多尺度学习问题依然具有挑战性，在贝叶斯情形下尚未得到解决。此问题的根源在于多势能的每一项在贝叶斯框架中由与尺度、噪声幅度及各学习任务固有不确定性相关的参数加权 [10]。尽管这些权重被认为是采样过程中的关键参数，但它们大多依赖手工调节 [32, 21, 31]，当真实不确定性未知时引入了隐含先验。合理设置这些参数既不简单也不具计算效率，

可能导致估计偏差或大量无效调参的资源浪费。因此，正确优化这些权重对于确保 HMC 从 Pareto 前沿附近的后验分布采样至关重要。这不仅实现稳健 BPINN 训练的必要条件，也是提升 UQ 估计可靠性的关键。

为了稳健处理 BPINNs 中的多任务 UQ 推断，本文关注的开放性问题：如何自动调整 BPINNs 中的权重以高效探索 Pareto 前沿并避免 UQ 推断中的偏差？如何管理对噪声分布（同方差或异方差）及其幅度的敏感性，而不引入隐含的先验？

我们首先刻画了 BPINN 可能的失败模式，这些模式在多尺度或多任务逆问题中特别普遍。随后提出了一种称为自适应加权哈密顿蒙特卡洛（Adaptively Weighted Hamiltonian Monte Carlo, AW-HMC）的改进采样器，通过在采样过程中平衡梯度方差来避免该问题。我们展示该方法导致加权后验分布更适合探索 Pareto 前沿。基准测试表明，该策略减少了采样偏差并增强了 BPINNs 的鲁棒性。尤其是，我们的方法改善了训练过程中 Leapfrog 步长的稳定性，确保了最佳积分并避免了过度减小时间步长。此外，该方法能够自动调整势能权重及其对应的不确定性，依据每项对噪声的敏感度及不同的尺度，从而显著提升 UQ 的可靠性，减少了包括先验分布在内的超参数调节需求，并降低了对噪声水平及任务尺度先验知识的依赖。我们展示该方法在收敛速度和计算成本方面均优于传统 BPINNs。我们还引入了一个新的预测质量度量，量化边缘化步骤中的收敛速率。最后，我们证明所提方法使 BPINNs 能够在具有稀疏且带噪数据的复杂实际问题中实现多尺度多任务的贝叶斯推断。

本文余下部分安排如下：第 2 节回顾了 BPINNs 和 HMC 采样器的一般原理，并刻画了 Sobolev 训练中的失败模式。第 3 节介绍了基于 BPINNs 的 UQ 自适应加权策略。我们在第 3.2 和 B 节通过已知解析解的基准问题验证该策略。随后，第 3.3 节展示了 AW-HMC 算法在 Lokta-Volterra 逆问题中的有效性，重点为动力参数的多尺度推断。第 4 节则演示了 AW-HMC 在流体动力学实际问题中的应用，特别展示了从稀疏且带噪数据中成功修复不可压缩狭窄血流，并且 UQ 估计与噪声水平及敏感性保持一致。最后，第 4.2 节探讨了复杂几何中的逆流问题，联合推断流动状态（逆雷诺数）和潜在压力场，基于部分速度测量数据。本文于第 5 节总结并讨论我们的观察结果。

2 从不确定性量化到贝叶斯物理信息神经网络：概念与局限性

基于数据驱动或黑箱代理模型的实际应用仍然是一个具有挑战性的任务。预测常常需要结合先验的物理知识，而这些知识的可靠性可能受到质疑，同时还要处理表现出测量不确定性的稀疏且带噪声的数据。这些现实问题还存在非线性 [21]、尺度性 [11] 和刚性 [19] 等问题，这些问题会显著影响常用方法的效率。因此，亟需开发能够稳健应对这些问题的数据驱动建模策略。

与此同时，构建在贝叶斯推断基础上的方法提出了一个研究社区关注的问题，即如何保证估计中的可信区间。这对于量化基础物理模型和测量数据的不确定性都非常重要，尽管在处理刚性、多尺度或多保真度问题时可能存在挑战。因此，在前述数据驱动方法中嵌入不确定性量化对于有效管理实际应用至关重要。

2.1 HMC-BPINN 的概念与原理

贝叶斯物理信息神经网络（Bayesian Physics-Informed Neural Networks, BPINNs）[59, 21, 20, 32, 24] 日益流行，这为将不确定性量化纳入 PINNs 标准并利用其预测能力提供了契机。该方法具有一个有趣的贝叶斯框架，宣称能够处理现实世界中稀疏且含噪声的数据，同时赋予模型及其预测以可靠性。

BPINN 的基本思想是将每个未知量，即神经网络和逆问题参数 Θ ，视为具有特定分布的随机变量，而非像传统 PINN 那样视为单一参数。各种采样策略均旨在通过边缘化过程探索参数 Θ 的后验分布

$$P(\Theta|\mathcal{D}, \mathcal{M}) \propto P(\mathcal{D}|\Theta)P(\mathcal{M}|\Theta)P(\Theta) \quad (2)$$

，条件是给定某些测量数据 $\mathcal{D}$ 和假设模型 $\mathcal{M}$ ，而非寻找满足优化问题 (1) 的最佳近似。后验分布表达式 (2) 来自贝叶斯定理，基本上包含数据拟合似然项 $P(\mathcal{D}|\Theta)$ 、偏微分方程似然项 $P(\mathcal{M}|\Theta)$ 以及联合先验分布 $P(\Theta)$ 。这些特定项在应用和不同章节中会逐案详细说明。贝叶斯边缘化将参数 Θ 的分布转化为预测的后验分布，也称为贝叶斯模型平均 (Bayesian Model Average, BMA)：

$$\underbrace{\mathcal{P}(y|x, \mathcal{D}, \mathcal{M})}_{\text{predictive BMA distribution}} = \int \underbrace{\mathcal{P}(y|x, \Theta)}_{\text{prediction for } \Theta} \underbrace{\mathcal{P}(\Theta|\mathcal{D}, \mathcal{M})}_{\text{posterior}} d\Theta \quad (3)$$

其中 x 和 y 分别指神经网络的输入（例如空间和时间点）和输出（例如场预测）。在该方程中，所有根据采样得到的 Θ 参数 (2) 所产生的不同预测，按其后验概率加权并平均，提供了 BPINN 输出的内在不确定性量化。总体而言，BPINNs 通过对参数 Θ 进行贝叶斯边缘化，形成了感兴趣量 (QoI)，即学习场和逆参数的预测分布 (3)。

针对深度神经网络的贝叶斯推断已经开发出多种方法，包括变分推断 (Variational Inference) [58, 23] 和马尔可夫链蒙特卡洛方法 (MCMC)。其中，一种基于哈密顿动力学的 MCMC 采样器——哈密顿蒙特卡洛 (Hamiltonian Monte Carlo, HMC) 由于其能够考虑后验分布的几何性质，处理高维问题而受到越来越多关注。Betancourt 通过对方法的概念性理解解释了 HMC 的高效性 [4]，并在理论上证明了链的遍历性和收敛性 [6, 25]。从数值角度，Yang 等人 [59] 强调了 BPINNs-HMC 在正问题和逆问题上的优越表现，相较其变分推断版本。这确立了 HMC 作为 BPINNs 的一种理论和数值上都非常有效的 MCMC 方案。

以下内容将简要回顾经典 BPINNs-HMC 的基本原理，并指出其局限性，特别是在多目标和多尺度问题中的表现。

HMC 的核心思想是假设一个虚拟粒子，其连续位置和动量为 (Θ, r) ，在无摩擦的负对数后验 (negative log posterior, NLP) 几何上遵循哈密顿动力学。该方法引入辅助变量 r ，将 (2) 的采样转化为在相空间中探索联合概率分布 $\pi(\Theta, r)$

$$\pi(\Theta, r) \sim e^{-H(\Theta, r)}. \quad (4)$$

。该分布依赖于哈密顿量的特定分解 $H(\Theta, r) = U(\Theta) + K(r)$ ，其中势能和动能分别为 $U(\Theta)$ 和 $K(r)$ ，满足

$$\pi(\Theta, r) \propto P(\Theta|\mathcal{D}, \mathcal{M})\mathcal{N}(r|0, M) \quad (5)$$

，动量服从均值为零的多元高斯分布，其协方差矩阵（或质量矩阵） M 通常取为缩放的单位矩阵。系统的哈密顿量表达为

$$H(\Theta, r) = U(\Theta) + \frac{1}{2}r^T M^{-1}r \quad (6)$$

，其中势能直接与目标后验分布相关。该能量项通常表示为负对数后验 $U(\Theta) = -\ln P(\Theta|\mathcal{D}, \mathcal{M})$ ，这导致多势能结构，如第 2.2 节详细说明。此结构保证了 Θ 的边缘分布能够直接提供目标后验分布的样本

$$P(\Theta|\mathcal{D}, \mathcal{M}) \sim e^{-U(\theta)} \quad (7)$$

，因为高效探索联合分布 $\pi(\Theta, r)$ 可直接映射为对目标分布的高效探索，正如 Betancourt 所描述 [4]。HMC 采样过程交替执行确定性步骤（求解无摩擦粒子沿哈密顿动力学系统轨迹）

$$\begin{cases} d\Theta = M^{-1}r dt \\ dr = -\nabla U(\Theta) dt, \end{cases} \quad (8)$$

和随机步骤（根据上述高斯分布重新采样动量）。由于哈密顿方程 (8) 理论上保持系统总能量不变，每个确定性步骤被限制在特定能级集合内，而随机步骤允许跨能级集扩散，实现相空间的有效探索。该能量守恒的理论条件要求数值方案保证能量守恒。

因此，常用辛积分器来数值求解哈密顿动力学 (8)：即 Störmer-Verlet 积分器，也称为跳蛙法 (leapfrog method)。然而，这些积分器并非完全无离散误差，实际中可能破坏哈密顿量在确定性迭代中的守恒。为减少数值积分中离散误差引起的偏差，流程中最终加入修正步骤，即基于哈密顿量跃迁的 Metropolis-Hasting 判据。该接受准则通过拒绝导致概率跃迁发散的样本，趋向于保持能量守恒。确定性轨迹的探索对两个超参数尤为敏感：跳蛙法中的步长 δt 和迭代次数 L 。调节这些参数较为困难，尤其当后验分布存在病态或高曲率区域时 [4]，可能导致不稳定、性能下降以及 MCMC 估计的有效性降低。尽管采用了保持哈密顿性质的数值方案，传统 HMC-BPINN 仍可能遇到病态偏差问题。

为应对这些发散效应，研究者们致力于开发策略，或自适应设置轨迹长度 L [17]，同时保持详细平衡条件，或利用标准自适应 MCMC 方法在线调整步长 δt [5]。其中，Hoffmann 和 Gelman 提出的 No-U-Turn 采样器 (No-U-Turn sampler, NUTS) [16] 是最流行的自适应策略之一。然而，这类发散轨迹表明即使有自适应方法，MCMC 估计仍可能存在显著偏差。面对导致后验分布几何行为显著不同或尺度差异巨大的多势能项，这类自适应方法的有效性值得质疑。事实上，自适应策略主要调整跳蛙超参数以确保最敏感势能项满足能量守恒，可能导致其他势能项及整体后验分布的超参数选择不佳。这反映了基于调整跳蛙超参数的自适应策略的局限性。

当这些发散病态广泛存在时，Betancourt [4] 建议的另一种方法是对目标分布进行正则化，但这在现实应用中可能较为繁琐且需额外调参。尽管如此，这为研究各学习任务对目标分布整体行为的影响提供了极好机会，并为新颖的自适应加权策略铺平了道路。

在后续章节中，我们将特别关注现实多任务和尺度范式带来的挑战。我们展示现有 BPINN 方法在这类问题中的重大失败，并利用基于发散概率跃迁的强大诊断工具识别主要病态。

2.2 多目标问题范式

关于 PINN 中多目标优化问题的讨论，从直接或逆问题产生的目标后验分布 (2) 的采样需要使用多势能项 $U(\Theta)$ 。此外，在实际应用中，我们必须处理稀疏且带噪声的测量数据，其保真度还可能涵盖不同的尺度：这正是具有多源数据的多保真度问题的情形 [22, 31]。

为了通用性，我们引入时空域 $\Omega = \tilde{\Omega} \times \mathcal{T}$ ，其中 $\tilde{\Omega} \subset \mathbb{R}^n$ ， $n = 1, 2, 3$ ，并假设 PDE 系统具有如下形式：

$$\begin{cases} \mathcal{F}(u(t, x), \Sigma) = 0, & (t, x) \in \Omega \\ \mathcal{H}(u(t, x), \Sigma) = 0, & (t, x) \in \Omega \\ \mathcal{B}(u(t, x), \Sigma) = 0, & (t, x) \in \Omega^\partial := \partial\tilde{\Omega} \times \mathcal{T} \\ \mathcal{I}(u(t, x), \Sigma) = 0, & (t, x) \in \Omega^I := \tilde{\Omega} \times \mathcal{T}_0 \end{cases} \quad (9)$$

其中 u 是主要未知量， $\mathcal{F}$ 是主微分方程（例如纳维-斯托克斯方程）， $\mathcal{H}$ 是附加约束（例如不可压缩条件）， $\mathcal{B}$ 和 $\mathcal{I}$ 分别为边界条件和初始条件， Σ 是 PDE 模型参数，可能是已知的或待推断的。解

场 u 的部分测量量也可能存在于子集 $\Omega^u \subset \Omega$ 中。时空域的这种连续描述随后被离散化，以便选择用于 BPINNs 采样的训练数据集。

我们首先定义训练数据集 $\mathcal{D}$ ，其分解为 $\mathcal{D} = \mathcal{D}^\Omega \cup \mathcal{D}^\partial \cup \mathcal{D}^I \cup \mathcal{D}^u$ ，包含在各自集合 Ω 、 Ω^∂ 、 Ω^I 和 Ω^u 中采样的散乱且带噪声的测量数据。关于数据损坏，我们假设对 u 上的稀疏观测存在独立的高斯噪声，因此 $\mathcal{D}^u$ 定义为

$$\mathcal{D}^u = \{(t_i, x_i, u_i), \text{ s.t. } (t_i, x_i) \in \Omega^u \text{ and } u_i := u(t_i, x_i) + \xi_u(t_i, x_i), i = 1 \dots N^u\} \quad (10)$$

其中噪声 $\xi_u \sim \mathcal{N}(0, \sigma_u^2 I)$ ，标准差 σ_u 可根据传感器的保真度进行估计（如果可获得）。BPINN 的神经网络部分随后为每个参数样本 $\Theta = \{\theta, \Sigma\}$ 提供 u 的代理模型，记为 u_Θ ，其先验分布记为 $P(\Theta)$ 。该先验考虑了神经网络参数 θ 的先验（假设为均值为零且相互独立的高斯分布）以及模型参数 Σ 的先验，因此在独立条件下有 $P(\Theta) = P(\theta)P(\Sigma)$ 。对于正问题，即 PDE 模型参数已知时，先验分布简化为 $P(\theta)$ 。当存在未知量的部分测量数据，意味着 $\mathcal{D}^u$ 非空（逆问题或图像修复问题中常见），则代理模型 u_Θ 应满足贝叶斯框架中的数据拟合似然项，即在集合 $\mathcal{D}^u$ 上量化神经网络预测与训练数据的拟合：

$$P(\mathcal{D}^u | \Theta) \propto \prod_{i=1}^{N^u} \exp \left(\frac{-(u_\Theta(t_i, x_i) - u_i)^2}{2\sigma_u^2} \right). \quad (11)$$

类似地，模型输出的边界条件在集合 $\mathcal{D}^\partial$ 上施加约束：

$$\mathcal{D}^\partial = \{(t_i, x_i, \mathcal{B}(u_i)), \text{ s.t. } (t_i, x_i) \in \Omega^\partial \text{ and } \mathcal{B}(u_i) := \mathcal{B}(u(t_i, x_i)) + \xi_b(t_i, x_i), i = 1 \dots N^\partial\} \quad (12)$$

通过满足下述边界似然项

$$P(\mathcal{D}^\partial | \Theta) \propto \prod_{i=1}^{N^\partial} \exp \left(\frac{-(\mathcal{B}(u_\Theta(t_i, x_i)) - \mathcal{B}(u_i))^2}{2\sigma_b^2} \right). \quad (13)$$

边界条件项的噪声敏感性同样通过独立的高斯分布刻画，即 $\xi_b \sim \mathcal{N}(0, \sigma_b^2 I)$ ，标准差 σ_b 需要被估计。区分 ξ_u 和 ξ_b 是因为数据损坏不一定均匀：实际上，面对异方差噪声时，测量分布的方差在局部可能不同。这在地球科学中尤为典型，例如基于 X 射线微断层扫描图像的数据驱动建模中，边界噪声估计 ξ_b 需要特别关注。这主要是由于伪影限制（如部分体积效应、边缘增强）倾向于增强材料界面处的模糊效应，进而影响介质有效性质的量化，如渗透率和微孔隙率 [35, 2]。初始条件同样存在类似情况，可能具有不同的敏感性 ξ_i 。在 BPINN 中，前述数据拟合项结合物理原理以正则化神经网络预测，基于 PDE 系统 (9)。

关于 PDE 似然项，定义 $\mathcal{D}^\Omega$ 为训练点集合，在这些点上强制代理模型满足 PDE 及额外物理约束：

$$\mathcal{D}^\Omega = \{(t_i, x_i) \in \Omega, \mathcal{F}(u_\Theta(t_i, x_i)) = \xi_f(t_i, x_i) \text{ and } \mathcal{H}(u_\Theta(t_i, x_i)) = \xi_h(t_i, x_i), i = 1 \dots N^\Omega\} \quad (14)$$

其中 ξ_f 和 ξ_h 表示两个方程中的模型不确定性，通常未知且容易导致物理模型误设。根据这些符号，正问题对应 $\mathcal{D}^u = \emptyset$ 且 Σ 已知，通过仅基于 PDE 物理假设对 Ω 上的场 u_Θ 进行直接预测。相反，逆问题旨在利用 PDE 模型和预测场 u 的部分带噪信息 $\mathcal{D}^u$ 共同推断 Σ 。最后，图像修复问题基于这些部分测量数据补全并恢复预测场中的缺失信息，同时结合 PDE 先验。

最终，参数 Θ 的目标后验分布 (2) 根据贝叶斯规则分解为一系列多任务似然项（包括数据拟合和 PDE 似然）及先验：

$$P(\Theta | \mathcal{D}, \mathcal{M}) \propto P(\mathcal{D}^u | \Theta) P(\mathcal{D}^\partial | \Theta) P(\mathcal{D}^I | \Theta) P(\mathcal{D}^\Omega, \mathcal{F} | \Theta) P(\mathcal{D}^\Omega, \mathcal{H} | \Theta) P(\theta) P(\Sigma) \quad (15)$$




图 1: Sobolev 训练中至多二阶导数的 HMC 均匀加权失效模式导致非守恒哈密顿量（中部），以及极差的函数近似效果（右侧）。这是由于有效梯度 $\nabla_{\theta} L_k$ 分布 ($k = 0, 1, 2$) 方差的强烈不平衡所致，图中相对于 $(N_s \times L)$ HMC 迭代次数绘制（左侧）。

对应于 HMC 采样器的多势能

$$U(\Theta) = \frac{\|u_{\Theta} - u\|_{\mathcal{D}^u}^2}{2\sigma_u^2} + \frac{\|\mathcal{B}(u_{\Theta}) - \mathcal{B}(u)\|_{\mathcal{D}^{\partial}}^2}{2\sigma_b^2} + \frac{\|\mathcal{I}(u_{\Theta}) - \mathcal{I}(u)\|_{\mathcal{D}^I}^2}{2\sigma_i^2} + \frac{\|\mathcal{F}(u_{\Theta})\|_{\mathcal{D}^{\Omega}}^2}{2\sigma_f^2} + \frac{\|\mathcal{H}(u_{\Theta})\|_{\mathcal{D}^{\Omega}}^2}{2\sigma_h^2} + \frac{\|\theta\|_{\mathbb{R}^d}^2}{2\sigma_{\theta}^2} + \frac{\|\Sigma - \mu_{\Sigma}\|_{\mathbb{R}^p}^2}{2\sigma_{\Sigma}^2} \quad (16)$$

依据方程 (7)。符号 $\|\cdot\|$ 对于对数似然项指代 RMS（均方根）范数——继承自开集 Ω 上的泛函 $\mathbb{L}^2$ -范数，对于对数先验项指代通常的欧几里得范数。此外，多势能 (16) 在此以一般框架书写，基于先验假设 $P(\theta) \sim \mathcal{N}(0, \sigma_{\theta}^2 I_d)$ 和 $P(\Sigma) \sim \mathcal{N}(\mu_{\Sigma}, \sigma_{\Sigma}^2 I_p)$ 。注意对数先验项可视为等价约束优化问题中的 $\mathbb{L}^2$ -正则项。然而，适当选择这些先验分布——即恰当调整参数 σ_{θ} 、 μ_{Σ} 和 σ_{Σ} ——通常并非易事且耗时。总体来看，方程 (16) 表明，即使在简单问题设定下，BPINN 可能面临极其类似于 PINN 中加权多目标损失的势能项，这些权重主要依赖手工调整。

因此，主要挑战是采样接近帕累托最优解，以确保 BPINNs 提供高效且可靠的预测和不确定性量化。否则，采样结果可能集中于局部极小值，偏向某一多势能项而牺牲其他项。

其次，虽然标准差 $\sigma_{\bullet}$ 是关键参数，与任务内在不确定性相关，但大多数作者要么赋予固定值，要么将其作为额外超参数进行训练 [32, 50, 21]。这可能导致高度偏倚的预测，尤其是在设置 PDE 残差标准差 σ_f 和 σ_h 时，因其引入了模型适用性的强先验。

最近 Psaros 等 [38] 讨论了包括主要针对数据拟合标准差的参数调整的替代方案，适用于未知且异方差噪声分布的情境。其方法要么依赖于离线学习，代价是预训练的生成对抗网络（GAN），要么基于额外参数训练进行在线权重学习。特别地，当考虑位置相关方差时，额外参数数量可能急剧增加，如 [38] 所示，适用于实际应用，但因此付出计算成本。如何在不增加计算复杂度的情况下，通过学习额外超参数来处理此类未知（齐次或异方差）噪声分布，仍是一个开放问题。

最后，尽管在整体不确定性量化中指出了物理模型误设的问题，但在 [38] 中，当对物理约束 $\mathcal{F}$ 和 $\mathcal{H}$ 采用误导性模型不确定性假设时，并未解决此问题。因此，如何避免通过手工调整通常未知或预设的超参数 σ_f 和 σ_h 引入强先验，以保证模型适用性，仍是一个具有挑战性的任务。

鉴于此，我们希望测试 Sect. 2.1 中介绍的常规模型 BPINNs-HMC 方法的鲁棒性，采用一个测试案例展示多目标及多尺度采样中所产生的问题，利用 Sobolev 培训的神经网络进行验证。

2.3 BPINNs 中 Sobolev 训练的失败模式

Sobolev 训练是多目标 BPINN 采样的一个特例，由于涉及的尺度差异，可能导致刚性学习问题 [29]。尽管如此，它在机器学习社区中被广泛使用，通过将目标函数导数的信息加入损失函数或其等效的势能中，以提升神经网络的预测效率和泛化能力 [12, 48, 54, 62]。

这种特殊训练为测试当前 BPINNs-HMC 方法在任务特定梯度消失失败模式下的鲁棒性提供了基线 [29]。同时，它也为基于已知的 Sobolev 多目标优化解析 ε -最优权重进行基准测试提供了机会 [29]。

这里对 Sobolev 回归任务进行了 BPINNs-HMC 采样测试，这意味着数据集限制为 $\mathcal{D} = \mathcal{D}^u$ ，包含函数及其导数 D_x^k ($k \geq 1$) 的测量，导数阶数最高为 K ，因此目标后验分布为

$$P(\Theta|\mathcal{D}) \propto \prod_{k=0}^K P(\mathcal{D}^u, D_x^k u|\Theta) P(\Theta) \quad (17)$$

势能因此具有如下通用形式

$$U(\Theta) = \sum_{k=0}^K \left[\frac{\lambda_k}{2\sigma_k^2} \|D_x^k u_\Theta - D_x^k u\|^2 \right] + \frac{\lambda_{K+1}}{2\sigma_{K+1}^2} \|\Theta\|^2 := \sum_{k=0}^{K+1} \lambda_k \mathcal{L}_k(\Theta) \quad (18)$$

其中 $L_k = \lambda_k \mathcal{L}_k$ 表示加权的第 k 个目标项， λ_k 是待定义的正权重参数（详见第 3.1 节）。本节中我们仅采用均匀加权策略，令 $\lambda_k = 1, \forall k$ ，对应经典的 BPINNs-HMC 形式。为简洁起见，式 (18) 中将神经网络及逆向参数的对数先验项合并，假设它们均服从相同的先验分布。

我们首先引入一个包含二阶导数的 1D Sobolev 训练，测试函数为 $u(x) = \sin^3(\omega x)$ ，定义域为 $\Omega = [-0.7, 0.7]$ ， $\omega = 6$ 。使用 100 个训练点，设置 leapfrog 参数为 $L = 100$ ，时间步长 $\delta t = 1e-3$ ，进行 $N_s = 200$ 次采样迭代。测试限定为函数逼近问题，因此后续中 Θ 仅指神经网络参数。除非另有说明，所有 σ_k 均设为 1，因为实际中我们无法获得导数或残差 PDE 项的噪声参数值，只能获得数据场 u 的观测噪声（如有）。

类似于 PINNs，本测试案例中均匀权重 λ_k 导致不同目标项间梯度方差不平衡。特别是，高阶导数项的梯度方差占主导，导致其他任务梯度消失，进而引发后验分布探索偏差。图 1（左）显示，高阶导数对应的梯度方差 $\text{Var}\{\nabla_\Theta L_2\}$ 迅速比其他有效梯度方差高出两个数量级。除了帕累托前沿探索效率低下外，高阶导数项还引发不稳定问题，导致 leapfrog 轨迹上的 Hamiltonian 不守恒（见图 1 中间）。如第 2.1 节所述，经典 HMC 中均匀加权引起的此类发散病态是结果估计偏差的强烈诊断指标，并质疑其有效性。

对抗这种影响的一个替代方法是减小时间步长 δt ，以平衡导数项的数量级，提升 BPINNs-HMC 的 Metropolis-Hasting 接受率。然而，leapfrog 迭代中的小时间步长更可能引发病态随机游行为或采样偏差 [16, 4]。为此，我们尝试利用带步长自适应的 No-U-Turn 采样器 (NUTS)，详见 Hoffmann 和 Gelman 的算法 5 [16]，并在 Python 开源包 hamiltonian 中实现 [11]。保持之前完全相同的 leapfrog 参数以符合相同假设，设定 $N = 20$ 次自适应步骤，最终适配步长为 $\delta t = 1.29e-4$ 。此时，我们仍未能有效探索帕累托前沿，见图 2 中有效梯度方差所示。该结果表明，二阶导数的逼近较信号本身更优，但采样表现出偏差，即信号 u 仅确定到一个线性函数，原因是高阶导数项占主导。此线性偏差也在图 2（右下）体现。这进一步验证了 NUTS 时间步长适配主要聚焦于高阶导数的保持，导致刚性问题。

总之，即使是简单的 1D Sobolev 训练配合平凡的均匀权重，也会因后验分布对高阶导数的敏感性引发经典 BPINNs-HMC 方法的主要失败，产生不稳定性。因此，Hamiltonian 守恒的发散使




图 2: Sobolev 训练中 NUTS 步长自适应在二阶导数范围内的失效模式: 有效梯度 $\nabla_{\Theta} L_k$ 分布的方差 (左上) 和哈密顿演化 (右上), 分别显示任务不平衡和能量水平的弱探索。信号逼近 (左下) 和逐点误差 (右下) 突出 u_{Θ} 的线性偏差。虚线垂直线界定了 NUTS 采样器中的自适应步数。

得该采样方法无法正常工作。此外, 确保 Hamiltonian 守恒的替代方案效果有限, 要么导致能量水平探索效率低下, 要么在多任务多尺度采样中产生强烈不平衡。这表明 Hamiltonian 马尔科夫链无法充分探索由该势能定义的目标分布的帕累托前沿, 且传统方法难以克服强不平衡条件。

因此, 我们的目标是开发一种策略, 实现不同任务间的平衡条件, 独立于其尺度, 通过寻找合适的加权形式。该方法对于解决 leapfrog 参数自适应设置之外的常见 HMC 问题至关重要, 且具有无需无谓减小时间步长即可减少不稳定性的优点。

3 用于 BPINNs 中无偏不确定性量化的自适应加权策略

传统的 BPINN 公式在多目标推断方面存在局限性, 例如稳定性和刚性问题、任务之间的病态冲突, 以及对帕累托最优前沿的偏置探索。这些问题不能仅通过像 NUTS 采样器中那样自适应设置 leapfrog 参数, 或手动调整标准差 σ 来解决, 因为后者会引入额外的计算成本或能量浪费。因此, 我们研究了另一种自适应方法, 该方法侧重于目标分布的直接正则化: 其目标是通过自动调整关键的 σ 参数来平衡任务权重。

3.1 一种逆狄利克雷自适应加权算法: AW-HMC

考虑到 HMC-BPINN 方法的局限性 (前文第 2 节已讨论), 开发一种新的替代方案变得尤为关键, 特别是在由真实数据引发的复杂多目标问题中。该策略必须解决以下主要病理问题: 1) 确保目标后验分布的帕累托前沿的探索, 2) 管理不同项的尺度敏感性, 3) 控制哈密顿系统的不稳定性。

独立于这些病理性考虑, 仍存在关键的 σ 参数设置问题, 尤其是在数据噪声水平和 PDE 模型置信度未知的情况下。尽管手动调节这些参数仍然普遍, 但我们可以依赖于 λ 权重的自适应来隐式

地确定噪声及固有的任务不确定性，而非引入可能导致误导性预测的强先验假设。

为满足上述所有需求，我们考虑基于逆狄利克雷分布的方法，该方法已在处理 PINNs 框架下的平衡训练和多尺度建模时展示出有效性 [29]。该方法依赖于根据损失项梯度的方差动态调整权重，可被解释为在高维多目标优化问题中相对于主要下降方向的训练不确定性。此策略相较传统训练显著改善了收敛性，并避免了特定任务的消失。

为 BPINNs 设计逆狄利克雷自适应加权算法的核心思想是将不同任务的训练不确定性纳入贝叶斯框架，从而同时考虑噪声、模型适用性和任务敏感性，同时确保帕累托前沿的探索。因此，我们尝试确定正权重参数 λ_k , $k = 0, \dots, K$ ，使得势能项的加权梯度分布 $\nabla_{\Theta} L_k = \lambda_k \nabla_{\Theta} \mathcal{L}_k$ 具有平衡的方差。我们提出通过设定基于逆狄利克雷分布的权重

$$\gamma^2 := \text{Var}\{\lambda_k \nabla_{\Theta} \mathcal{L}_k\} \simeq \min_{t=0, \dots, K} (\text{Var}\{\nabla_{\Theta} \mathcal{L}_t\}), \quad \forall k = 0, \dots, K \quad (19)$$

确保梯度分布具有相同方差：

$$\lambda_k = \left(\frac{\min_{t=0, \dots, K} (\text{Var}\{\nabla_{\Theta} \mathcal{L}_t\})}{\text{Var}\{\nabla_{\Theta} \mathcal{L}_k\}} \right)^{1/2} = \left(\frac{\gamma^2}{\text{Var}\{\nabla_{\Theta} \mathcal{L}_k\}} \right)^{1/2} \quad (20)$$

满足条件

$$\lambda_k \mathcal{N}(\mu_k, \text{Var}\{\nabla_{\Theta} \mathcal{L}_k\}) = \left(\frac{\gamma^2}{\text{Var}\{\nabla_{\Theta} \mathcal{L}_k\}} \right)^{1/2} \mathcal{N}(\mu_k, \text{Var}\{\nabla_{\Theta} \mathcal{L}_k\}) = \mathcal{N}(\mu_k, \gamma^2). \quad (21)$$

注意，此处不讨论对应先验 $P(\Theta)$ 的 λ_{K+1} 情况，因为对数先验项在等价约束优化问题中更类似于 $\mathbb{L}^2$ 正则化，权重平衡方法主要集中于势能的对数似然项。实际上，采样应有效探索在数据拟合与不同 PDE 似然项之间平衡条件下的帕累托前沿。相反，我们不希望依赖非信息先验来实现任务平衡，因此施加以下上界

$$\text{Var}\{\lambda_{K+1} \nabla_{\Theta} \mathcal{L}_{K+1}\} \leq \gamma^2, \quad (22)$$

该约束可通过设定 $\lambda_{K+1} \leq \sigma_{K+1}$ 实现，且与先验假设 $P(\Theta) \sim \mathcal{N}(0, \sigma_{K+1}^2 I)$ 相关联。该约束源于观察到

$$\lambda_{K+1} \nabla_{\Theta} \mathcal{L}_{K+1}(\Theta^{t_\tau}) = \frac{\lambda_{K+1}}{\sigma_{K+1}^2} \Theta^{t_\tau} \quad \text{s.t.} \quad \text{Var}\{\lambda_{K+1} \nabla_{\Theta} \mathcal{L}_{K+1}(\Theta^{t_\tau})\} = \frac{\lambda_{K+1}^2}{\sigma_{K+1}^4} \text{Var}\{\Theta^{t_\tau}\} \leq \frac{1}{\sigma_{K+1}^2} \text{Var}\{\Theta^{t_\tau}\} \quad (23)$$

其中 Θ^{t_τ} 表示第 τ 次迭代采样的参数集合。上述上界还提供了后验参数 Θ 方差与先验分布之间的离散度指标，可用于根据 γ^2 设定 σ_{K+1} 的值。

我们研究了一种在线方法以应对 BPINNs-HMC 的失效模式，使得权重自适应策略 (20) 依赖于采样迭代次数 τ 。这导致了改进的哈密顿蒙特卡洛方法，称为自适应加权哈密顿蒙特卡洛 (Adaptively Weighted Hamiltonian Monte Carlo, AW-HMC)，详见算法 1。该权重策略持续进行直至达到预设的自适应迭代次数 N ，该次数可能与通常的烧入步数 M 不同。假设 $N \leq M$ ，这使我们能够获得适合帕累托前沿探索的加权后验分布。事实上，有限的自适应保持链的遍历性和渐近收敛性，同时保持 $N \leq M$ 确保后验分布来源于相同的加权势能。在实践中，先验烧入阶段通常与自适应步数紧密相关，取 $M = N$ 。我们还引入符号 $H_{\lambda_\tau}(\Theta, r)$ 表示加权哈密顿量

$$H_{\lambda_\tau}(\Theta, r) = \sum_{k=0}^{K+1} \lambda_k(\tau) \mathcal{L}_k(\Theta) + \frac{1}{2} r^T M^{-1} r \quad (24)$$

该哈密顿量定义了 Metropolis-Hasting 接受准则的新转移概率。




图 3: 自适应加权哈密顿蒙特卡洛 (AW-HMC) 在 Sobolev 训练中考虑到最高二阶导数的表现, 与 ϵ -最优加权的比较。有效梯度分布方差 $\text{Var}\{\nabla_{\Theta} L_k\}$ 在任务之间的平衡条件下 (左侧)。满足能量守恒的哈密顿动力学演化过程 (中间)。结果场预测及 ϵ -最优结果与 AW-HMC 策略的比较 (右侧)。

当前基于梯度最小方差的目标分布平衡 (20) 可被解释为依据多势能中最可能或最不敏感项调整权重。因此, 该方法具有加速 BPINNs 收敛至帕累托最优解的优势, 并提升输出不确定性量化的可靠性, 其样本源自帕累托前沿。实际上, 该加权策略通过自适应调整 λ 参数, 自动增加最不可能任务的不确定性。这些观察基于在 A 中详细推导的每个梯度方差的上界, 该上界涉及预测误差、PDE 残差及表征各任务平均梯度下降方向变异性的敏感性项。鉴于此, 我们能够从基本且通用的角度在公式 (48) 中给出联合方差 γ^2 的上界。

最后, 基于逆狄利克雷的自适应加权避免了不合理的时间步长减小, 采样无需满足所有刚性尺度需求以保证哈密顿守恒。该方法使采样过程免于对 leapfrog 超参数 δt 和 L 进行过度调节。此外, 这防止了采样过程中的病态随机游走或发散行为, 因为其允许使用最优积分时间, 在收敛速率和时间步长对不同学习任务的适应性方面均表现优异。

当前 AW-HMC 算法首先在具有不同复杂度的 Sobolev 训练基准上进行验证, 为与 ϵ -最优性结果的比较提供基础。这也使我们能够建立 BPINNs 收敛诊断的新指标。随后, 我们在更复杂的多任务与多尺度问题上实验了该方法的鲁棒性和效率, 内容详见各相关章节。

3.2 Sobolev 训练基准与收敛诊断

我们在多个应用上研究了所提出的自适应加权 BPINN 方法的性能, 本节首先从 Sobolev 训练基准开始。我们首先将这一新的自适应加权策略应用于第 2.3 节中介绍的 1D Sobolev 训练, 使用完全相同的超参数设置。自适应步骤数设为 $N = 20$, 与 NUTS 退化情况相同, 以确保不同方法间的公平比较。

此外, 我们将预测结果与权重 λ_k 根据 ϵ -最优解析解 [52] 设定的参考情况进行比较, 该解析解可基于方程 [29] 用于 Sobolev 训练中确定:

$$\lambda_k^{\epsilon} = \frac{\prod_{j \neq k} \mathcal{I}_j}{\sum_{k=1}^K \prod_{j \neq k} \mathcal{I}_j} \quad \text{s.t.} \quad \mathcal{I}_k = \int_{\Omega} |D_x^k(u)|^2 dx. \quad (25)$$

我们假设观测噪声为 $\xi_u \sim \mathcal{N}(0, \sigma_u^2 I)$, 且满足 $\sigma_k = \sigma_u, \forall k$, 其中 $\sigma_u = 0.1$, 对该 ϵ -最优解进行了方法测试。结果表明, 两种方法之间具有良好的一致性, 哈密顿量趋向相同能级, 如图 3 (中) 所示: 实际上, ϵ -最优方法与 AW-HMC 方法在哈密顿量值上的 $\mathbb{L}^2$ 相对误差在自适应步骤后约为 $1e-4$ 级别。AW-HMC 方法相比该最优解, 对于信号及其导数的 $\mathbb{L}^2$ 相对误差均约为 $1e-3$ 。最后,

Algorithm 1: 自适应加权哈密顿蒙特卡洛 (AW-HMC)

Input: Initial Θ^{t_0} , N_s number of samples, L number of leapfrog steps, δt leapfrog step size, N number of adaptive iterations, M burning steps and M the mass matrix.

1 Sampling procedure:

2 for $\tau = 1 \dots N_s$ do

3 Sample $r^{t_{\tau-1}} \sim \mathcal{N}(0, M)$;

4 Set $(\Theta_0, r_0) \leftarrow (\Theta^{t_{\tau-1}}, r^{t_{\tau-1}})$;

5 Weights adaptation:

6 if $\tau \leq N$ then

7 Compute $\lambda_k(\tau) = \left(\frac{\min_{j=0, \dots, K} (\text{Var}\{\nabla_{\Theta} \mathcal{L}_j(\Theta_0)\})}{\text{Var}\{\nabla_{\Theta} \mathcal{L}_k(\Theta_0)\}} \right)^{1/2} \quad \forall k = 0, \dots, K$ and
 $\lambda_{K+1}(\tau) = 1$;

8 else

9 $\lambda_k(\tau) = \lambda_k(\tau - 1) \quad \forall k = 0, \dots, K$ and $\lambda_{K+1}(\tau) = 1$

10 end

11 Leapfrog:

12 for $i = 0 \dots L - 1$ do

13 $r_i \leftarrow r_i - \frac{\delta t}{2} \sum_{k=0}^{K+1} \lambda_k(\tau) \nabla_{\Theta} \mathcal{L}_k(\Theta_i)$;

14 $\Theta_{i+1} \leftarrow \Theta_i + \delta t M^{-1} r_i$;

15 $r_{i+1} \leftarrow r_i - \frac{\delta t}{2} \sum_{k=0}^{K+1} \lambda_k(\tau) \nabla_{\Theta} \mathcal{L}_k(\Theta_{i+1})$;

16 end

17 Metropolis-Hastings:

18 Sample $p \sim \mathcal{U}(0, 1)$;

19 Compute $\alpha = \min(1, \exp(H_{\lambda_{\tau}}(\Theta_0, r_0) - H_{\lambda_{\tau}}(\Theta_L, r_L)))$ using (24);

20 if $p \leq \alpha$ then

21 $\Theta^{t_{\tau}} = \Theta_L$;

22 else

23 $\Theta^{t_{\tau}} = \Theta_0$;

24 end

25 Collect the samples after burning : $\{\Theta^{t_i}\}_{i=M}^{N_s}$

26 end




图 4: 有效梯度分布方差 $\text{Var}\{\nabla_{\Theta} L_k\}$ 及关于一维 Sobolev 训练至三阶导数的 Hamiltonian 演化。NUTS 形式（上方）突出显示了左侧学习任务之间的强烈不平衡，以及右侧在探索能量水平集时的随机游走行为。AW-HMC 策略（下方）及与 ϵ -最优性的比较。

我们还指出图 3（左）中梯度方差的平衡性，与使用 ϵ -最优解析权重时观察到的情况相同。因此，AW-HMC 方法在梯度方差平衡、哈密顿能级探索以及整体 BMA 预测方面与 ϵ -最优解表现相似。

我们新方法在不同任务之间展现出极为平衡的条件：有效梯度分布方差 $\text{Var}\{\nabla_{\Theta} L_k\}$ 在整个训练过程中保持同一数量级，甚至在有限的自适应步骤后亦是如此。这意味着权重自适应调整后的后验分布非常适合于向 Pareto 前沿的探索收敛，从而提高了采样效率。防止梯度方差的强烈失衡行为，进而避免任务特异性偏置，显著提升了此类多目标势能的边际化效果，相较于第 2.3 节中呈现严重失败的传统方法有明显改进。

为了进一步展示该方法的稳健性，我们考虑了该测试案例的三阶导数扩展，其中即使使用 NUTS 自适应时间步长策略（达到 $\delta t = 1.36\text{e-}7$ ）也会产生病态随机游走行为，导致采样完全失效（见图 4 顶部行及图 5）。时间步长显著减小主要由于三阶导数项引入的增强刚性，在该多任务学习中尤为明显。实际上，由于刚性，哈密顿轨迹在确定性步长中更易发散，需通过小的 δt 来补偿发散。为避免病态随机游走，必须增加整体积分时间，但这不可避免地导致计算成本过高——在此跳跃蛙时间步长限制下。这凸显了 NUTS 在面对带有不同尺度的刚性多任务采样时的主要局限。

相比之下，我们的方法克服了这些重大失败（见图 5），且无需对 δt 施加额外限制，同时提供了不同任务间的梯度方差平衡，如图 4（底部行）所示。我们还将 AW-HMC 方法的结果与基于 ϵ -最优性解析权重的结果进行了比较，两者表现高度一致。此外，为了应对 BPINNs 由于采样变异性引起的随机过程，我们进行了多次采样重复，采用不同的神经网络参数和动量初始化。这导致了图 6 中展示的权重沿自适应步骤的平均演化，显示出与解析 ϵ -最优权重相同的数量级。




图 5: 一维 Sobolev 训练至三阶导数: 比较 AW-HMC 与 NUTS 方案在函数及其导数上的 BMA 预测。任务之间的不平衡以及 NUTS 的随机游走行为 (见图 4) 导致 BMA 预测效果不佳。AW-HMC 方法克服了这些影响, 显著提升了目标分布的采样效果。

除上述不同方法与解析解之间的定性比较外, 我们随后引入了一个新的度量指标, 用于量化预测质量。该指标补充了常用指标, 提供了沿边际化过程采样收敛性的量化。AW-HMC 过程中燃烧步骤后的样本 —— 即所有 $\{\Theta^{t_i}\}_{i=M}^{N_s}$ 实例 —— 首先用于确定如式 (3) 所定义的贝叶斯模型平均估计。每个样本为由 Θ^{t_i} 表征的神经网络提供预测 $P(y|x, \Theta^{t_i})$, 且理论上从后验分布 $P(\Theta|\mathcal{D}, \mathcal{M})$ 中抽取, 因此 BMA 通常被近似为 [57]:

$$P(y|x, \mathcal{D}, \mathcal{M}) \simeq \frac{1}{N_s - M} \sum_{i=M}^{N_s} P(y|x, \Theta^{t_i}) \quad \text{with} \quad \Theta^{t_i} \sim P(\Theta|\mathcal{D}, \mathcal{M}). \quad (26)$$

在 Sobolev 训练中, 我们将神经网络输出视为函数本身及其所有导数的预测 $y = \{D_x^k u_\Theta, k = 0 \dots K\}$, 因此可以根据式 (26) 计算相对于每个输出的相对 BMA 误差, 定义为:

$$\text{BMA-E}^k = \frac{\|P(D_x^k u_\Theta | x, \mathcal{D}, \mathcal{M}) - D_x^k u\|^2}{\|D_x^k u\|^2}, \quad \forall k = 0 \dots K \quad (27)$$

此处符号 $\|\cdot\|$ 表示函数空间中的 $\mathbb{L}^2$ 范数。基于上述定义, 为了体现边际化过程中 BMA 的收敛性, 我们引入了新的诊断指标, 称为累计 (相对) BMA 误差, 定义如下:

$$\text{BMA-CE}^k(\tau) = \frac{\left\| \frac{1}{\tau - N} \sum_{i=N}^{\tau} P(D_x^k u_\Theta | x, \Theta^{t_i}) - D_x^k u \right\|^2}{\|D_x^k u\|^2}, \quad \forall k = 0 \dots K \quad (28)$$

该定义依赖于自适应步骤后的采样迭代次数, 适用于算法 1 中 $\tau > N$ 的情况。此公式可推广至所有神经网络输出, 构建更通用的框架, 并以收敛速率量化采样效率。图 7 展示了 Sobolev 训练三阶




图 6: 左侧显示自适应步骤 ($\tau \leq N$) 中 λ_k 权重的演变, 以及与 Sobolev 训练中最高到三阶导数的解析 ϵ -最优权重的比较。右侧显示 AW-HMC 算法多次重复的平均权重演变。这是由神经网络参数和动量的不同初始化引起的, 以考虑样本的变异性。双头箭头表示相对权重 $\lambda_0/\lambda_i, i = 1...3$ 的数量级。

扩展中累计 BMA 误差, 突出 AW-HMC 采样器对各个函数任务的收敛性 (左图)。相比之下, 病态 HMC 和 NUTS 形式的误差几乎保持不变, 分别因大量拒绝和随机游走行为所致 (见图 7 右图)。

最后, 我们将该 Sobolev 训练测试案例扩展至多个二维基准, 研究了函数复杂度和训练点数量对贝叶斯模型平均误差的影响。基准问题详情及训练设置见 B, 结果显示 AW-HMC 算法在 BPINNs 中具备更强的稳健性和效率。

3.3 多尺度洛特卡-沃尔泰拉逆问题

我们展示了 AW-HMC 在多尺度动力学逆问题中的应用, 以量化尺度变化的影响。正如 Linka 等人 [21] 指出, 尺度敏感性可能会阻碍经典 BPINNs 的性能, 尤其是在考虑非线性动力系统时。多尺度特性和由现实问题引起的刚性, 其中任务特定梯度消失普遍存在, 因此成为量化本方法鲁棒性的有趣基准。

在此背景下, 我们考虑具有高度不同数量级参数的洛特卡-沃尔泰拉动力系统, 其由以下常微分方程 (ODE) 系统定义:

$$\begin{cases} \frac{du}{dt} = \alpha u - \beta uv, & t \in \Omega \\ \frac{dv}{dt} = \delta uv - \gamma v, & t \in \Omega \\ u(0) = u_0, v(0) = v_0 \end{cases} \quad (29)$$

该系统描述了捕食者-猎物物种的时间演化。符号 $u(t)$ 和 $v(t)$ 分别表示在给定时间 t 的猎物和捕食者种群规模, 而参数 $\alpha, \beta, \delta, \gamma \geq 0$ 控制种群动态, 作为增长率和衰减率。随后, 我们将初始种群设置为 $u_0 = 100$ 和 $v_0 = 20$, 参数选为 $\alpha = 1, \beta = 0.1, \delta = 0.01$ 和 $\gamma = 0.5$, 这些参数故意选取了不同的数量级。这构建了一个基于真实动力学且涉及不同尺度的逆问题基准。

观测数据首先通过在均匀时间网格 $\Omega = [0, 50]$ 上以细分分辨率 400 点数值求解 ODE 系统 (29) 生成。数据被随机采样, 仅在不同采样器的训练阶段使用一半。数据集 $\mathcal{D}$ 包含了在 200 个不同时间点对 u 和 v 的部分测量, 可能添加了一些噪声, 同时保持相同的配点以满足 ODE 约束。本节重




图 7: 累计相对 BMA 误差, 根据公式 (28) 计算, 在采样迭代 $\tau > N$ 期间针对 Sobolev 训练至三阶导数。左侧为 AW-HMC 策略, 右侧为经典 HMC 和 NUTS 公式的比较。这些量在病态情况下几乎保持不变, 原因是大量拒绝或病态随机游走, 突出显示了常规 BPINNs-HMC 公式 (右侧) 中缺乏收敛性。




图 8: Lokta-Volterra 多尺度推断: 逆参数 α_θ , β_θ , δ_θ 和 γ_θ 的边际后验分布直方图 (上)。采样过程中参数轨迹的相位图 (下), 展示了在自适应步骤期间 (蓝色) 各自模式的收敛, 以及自适应步骤后 (红色) 对模式邻域的高效探索。真实参数分别为 $\alpha = 1$, $\beta = 0.1$, $\delta = 0.01$ 和 $\gamma = 0.5$, 构成具有独立尺度的逆问题。




图 9: 洛特卡-沃尔泰拉多尺度推断: 两个物种种群沿物理时间的 BMA 预测及其不确定性, 位于左下角和左上角。神经网络输出 $y = (u_\Theta, v_\Theta)$ 的相对 BMA-CE 误差 (定义见方程 (28)) 随着采样迭代的变化绘制, 位于右上角。虚线竖线标记了序贯训练中引入 ODE 似然项的时刻。

点关注通过这些测量数据推断未知模型参数 $\Sigma = \{\alpha, \beta, \delta, \gamma\}$ 的逆问题, 同时恢复原始更细分辨率上的整个物种演化。

针对两个种群之间显著的尺度差异, 我们考虑了捕食者-猎物任务的分离, 使得每个场 u 和 v 分别满足数据拟合似然项和 ODE 残差似然项。我们还假设 Σ 服从对数正态先验分布, 以确保逆参数的正值性, 正如 Yang 等人 [59] 所示, 此类先验有助于推断, 并且我们对神经网络参数 θ 设定独立的正态分布。实际上, 我们通过变量变换引入 $\Sigma = e^{\tilde{\Sigma}} := \{e^{\tilde{\alpha}}, e^{\tilde{\beta}}, e^{\tilde{\delta}}, e^{\tilde{\gamma}}\}$ 来推断 $\tilde{\Sigma}$, 并假设其也服从正态先验分布。对于该测试案例, 我们施加强弱信息先验, 特别是在 $\tilde{\Sigma}$ 上, 因为我们期望方法能够通过任务的无偏自适应加权处理多尺度推断。因此, 我们假设神经网络参数和逆参数均服从相同的先验分布, 即 $\Theta \sim \mathcal{N}(0, \sigma_\Theta^2 I_{p+d})$, 其中 $\Theta = \{\theta, \tilde{\Sigma}\}$ 。

在这些假设下, 我们可以定义对应哈密顿系统的多势能:

$$U(\Theta) = \frac{\lambda_0}{2\sigma_0^2} \|u_\Theta - u\|_{\mathcal{D}}^2 + \frac{\lambda_1}{2\sigma_1^2} \|v_\Theta - v\|_{\mathcal{D}}^2 + \frac{\lambda_2}{2\sigma_2^2} \left\| \frac{du_\Theta}{dt} - \alpha_\Theta u_\Theta + \beta_\Theta u_\Theta v_\Theta \right\|_{\mathcal{D}}^2 + \frac{\lambda_3}{2\sigma_3^2} \left\| \frac{dv_\Theta}{dt} - \delta_\Theta u_\Theta v_\Theta + \gamma_\Theta v_\Theta \right\|_{\mathcal{D}}^2 + \frac{1}{2\sigma_\Theta^2} \|\Theta\|_{\mathbb{R}^{p+d}}^2 \quad (30)$$

其中推断的逆参数定义为 $\Sigma_\Theta = e^{\tilde{\Sigma}_\Theta}$, 且我们将所有的 $\sigma_\bullet$ 设为 1, 因为我们不希望对任务和模型不确定性施加强先验。如前文第 2.2 节所述, 范数分别为均方根 (RMS) 范数和最后一项的欧几里得范数。参数的先验假设服从标准差较大的高斯分布 $\sigma_\Theta = 10$, 意味着稍微分散的分布导致对 Θ 参数的弱信息先验。这也保证了约束 (22) 对非信息先验的满足。

对于此类逆建模, 采样采用顺序训练分解。即 1) 先用 AW-HMC 策略采样神经网络参数, 主要针对数据拟合似然项 (设置 $\lambda_2 = \lambda_3 = 0$); 2) 然后引入 (30) 中的 ODE 残差任务, 利用 AW-HMC

λ_k Seq. step	λ_0	λ_1	λ_2	λ_3
Data-fitting (step 1)	3.83e-2	1	—	—
Data-fitting + ODE tasks (step 2)	4.87e-2	1	9.16e-3	1.16e-1

$\tilde{\sigma}_k$ Seq. step	$\tilde{\sigma}_0$	$\tilde{\sigma}_1$	$\tilde{\sigma}_2$	$\tilde{\sigma}_3$
Data-fitting (step 1)	5.109	1	—	—
Data-fitting + ODE tasks (step 2)	4.531	1	10.45	2.936

表 1: 在 Lokta-Volterra 多尺度反问题中, 自适应步骤后获得的权重参数 λ_k , 对应每个顺序步骤 (上排)。由权重自适应得到的有效标准差 $\tilde{\sigma}_k$, 计算公式为 $\tilde{\sigma}_k = \sqrt{1/\lambda_k}$, 对应每个顺序步骤 (下排)。这突出了与猎物物种相关任务的不确定性增加。顺序步骤的划分详见第 3.3 节。

算法并以步骤 1) 产生的初始神经网络参数 θ^{t_0} 进行, 估计缺失的逆参数。最后, BMA 预测和不确定性量化依赖于整个采样过程。在两步顺序训练中, 自适应和采样迭代次数先设为 $N = 20$ 和 $N_s = 100$, 然后为 $N = 50$ 和 $N_s = 200$, 跳跃蛙参数分别为 $L = 100$, $\delta t = 5\text{e-}4$ 和 $2\text{e-}4$, 对应步骤 1) 和 2) 的时间步长。神经网络由 4 层组成, 每层 32 个神经元, 采用 sin 激活函数, 考虑到洛特卡-沃尔泰拉系统解的周期性特征。

在该逆问题上, 经典 BPINNs-HMC 算法面临大量拒绝采样, 因为哈密顿轨迹无法保持守恒, 导致采样失效 (见图 17)。即便是时间步长的自适应策略, 也难以处理多尺度动力学, 需要极大降低 δt 值以获得一定稳定性, 详见附录 C。这种对跳跃蛙时间步长的限制自然导致无法收敛至帕累托前沿, 逆参数推断效果不佳, 且先验信息弱 (参见附录 C 中的图 18 和 19)。事实上, Linka 等人 [21] 在学习 COVID-19 动力学时也遇到同样问题, 并在其文献第 4.3 节 [21] 中对逆参数施加了依赖适当尺度的对数正态先验分布。适当尺度的需求强烈影响推断, 因为它需要先验知识, 进而导致采样偏倚。

相反, 我们假设与尺度无关的独立先验, 展示了我们的方法能够在最小调参和较小 δt 降低的情况下, 准确恢复所有 Σ 参数并预测物种演化。恢复不同尺度不再依赖逆参数尺度的先验知识即可收敛到各自的极值。图 8 展示了各逆参数 Σ_Θ 的边缘后验分布及其在相空间分布 $\pi(\Theta, r)$ 中的轨迹。后者绘制了完整采样轨迹, 这些轨迹在自适应步骤中收敛到各自的极值, 最终在 $\tau > N$ 时围绕极值采样。此结果验证了 AW-HMC 快速识别逆问题不同模式并处理多尺度动力学的能力。

为量化参数识别效果, 我们还测量了参数 $\Sigma_\Theta = \{\alpha_\Theta, \beta_\Theta, \delta_\Theta, \gamma_\Theta\}$ 推断的相对误差

$$E_{\Sigma_\Theta} = \frac{|\Sigma_\Theta - \Sigma|}{\Sigma} \quad (31)$$

其中预测由 $\Sigma_\Theta = \frac{1}{N_s - N} \sum_{i=N}^{N_s} e^{\Sigma_\Theta^T t_i}$ 给出, 我们展示四个逆参数的相对误差均在 $5\text{e-}2$ 附近。图 9 显示了作为神经网络输出 $y = (u_\Theta, v_\Theta)$ 的 BMA 物种种群预测演化, 并与精确解进行了定性和定量比较。为此, 我们计算了两个物种的相对 BMA 累积误差, 展示采样收敛性, 见图 9 右上角。相比纯基于数据的采样, 两步顺序训练中引入 ODE 残差似然项显著提升了预测收敛性。

该测试案例还揭示了猎物种群演化中的更高不确定性, 其有效标准差约为其他种群的四倍 (见

表 1)。这一特定任务的不确定性增强由自适应步骤末尾势能 (30) 中 λ_0 和 λ_2 的较小值体现, 相较于 λ_1 和 λ_3 。因此, AW-HMC 策略得益于其自适应加权 λ 参数的能力, 基于梯度方差内在地刻画任务不确定性。

4 计算流体力学中的应用: 狭窄血流

我们展示了第 3.1 节中提出的方法在流体力学实际问题中的应用, 更准确地说, 是在非对称几何中不可压缩狭窄流动的修复和逆问题研究。目标是展示当前 AW-HMC 算法在更复杂二维几何和带噪声及数据稀疏性的非线性偏微分方程动力学上的泛化能力和性能。

测量数据通过在离散位置随机采样完全解析的计算流体动力学 (CFD) 解生成。非对称狭窄血管几何中血管流动的直接数值模拟采用基于离散校正粒子强度交换 (DC PSE) 方法的无网格求解器进行, 具体方法详见文献 [7]。

4.1 带有稀疏和噪声数据的修复问题

$=(\mathbf{u}, \mathbf{v})$

修复问题在 MRI 或 CT 医学成像中引起了越来越多的关注, 作为利用深度学习方法减少伪影和恢复缺失 ω_{ting2021} 。尽管通常的修复框架仅结合测量数据进行图像处理, Zheng 等人通过将基础物理作为间接测量 $\frac{\partial v}{\partial x} - \frac{\partial u}{\partial y} 20_{\text{inpainting}}$ 。本节内容属于同一背景——其思想是基于稀疏且带噪声的测量数据推断完整的流场重建, 同

狭窄流动动力学的控制方程在二维中以速度 $\mathbf{u} = (u, v)$ 和涡量 ω 形式表达, 满足不可压缩稳态纳维-斯托克斯方程: $\langle \text{PLACEHOLDER}_{ENV46} \rangle$ 或等价地, $\langle \text{PLACEHOLDER}_{ENV47} \rangle$ 其中 Re 表示无量纲雷诺数 $\frac{\partial v}{\partial x} - \frac{\partial u}{\partial y}$, 不可压缩条件保证 $\nabla \cdot \mathbf{u} = 0$ 。我们考虑二维狭窄空间域 $\Omega \subset [0, 10] \times [0, 1]$, 并假设两种不同的边界条件: 1) 狭窄区域的上下壁面, 记为 $\partial\Omega_1$, 施加无滑移条件, 即 $u_{\partial\Omega_1} = 0$ 且 $\omega = (\nabla \times \mathbf{u})_{\partial\Omega_1}$; 2) 入口和出口边界, 记为 $\partial\Omega_2$, 对主流方向上的速度分别施加规定的抛物线剖面和诺依曼条件。这些边界 $\mathcal{D}^{\omega_{\text{ourantas}_{u_{\text{sing2016}}}}$ 。我们还假设雷诺数已知且根据 CFD 模拟设置为 $Re = 200$, 因此待推断的参数集合 heta 限定为神经网络权重和偏置。

测量数据集 $\mathcal{D}$ 由定义在 $\mathcal{D}^{\partial_1}$ 和 $\mathcal{D}^{\partial_2}$ 上的带噪声涡量数据组成, 分别对应集合 $\partial\Omega_1$ 和 $\partial\Omega_2$, 如式 (12) 所示, 同时包含 1282 个内部离散点 $\mathcal{D}^{\omega}$, 覆盖了重建整个涡量场所需数据的不到 2%。我们最终定义 $\mathcal{D}^{\Omega}$ 数据集为 6408 个内部点, 占整个重建数据场的 6%, 在 $\sigma_{\bullet}$ 在物理约束修复问题中被满

$$U(\Theta) = \frac{\lambda_0}{2\sigma_0^2} \|\omega_{\Theta} - \omega\|_{\mathcal{D}^{\omega}}^2 + \frac{\lambda_1}{2\sigma_1^2} \|\omega_{\Theta} - \omega|_{\partial\Omega_1}\|_{\mathcal{D}^{\partial_1}}^2 + \frac{\lambda_2}{2\sigma_2^2} \|\omega_{\Theta} - \omega|_{\partial\Omega_2}\|_{\mathcal{D}^{\partial_2}}^2 + \frac{\lambda_3}{2\sigma_3^2} \left\| u_n \frac{\partial \omega_{\Theta}}{\partial x} + v_n \frac{\partial \omega_{\Theta}}{\partial y} - \frac{1}{Re} \Delta \omega_{\Theta} \right\|_{\mathcal{D}^{\Omega}}^2 + \frac{1}{2\sigma_{\Theta}^2} \|\Theta\|_{R_p}^2 \quad (32)$$

足。多势能函数定义为: 其中 u_n 和 v_n 是在 $\mathcal{D}^{\Omega}$ 集合上速度场的带噪声观测值。之后我们采用分阶段训练, 第二阶段加入 PDE 残差似然项, AW-HMC 参数首先设为 $N = 50$ 和 $N_s = 200$, 随后为 $N = 50$ 和 $N_s = 250$, 跃步路径长度为 $L = 150$, 时间步长 $\delta t = 5e-4$ 。与之前的基准相同, 我们将所有 $\sigma_{\bullet}$ 设为 1, 并假设神经网络参数先验为均值为 0、标准差为 $\sigma_{\Theta} = 10$ 的中心正态分布。该神经网络由 4 层组成, 每层 32 个神经元, 激活函数为双曲正切函数。速度和涡量的 CFD 解 $(\mathbf{u}, \omega)$ 均被加性高斯噪声破坏, 即 $\bullet_n = \bullet + \sigma \xi$, 其中 $\xi \sim \mathcal{N}(0, \psi^2)$ 是元素独立同分布的均值为 0、方差为 $\psi^2 = \text{Var}\{\bullet\}$ 的高斯随机向量, σ 表示加噪声的强度。

在此物理信息修复问题中, 我们考察噪声水平 σ 对涡量场 BMA 预测及物理约束的影响, 并将 BMA 收敛性概

Noise level \ λ_k	λ_0	λ_1	λ_2	λ_3
$\sigma = 0$	1	0.46	0.88	0.51
$\sigma = 0.1$	1	0.19	0.35	0.29
$\sigma = 0.2$	1	0.12	0.39	0.27

Noise level \ $\tilde{\sigma}_k$	$\tilde{\sigma}_0$	$\tilde{\sigma}_1$	$\tilde{\sigma}_2$	$\tilde{\sigma}_3$
$\sigma = 0$	1	1.47	1.07	1.40
$\sigma = 0.1$	1	2.29	1.69	1.86
$\sigma = 0.2$	1	2.89	1.60	1.92

表 2: 物理信息修复问题中各 σ 噪声水平对应的最终 λ_k 权重参数 (顶部行)。通过权重调整计算得到的有效标准差 $\tilde{\sigma}_k$, 其计算公式为 $\tilde{\sigma}_k = \sqrt{1/\lambda_k}$, 针对每个噪声水平 (底部行)。这突出了有效标准差对噪声幅度和任务对噪声水平敏感性的整体适应性。特别地, 与 λ_1 相关的壁面边界条件表现出最高的噪声敏感性。

残差。具体计算基于

$$\begin{aligned} \text{BMA-CE}^\omega(\tau) &= \left\| \frac{1}{\tau - N} \sum_{i=N}^{\tau} P(\omega_\Theta | x, \Theta^{t_i}) - \omega \right\|^2 \\ \text{BMA-CE}^{\mathcal{F}}(\tau) &= \left\| \frac{1}{\tau - N} \sum_{i=N}^{\tau} P(\mathcal{F}(\omega_\Theta) | x, \Theta^{t_i}) \right\|^2 \end{aligned} \quad (33)$$

其中 $\mathcal{F}(\omega_\Theta)$ 是由方程 (35) 计算得到的 PDE 评估。不同噪声水平的比较曲线如图 11 所示, 显示采样收敛至最终 BMA 误差, 分别约为 $1.05\text{e-}3$ 、 $2.9\text{e-}3$ 和 $4.08\text{e-}3$, 对应噪声水平 $\sigma = 0, 0.1$ 和 0.2 。此外, PDE 残差约束独立于噪声水平收敛, 所有情况下最终 BMA 误差均约为 $2\text{e-}3$ 。

为了补充修复方法在恢复整个涡量场及其不确定性方面的性能评估, 我们还使用了 Yao 等人定义的预测区间覆盖概率 (PICP) 指标 [61]。该指标作为后验近似质量的评估, 计算包含真实观测值的 95% 预测区间的比例, 定义为:

$$\text{PICP} = \frac{1}{N} \sum_{i=1}^N \mathbb{1}_{(\omega_\Theta^l)_i \leq \omega_i \leq (\omega_\Theta^h)_i} \quad (34)$$

其中 ω_Θ^l 和 ω_Θ^h 分别是涡量预测分布的 2.5% 和 97.5% 分位数。此处 N 表示预测数据集中的观测总数, 即计算域 Ω 的网格分辨率。在本应用中, 该 PICP 指标显示无论噪声水平如何, 神经网络输出涡量的后验分布均覆盖了超过 99% 的真实观测值。

我们还期望自适应加权参数 λ_k 能够捕捉对噪声水平 σ 的敏感性及任务对噪声的内在敏感度, 无需对噪声水平预设。这是我们方法论的关键点, 因为我们有意图在 (32) 中将 σ_k 与噪声幅度解耦, 依赖自适应加权策略来量化相关不确定性。与此相反, 在处理带噪声测量数据的实际应用中, 研究人员通常假设各传感器的可靠性已知, 并据此设定标准差 σ_k 。这些参数也可以作为额外的可学习参数进行推断, 但通常会增加在线学习的替代神经网络形式 [38]。相比之下, AW-HMC 方法的优势在于其计算成本与经典 BPINNs-HMC




图 10: 物理信息修复问题: 无噪声情况下非对称狭窄中涡度场 ω_Θ 的 BMA 预测与真实解 ω 的比较 (上方)。精确场上的黑点对应数据集 $\mathcal{D}$ 的训练测量值。不同噪声水平 ($\sigma = 0, 0.1, 0.2$) 下预测涡度场 ω_Θ 的不确定性标准差 (Std) 和均方误差 (MSE) 比较, 显示在下方行。

相近。此外, AW-HMC 通过关注在最优积分时间的帕累托前沿探索, 提高了收敛速度, 从而缩短了整体采样时间, 具有竞争力。

图 10 中的结果展示了 AW-HMC 方法的抗噪声性能, 并强调了相对于噪声和任务的敏感性考量 (见表 2)。我们首先注意到 λ 值的自动调整随噪声水平变化而异, 导致整体不确定性随噪声增加而增强。我们还观察到根据不同任务对噪声的敏感度, 不确定性调整存在差异。事实上, 图 10 中涡量场局部标准差的比较显示, 壁面边界条件对噪声最为敏感, 自动提高了这些区域的不确定性; 而入口和出口边界则相对不那么敏感, 其不确定性对噪声水平的适应较弱。简而言之, 该应用展示了我们新自适应方法在自动调整权重及其对应不确定性以反映任务对噪声的内在敏感性, 并适应噪声幅度方面的能力。

$$u \frac{\partial \omega}{\partial x} + v \frac{\partial \omega}{\partial y} = \frac{1}{Re} \Delta \omega, \quad \text{in } \Omega \quad (35)$$

$$(\mathbf{u} \cdot \nabla) \omega = Re^{-1} \Delta \omega, \quad \text{in } \Omega \quad (36)$$

4.2 带参数估计和隐场恢复的逆问题

作为第二个 CFD 应用, 我们考虑一个不对称且陡峭狭窄几何形状中的多目标流动逆问题。该问题旨在通过我们的自适应加权策略, 同时提供流动状态的参数估计和隐含场的恢复。此类考虑基




图 11: 涡度物理信息修复问题: 贝叶斯模型平均累积误差诊断, 如式 (33) 所定义, 在采样迭代过程中的表现及不同噪声水平下的结果。左侧为涡度场预测的 BMA-CE, 右侧为满足 (35) 的 PDE 残差 $\mathcal{F}$ 的 BMA-CE。虚线垂直线标记了序贯训练中 PDE 约束的引入。




图 12: CFD 逆问题: 非对称狭窄中速度场 $u_\theta = (u_\theta, v_\theta)$ 的 BMA 预测及其不确定性标准差 (Std) 和均方误差 (MSE), 位于顶部。推断的潜在压力场的 BMA 和不确定性, 以及沿中心线 $y = 0.5$ 绘制的压力演变, 导致平均压降为 1.78 —— 位于底部。




图 13: CFD 逆问题: 速度场分量 $\mathbf{u} = (u, v)$ 、无散条件 $\mathcal{H}(\mathbf{u})$ (左侧) 以及 PDE 残差 $\mathcal{F}(u)$ 和 $\mathcal{F}(v)$ (右侧) 在采样迭代过程中的贝叶斯模型平均累计误差。虚线曲线表示如公式 (40) 所定义的压力梯度范数 BMA-CE 误差的后验检验




图 14: CFD 逆问题: 从左到右, 逆雷诺参数边缘后验分布的直方图, 其轨迹在采样过程中的相位图, 以及使用式 (39) 中定义的绝对相对范数的 BMA-CE 误差。相对 BMA-CE 误差关于 Re_Θ 在顺序训练第二步采样的所有 τ 次迭代中绘制。

于现实应用，利用不完整或损坏的测量数据，试图推导额外信息，而这些信息直接获得起来仍然具有挑战性或不切实际。

针对物理和生物医学问题，Raissi 等人研究了通过物理信息深度学习从流动可视化中提取隐藏的流体力学感兴趣量 [41, 42]。作者仅依赖满足不可压缩 Navier-Stokes 方程的被动标量浓度测量，推断外部和内部流动中的速度和压力场。

在此方向上，我们聚焦于狭窄流动动力学的速度 $\mathbf{u} = (u, v)$ 和压力 p 形式，使得连续性和动量控制的稳态方程写为：

$$\begin{cases} (\mathbf{u} \cdot \nabla)\mathbf{u} = -\nabla p + Re^{-1}\Delta\mathbf{u}, & \text{in } \Omega \\ \nabla \cdot \mathbf{u} = 0, & \text{in } \Omega \end{cases} \quad (37)$$

在狭窄域 $\Omega \subset [0, 10] \times [0, 1]$ 上满足不可压缩条件。我们在壁面接口施加附着边界条件，使得 $\mathbf{u}|_{\partial\Omega_1} = 0$ ，并分别施加如下入口/出口边界条件：

$$\begin{aligned} u &= 4y - 4y^2, v = 0 \quad \forall (x, y) \in \{0\} \times [0, 1] \\ \frac{\partial u}{\partial x} &= 0, v = 0 \quad \forall (x, y) \in \{10\} \times [0, 1]. \end{aligned} \quad (38)$$

直接数值模拟采用 DC-PSE 公式 [7]，雷诺数设为 $Re = 200$ ，与前一节相同。该模拟用于在 Ω 上生成高分辨率的观测数据。数据集 $\mathcal{D}$ 由速度场 $\mathbf{u}$ 的部分测量组成，随机采样得到 9559 个训练点，占整个目标分辨率的不到 3%。相同的配点还用于施加 PDE 约束，记为 $\mathcal{F}(\mathbf{u}) := (\mathcal{F}(u), \mathcal{F}(v))$ ，以及无散条件 $\mathcal{H}(\mathbf{u})$ 。

最后，我们通过推断流动状态来建立逆问题，将雷诺数视为未知模型参数 $\Sigma = \{Re\}$ 。同时，我们处理多任务问题，从速度场的部分测量和流体动力学假设中恢复隐含压力。特别地，压力场预测在采样过程中被调整，使其梯度满足控制方程 (37)。正如 Navier-Stokes 方程的性质通常所确定的，压力场不是唯一确定的，且由于缺乏该场的精确边界条件，因此其值可由一个常数确定。随后，各感兴趣量——速度和压力的预测结果在图 12 中以原始更细分辨率恢复。如同在第 3.3 节中，我们为物理参数选择对数正态先验分布，为神经网络参数选择独立正态分布，并采用分阶段训练方法，在第二个采样阶段加入 PDE 约束。

推断验证首先通过计算速度场分量、PDE 约束和不可压缩条件的 BMA-CE 诊断完成，计算方式同方程 (33)。结果见图 13，显示各项指标收敛至最终 BMA 误差，分别约为 $BMA-CE^u(N_s) = 6.4e-3$ 、 $BMA-CE^v(N_s) = 1e-3$ 、 $BMA-CE^{\mathcal{F}(\mathbf{u})}(N_s) = (4.2e-2, 4.7e-2)$ 和 $BMA-CE^{\mathcal{H}(\mathbf{u})}(N_s) = 2.9e-2$ 。随后，速度场的贝叶斯模型平均预测与真实观测值在图 12 中对比，提供了包括不确定性在内的局部均方误差 (MSE)，显示误差较大区域的标准差也有所增加。PICP 指标估计速度场真实值有超过 95% 被后验分布 $\mathbf{u}_\Theta$ 恢复。

对于逆向参数，我们基于相对 L1 范数计算了 BMA 累积误差，定义如下

$$BMA-CE^{Re}(\tau) = \frac{\left| \frac{1}{\tau} \sum_{i=1}^{\tau} Re_{\Theta^{t_i}} - Re \right|}{|Re|}, \quad \forall \tau = 1 \dots N_s \quad (39)$$

其中 $Re_{\Theta^{t_i}}$ 表示由参数 Θ^{t_i} 表征的采样点对雷诺数的预测。图 14 显示该相对误差收敛，采样结束时残差达 $5.4e-2$ 。同时展示了 Re_Θ 边缘后验分布的直方图及其在相空间中的轨迹，说明自适应步骤 $\tau < N$ 期间其向众数收敛。实际上，我们的方法基于测量数据 $\mathcal{D}$ 推断的雷诺数估计，与精确值一致，预测区间为 $Re_\Theta \in [182.82, 208.06]$ 。

隐含压力场 BMA（可加常数不变）在图 12 中展示了其不确定性，能够捕捉到由陡峭狭窄几何引起的显著压力降——平均估计约为 1.78。事实上，Sun 等人在对称几何中强调，随着狭窄几何变窄，此类压力降呈现非线性 [49]，这与我们在不对称案例中的结果一致。由于本应用中压力真实值未知，我们通过事后检查压力梯度进一步验证逆问题。为此，我们对压力恢复的梯度范数提供了约 91% 的 PICP 估计，并引入如下压力 BMA-CE 后验诊断：

$$\text{BMA-CE}^{\nabla p}(\tau) = \left\| \frac{1}{\tau - N} \sum_{i=N}^{\tau} |P(\nabla p_{\Theta} | x, \Theta^{t_i})| - |\nabla p| \right\|^2 \quad (40)$$

其中 $|\cdot|$ 表示向量范数， ∇p 为方程 (37) 中精确压力梯度的计算。结果以虚线形式绘制于图 13 的采样迭代过程中，残差误差为 $7.6\text{e}-2$ 。这表明我们的自适应加权策略所得到的预测压力梯度与真实梯度吻合良好。

总体而言，当前的 AW-HMC 方法依赖多任务采样，通过部分速度场测量识别流动状态，从而处理满足非线性物理 PDE 约束的复杂流动逆问题及隐场恢复。

5 总结性评论

BPINNs 最近作为一种有前景的深度学习框架在数据同化和不确定性量化（UQ）方面崭露头角 [59]。这为将物理信息神经网络（PINN）的预测能力与贝叶斯推断框架中的不确定性量化相结合提供了可能，后者采用了马尔可夫链蒙特卡洛（MCMC）采样的方法。这使得在带有物理模型约束的稀疏且噪声数据条件下，实现对预测置信度的量化成为可能，这对复杂系统的应用尤为吸引人。为此，哈密顿蒙特卡洛（Hamiltonian Monte Carlo）已被确立为一种强大的 MCMC 采样器，因其能够高效地探索高维目标分布 [4]。借助此方法，BPINNs 扩展了 PINNs 在贝叶斯 UQ 环境下的应用。

正如本文所展示的，BPINNs 仍然存在与 PINNs 类似的失败模式：多目标损失函数转化为 BPINN 中的多势能采样问题。这带来了与标准 PINNs 中发现的在平衡推断任务和有效探索帕累托前沿之间相同的困难 [43]。我们通过一个 Sobolev 训练基准进行了说明，该基准容易出现刚性、不同比例和任务特定梯度消失的问题。我们强调，BPINNs 对势能中 λ 权重的选择非常敏感，这可能导致偏倚的预测或采样失效。因此，标准权重策略在多尺度问题和多任务推断中效率不高，同时人工调节权重也难以做到可重复且可靠。最近提出的替代方法 [38] 需要额外的超参数调节或使用 GAN 预训练权重，代价是计算复杂度的增加。此外，先前的方法主要关注测量噪声估计，未涉及物理模型误差的关注，而这在 UQ 建模目标下同样至关重要。

因此，稳健的自动加权策略对于将 BPINNs 应用于多尺度和多任务（逆）问题以及提升 UQ 估计的可靠性至关重要。为此，本文提出了 AW-HMC BPINN 方案，为标准 BPINNs 提供了一种即插即用的自动自适应加权策略。正如基准测试中所示，AW-HMC 有效地处理了多势能采样、能量守恒不稳定性、不同比例以及数据中的噪声问题。

我们展示了该策略确保了加权的后验分布能够很好地探索帕累托前沿，通过基于逆狄利克雷加权（Inverse Dirichlet weighting）[29] 适当调整 λ 权重，从而实现了采样平衡。因此，这些权重可以直接解释为训练不确定性，由任务特定训练梯度的方差进行度量。这导致权重根据模型自适应调整，以产生对 BPINN HMC 采样最不敏感的多势能能量。这种方法提升了收敛性、鲁棒性和 UQ 可靠性，因为采样重点集中在帕累托前沿，从而使 BPINNs 能够有效且高效地解决多任务 UQ 问题。

所提方法在计算上也比以往方法更高效，因为它无需额外的超参数或网络层。这同样保证了跳蛙积分训练中的最佳积分时间和收敛性。它防止了步长趋近于零或变得非常小，避免了 No-U-Turn

采样 (NUTS) 中常见的为避免 HMC 不稳定特征的病态发散轨迹而出现的问题。该方法改善了这一状况, 因为步长不再需要满足所有刚性尺度要求以保证能量守恒。结果缩短了整体积分时间和采样数量需求, 实现了计算效率与采样稳定性鲁棒性的结合。

我们的结果还表明, AW-HMC 减少了采样偏差, 因为它能够根据各项对噪声或固有尺度的敏感性自动调整 λ 参数及其对应的不确定性估计。传统方法中, 由于手动调权引入的偏差和隐式先验, 这种调整是不允许的。事实上, 我们演示了该方法在多尺度问题中捕获不同数量级逆参数的效率, 且假设缩放方面完全独立的先验。而之前, 这通常通过对这些参数施加已适当缩放的先验分布来解决, 否则经典 BPINN 形式易于失败。提出的自适应权重策略完全避免了这些问题, 在多尺度逆问题中表现更佳。

我们还在计算流体力学 (CFD) 中不对称二维几何的不可压缩流体现实应用中验证了该方法。展示了 AW-HMC BPINNs 在 CFD 修复中的应用, 并研究了噪声对多势能能量的影响。这突显了该方法对噪声测量的鲁棒性, 同时也展现了其自动调整 λ 值以准确估计噪声水平的能力。在这方面, 我们展示了随着噪声增加不确定性增强的情况, 且无需对噪声水平设置先验, 并捕获了任务对噪声的不同固有敏感性。总体而言, 这为自动应对由未知异方差噪声分布产生的多保真度问题提供了一种有效替代方案。

综上所述, 当前结果使 BPINNs 成为科学数据同化的有希望方法。它们现具备有效解决多尺度和多任务推断问题的潜力, 能将 UQ 与物理先验耦合, 并处理稀疏且含噪声的数据问题。在所有这些方面, 本文提出的方法保证了高效的帕累托前沿探索、正确缩放多尺度和刚性动力学, 以及从数据中导出无偏不确定性信息。我们的方法对噪声分布、不同问题尺度及权重仅做最小假设, 且计算高效。这拓展了 BPINNs 在更复杂现实问题中的应用, 解决了以往难以直接处理的挑战。

我们预计这些改进特别适用于多孔介质研究、系统生物学和地球科学领域, 在这些领域中 BPINNs 为数据驱动建模提供了有前景的途径。它们可支持并推进形态几何提取和预测的工作 [36, 47], 以及直接从样本图像进行材料性质 [1] 和物理性质 [44] 的上尺度和粗粒化。然而, 从不完美图像捕获这些特征仍具挑战性, 且通常伴随不确定性, 例如由于不可避免的成像伪影。这需要开发基于均质化的方法 [18] 来桥接尺度并量化这些不确定性 [35], 或者利用数据同化以补偿图像中的部分知识缺失。当前带有 AW-HMC 的 BPINNs 形式为此提供了潜在解决方案。

A 逆 Dirichlet 加权方差的上界

在第 3.1 节中提出的逆 Dirichlet 自适应加权 HMC 算法保证了多势能项的梯度在采样过程中具有平衡的分布, 如下所示的联合方差:

$$\gamma^2 := \text{Var}\{\lambda_k \nabla_{\Theta} \mathcal{L}_k\} \simeq \min_{t=0, \dots, K} (\text{Var}\{\nabla_{\Theta} \mathcal{L}_t\}), \quad \forall k = 0, \dots, K. \quad (41)$$

本节中, 我们使用一个通用案例来证明 γ^2 是一个上界, 并且由一个依赖于预测误差或 PDE 残差、它们关于 Θ 的均值变异的离散程度以及 $\sigma_{\bullet}$ 参数设定的可靠性准则所控制。

这首先说明了合理设置 σ 参数的必要性, 以避免任务梯度分布的偏倚和不平衡, 因为这些参数对梯度分布的控制起着关键且任意的影响。同时也强调了手动调节 σ 值可能是一项极其敏感且在实际中难以实现的任务。因此, 在本文所呈现的所有应用中, 我们选择统一设置这些参数, 而转而依赖于 λ 的自动调整来确保, 除其他外, Pareto 前沿的有效探索。由此可见, 这些标准差参数对每个梯度分布——相对于 Θ ——施加了强约束, 因此影响了每个任务的不确定性。

为简化起见，我们采用两个任务采样，其中一个为场 u 的数据拟合项，另一个为 PDE 约束，记为 $\mathcal{F}$ ，因此数据集被分解为 $\mathcal{D} = \mathcal{D}^u \cup \mathcal{D}^\Omega$ ，遵循第 2.2 节中引入的符号。多势能因此简化为：

$$U(\Theta) = \frac{\lambda_0}{2\sigma_0^2} \|u_\Theta - u\|_{\mathcal{D}^u}^2 + \frac{\lambda_1}{2\sigma_1^2} \|\mathcal{F}(u_\Theta)\|_{\mathcal{D}^\Omega}^2 + \frac{1}{2\sigma_\Theta^2} \|\Theta\|^2 := \sum_{k=0}^{K+1} \lambda_k \mathcal{L}_k(\Theta) \quad (42)$$

在此我们选择保留 σ 符号以便演示，并将 Θ 限制为神经网络参数，即使以下内容同样适用于逆问题范式。回顾一下，用于训练的测量数据 $\mathcal{D}^u$ 可以与施加 PDE 约束的配点 $\mathcal{D}^\Omega$ 不同，它们各自的数量分别记为 N^u 和 N^Ω 。根据第 2.2 节的符号，两个任务势能的梯度分别写为：

$$\begin{aligned} \frac{\partial \mathcal{L}_0}{\partial \Theta_j}(\Theta) &= \frac{1}{\sigma_0^2 N^u} \sum_{i=0}^{N^u} \left(u_\Theta(x_i) - u_i \right) \frac{\partial u_\Theta}{\partial \Theta_j}(x_i) \\ \frac{\partial \mathcal{L}_1}{\partial \Theta_j}(\Theta) &= \frac{1}{\sigma_1^2 N^\Omega} \sum_{i=0}^{N^\Omega} \mathcal{F}\left(u_\Theta(x_i)\right) \frac{\partial \mathcal{F}(u_\Theta)}{\partial \Theta_j}(x_i) \end{aligned} \quad (43)$$

对于 $\Theta \in \mathbb{R}^p$ ，我们可以据此分解方差 $\text{Var}_\Theta[\nabla_\Theta \mathcal{L}_k]$, $k = 0, 1$ 。为此，我们先计算它们关于 Θ 的均值，分别为

$$\mathbb{E}_\Theta[\nabla_\Theta \mathcal{L}_0] = \frac{1}{N^p} \sum_{j=0}^{N^p} \frac{\partial \mathcal{L}_0}{\partial \Theta_j}(\Theta) = \frac{1}{\sigma_0^2 N^u} \sum_{i=0}^{N^u} \left(u_\Theta(x_i) - u_i \right) \mathbb{E}_\Theta[\nabla_\Theta u_\Theta](x_i) = \frac{1}{\sigma_0^2} \mathbb{E}_{\mathcal{D}^u}[(u_\Theta - u) \mathbb{E}_\Theta[\nabla_\Theta u_\Theta]] \quad (44)$$

和

$$\mathbb{E}_\Theta[\nabla_\Theta \mathcal{L}_1] = \frac{1}{\sigma_1^2} \mathbb{E}_{\mathcal{D}^\Omega}[\mathcal{F}(u_\Theta) \mathbb{E}_\Theta[\nabla_\Theta \mathcal{F}(u_\Theta)]] \quad (45)$$

当 $\mathcal{F}$ 是线性算子时，有特殊配置 $\nabla_\Theta \mathcal{F}(u_\Theta) = \mathcal{F}(\nabla_\Theta u_\Theta)$ 。最后，我们可以将其推广到方差计算，如下：

$$\begin{aligned} \text{Var}_\Theta[\nabla_\Theta \mathcal{L}_0] &= \frac{1}{N^p} \sum_{j=0}^{N^p} \left(\frac{\partial \mathcal{L}_0}{\partial \Theta_j} - \mathbb{E}_\Theta[\nabla_\Theta \mathcal{L}_0] \right)^2 \\ &= \frac{1}{N^p (N^u \sigma_0^2)^2} \sum_{j=0}^{N^p} \left[\sum_{i=0}^{N^u} \left(u_\Theta(x_i) - u_i \right) \left(\frac{\partial u_\Theta}{\partial \Theta_j}(x_i) - \mathbb{E}_\Theta[\nabla_\Theta u_\Theta](x_i) \right) \right]^2 \\ &= \frac{1}{(N^u \sigma_0^2)^2} \sum_{i=0}^{N^u} \sum_{k=0}^{N^u} \left(u_\Theta(x_i) - u_i \right) \left(u_\Theta(x_k) - u_k \right) \text{Cov}_\Theta[\nabla_\Theta u_\Theta(x_i), \nabla_\Theta u_\Theta(x_k)] \\ &\leq \frac{1}{\sigma_0^4} \|u_\Theta - u\|_{\infty, \mathcal{D}^u}^2 \text{Cov}_\Theta \left[\frac{1}{N^u} \sum_{i=0}^{N^u} \nabla_\Theta u_\Theta(x_i), \frac{1}{N^u} \sum_{k=0}^{N^u} \nabla_\Theta u_\Theta(x_k) \right] \\ &= \frac{1}{\sigma_0^4} \|u_\Theta - u\|_{\infty, \mathcal{D}^u}^2 \text{Var}_\Theta[\mathbb{E}_{\mathcal{D}^u}[\nabla_\Theta u_\Theta]] \end{aligned} \quad (46)$$

这给出了数据拟合项梯度方差的上界。同理，我们得到 PDE 约束的上界为：

$$\text{Var}_\Theta[\nabla_\Theta \mathcal{L}_1] \leq \frac{1}{\sigma_1^4} \|\mathcal{F}(u_\Theta)\|_{\infty, \mathcal{D}^\Omega}^2 \text{Var}_\Theta[\mathbb{E}_{\mathcal{D}^\Omega}[\nabla_\Theta \mathcal{F}(u_\Theta)]] \quad (47)$$

这里符号 $\|\cdot\|_{\infty, \mathcal{D}^\bullet}$ 表示在由 $\mathcal{D}^\bullet$ 训练点组成的空间域上的离散 ℓ^∞ 范数， $\mathbb{E}_{\mathcal{D}^\bullet}$ 表示对应数据集上的空间均值。因此，任务梯度的方差由交叉复杂分量 $\text{Var}_\Theta \mathbb{E}_{\mathcal{D}^\bullet}$ 控制，该分量可被解释为评估梯度下




图 15: 二维 Sobolev 训练基准: 相对 BMA 误差的比较, 如 (27) 中定义, 关于训练点数量绘制, 针对由不同 l 值引起的各种形状复杂度。训练点数量增加, 直到达到整个数据集的大约 30%, 即 20000 个训练点。

降方向相对于 Θ 的离散程度的敏感性项, 并在空间上求均值。最后, 由于 $\sigma_\bullet$ 值统一设置为 1 以避免偏倚采样, 这意味着 λ 值被计算为使梯度分布的联合方差有界:

$$\gamma^2 \leq \min \left\{ \|u_\Theta - u\|_{\infty, \mathcal{D}^u}^2 \text{Var}_\Theta [\mathbb{E}_{\mathcal{D}^u} [\nabla_\Theta u_\Theta]], \|\mathcal{F}(u_\Theta)\|_{\infty, \mathcal{D}^\Omega}^2 \text{Var}_\Theta [\mathbb{E}_{\mathcal{D}^\Omega} [\nabla_\Theta \mathcal{F}(u_\Theta)]] \right\} \quad (48)$$

这凸显了权重是根据最可能的任务进行调整的, 从而提高了不确定性量化的可靠性。本计算方法可以直接推广到更复杂的多势能项, 用于直接和逆向的真实世界问题, 至此我们的分析告一段落。

B 二维 Sobolev 训练基准

我们将第 3.2 节中使用的 Sobolev 基准扩展到二维训练, 包含梯度和拉普拉斯算子, 目标泛函形式为:

$$u(x, y) = \sum_{i=1}^{N_{rep}} A_x^i \cos(2\pi L^{-1} l_x^i x + \phi_x^i) A_y^i \sin(2\pi L^{-1} l_y^i y + \phi_y^i) \quad (49)$$

这使我们能够处理更广泛的形状复杂性和尖锐界面, 除此之外还包括由高阶导数引入的刚性。我们设置域大小为 $L = 2\pi$, 重复次数为 $N_{rep} = 5$, 参数 A_x 和 A_y 独立且均匀地从区间 $[-2, 2]$ 中采样, ϕ_x 和 ϕ_y 亦从 $[0, 2\pi]$ 中均匀采样。为了处理多种形状复杂性, 我们考虑参数 l 的范围, 使得局部长度尺度 l_x 和 l_y 随机采样自集合 $\{1, 2, \dots, l\}$ 。二维空间域 $[0, 2\pi]^2$ 由分辨率为 256×256 的均匀网格覆盖, 并配合随机选取的训练点。随后, 我们研究了多种形状复杂性 (通过设置不同的 l 值) 以及训练点数量对我们基于 AW-HMC 方法的贝叶斯模型平均 (BMA) 结果的影响。

在图 15 中展示的整体基准设置结果表明, 随着训练点数量的增加, BMA 误差呈收敛趋势, 这与 l 值无关, 尽管随着形状复杂性的增加, 相对 BMA 误差达到了更高的上限。这些相对 BMA 误差根据公式 (27) 计算, 是 Sobolev 采样多次重复的平均结果, 重复过程是并行进行的。实际上, 为了应对可能由采样变异性引发的随机过程, 我们进行了多次试验, 每次试验均从神经网络参数 Θ^{t_0} 和动量参数 r^{t_0} 的不同初始化开始, 导致不同的采样实现。我们可以利用这些采样变异性来计算这些重复的标准差, 如图 15 中的彩色带所示。

此外, 在图 16 中, 我们分别展示了多势能泛函每一项的 BMA 预测结果、基于采样过程预测标准差的预测不确定性, 以及在 $l = 8$ 且训练点数为 10000 (随机采样于整个域内) 情况下的相对




图 16: 二维 Sobolev 训练基准: BMA 预测、预测标准差以及相对 BMA 误差, 局部展示多目标势能的每一项。我们在有限情形 $l = 8$ 下进行了约 15% 的训练点。全局相对 BMA 误差在整个区域上的平均值分别约为 $1.69e - 3$ 、 $3.42e - 3$ 和 $5.6e - 3$ 。




图 17: 经典 HMC 在第 3.3 节定义的 Lotka-Volterra 多尺度逆问题中使用均匀权重时的失效模式。沿物理时间的两种物种种群的 BMA 预测及其不确定性 — 底部和左上图。采样迭代过程中相对 BMA-CE 误差展示了该方法的收敛性不足 — 右上图。

BMA 误差。结果显示，在边界墙附近存在更高误差的区域具有增强的不确定性，并凸显了我们方法能够同时捕捉不同数量级的复杂形状场的能力。我们还可以强调，此类二维 Sobolev 训练基准在传统的 BPINNs-HMC 公式下此前是难以实现的。

C 常规方法在洛特卡-沃尔泰拉逆问题上的失败

我们考虑在第 3.3 节中介绍的洛特卡-沃尔泰拉逆问题，以研究多尺度动力学对常规方法——即带有均匀权重的 HMC 和 NUTS——的影响。采样和 leapfrog 参数设置与 AW-HMC 测试案例相应，其中 N 分别指代 HMC 和 NUTS 公式中的燃烧步数和自适应步数。因此，我们在假设 1) 它们的时间复杂度相同，且 2) 我们对逆参数尺度不施加任何信息先验的条件下，比较不同的采样器。实际上，第一个条件表明不同的 leapfrog 参数可能会改进这些传统方法的推断效果。然而，这意味着 leapfrog 时间步长 δt 显著减小，从而导致能量水平的探索变慢。因此，这些方法需要通过增加 L 来延长积分时间，或者使用大量样本，才能获得合适的预测。需要提醒的是，独立于后验分布采样效率不足的问题，对多势能权重的错误选择会偏置采样器，使其偏离帕累托前沿的探索。第二个假设基于希望在对多尺度动力学进行不确定性量化时，不依赖于任何分尺度的先验知识。这一点源于 Linka 等人 [21] 的论断，即尺度敏感性会破坏 BPINNs-HMC 的性能。最后，我们还考虑顺序训练，以为不同方法之间提供适当的比较基础。

结果显示，经典的均匀权重 HMC（见图 17 — 右上）缺乏收敛性，同时任务之间存在严重不平衡。相对 BMA-CE 误差有效地表征了捕食者种群相比于猎物种群的极差收敛性，这直接导致对两种群体的 BMA 预测效率低下（见图 17 — 左下和左上）。这种失败模式主要是由于样本被大量




图 18: 带有 NUTS 自适应的 HMC 在第 3.3 节定义的洛特卡-沃尔泰拉多尺度逆问题中的失败模式。物理时间下两个物种种群的 BMA 预测及其不确定性 — 底部和左上图。采样迭代过程中相对 BMA-CE 误差，显示任务间的不平衡及对猎物种群的优先自适应 — 右上图。




图 19: HMC 使用 NUTS 在 Lokta-Volterra 多尺度推断中的失败模式：逆参数边际后验分布的直方图（上部）及其采样过程中轨迹的相位图（下部）。图 18 中的偏差预测阻碍了逆参数的正确推断，导致更新参数中出现随机游走的病态行为。

拒绝（接受率低于 1%），原因是沿 leapfrog 步骤的哈密顿轨迹不守恒。因此，这证实了当面临多尺度动力学引起的不稳定性时，BPINNs-HMC 范式缺乏鲁棒性。

作为替代，NUTS 方法在该多尺度逆问题上也难以收敛，导致预测不佳，尤其是对捕食者种群。这里的问题不在于大量样本被拒绝，而是时间步长被严格减小，最终在自适应步骤结束时分别达到 $\delta t = 8.26\text{e-}5$ 和 $2.81\text{e-}5$ ，相比 AW-HMC 下降了近十倍。相对 BMA-CE 误差（见图 18 — 右上）表明，这种时间步长自适应适用于猎物种群的收敛，因为猎物是最敏感的任务。这里的敏感性应理解为对潜在能量相对于参数 Θ 的微小变化会对哈密顿能量守恒施加最强约束。然而，时间步长的自适应对捕食者种群并不理想，甚至导致神经网络在顺序训练过程中效率低下。这表现为种群演化的误导性预测（见图 18 — 左下和左上）以及逆参数推断失败（见图 19）。逆参数轨迹的相位图展示了 NUTS 采样器在适当识别由不同尺度产生的模式时遇到的困难。总体来看，NUTS 采样器由于无法捕捉多尺度行为，导致其难以收敛至帕累托前沿，并且在弱先验条件下对逆参数的推断存在误导。

D CFD 逆问题中多势能的表征

如第 4.2 节所定义的 CFD 逆问题，涉及基于速度场的部分观测数据，恢复潜在压力场 p_Θ 以及流动状态参数——由雷诺数 Re_Θ 给出。用于 AW-HMC 采样的训练数据集 $\mathcal{D}$ 首先被分解为 9559 个随机采样的速度 u 测量值，分别定义了内部点和边界点的集合 $\mathcal{D}^u$ 和 $\mathcal{D}^\partial$ 。相同的配点定义了 $\mathcal{D}^\Omega$ ，在此处我们施加 PDE 约束和无散条件。考虑的问题中所用的陡峭狭窄几何形状在壁面界面处产生了尖锐梯度。后者需要被充分捕捉，以在潜在压力和逆参数的推断中获得一致性。因此，我们用部分速度一阶导数的测量数据补充训练。这使我们能够确保 PDE 约束 (37) 中的对流项与速度数据保持一致，从而推断相应的压力场。因此，多势能表达式写为：

$$\begin{aligned}
U(\Theta) = & \frac{\lambda_0}{2\sigma_0^2} \|u_\Theta - u\|_{\mathcal{D}^u}^2 + \frac{\lambda_1}{2\sigma_1^2} \|v_\Theta - v\|_{\mathcal{D}^u}^2 + \frac{\lambda_2}{2\sigma_2^2} \|u_\Theta - u\|_{\mathcal{D}^\partial}^2 + \frac{\lambda_3}{2\sigma_3^2} \|v_\Theta - v\|_{\mathcal{D}^\partial}^2 \\
& + \frac{\lambda_4}{2\sigma_4^2} \|\partial_x u_\Theta - \partial_x u\|_{\mathcal{D}^u}^2 + \frac{\lambda_5}{2\sigma_5^2} \|\partial_x v_\Theta - \partial_x v\|_{\mathcal{D}^u}^2 + \frac{\lambda_6}{2\sigma_6^2} \|\partial_x u_\Theta - \partial_x u\|_{\mathcal{D}^\partial}^2 \\
& + \frac{\lambda_7}{2\sigma_7^2} \|\partial_x v_\Theta - \partial_x v\|_{\mathcal{D}^\partial}^2 + \frac{\lambda_8}{2\sigma_8^2} \|Re_\Theta^{-1} \Delta u_\Theta - (u_\Theta \partial_x u_\Theta + v_\Theta \partial_y u_\Theta) - \partial_x p_\Theta\|_{\mathcal{D}^\Omega}^2 \\
& + \frac{\lambda_9}{2\sigma_9^2} \|Re_\Theta^{-1} \Delta v_\Theta - (u_\Theta \partial_x v_\Theta + v_\Theta \partial_y v_\Theta) - \partial_y p_\Theta\|_{\mathcal{D}^\Omega}^2 \\
& + \frac{\lambda_{10}}{2\sigma_{10}^2} \|\nabla \cdot u_\Theta\|_{\mathcal{D}^\Omega}^2 + \frac{\lambda_{11}}{2\sigma_{11}^2} \|\partial_y u_\Theta - \partial_y u\|_{\mathcal{D}^u}^2 + \frac{\lambda_{12}}{2\sigma_{12}^2} \|\partial_y u_\Theta - \partial_y u\|_{\mathcal{D}^\partial}^2 + \frac{1}{2\sigma_\Theta^2} \|\Theta\|_{R_{p+1}}^2
\end{aligned} \tag{50}$$

其中符号 $\|\cdot\|$ 指代 $\mathcal{D}^\bullet$ 上的均方根范数或 $\mathbb{R}^{p+1}$ 上的欧几里得范数。

参考文献

- [1] Naif Alqahtani, Fatimah Alzubaidi, Ryan T. Armstrong, Pawel Swietojanski, and Peyman Mostaghimi. Machine learning for predicting properties of porous media from 2d X-ray images. *Journal of Petroleum Science and Engineering*, 184:106514, 2020.
- [2] Naif J. Alqahtani, Yufu Niu, Ying Da Wang, Traiwit Chung, Zakhar Lanetc, Aleksandr Zhuravljov, et al. Super-Resolved Segmentation of X-ray Images of Carbonate Rocks Using Deep Learning. *Transport in Porous Media*, 143(2):497–525, 2022.

- [3] Karim Armanious, Vijeth Kumar, Sherif Abdulatif, Tobias Hepp, Sergios Gatidis, and Bin Yang. ipA-MedGAN: Inpainting of Arbitrary Regions in Medical Imaging. In 2020 IEEE International Conference on Image Processing (ICIP), pages 3005–3009, 2020.
- [4] Michael Betancourt. A conceptual introduction to hamiltonian monte carlo. arXiv, 2018. arXiv:1701.02434.
- [5] Michael Betancourt, Simon Byrne, and Mark Girolami. Optimizing The Integrator Step Size for Hamiltonian Monte Carlo. arXiv, 2014. arXiv:1411.6669.
- [6] Michael Betancourt, Simon Byrne, Sam Livingstone, and Mark Girolami. The geometric foundations of Hamiltonian Monte Carlo. *Bernoulli*, 23(4):2257–2298, 2017.
- [7] George C. Bourantas, Bevan L. Cheeseman, Rajesh Ramaswamy, and Ivo F. Sbalzarini. Using DC PSE operator discretization in Eulerian meshless collocation methods improves their robustness in complex geometries. *Computers & Fluids*, 136:285–300, 2016.
- [8] Steven L. Brunton, Joshua L. Proctor, and J. Nathan Kutz. Discovering governing equations from data by sparse identification of nonlinear dynamical systems. *Proceedings of the National Academy of Sciences*, 113(15):3932–3937, 2016.
- [9] Zhao Chen, Vijay Badrinarayanan, Chen-Yu Lee, and Andrew Rabinovich. GradNorm: Gradient normalization for adaptive loss balancing in deep multitask networks. In *Proceedings of the 35th International Conference on Machine Learning*, pages 794–803. PMLR, 2018.
- [10] Roberto Cipolla, Yarin Gal, and Alex Kendall. Multi-task Learning Using Uncertainty to Weigh Losses for Scene Geometry and Semantics. In 2018 IEEE/CVF Conference on Computer Vision and Pattern Recognition, pages 7482–7491, 2018.
- [11] Adam D. Cobb and Brian Jalaian. Scaling Hamiltonian Monte Carlo inference for Bayesian neural networks with symmetric splitting. In *Proceedings of the Thirty-Seventh Conference on Uncertainty in Artificial Intelligence*, pages 675–685. PMLR, 2021.
- [12] Wojciech M. Czarnecki, Simon Osindero, Max Jaderberg, Grzegorz Swirszcz, and Razvan Pascanu. Sobolev Training for Neural Networks. In *Advances in Neural Information Processing Systems*, volume 30. Curran Associates, Inc., 2017.
- [13] Marta D’Elia, Hang Deng, Cedric Fraces, Krishna Garikipati, Lori Graham-Brady, Amanda Howard, et al. Machine Learning in Heterogeneous Porous Materials. arXiv, 2022. arXiv:2202.04137.
- [14] Salar Fattahi and Somayeh Sojoudi. Data-Driven Sparse System Identification. In 2018 56th Annual Allerton Conference on Communication, Control, and Computing (Allerton), pages 462–469. IEEE, 2018.
- [15] Alex Graves. Practical Variational Inference for Neural Networks. In *Advances in Neural Information Processing Systems*, volume 24. Curran Associates, Inc., 2011.
- [16] Matthew D. Hoffman and Andrew Gelman. The No-U-turn sampler: adaptively setting path lengths in Hamiltonian Monte Carlo. *The Journal of Machine Learning Research*, 15(1):1593–1623, 2014.
- [17] Matthew D. Hoffman, Alexey Radul, and Pavel Sountsov. An Adaptive-MCMC Scheme for Setting Trajectory Lengths in Hamiltonian Monte Carlo. In *Proceedings of The 24th International Conference on Artificial Intelligence and Statistics*, pages 3907–3915. PMLR, 2021.
- [18] Laurène Hume and Philippe Poncet. A velocity-vorticity method for highly viscous 3d flows with application to digital rock physics. *Journal of Computational Physics*, 425:109910, 2021.
- [19] Weiqi Ji, Weilun Qiu, Zhiyu Shi, Shaowu Pan, and Sili Deng. Stiff-PINN: Physics-informed neural network for stiff chemical kinetics. *The Journal of Physical Chemistry A*, 125(36):8098–8106, 2021.

- [20] Guang Lin, Yating Wang, and Zecheng Zhang. Multi-variance replica exchange SGMCMC for inverse and forward problems via Bayesian PINN. *Journal of Computational Physics*, 460:111173, 2022.
- [21] Kevin Linka, Amelie Schäfer, Xuhui Meng, Zongren Zou, George Em Karniadakis, and Ellen Kuhl. Bayesian Physics Informed Neural Networks for real-world nonlinear dynamical systems. *Computer Methods in Applied Mechanics and Engineering*, page 115346, 2022.
- [22] Dehao Liu and Yan Wang. Multi-Fidelity Physics-Constrained Neural Network and its application in materials modeling. *Journal of Mechanical Design*, 141(12), 2019.
- [23] Qiang Liu and Dilin Wang. Stein Variational Gradient Descent: A general purpose bayesian inference algorithm. In *Advances in Neural Information Processing Systems*, volume 29. Curran Associates, Inc., 2016.
- [24] Xu Liu, Wen Yao, Wei Peng, and Weien Zhou. Bayesian Physics-Informed Extreme Learning Machine for Forward and Inverse PDE Problems with Noisy Data. *arXiv*, 2022. arXiv:2205.06948.
- [25] Samuel Livingstone, Michael Betancourt, Simon Byrne, and Mark Girolami. On the geometric ergodicity of Hamiltonian Monte Carlo. *Bernoulli*, 25(4A):3109 – 3138, 2019.
- [26] Suryanarayana Maddu, Bevan L. Cheeseman, Christian L. Müller, and Ivo F. Sbalzarini. Learning physically consistent differential equation models from data using group sparsity. *Physical Review E*, 103:042310, 2021.
- [27] Suryanarayana Maddu, Bevan L. Cheeseman, Ivo F. Sbalzarini, and Christian L. Müller. Stability selection enables robust learning of differential equations from limited noisy data. *Proceedings of the Royal Society A*, 478(2262):20210916, 2022.
- [28] Suryanarayana Maddu, Dominik Sturm, Bevan L. Cheeseman, Christian L. Müller, and Ivo F. Sbalzarini. STENCIL-NET: Data-driven solution-adaptive discretization of partial differential equations. *arXiv*, 2021. arXiv:2101.06182.
- [29] Suryanarayana Maddu, Dominik Sturm, Christian L Müller, and Ivo F Sbalzarini. Inverse Dirichlet weighting enables reliable training of physics informed neural networks. *Machine Learning: Science and Technology*, 3(1):015026, 2022.
- [30] José V. Manjón, José E. Romero, Roberto Vivo-Hernando, Gregorio Rubio, Fernando Aparici, Maria de La Iglesia-Vaya, et al. Blind MRI Brain Lesion Inpainting Using Deep Learning. In *Simulation and Synthesis in Medical Imaging*, pages 41–49. Springer International Publishing, 2020.
- [31] Xuhui Meng, Hessam Babaei, and George Em Karniadakis. Multi-fidelity Bayesian neural networks: Algorithms and applications. *Journal of Computational Physics*, 438:110361, 2021.
- [32] Joseph P. Molnar and Samuel J. Grauer. Flow field tomography with uncertainty quantification using a Bayesian physics-informed neural network. *Measurement Science and Technology*, 33(6):065305, 2022.
- [33] Jan Oldenburg, Finja Borowski, Alper Öner, Klaus-Peter Schmitz, and Michael Stiehm. Geometry aware physics informed neural network surrogate for solving navier – stokes equation (GAPINN). *Advanced Modeling and Simulation in Engineering Sciences*, 9(1):8, 2022.
- [34] Jaideep Pathak, Brian Hunt, Michelle Girvan, Zhixin Lu, and Edward Ott. Model-free prediction of large spatiotemporally chaotic systems from data: a reservoir computing approach. *Physical Review Letters*, 120:024102, Jan 2018.
- [35] Sarah Perez, Peter Moonen, and Philippe Poncet. On the Deviation of Computed Permeability Induced by Unresolved Morphological Features of the Pore Space. *Transport in Porous Media*, 141(1):151–184, 2022.
- [36] Johan Phan, Leonardo C. Ruspini, and Frank Lindseth. Automatic segmentation tool for 3D digital rocks by deep learning. *Scientific Reports*, 11(1):19123, 2021.

- [37] Philippe Poncet, Roland Hildebrand, Georges-Henri Cottet, and Petros Koumoutsakos. Spatially distributed control for optimal drag reduction of the flow past a circular cylinder. *Journal of Fluid Mechanics*, 599:111–120, 2008.
- [38] Apostolos F. Psaros, Xuhui Meng, Zongren Zou, Ling Guo, and George Em Karniadakis. Uncertainty quantification in scientific machine learning: Methods, metrics, and comparisons. *Journal of Computational Physics*, 477:111902, 2023.
- [39] Nasim Rahaman, Aristide Baratin, Devansh Arpit, Felix Draxler, Min Lin, Fred A. Hamprecht, et al. On the Spectral Bias of Neural Networks. In *Proceedings of the 36th International Conference on Machine Learning*, pages 5301–5310. PMLR, 2019.
- [40] Maziar Raissi, Paris Perdikaris, and George Em Karniadakis. Physics-informed neural networks: A deep learning framework for solving forward and inverse problems involving nonlinear partial differential equations. *Journal of Computational Physics*, 378:686–707, 2019.
- [41] Maziar Raissi, Alireza Yazdani, and George Em Karniadakis. Hidden Fluid Mechanics: A Navier-Stokes informed deep learning framework for assimilating flow visualization data. *arXiv*, 2018. arXiv:1808.04327.
- [42] Maziar Raissi, Alireza Yazdani, and George Em Karniadakis. Hidden fluid mechanics: Learning velocity and pressure fields from flow visualizations. *Science*, 367(6481):1026–1030, 2020.
- [43] Franz M. Rohrhofer, Stefan Posch, and Bernhard C. Geiger. On the Pareto Front of Physics-Informed Neural Networks. *arXiv*, 2021. arXiv:2105.00862.
- [44] Javier E. Santos, Ying Yin, Honggeun Jo, Wen Pan, Qinjun Kang, Hari S. Viswanathan, et al. Computationally Efficient Multiscale Neural Networks Applied to Fluid Flow in Complex 3D Porous Media. *Transport in Porous Media*, 140(1):241–272, 2021.
- [45] Hayden Schaeffer. Learning partial differential equations via data discovery and sparse optimization. *Proceedings of the Royal Society A: Mathematical, Physical and Engineering Sciences*, 473(2197):20160446, 2017.
- [46] Ozan Sener and Vladlen Koltun. Multi-Task Learning as Multi-Objective Optimization. In *Advances in Neural Information Processing Systems*, volume 31. Curran Associates, Inc., 2018.
- [47] Reza Shams, Mohsen Masihi, Ramin Bozorgmehry Boozarjomehry, and Martin J. Blunt. A hybrid of statistical and conditional generative adversarial neural network approaches for reconstruction of 3D porous media (ST-CGAN). *Advances in Water Resources*, 158, 2021.
- [48] Hwijae Son, Jin Woo Jang, Woo Jin Han, and Hyung Ju Hwang. Sobolev Training for Physics Informed Neural Networks. *arXiv*, 2021. arXiv:2101.08932.
- [49] Luning Sun, Han Gao, Shaowu Pan, and Jian-Xun Wang. Surrogate modeling for fluid flows based on physics-constrained deep learning without simulation data. *Computer Methods in Applied Mechanics and Engineering*, 361:112732, 2020.
- [50] Luning Sun and Jian-Xun Wang. Physics-constrained bayesian neural network for fluid flow reconstruction with sparse and noisy data. *Theoretical and Applied Mechanics Letters*, 10(3):161–169, 2020.
- [51] Minh-Trieu Tran, Soo-Hyung Kim, Hyung-Jeong Yang, and Guee-Sang Lee. Multi-Task Learning for Medical Image Inpainting Based on Organ Boundary Awareness. *Applied Sciences*, 11(9), 2021.
- [52] Remco van der Meer, Cornelis W. Oosterlee, and Anastasia Borovykh. Optimally weighted loss functions for solving PDEs with Neural Networks. *Journal of Computational and Applied Mathematics*, 405:113887, 2022.

- [53] Pantelis R. Vlachas, Jaideep Pathak, Brian R. Hunt, Themistoklis P. Sapsis, Michelle Girvan, Edward Ott, et al. Backpropagation algorithms and Reservoir Computing in Recurrent Neural Networks for the forecasting of complex spatiotemporal dynamics. *Neural Networks*, 126:191–217, 2020.
- [54] Nikolaos N. Vlassis and WaiChing Sun. Sobolev training of thermodynamic-informed neural networks for interpretable elasto-plasticity models with level set hardening. *Computer Methods in Applied Mechanics and Engineering*, 377:113695, 2021.
- [55] Sifan Wang, Yujun Teng, and Paris Perdikaris. Understanding and mitigating gradient flow pathologies in physics-informed neural networks. *SIAM Journal on Scientific Computing*, 43(5):A3055–A3081, 2021.
- [56] Sifan Wang, Xinling Yu, and Paris Perdikaris. When and why PINNs fail to train: a neural tangent kernel perspective. *Journal of Computational Physics*, 449:110768, 2022.
- [57] Andrew G Wilson and Pavel Izmailov. Bayesian Deep Learning and a Probabilistic Perspective of Generalization. In *Advances in Neural Information Processing Systems*, volume 33, pages 4697–4708. Curran Associates, Inc., 2020.
- [58] Anqi Wu, Sebastian Nowozin, Edward Meeds, Richard E. Turner, José Miguel Hernández-Lobato, and Alexander L. Gaunt. Deterministic Variational Inference for Robust Bayesian Neural Networks. In *7th International Conference on Learning Representations*. OpenReview.net, 2019.
- [59] Liu Yang, Xuhui Meng, and George Em Karniadakis. B-PINNs: Bayesian physics-informed neural networks for forward and inverse PDE problems with noisy data. *Journal of Computational Physics*, 425:109913, 2021.
- [60] Yibo Yang and Paris Perdikaris. Adversarial uncertainty quantification in physics-informed neural networks. *Journal of Computational Physics*, 394:136–152, 2019.
- [61] Jiayu Yao, Weiwei Pan, Soumya Shubhra Ghosh, and Finale Doshi-Velez. Quality of Uncertainty Quantification for Bayesian Neural Network Inference. *arXiv*, 2019. arXiv:1906.09686.
- [62] Wentao Yuan, Qingtian Zhu, Xiangyue Liu, Yikang Ding, Haotian Zhang, and Chi Zhang. Sobolev Training for Implicit Neural Representations with Approximated Image Derivatives. In *Computer Vision – ECCV 2022*, volume 13675, pages 72–88. Springer Nature Switzerland, 2022.
- [63] Qiang Zheng, Lingzao Zeng, and George Em Karniadakis. Physics-informed semantic inpainting: Application to geostatistical modeling. *Journal of Computational Physics*, 419:109676, 2020.