
物理信息驱动的张量基神经网络用于湍流封闭建模

Leon Riccius, Atul Agrawal & Phaedon-Stelios Koutsourelakis
Professorship of Data-driven Materials Modeling
School of Engineering and Design
Technical University of Munich
Boltzmannstr. 15, 85748 Garching, Germany
{leon.riccius, atul.agrawal, p.s.koutsourelakis}@tum.de

Abstract

尽管高性能计算资源日益普及，雷诺平均纳维-斯托克斯（RANS）模拟仍然是实际工程应用中湍流分析的主要方法。线性涡粘性模型（LEVM）作为最常用的模型类型，无法准确预测复杂的湍流状态。本研究将基于深度神经网络的非线性涡粘性模型与湍流可实现性约束相结合，通过引入归纳偏置显著改进了各向异性张量的预测效果。通过重心图可视化分析，我们证明所提出的机器学习方法在曲面和流动分离等传统难题中，其各向异性张量预测结果相比所有 LEVM 均展现出显著提升。然而，这种改进的各向异性张量在一般情况下并未带来比最优 LEVM 更优的平均速度和压力场预测结果。

1 引言

不可压缩纳维-斯托克斯方程对于描述低雷诺数下的流体运动至关重要，影响着飞机设计和洋流建模等领域。湍流的完全求解计算代价高昂，工程师通常采用雷诺平均 Navier-Stokes (RANS) 等降阶模型以提高效率。这些模型采用如 Launder-Sharma $k - \epsilon$ Launder and Sharma [1974] 或 Wilcox $k - \omega$ Wilcox [2008] 等闭合模型，其基于线性假设导致在复杂流动场景中精度受限。非线性模型虽有探索却面临挑战。本文工作建立在数据驱动方法 Duraisamy et al. [2019] 推动湍流建模研究复兴的基础上，旨在突破 2000 年代初早期进展后的停滞局面。

本研究结合王及其同事 Wang and Xiao [2016], Wang et al. [2017b] 提出的流动特征与 Ling 等人 Ling et al. [2016] 设计的神经网络架构，实现 RANS 闭合中各向异性张量的逐点估计。训练目标通过物理可实现性约束损失项得到强化，该损失项惩罚违反湍流状态物理约束的预测。所训练网络在未见过的流动场景中完成测试，并作为源项嵌入 RANS 方程以预测平均流量。

37th Conference on Neural Information Processing Systems (NeurIPS 2023).




图 1: 表示 RANS $k - \omega$ 模型湍流特性的重心图 (a) 及 DNS (b)

2 物理引导的张量基神经网络

2.1 雷诺应力与可实现性约束

雷诺应力张量 $\tau_{ij} = \langle u_i u_j \rangle$, 其中 $u_i = U_i - \langle U_i \rangle$ 通过时间平均 (平均量由 $\langle \cdot \rangle$ 表示) 纳维-斯托克斯方程得到, 并依赖于速度场 U_i 的脉动量 u_i 。它可以分解为各向同性部分 δ_{ij} 和各向异性部分 a_{ij} , 其表达式为 $a_{ij} = \tau_{ij} - 2/3 k \delta_{ij}$ 。湍流动能 k 是雷诺应力张量的迹。

各向异性张量 a_{ij} 的迹为零, 其归一化版本 b_{ij} 被称为各向异性张量, 即:

$$b_{ij} = \frac{a_{ij}}{2k} = \frac{\tau_{ij}}{\langle u_k u_k \rangle} - \frac{1}{3} \delta_{ij}, \quad (1)$$

雷诺应力张量是一个对称的、半正定的二阶张量, 其行列式和迹均为非负值。根据 Schumann [1977], 对各向异性张量的物理约束 (亦称为可实现性约束) 为:

$$-\frac{1}{3} \leq b_{\alpha\alpha} \leq \frac{2}{3} \quad \forall \alpha \in \{1, 2, 3\}, \quad -\frac{1}{2} \leq b_{\alpha\beta} \leq \frac{1}{2} \quad \forall \alpha \neq \beta. \quad (2)$$

文献 Banerjee et al. [2007] 中提出的重心图通过 $\mathbf{b}$ 的特征值分解定义了湍流的三种基本状态。所有其他湍流状态均可表示为这三种极限状态的线性组合。这些极限状态构成一个所有可接受状态的三角形; 其顶点由可实现性约束 (2) 确定。如图 1 所示, 重心三角形中的每个点对应唯一一种颜色。该映射关系详见补充材料 6.1。

2.2 闭合模型

尽管 LEVM 假设 $\mathbf{b}$ 是平均速度梯度的线性函数, 但当放弃该假设时可以建立更广泛的湍流模型。代数应力模型类由非线性涡粘性模型 (NLEVM) 构成, 这些模型通过局部湍流动能 k 、涡粘性 ϵ 和平均速度梯度确定雷诺应力。Pope Pope [1975] 证明: 所有由归一化平均应变率 $\hat{\mathbf{S}} = \epsilon/2k(\nabla \langle \mathbf{U} \rangle + \nabla \langle \mathbf{U} \rangle^T)$ 和归一化旋转率 $\hat{\mathbf{\Omega}} = \epsilon/2k(\nabla \langle \mathbf{U} \rangle - \nabla \langle \mathbf{U} \rangle^T)$ 构成且满足这些要求的二阶张量, 均可表示为十个基张量 $\mathcal{T}_{ij}^{(n)}$ 的线性组合。NLEVM 最一般的形式为:

$$b_{ij} = \sum_{n=1}^{10} G^{(n)}(\lambda_1, \dots, \lambda_5) \mathcal{T}_{ij}^{(n)}(\hat{S}_{ij}, \hat{\Omega}_{ij}), \quad (3)$$

其中 $G^{(n)}$ 为基张量的系数, λ_k 为依赖于 $\hat{\mathbf{S}}$ 和 $\hat{\mathbf{\Omega}}$ 的张量不变量。Ling 等人 Ling et al. [2016] 提出了张量基神经网络 (TBNN), 利用现代机器学习方法从高保真流体模拟数据中学习这些函数 $G^{(n)}$ 。尽管相比 $k - \epsilon$ 模型获得了改进结果, 但从这五个不变量中提取足够信息已被证明困难。特别是在具有至少一个均匀方向的流动工况中, 不变量 λ_3 和 λ_4 在整个流场区域消失。该论断的证明见补充材料 6.2。然而可以通过引入更多局部流动量特征并推导更多不变量, 同时继续采用 $\mathcal{T}^{(n)}$ 构成的完整性基底来实现扩展。本文部分工作遵循 Wang 等人 Wang et al. [2017a] 的研究, 他们推导了包含湍流动能梯度和压力梯度的扩展特征集。该模型使用 PyTorch Paszke et al. [2019] 实现, 可通过 github.com/pkmtum/PI_TBNN 访问。

2.2.1 在训练中实施可实现性约束

Ling 等人 Ling et al. [2016] 通过将点简单投影到重心三角形最近的边界上来在后处理过程中实施可实现性约束。我们建议在 TBNN 的训练中整合这些约束，然后将这种方法通俗地称为物理信息张量基神经网络（PI-TBNN）。方程 (2) 中给出的不等式可以通过惩罚方法转化为对损失函数的贡献。该额外项反映了关于问题结构的归纳偏置，并本质上充当正则化项。换句话说，如果训练样本处于可实现湍流状态域之外，惩罚项将将其拉回域内。约束条件为

$$\begin{aligned} c_1(\mathbf{b}) &= \min_{\alpha} (b_{\alpha\alpha}) - 1/3 < 0 \quad \forall \alpha \in \{1, 2, 3\}, & c_4(\mathbf{b}) &= 2|b_{12}| - (b_{11} + b_{22} + 2/3) < 0, \\ c_2(\mathbf{b}) &= (3|\phi_2| - \phi_2)/2 - \phi_1 < 0, & c_5(\mathbf{b}) &= 2|b_{13}| - (b_{11} + b_{33} + 2/3) < 0, \\ c_3(\mathbf{b}) &= 1/3 - \phi_2 < 0, & c_6(\mathbf{b}) &= 2|b_{23}| - (b_{22} + b_{33} + 2/3) < 0, \end{aligned} \quad (4)$$

其中 ϕ_i 表示 $\mathbf{b}$ 的特征值以区别于不变量。 ϕ_1 和 ϕ_2 分别是最大和次大特征值。惩罚项具体表示为

$$\mathcal{L}(\hat{\mathbf{b}}(\boldsymbol{\lambda}, \boldsymbol{\theta})) = \beta \sum_{k=1}^6 \max(0, c_k(\hat{\mathbf{b}}(\boldsymbol{\lambda}, \boldsymbol{\theta}))), \quad (5)$$

其中 $\boldsymbol{\lambda}$ 是不变量集合， $\boldsymbol{\theta}$ 为神经网络参数， $\hat{\mathbf{b}}(\boldsymbol{\lambda}, \boldsymbol{\theta})$ 是预测的各向异性张量。惩罚系数 β 决定其对损失函数的影响。综合考虑均方误差损失、正则化项和惩罚项的完整损失函数由下式给出：

$$E(\boldsymbol{\lambda}_i, \boldsymbol{\theta}) = \frac{1}{D} \sum_{i=1}^D \|\hat{\mathbf{b}}(\boldsymbol{\lambda}_i, \boldsymbol{\theta}) - \mathbf{b}_i\| + \frac{\alpha}{2} \|\boldsymbol{\theta}\|_2^2 + \frac{\beta}{D} \sum_{i=1}^D \sum_{k=1}^6 \max(0, c_k(\hat{\mathbf{b}}(\boldsymbol{\lambda}_i, \boldsymbol{\theta}))), \quad (6)$$

其中 $\mathbf{b}_i$ 为高保真响应数据。数据点数量记为 D 。系数 α 控制 L_2 正则化的强度。

3 数值结果

本文总共采用了四种流动几何结构作为基准测试案例。包括周期性丘状流动（PH）Mellen et al. [2000]、收敛发散通道流动（CDC）Laval and Marquillie [2011] 以及弯曲后向台阶流动（CBFS）Bentaleb et al. [2012]。这些案例在曲面上呈现逆压梯度特性，导致流动分离并伴随后续再附着现象。

数据集还扩展至包含方截面管道（SD）流动案例 Pinelli et al. [2010]。该场景能够清晰展现 LEVMs 的局限性，特别适合研究预测各向异性张量的正向传播特性。

所有流动案例均在 OpenFOAM Weller et al. [1998] 中完成复现以获取基准 RANS 数据。流动案例的设置方法与文献 Leon Riccius [2021] 完全一致。数据集的详细描述请参见补充材料 6.3。

3.1 各向异性张量预测

PI-TBNN 在训练过程中未见过的流动案例上进行了测试。这些案例在几何形状或雷诺数上与训练数据不同。图 2 使用重心色图比较了方管（SD）的各向异性张量。只有具有扩展特征集的 TBNN 能够准确重现该流动案例的湍流状态。图 3 中的 PH 几何结构也呈现类似情况，其中 $k-\omega$ 模型无法分别捕捉顶部的一维压缩（1C）湍流和流场主体的轴对称膨胀。然而，PI-TBNN 确实展现了此类特性。对于所有考虑的测试案例，PI-TBNN 在均方根误差（RMSE）上相比基准 $k-\omega$ 模型降低了约 70%，相比 Ling et al. [2016] 的 RMSE 降低了 50%（见表 1）。




图 2: 应力类型: $k-\omega$ (a), 采用 FS1 的 PI-TBNN (b), 采用 FS[1-3] 的 PI-TBNN (c), DNS (d) 用于 SD。

表 1: 三个测试案例中 RANS、PI-TBNN 和 TBNN 预测的 $\mathbf{b}$ 均方根误差。

Flow case	LEVM $k-\omega$	PI-TBNN, FS1	PI-TBNN, FS[1-3]	TBNN Ling et al. [2016]	Ling et al.
Square duct	0.2175	0.0992	0.0663	0.14	
Periodic hills	0.1016	0.0628	0.0419		
Curved backward-facing step	0.1173	0.0619	0.0414		

3.2 各向异性张量传播

尽管一些涉及壁面剪切应力计算的应用可直接受益于 $\mathbf{b}$ 预测的改进, 感兴趣的量通常是平均速度和压力场。因此, 使用 PI-TBNN 模型求解了平均速度和压力场的雷诺方程。表2显示, 对于 PH 和 CBFS 几何结构, PI-TBNN 相较 $k-\epsilon$ 模型具有小幅优势, 并在方管流动案例中表现出更优的面内预测性能。然而, 对于所有三种测试几何结构, 最准确的模型仍是 $k-\omega$ 模型。令人惊讶的是, 在 CBFS 几何结构中, PI-TBNN 在流动分离区域表现出最大的差异, 如图4所示。在周期性山丘测试案例中, $k-\omega$ 模型甚至优于使用 DNS 各向异性张量得到的平均场, 表明改进的各向异性张量并不必然导致平均速度和压力场的提升 (这一现象也见于 Taghizadeh et al. [2020], Duraisamy [2021])。Ling 等 Ling et al. [2016] 和 Wu 等 Wu et al. [2018] 均报告了相较 LEVM 在平均场预测中的改进, 但其基准 LEVM 采用了 $k-\epsilon$ 模型, 该模型相较真实值的偏差大于 $k-\omega$ 模型 (即其类别中性能最优模型)。

4 结论

我们引入了 PI-TBNN, 它通过扩展的特征集和以损失函数物理信息增强形式的归纳偏置对 TBNN 框架进行了改进。特征增加的合理性既来自理论分析—证明二维流动场景的独立不变量数量为三个而非五个—也通过预测性能提升得到实证验证。结果表明, 与 Ling 等人提出的原始 TBNN 模型 Ling et al. [2016] 相比, 新方法在各向异性张量预测精度上显著提高。




图 3: LEVM $k-\omega$ (a)、PI-TBNN (b) 和 DNS (c) 的应力类型可视化

表 2: 均方根误差 $\mathbf{U}$: 基于各向异性张量的 RANS 方法 ($k-\omega$ 、 $k-\epsilon$ 、PI-TBNN 和 DNS)。参考速度场来自 DNS。

Flow case	$k-\omega$	$k-\epsilon$	$b_{\text{PI-TBNN}}$	b_{DNS}
Square duct RMSE($\mathbf{U}$)	0.0496	0.0667	0.0716	0.0322
Square duct RMSE($[U_2, U_3]$)	0.0066	0.0066	0.0045	0.0025
Periodic hills RMSE($\mathbf{U}$)	0.0375	0.0545	0.0541	0.0465
Curved backward-facing step RMSE($\mathbf{U}$)	0.0609	0.0883	0.0868	




图 4: 流向平均速度剖面在特定 x 位置处的周期性山丘流 (a), 以及 CBFS (b)。

这种改进通过重心色图得到可视化展示, 并通过均方根误差 (RMSE) 量化评估。然而, 该方法在预测平均速度和压力场方面仍存在局限性。虽然其在流动分离几何场景中仍优于广泛应用的 $k-\epsilon$ 模型, 但始终无法与 $k-\omega$ 模型竞争。

基于 DNS 各向异性张量的 RANS 预测存在较大偏差, 这表明训练同时改进雷诺应力预测和直接针对平均场量预测的模型可能更具优势, 例如文献Agrawal and Koutsourelakis [2023], Hayek et al. [2018], Parish and Duraisamy [2016] 中提出的方法。

5 更广泛的影响

湍流是众多流体流动中的一种关键物理特性。理解这一现象对于复杂设计、环境建模以及众多工程应用至关重要。在过去几十年里, 计算能力显著提升, 使得直接数值模拟等尺度解析模拟方法能够应用于若干典型湍流问题。然而, 工业应用中仍需依赖雷诺平均纳维-斯托克斯方程 (RANS) 等快速近似方法, 其准确性高度依赖于湍流封闭模型。

本研究是对Ling et al. [2016] 提出的基于数据驱动的湍流封闭模型的进一步扩展。通过将深度神经网络与基于湍流可实现性约束的归纳偏置相结合, 并引入丰富的特征集, PI-TBNN 模型展现了显著改进。这种改进通过重心图可视化展示的均方根误差 (RMSE) 降低, 标志着我们在捕捉复杂湍流状态 (特别是涉及曲面和流动分离的场景) 方面迈出了重要一步。

然而, 本研究也揭示了改进的各向异性张量预测与预测平均速度和压力场这一终极目标之间的复杂关系。尽管 PI-TBNN 在提升各向异性张量预测方面表现优异, 但在平均场预测方面并未始终优于经典的 $k-\omega$ 模型, 这凸显了该领域仍需进一步探索的必要性。

我们未发现与本研究直接相关的伦理问题。该研究对社会的影响主要体现在机器学习技术提升流体湍流基础理解这一宏观研究背景中。

参考文献

- A. Agrawal and P.-S. Koutsourelakis. A probabilistic, data-driven closure model for RANS simulations with aleatoric, model uncertainty. arXiv preprint, 7 2023. doi: <https://doi.org/10.48550/arXiv.2307.02432>. URL <http://arxiv.org/abs/2307.02432>.
- S. Banerjee, R. Krahel, F. Durst, and C. Zenger. Presentation of anisotropy properties of turbulence, invariants versus eigenvalue approaches. *Journal of Turbulence*, 8:1–27, 2007. ISSN 14685248. doi: 10.1080/14685240701506896. URL <https://www.tandfonline-com.eaccess.ub.tum.de/doi/abs/10.1080/14685240701506896>.
- Y. Bentaleb, S. Lardeau, and M. A. Leschziner. Large-eddy simulation of turbulent boundary layer separation from a rounded step. *Journal of Turbulence*, 13:1–28, 1 2012. ISSN 14685248. doi: 10.1080/14685248.2011.637923. URL <https://www.tandfonline.com/doi/full/10.1080/14685248.2011.637923>.
- K. Duraisamy. Perspectives on machine learning-augmented Reynolds-averaged and large eddy simulation models of turbulence. *Physical Review Fluids*, 6(5):050504, 5 2021. ISSN 2469990X. doi: 10.1103/PHYSREVFLUIDS.6.050504/FIGURES/5/MEDIUM. URL <https://journals.aps.org/prfluids/abstract/10.1103/PhysRevFluids.6.050504>.
- K. Duraisamy, G. Iaccarino, and H. Xiao. Turbulence Modeling in the Age of Data. *Annual Review of Fluid Mechanics*, 51(1):357–377, 2019. ISSN 0066-4189. doi: 10.1146/annurev-fluid-010518-040547.
- M. E. Hayek, Q. Wang, and G. M. Laskowski. Adjoint-based optimization of RANS eddy viscosity model for U-bend channel flow. In *AIAA Aerospace Sciences Meeting*, 2018, number 210059, Reston, Virginia, 1 2018. American Institute of Aeronautics and Astronautics Inc, AIAA. ISBN 9781624105241. doi: 10.2514/6.2018-2091. URL <https://arc.aiaa.org/doi/10.2514/6.2018-2091>.
- B. E. Launder and B. I. Sharma. Application of the energy-dissipation model of turbulence to the calculation of flow near a spinning disc. *Letters in Heat and Mass Transfer*, 1(2):131–137, 11 1974. ISSN 00944548. doi: 10.1016/0094-4548(74)90150-7.
- J. P. Laval and M. Marquillie. Direct numerical simulations of converging-diverging channel flow. In *ERCOFTAC Series*, volume 14, pages 203–209. Springer Netherlands, 2011. ISBN 9789048196029. doi: 10.1007/978-90-481-9603-6{_}21.
- Leon Riccius. Machine Learning Augmented Turbulence Modelling for the Reynolds Stress Closure Problem, 3 2021.
- J. Ling, A. Kurzawski, and J. Templeton. Reynolds averaged turbulence modelling using deep neural networks with embedded invariance. *Journal of Fluid Mechanics*, 807:155–166, 2016. ISSN 14697645. doi: 10.1017/jfm.2016.615.
- C. P. Mellen, J. Frohlic, and W. Rodi. Large Eddy Simulation of the flow over periodic hills. 16th IMACS World Congress, pages 3–8, 2000.
- E. J. Parish and K. Duraisamy. A paradigm for data-driven predictive modeling using field inversion and machine learning. *Journal of Computational Physics*, 305:758–774, 2016. ISSN 10902716. doi: 10.1016/j.jcp.2015.11.012. URL <http://www.elsevier.com/open-access/userlicense/1.0/>.
- A. Paszke, S. Gross, F. Massa, A. Lerer, J. Bradbury, G. Chanan, T. Killeen, Z. Lin, N. Gimelshein, L. Antiga, A. Desmaison, A. Köpf, E. Yang, Z. DeVito, M. Raison, A. Tejani, S. Chilamkurthy,

- B. Steiner, L. Fang, J. Bai, and S. Chintala. PyTorch: An imperative style, high-performance deep learning library, 12 2019. ISSN 23318422. URL <http://arxiv.org/abs/1912.01703>.
- A. Pinelli, M. Uhlmann, A. Sekimoto, and G. Kawahara. Reynolds number dependence of mean flow structure in square duct turbulence. *Journal of Fluid Mechanics*, 644:107–122, 2010. ISSN 00221120. doi: 10.1017/S0022112009992242. URL <http://openaccess.city.ac.uk/>.
- S. B. Pope. A more general effective-viscosity hypothesis. *Journal of Fluid Mechanics*, 72(2):331–340, 11 1975. ISSN 14697645. doi: 10.1017/S0022112075003382. URL http://www.journals.cambridge.org/abstract_S0022112075003382.
- U. Schumann. Realizability of Reynolds-stress turbulence models. *Physics of Fluids*, 20(5):721–725, 1977. ISSN 10706631. doi: 10.1063/1.861942. URL <https://doi.org/10.1063/1.861942>.
- S. Taghizadeh, F. D. Witherden, and S. S. Girimaji. Turbulence closure modeling with data-driven techniques: physical compatibility and consistency considerations. *New Journal of Physics*, 22(9):093023, 9 2020. ISSN 1367-2630. doi: 10.1088/1367-2630/ABADB3. URL <https://iopscience.iop.org/article/10.1088/1367-2630/abadb3><https://iopscience.iop.org/article/10.1088/1367-2630/abadb3/meta>.
- J. X. Wang and H. Xiao. Data-driven CFD modeling of turbulent flows through complex structures. *International Journal of Heat and Fluid Flow*, 62:138–149, 2016. ISSN 0142727X. doi: 10.1016/j.ijheatfluidflow.2016.11.007.
- J. X. Wang, J. Wu, J. Ling, G. Iaccarino, and H. Xiao. A comprehensive physics-informed machine learning framework for predictive turbulence modeling, 2017a.
- J. X. Wang, J. L. Wu, and H. Xiao. Physics-informed machine learning approach for reconstructing Reynolds stress modeling discrepancies based on DNS data. *Physical Review Fluids*, 2(3):34603, 2017b. ISSN 2469990X. doi: 10.1103/PhysRevFluids.2.034603.
- H. G. Weller, G. Tabor, H. Jasak, and C. Fureby. A tensorial approach to computational continuum mechanics using object-oriented techniques. *Computers in Physics*, 12(6):620, 12 1998. ISSN 08941866. doi: 10.1063/1.168744. URL <http://scitation.aip.org/content/aip/journal/cip/12/6/10.1063/1.168744>.
- D. C. Wilcox. Formulation of the k- ω turbulence model revisited. In *AIAA Journal*, volume 46, pages 2823–2838, 11 2008. doi: 10.2514/1.36541. URL <https://arc.aiaa.org/doi/abs/10.2514/1.36541>.
- J. L. Wu, H. Xiao, and E. Paterson. Physics-informed machine learning approach for augmenting turbulence models: A comprehensive framework. *Physical Review Fluids*, 7(3):74602, 2018. ISSN 2469990X. doi: 10.1103/PhysRevFluids.3.074602.

6 补充材料

6.1 RGB 颜色映射图

如图1所示，重心三角形中的每个点对应唯一的颜色。从重心坐标到 RGB 值的映射遵循

$$\begin{bmatrix} R \\ G \\ B \end{bmatrix} = \frac{1}{\max C_{ic}} \left(C_{1c} \begin{bmatrix} 1 \\ 0 \\ 0 \end{bmatrix} + C_{2c} \begin{bmatrix} 0 \\ 1 \\ 0 \end{bmatrix} + C_{3c} \begin{bmatrix} 0 \\ 0 \\ 1 \end{bmatrix} \right) \quad \text{for } i \in \{1, 2, 3\}. \quad (7)$$

6.2 标量不变量

对于具有单方向均匀性的流动，五个标量不变量中的两个（ λ_3, λ_4 ）为零。这两个不变量表达为

$$\lambda_3 = \text{tr}(\hat{\mathbf{S}}^3), \quad \lambda_4 = \text{tr}(\hat{\mathbf{\Omega}}^2 \hat{\mathbf{S}}). \quad (8)$$

假设流动在 z 方向具有均匀性，则平均速度对 z 的偏导数消失，此时平均应变速率张量和旋转张量表达为

$$\hat{S}_{ij} = \frac{1}{2} \frac{k}{\epsilon} \begin{bmatrix} 2 \frac{\partial \langle U_x \rangle}{\partial x} & \frac{\partial \langle U_x \rangle}{\partial y} + \frac{\partial \langle U_y \rangle}{\partial x} \\ \frac{\partial \langle U_y \rangle}{\partial x} + \frac{\partial \langle U_x \rangle}{\partial y} & 2 \frac{\partial \langle U_y \rangle}{\partial y} \end{bmatrix}, \quad \hat{\Omega}_{ij} = \frac{1}{2} \frac{k}{\epsilon} \begin{bmatrix} 0 & \frac{\partial \langle U_x \rangle}{\partial y} - \frac{\partial \langle U_y \rangle}{\partial x} \\ \frac{\partial \langle U_y \rangle}{\partial x} - \frac{\partial \langle U_x \rangle}{\partial y} & 0 \end{bmatrix}. \quad (9)$$

雷诺方程的不可压缩性约束简化为

$$\frac{\partial \langle U_i \rangle}{\partial x_i} = \text{tr} \left(\frac{\partial \langle U_i \rangle}{\partial x_j} \right) = \frac{\partial \langle U_x \rangle}{\partial x} + \frac{\partial \langle U_y \rangle}{\partial y} = 0. \quad (10)$$

当结合不可压缩性约束条件使用 $\hat{\mathbf{S}}$ 与 $\hat{\mathbf{\Omega}}$ 的简化表达式时，不变量 λ_3 的表达式为

$$\text{tr}(\hat{S}_{ij}^3) = \quad (11)$$

$$\begin{aligned} & \frac{k^3}{8\epsilon^3} \text{tr} \left(\begin{bmatrix} \hat{S}_{11}(\hat{S}_{11}^2 + \hat{S}_{12}^2) + \hat{S}_{12}(\hat{S}_{11}\hat{S}_{12} + \hat{S}_{12}\hat{S}_{22}) & \hat{S}_{12}(\hat{S}_{11}^2 + \hat{S}_{12}^2) + \hat{S}_{22}(\hat{S}_{11}\hat{S}_{12} + \hat{S}_{12}\hat{S}_{22}) \\ \hat{S}_{11}(\hat{S}_{11}\hat{S}_{12} + \hat{S}_{12}\hat{S}_{22}) + \hat{S}_{12}(\hat{S}_{12}^2 + \hat{S}_{22}^2) & \hat{S}_{22}(\hat{S}_{12}^2 + \hat{S}_{22}^2) + \hat{S}_{12}(\hat{S}_{11}\hat{S}_{12} + \hat{S}_{12}\hat{S}_{22}) \end{bmatrix} \right) \\ &= \frac{k^3}{8\epsilon^3} \left(\hat{S}_{11}(\hat{S}_{11}^2 + \hat{S}_{12}^2) + 2\hat{S}_{12}^2 \underbrace{(\hat{S}_{11} + \hat{S}_{22})}_{=0} + \hat{S}_{22}(\hat{S}_{22}^2 + \hat{S}_{12}^2) \right), \end{aligned} \quad (12)$$

$$= \frac{k^3}{8\epsilon^3} \left(\hat{S}_{11}(\hat{S}_{11}^2 + \hat{S}_{12}^2) + \hat{S}_{22}(\hat{S}_{11}^2 + \hat{S}_{12}^2) \right), \quad (13)$$

$$= \frac{k^3}{8\epsilon^3} \left(\underbrace{(\hat{S}_{11} + \hat{S}_{22})}_{=0} (\hat{S}_{11}^2 + \hat{S}_{12}^2) \right) = 0. \quad (14)$$

不变量 λ_4 的推导相对直接，因此直接以平均速度梯度形式表达为

$$\text{tr}(\hat{\Omega}_{ij}^2 \hat{S}_{jk}) = \text{tr} \left(\frac{k^3}{8\epsilon^3} \left(\frac{\partial \langle U_x \rangle}{\partial y} - \frac{\partial \langle U_y \rangle}{\partial x} \right)^2 \begin{bmatrix} 2 \frac{\partial \langle U_x \rangle}{\partial x} & \frac{\partial \langle U_x \rangle}{\partial y} + \frac{\partial \langle U_y \rangle}{\partial x} & 0 \\ \frac{\partial \langle U_y \rangle}{\partial x} + \frac{\partial \langle U_x \rangle}{\partial y} & 2 \frac{\partial \langle U_y \rangle}{\partial y} & 0 \\ 0 & 0 & 0 \end{bmatrix} \right) \quad (15)$$

$$= \frac{k^3}{4\epsilon^3} \left(\frac{\partial \langle U_x \rangle}{\partial y} - \frac{\partial \langle U_y \rangle}{\partial x} \right) \underbrace{\left(\frac{\partial \langle U_x \rangle}{\partial x} + \frac{\partial \langle U_y \rangle}{\partial y} \right)}_{=0} = 0. \quad (16)$$

6.3 数据集

训练采用了高保真直接数值模拟 (DNS) 和大涡模拟 (LES) 数据。在可获取的两个 CDC DNS 数据中，雷诺数为 $\text{Re} = 7900$ 的数据用于估计正则化参数。较高雷诺数 $\text{Re} = 12600$ 的模拟数据用于训练和验证，同时结合 $\text{Re} = 2800$ 的 DNS 和 $\text{Re} = 10595$ 的 LES 用于 PH 流动，以及雷诺数为 $\text{Re} = \{2000, 2400, 2900, 3200\}$ 的 SD 流动 DNS 数据。数据集按照 70/30 的比例划分为训练集和验证集，因此可用于训练的总数据点数为 26600。

测试集包含三种流动几何结构 (SD、PH 和 CBFS)。其中 SD 和 PH 两种几何结构同样出现在训练和验证集中，但处于不同雷诺数条件下。选取 $\text{Re} = 5600$ 的周期性山丘案例用于研究插值特性——机器学习 (ML) 模型此前已学习过该流动几何结构，应能产生良好预测结果。

方形管道是一种典型流动案例，可清晰展示 LEVMs 的缺陷，并适用于演示雷诺应力向流动场传播的困难性。最后，弯曲后向台阶案例用于测试 ML 模型的外推能力。