

一种用于条件期望的严格界限的广义矩方法

Wouter J.E.C. van Eekelen

Booth School of Business, University of Chicago, Wouter.vanEekelen@chicagobooth.edu

February 26, 2026

In this paper, we address the problem of bounding conditional expectations when moment information of the underlying distribution and the random event conditioned upon are given. To this end, we propose an adapted version of the generalized moment problem which deals with this conditional information through a simple transformation. By exploiting conic duality, we obtain sharp bounds that can be used for distribution-free decision-making under uncertainty. Additionally, we derive computationally tractable mathematical programs for distributionally robust optimization (DRO) with side information by leveraging core ideas from ambiguity-averse uncertainty quantification and robust optimization, establishing a moment-based DRO framework for prescriptive stochastic programming.

Key words: Conditional expectations, sharp bounds, conic duality, prescriptive stochastic programming, distributionally robust optimization with side information

1. 引言

随机模型的无分布性能分析旨在仅利用关于潜在概率分布的有限信息，获得随机变量目标函数期望的紧界。传统上，给定随机变量的矩信息，这些问题被建模为广义矩问题。通过求解半无限优化问题，即在所有允许的随机变量分布上进行优化，能够找到这些随机变量目标函数的最尖锐（即“最优”）的上界和/或下界。在本文中，我们探讨一种新的情形，除了给定的矩序列外，我们还拥有更强的信息——即我们知道某个特定随机事件将会发生，该事件涉及随机变量的实现而非其潜在的概率分布。我们关注的是在已知该随机事件的情况下，求解带有该知识的矩问题，该知识可能基于假设、断言、专家判断或过去的观察。或者，我们可能希望确定如果发生这种随机事件，随机模型的最坏情况表现。条件期望为建模该事件信息提供了一种途径，使我们能够在知道指定随机事件将发生的情况下，获得随机变量函数期望值的最佳估计。

有趣的是，为这一新情形定义一个带条件期望的广义矩框架，而非传统的期望，其中随机变量不受限于取事件集的子集值。然而，随机变量在随机事件条件下会产生不同的概率学概念，需要与传统广义矩问题理论不同的分析方法。

概率论学者自19世纪末以来便对矩问题进行了研究，参见如 [1, 2, 3, 4] 等文献。在其最经典的形式中，矩问题是一个可行性问题，旨在确定是否存在满足给定分布信息的概率分布。Chebyshev 提出仅给定均值-方差信息时，求随机变量尾部分布最优界的问题，他的学生 Markov 后来利用连分数技术解决了该问题，最终得出了著名的 Chebyshev 不等式。直到20世纪50至60年代，这类文献的兴趣才被重新点燃，催生了大量关于 Chebyshev 系统的文献。我们参考 [5] 的专著以获得全面综述。

广义矩问题重新获得关注的重要原因之一是对偶理论作为解决该问题的新方法的出现，如 [6, 7] 等工作所示。正如 [8] 中总结的，[9] 首次将 Chebyshev 不等式推广到多元情形。由于传统仅利用矩信息的 Chebyshev 不等式被认为过于宽松，无法用于实际应用，[10] 利用结构性质对这些界进

行了强化。近年来，矩问题、多项式非负性与半正定规划之间的联系被广泛利用（见如 [1, 2, 3, 4, 5]）。[6] 讨论了广义矩问题的对偶结果与更一般的锥对偶理论之间的关系，并将这些概念扩展到更一般的拓扑向量空间。[7] 在其现代讨论中重新审视了广义矩问题，强调其在决策理论中的多种应用。在其工作中，Smith 简要提及了带有先验信息的设定，但指出所得期望不再是概率测度的线性函数，因此问题更具挑战性，无法直接应用其讨论的技术。作为解决方案，[8] 建议采用线性化技术，如 [9] 和 [10] 所述，将问题转化为一系列常规广义矩问题。

沿着 [7] 的思路，我们定义了一种新型的广义矩问题变体，并利用半无限规划理论，在目标函数为概率分布的分式函数（而非线性函数）的情形下获得紧界。关于一般半无限规划理论的全面综述见 [11]。据我们所知，目前尚无通用技术可用于获得条件期望的紧界。尽管 [7] 提供了传统幂矩条件期望的一些界，但这些仅针对单个随机变量的期望，且不一定紧。此外，[7] 主要利用条件信息来强化 Chebyshev 类型的尾概率界。相比之下，我们提供了一个通用框架，用于在有限信息下获得条件期望的最优界。

将上述思想扩展至决策制定领域，我们关注获得包含决策向量的随机变量某目标函数期望的紧界，以防范自然界的最好情况。[12] 可谓首个将极小极大优化引入运筹学领域的人士。Scarf 考察了单品新闻供应商问题，其中需求分布未知，仅由有限信息表征。允许的分布集合（即模糊集）包含所有具有指定均值和方差的分式函数。Scarf 利用对偶技术找到最大化新闻供应商总成本的最坏分布，再确定订单量以使该最大总成本最小化。随后，广义矩问题被广泛应用于解决此类极小极大优化问题（参见如 [13, 14, 15, 16, 17]）。

极小极大优化发展为分布鲁棒随机优化或分布鲁棒优化（DRO）领域。该术语最早由 [18] 提出，自此成为运筹学界的标准术语。分布鲁棒优化被视为处理不确定性决策的两个独立领域——鲁棒优化与随机规划——之间的统一范式。鲁棒优化 [19, 20] 通过不确定性集有效处理参数不确定性，尽管利用不确定性集编码不确定性通常带来计算可行性，但所得解可能过于保守。相比之下，随机规划利用完整分布信息捕获参数不确定性，但模型往往难以求解 [21]。模糊集是一种强大的建模工具，用于通过支持集及描述性统计量捕获不确定参数的分布信息。大量关于分布鲁棒优化（DRO）的文献基于矩信息，部分信息由均值、矩和离散度量给出 [22, 23, 24, 25]。如 [26] 所述，基于矩的 DRO 问题的可解性依赖于目标函数与模糊集结构之间的复杂相互作用。另一类流行的模糊集基于统计距离度量，限制其成员与参考分布保持特定距离，例如 ϕ -散度和 Wasserstein 距离（见如 [27, 28]）。本文聚焦于基于矩的信息。

条件矩信息在多项工作中被用于描述模糊集。在极小极大随机规划文献中，[29] 将此类信息纳入广义矩问题的约束，以界定随机规划问题的目标值。[30] 将模糊集限制为多项式密度函数，展示了这些模糊集的高度表达能力，因为它们能方便地包含关于条件概率、条件矩及边际分布的分布信息。[31] 引入了基于广义矩的条件期望约束的场景模糊集。尽管这些工作使用了条件矩信息，但其目标仍是最大化常规期望，因而其方法无法直接处理以条件期望为目标的情形。

此处应提及一些关于目标函数为分式的分布鲁棒优化工作。在仅有支持信息时，[32] 将鲁棒优化扩展至分式规划，其中目标函数是两个不确定参数函数的比值。[33] 解决了带矩约束的 DRO 问题，最大化代表收益风险比的模糊分式函数。[34] 也研究了这类分式 DRO 问题，利用半无限规划

的上界表述解决模糊收益风险比问题，并设计了基于 Wasserstein 模糊集的数据驱动建模与求解框架。

利用条件信息，我们可以用条件期望界限增强 DRO 框架中的“最坏情况”决策。针对该情形，存在一个独立的研究方向称为情境分布鲁棒优化，其中关于随机变量实现的先验知识通常称为侧信息。此研究方向是处方随机规划范式的自然延伸。在该范式中，关注的核心对象是侧信息与结果随机变量的联合分布，若已知该联合分布，则通过条件该分布于侧信息可更准确地估计结果变量。然而实际中，该联合分布通常未知，仅通过有限数据样本估计。处方随机规划的最终目标是开发一种优化方法，利用可用侧信息在对侧信息对不确定结果参数预测能力仅有有限了解的条件下改进决策（参见如 [??]）。

情境 DRO 建模范式假设除了侧信息外，联合分布还包含于由有限可用信息定义的模糊集中。此范式的研究尚较稀少。我们强调若干工作。[?] 通过部分质量运输问题描述模糊集，并利用概率修剪方法求解情境 DRO 问题。相对地，[?] 直接利用最优传输模糊集，成功对含侧信息的 DRO 问题找到可解的锥改写。[?] 考虑了以侧信息及结果参数可用数据样本经验分布为中心的 Wasserstein 球模糊集 [?]。尽管 Wasserstein 球模糊集是通过最优传输理论获得的一类分布模糊集，[?] 中的模型与结果因采用构建模糊集的 ∞ 型 Wasserstein 距离的特殊性质而表现出质的不同。

上述文献多考虑通过定义概率分布间距离的度量（如 Wasserstein 度量）确定的模糊集，而本文将聚焦于由广义矩信息描述的模糊集。

本文的主要贡献总结如下。

1. 我们扩展了半无限规划和广义矩问题的理论，通过推导半无限设置下线性分式规划的对偶性结果。我们扩展了广义矩问题理论中的若干著名结果，以便界定条件期望，而非随机变量函数的标准期望。大多数结果能够推广到带有条件期望的情形，这一点特别引人注目，因为条件期望是概率测度的非线性函数（因此不适用于基于半无限线性规划的标准技术）。
2. 我们将这些广义条件界问题的新颖结果应用于简单随机变量的单变量函数。通过原始-对偶论证，我们获得了针对不同类型离散信息的若干闭式界。除了广义矩信息外，我们还展示了分布的结构性质也可以被纳入。我们进一步通过解决一个来自鲁棒垄断定价文献的极小极大优化问题来展示我们的方法。此外，断言在单变量设置中，大多数计算与线性期望算子一样具有可解性。
3. 我们利用鲁棒不确定性量化和分布鲁棒凸优化的研究成果，为多变量问题开发了锥重构形式。随后，我们将这些重构形式应用于上下文 DRO，提出了一个带有侧信息的分布鲁棒优化广义矩框架。该框架旨在用于条件决策，结合了侧信息和包含在模糊集中分布信息。重构形式的计算可解性被发现与具有随机变量支持限制的分布鲁棒凸优化问题的可解性密切相关。

本文余下部分安排如下。第 2 节介绍带条件期望的广义矩界问题，并详细阐述对偶方法。第 3 节讨论若干单个随机变量函数条件期望的紧界实例。第 4 节展示基于矩的情境 DRO 框架。大部分次要结果的证明附于附录。最后，第 5 节总结全文并提出若干未来研究方向。

2. 广义条件期望问题的对偶框架

我们首先在第 2.1 节描述条件期望界定的问题，随后在第 2.2 节推导相关的对偶问题。然后，在第 2.3 节，我们给出将在后续章节中用以获得期望的精确界限的基础性结果。

2.1. 问题陈述

我们的目标是找到随机向量 X 条件期望的最优上界。首先介绍一些符号。令 $\mathbb{E}$ 表示期望算子， $g(\cdot)$ 表示 X 的任意可测函数。随机向量 X 定义在支持集 $\Omega \subseteq \mathbb{R}^n$ 上，我们假设该支持集是带有 Borel σ -代数 $\mathcal{B}_\Omega$ 的闭集。随机向量 X 由概率测度 $\mathbb{P} : \mathcal{B}_\Omega \rightarrow [0, 1]$ 控制，对于可测集合 $\mathcal{S} \in \mathcal{B}_\Omega$ ，有 $\mathbb{P}(\mathcal{S}) = \mathbb{P}(X \in \mathcal{S})$ 。此外， $\mathbb{P}$ 位于某个概率测度的凸集 $\mathcal{P}$ 中。本文中，“概率测度”和“概率分布”两个术语可互换使用。我们假设 $\Xi \in \mathcal{B}_\Omega$ 是一个任意的可测事件，用于描述观察到的随机事件，关联于 X 的实现。令 Ξ 是一个具有严格正测度的集合，即 $\mathbb{P}(X \in \Xi) > 0$ ，从而 $\mathbb{E}[g(X)|\Xi]$ 有定义，表示条件于 X 取值在集合 Ξ 上的条件期望。现在我们具备了必要的符号，可以构建一个经过调整的广义矩问题版本，该版本结合了随机事件，或者换一种说法，结合了边信息。本文的核心问题可表述如下：

$$\sup_{\mathbb{P} \in \mathcal{M}_+(\Omega)} \mathbb{E}_{\mathbb{P}}[g(X)|X \in \Xi] \quad \text{subject to} \quad \mathbb{E}_{\mathbb{P}}[h_j(X)] = q_j \text{ for } j = 0, \dots, m, \quad (1)$$

其中 $\mathcal{M}_+(\Omega)$ 表示定义在支持集 Ω 上的所有非负测度， $g, h_0, \dots, h_m$ 是实值可测函数，分别表示目标函数及可用的（广义）矩信息。概率质量约束被显式包含为 $h_0 \equiv 1$ 且 $q_0 = 1$ 。令 $\mathcal{P}$ 表示包含真实概率分布的歧义集合（ambiguity set）。对于给定的矩向量 $\mathbf{q}$ ，定义集合

$$\mathcal{P}(\mathbf{q}) := \left\{ \mathbb{P} \in \mathcal{P}_0(\Omega) : \int h_j(x) d\mathbb{P}(x) = q_j, j = 0, \dots, m \right\}, \quad (2)$$

该集合包含所有满足给定矩序列的概率分布。这里，我们通常假设 $\mathbb{P}$ 是支持包含于 Ω 的概率测度集合 $\mathcal{P}_0(\Omega)$ 的元素。因此，约束 $h_0 \equiv 1$ 被隐式假设以标准化 $\mathcal{M}_+(\Omega)$ 中的测度，从而获得概率分布。作为一个密切相关的概念，我们考虑产生非空歧义集合 $\mathcal{P}(\mathbf{q})$ 的矩锥 $\mathbf{q} \in \mathbb{R}^m$ ，其定义为

$$\mathcal{Q} := \left\{ \mathbf{q} \in \mathbb{R}^m : \exists \mathbb{P} \in \mathcal{M}_+(\Omega) \text{ 使得 } \mathbb{P} \in \mathcal{P}(\mathbf{q}) \right\} \Theta$$

因此，该集合包含所有使得 (1) 有解的矩向量 $\mathbf{q}$ 。换句话说，矩约束是一致的，或者存在一个概率分布使得广义矩问题可行。我们在此之后假设矩约束是一致的，因此歧义集合 $\mathcal{P}$ 非空，从而问题 (1) 总存在可行解。

既然我们已经介绍了所需的符号并研究了 (1) 的约束，接下来讨论目标函数。与广义矩问题中研究的随机向量函数的常规期望 $\mathbb{E}[g(X)]$ 不同，我们现在研究

$$\mathbb{E}_{\mathbb{P}}[g(X)|X \in \Xi] = \int_{\Xi} g(x) d\mathbb{Q}(x) = \frac{\mathbb{E}_{\mathbb{P}}[g(X)\mathbb{1}_{\Xi}(X)]}{\mathbb{E}_{\mathbb{P}}[\mathbb{1}_{\Xi}(X)]}, \quad (3)$$

其中 $\mathbb{Q}$ 表示条件概率测度（假设其存在）。注意，目标函数是概率分布 $\mathbb{P}$ 的分式函数，因此是非线性的。由此可知，(1) 属于分布鲁棒分式优化问题类别，这类问题本质上比简单最大化函数期望的标准问题更难求解（参见例如 [??]）。

2.2. 等价问题及其对偶

问题 (1) 可以等价地表述为一个半无限线性分式规划 (LFP) 问题。问题 (1) 的半无限线性分式规划重写形式为

$$\begin{aligned} \sup_{\mathbf{P}(x) \geq 0} \quad & \frac{\int_{\Omega} g(x) \mathbb{1}_{\Xi}(x) d\mathbf{P}(x)}{\int_{\Omega} \mathbb{1}_{\Xi}(x) d\mathbf{P}(x)} \\ \text{s.t.} \quad & \int_{\Omega} h_j(x) d\mathbf{P}(x) = q_j, \quad \forall j = 0, \dots, m, \\ & \mathbf{P}(X \in \Xi) > 0, \end{aligned} \quad (4)$$

其中 $\mathbb{1}_{\Xi}(x)$ 当且仅当 $x \in \Xi$ 时取值为 1，否则取值为 0。这里线性分式目标的优化是针对无限维变量（即概率分布）进行的。我们还具有有限数量的约束来描述矩信息。最后一个约束确保条件期望的定义良好，避免在测度为零的集合上进行条件化。

在有限维情形下，这些线性分式规划可以通过 Charnes-Cooper 变换降维为线性规划 [?, Theorem 2]。如果将此推广到无限维空间，Charnes-Cooper 变换变为

$$\frac{d\mathbf{Q}(x)}{d\mathbf{P}(x)} = \alpha, \text{ with } \alpha = \frac{1}{\int_{\Omega} \mathbb{1}_{\Xi}(x) d\mathbf{P}(x)}. \quad (5)$$

从某种意义上说，这个广义的 Charnes-Cooper 变换构成了测度的变换，从原始概率测度 $\mathbf{P}$ 变换到其条件测度 $\mathbf{Q}$ 。变量 α 是一个缩放参数，实质上反映了对随机事件的归一化。

经过变换 (5)，问题 (4) 化简为半无限线性规划 (LP)

$$\begin{aligned} \sup_{\alpha, \mathbf{Q}(x) \in \mathbb{R}_+} \quad & \int_{\Omega} g(x) \mathbb{1}_{\Xi}(x) d\mathbf{Q}(x) \\ \text{s.t.} \quad & \int_{\Omega} h_j(x) d\mathbf{Q}(x) = \alpha q_j, \quad \forall j = 0, \dots, m, \\ & \int_{\Omega} \mathbb{1}_{\Xi}(x) d\mathbf{Q}(x) = 1. \end{aligned} \quad (6)$$

其中约束 (6) 的所有右侧均被 α 缩放，最后一行确保 $\mathbf{Q}$ 在其支持集 Ξ 上是一个合适的（条件）分布。为了确定 (6) 的对偶问题，可以采用半无限线性规划对偶理论，参见 [?] 第 6 章。由标准计算可得，(6) 的拉格朗日对偶问题为

$$\begin{aligned} \inf_{\lambda_0, \dots, \lambda_{m+1}} \quad & \lambda_{m+1} \\ \text{s.t.} \quad & \sum_{j=0}^m \lambda_j q_j \leq 0, \\ & \sum_{j=0}^m \lambda_j h_j(x) + \lambda_{m+1} \mathbb{1}_{\Xi}(x) \geq g(x) \mathbb{1}_{\Xi}(x), \quad \forall x \in \Omega, \end{aligned} \quad (7)$$

其中对偶变量 $\lambda_0, \dots, \lambda_{m+1}$ 分别对应原问题 (6) 中的各个约束。此后，我们使用简写记号 $h_{m+1}(x) := \mathbb{1}_{\Xi}(x)$ 。注意对偶问题具有有限个决策变量，但约束个数无限。根据弱对偶性，从 (7) 的可行解可以得到 (6) 的上界。问题 (7) 的最优对偶解通过弱对偶性给出一个可行的上界，但该上界是否严格（即强对偶是否成立）仍是一个未解问题，我们将在下一小节中寻求答案。

2.3. 广义条件约束问题的强对偶性

本节的目的有两个：我们证明 (7) 与 (1) 是强对偶的，并将该结果扩展到可能包含结构性质（如对称性和单峰性）的更一般的凸概率测度集合 $\mathcal{P}_0$ ；同时，我们展示 (1) 可以简化为一个有限维问题，在该问题中对于一个参数化的分布族进行优化。

由于 (1) 的目标函数关于期望算子是非线性的，因此如何将广义矩问题的强对偶性充分条件传递到带条件期望的情形尚不明确。因此，为了证明我们的主要结果，我们使用问题 (4) 的另一种等价形式。该形式的等价性由以下引理给出，该引理强烈依赖于分数与参数非线性规划之间的关系 [??]。

LEMMA 1. 假设问题 (4) 具有有限的最优值。则问题 (4) 等价于

$$\begin{aligned} \inf_{\tau \in \mathbb{R}} \quad & \tau \\ \text{s.t.} \quad & \sup_{P \in \mathcal{P}} \mathbb{E}_P [g(X) \mathbb{1}_\Xi(X) - \tau \mathbb{1}_\Xi(X)] \leq 0. \end{aligned} \quad (8)$$

即，最优值 τ^* 与 (1) 的最优值一致，并且 (1) 和 (8) 中的上确界均由相同的极端分布 P^* 精确实现，或由一组相同的分布序列 $\{P_k^*\}_{k \geq 1}$ 渐进实现。

该结果与 [?] 中的命题 2.1 密切相关，后者以类似方式处理一类分数型的 DRO 问题。显然，(8) 比原始的半无限规划形式 (4) 更易处理，因为该问题关于 P 是线性的，而非非线性分数型的。这一点可以从 (8) 的约束中看出，其中期望 $\mathbb{E}_P[\cdot]$ 是线性出现的，而在 (3) 中，我们有期望算子的分数形式。根据矩问题的对偶理论，求解问题 (8) 等价于求解对偶问题 (7)。因此，由于 (4) 与 (8) 等价，求解 (4) 也等价于求解 (7)。下面我们将展示强对偶性成立。为此，我们做出以下假设：

(A1) 函数 $g(x)$ 在支撑集 Ω 上有界。

(A2) 存在一个正常数 $\epsilon > 0$ ，使得

$$\inf_{P \in \mathcal{P}} \mathbb{E}_P [\mathbb{1}_\Xi(X)] \geq \epsilon.$$

(A3) 斯莱特条件成立；即 $q \in \text{int}(\mathcal{Q}_{\mathcal{P}})$ ，其中 “int” 表示集合的内部。

假设 (A1) 是标准假设，并且可以放宽。例如，当 Ω 是紧集且 $g(x)$ 连续时，根据魏尔斯特拉斯极值定理，该假设成立。该假设用于保证 (4) 的最优值是有限的。假设 (A2) 为条件期望的良好定义提供了充分条件，避免了对零测度集合的条件化。假设 (A3) 构成了关于 X 的矩的 Slater 类型条件，这是广义矩问题中的标准假设；详见例如 [?] 中的命题 3.4。在这些正则条件下，我们证明了对于一般凸概率分布集合 $\mathcal{P}_0$ （可能具有结构性质，例如对称性和单峰性），强对偶性成立。我们将重点关注具备混合表示的结构模糊集合 $\mathcal{P}_0(\Omega)$ 。换言之，我们假设 $\mathcal{P}_0$ 可以由一个方便的分布类别 $\mathcal{T}$ “生成”，即每个 $P \in \mathcal{P}_0$ 都可以写成极端分布（即凸集合 $\mathcal{P}_0$ 的极点）族 $\mathcal{T}$ 的混合（即无穷凸组合）。对于任意 Borel 集合 $\mathcal{S} \in \mathcal{B}_\Omega$ ，应满足

$$P(X \in \mathcal{S}) = \int_{\mathcal{T}} \mathbb{T}_t(X \in \mathcal{S}) dM(t),$$

其中 $\mathbf{T}_t \in \mathcal{T} \subseteq \mathcal{P}_0$ 是极端分布族 $\mathcal{P}_0$ 的参数化表示, $\mathbf{M}$ 表示从极端分布族 $\mathcal{T}$ 生成 $\mathbf{P}$ 的混合分布。该极端分布族的有限维参数化在确定最优界时非常有用。关于 DRO 中这些结构模糊集合的详细讨论, 参见 [?] 的工作。我们在表述主要结果时采用带有结构性质的这类一般模糊集合。

最后, 在表述主要结果之前, 我们介绍一些广义矩问题锥对偶理论中的技术符号 (参见例如 [? ?])。设 $\mathcal{A} = \text{co}(\mathcal{P}_0)$ 为由概率分布集合 $\mathcal{P}_0$ 生成的测度锥 $\mathcal{A}$ 。定义其对偶锥为 $\mathcal{A}^* := \{h \in \mathcal{H} : \int_{\Omega} h(x) d\mathbf{P}(x) \geq 0, \forall \mathbf{P} \in \mathcal{A}\}$, 其中 $\mathcal{H}$ 是由 $g, h_0, \dots, h_m$ 组合形成的函数线性空间, 函数空间与测度空间通过积分算符配对。现已有必要的预备知识证明强 (锥) 对偶性。引理 1 结合假设 (A1)–(A3) 为我们表述主要结果奠定了基础。

THEOREM 1 (强锥对偶性). 假设条件 (A1)–(A3) 成立。则原问题 (1) 的最优值是有限的, 且等于其对偶问题

$$\begin{aligned} & \inf_{\lambda_0, \dots, \lambda_{m+1}} \lambda_{m+1} \\ \text{s.t.} \quad & \sum_{j=0}^m \lambda_j q_j \leq 0, \\ & \sum_{j=0}^{m+1} \lambda_j h_j(x) - g(x) \mathbb{1}_{\Xi}(x) \in \mathcal{A}^*, \end{aligned} \tag{9}$$

其中 $\mathcal{A}^*$ 是 $\mathcal{A}$ 的对偶锥。

Proof. 假设保证对所有 $\mathbf{P} \in \mathcal{P}$,

$$\begin{aligned} \left| \frac{\mathbb{E}_{\mathbf{P}}[g(X) \mathbb{1}_{\Xi}(X)]}{\mathbb{E}_{\mathbf{P}}[\mathbb{1}_{\Xi}(X)]} \right| & \leq \frac{1}{\epsilon} |\mathbb{E}_{\mathbf{P}}[g(X)]| \\ & \leq \sup_{\mathbf{P} \in \mathcal{P}} \frac{1}{\epsilon} |\mathbb{E}_{\mathbf{P}}[g(X)]| \\ & \leq \frac{1}{\epsilon} \sup_{x \in \Omega} |g(x)| < \infty. \end{aligned}$$

因此, 不妨将问题 (1) 等价地替换为 (8)。由于该问题的约束关于概率分布 $\mathbf{P}$ 是线性的, 标准的广义矩问题锥对偶理论即可适用, 而其成立条件为 Slater 类型条件, 如 [?] 中所定义。注意, 如果我们将 τ 替换为 λ_3 并将对偶问题纳入 (8) 的约束中, 则 (8) 等价于 (9)。当 $\mathcal{A} = \mathcal{M}_+$ 时, 强锥对偶问题 (9) 归约为半无限线性规划 (7)。一般测度锥的结果可由 [?] 中定理 3.1 的锥对偶论证得到。 $\square$

因此, 对偶性使我们能够将原始问题 (具有无限维变量) 化简为一个具有 $m+1$ 个变量但含无限约束的对偶问题。约束由概率测度索引, 即约束应对所有 $\mathbf{P} \in \mathcal{P}_0$ 均成立。该索引可能较为复杂, 但若改用生成集合 $\mathcal{T}$, 复杂性可大幅降低, 如 [?] 所示。在此情况下, 对偶锥可化简为 $\mathcal{A}^* = \{h \in \mathcal{H} : \int_{\Omega} h(x) d\mathbf{P}(x) \geq 0, \forall \mathbf{P} \in \mathcal{T}\}$, 因此约束只需对 $\mathcal{P}_0$ 的极点集合取值。

另一个经典结果表明, 模拟广义矩问题的半无限线性规划可化简为具有相同最优值的等价有限维问题。Richter-Rogosinski 定理 (参见例如 [? ? ?]) 指出半无限线性规划存在支持点数最多为 $m+1$ 的极端分布。类似于常规半无限线性规划的基解, 我们定义基分布为 $\mathcal{P}_0$ 的极端分布的凸组

合。由于存在 $m+1$ 个矩函数，这些基分布最多由 $m+1$ 个极端点（即 $\mathcal{T}$ 中的元素）组成。记 $\mathcal{D}(\mathbf{q})$ 为满足给定矩序列 $\mathbf{q}$ 的基分布集合。我们据此陈述以下结果，这是凸分布类基本定理的一个适配，但针对广义条件约束问题。

THEOREM 2 (条件期望的基本定理). 考虑问题 (1)。在假设 (A1)–(A3) 下，

$$\sup_{\mathbf{P} \in \mathcal{D}(\mathbf{q})} \mathbb{E}_{\mathbf{P}}[g(X)|X \in \Xi] = \sup_{\mathbf{P} \in \mathcal{D}(\mathbf{q})} \mathbb{E}_{\mathbf{P}}[g(X)|X \in \Xi].$$

此外，如果最优值被达到，则存在一个最优的基分布，它是生成集合 $\mathcal{T}$ 中 $m+1$ 个概率分布的凸组合，并且达到该值。

Proof. 同样地，在上述假设下，仅需考虑等价问题 (8)。由于 (8) 的约束在 $\mathbf{P}$ 上是线性的，标准广义矩问题结果可适用。因此，应用 [?] 中定理 6.1 即得所需结果。此结论由引理 1 支持，该引理表明 (1) 和 (8) 中的上确界由相同极端分布达到或由同一分布序列渐近达到。 $\square$

该定理表明，即使最优界未被实现，也只需考虑基可行分布集合 $\mathcal{D}(\mathbf{q})$ 即可确定上确界。该结果适用于一般凸分布类 $\mathcal{P}$ ，其最优分布可取为极端分布族 $\mathcal{T}$ 的凸组合。我们进一步指出，即使条件期望的上确界趋于无穷大时，这两个定理仍成立。在这种情况下，存在一个最大化序列的概率测度（也取自基分布集合），其条件期望发散。引理 1 的证明表明假设 (A2) 足以保证两种表述的等价性。假设 (A1) 主要保证最优值的有限性。若无 (A1)，原始问题可能无界，导致弱对偶性下对偶问题不可行。结合第 2.2 节描述的弱对偶概念以及定理 2 中提出的由 $\mathcal{T}$ 生成的基分布化简方法，为解决该问题 (1) 提供了一种有效途径，下一节将对此进行演示。

3. 条件期望的紧界

本节中，我们研究了若干关于 $n=1$ 的简单例子；即 X 是一个以自身为条件的随机变量。首先，在第 3.1 节中，我们在已知均值-离散度信息以及潜在分布的结构性质的情况下，寻求条件期望 $\mathbb{E}[X|X \geq t]$ 的最优界。我们通过对偶原理找到紧界。接着，在第 3.2 节中，我们以稳健定价文献中的一个例子展示该方法亦适用于任意选择的 $g(x)$ 。最后，第 3.3 节表明，在单变量情形下，可以通过求解半正定规划问题获得紧界。

3.1. 均值-离散度信息的简单示例

为了便于说明，我们集中讨论事件 $\Xi = \{X \geq t\}$ 。因此，我们寻求对条件期望进行界定

$$\mathbb{E}_{\mathbf{P}}[g(X)|X \geq t] = \frac{\int_{\Omega} g(x) \mathbb{1}_{\Xi}(x) d\mathbf{P}(x)}{\int_{\Omega} \mathbb{1}_{\Xi}(x) d\mathbf{P}(x)},$$

其中 $\mathbb{1}_{\Xi}(x)$ 是指示函数，用于表示事件 $\{X \geq t\}$ 的发生， $\mathbf{P}$ 是底层概率分布，我们假设其属于均值-方差不确定集 $\mathcal{P}_{(\mu, \sigma)}$ ，该集合包含所有符合已知均值-方差信息的分布。于是，感兴趣的问题可以表述为

$$\begin{aligned} & \sup_{\mathbf{P}(x) \geq 0} \frac{\int_{\Omega} g(x) \mathbb{1}_{\Xi}(x) d\mathbf{P}(x)}{\int_{\Omega} \mathbb{1}_{\Xi}(x) d\mathbf{P}(x)} \\ & \text{s.t.} \quad \int_{\Omega} d\mathbf{P}(x) = 1, \int_{\Omega} x d\mathbf{P}(x) = \mu, \int_{\Omega} x^2 d\mathbf{P}(x) = (\sigma^2 + \mu^2), \end{aligned} \tag{10}$$

这是一个半无限线性分数规划问题。通过第 2.1 节介绍的广义 Charnes-Cooper 变换，可以将 (10) 写成

$$\begin{aligned} & \sup_{\alpha, Q(x) \geq 0} \int_{\Omega} g(x) \mathbb{1}_{\Xi}(x) dQ(x) \\ \text{s.t.} \quad & \int_{\Omega} dQ(x) = \alpha, \int_{\Omega} x dQ(x) = \alpha\mu, \int_{\Omega} x^2 dQ(x) = \alpha(\sigma^2 + \mu^2), \int_{\Omega} \mathbb{1}_{\Xi}(x) dQ(x) = 1, \end{aligned} \quad (11)$$

其中 α 是决策变量，表示 X 超过 t 的“最坏情况”概率。(11) 的半无限线性规划对偶问题为

$$\begin{aligned} & \inf_{\lambda_0, \lambda_1, \lambda_2, \lambda_3} \lambda_3 \\ \text{s.t.} \quad & \lambda_0 + \lambda_1\mu + \lambda_2(\sigma^2 + \mu^2) \leq 0, \\ & \lambda_0 + \lambda_1x + \lambda_2x^2 + \lambda_3 \mathbb{1}_{\Xi}(x) \geq g(x) \mathbb{1}_{\Xi}(x), \quad \forall x \in \mathbb{R}, \end{aligned} \quad (12)$$

对于该随机事件 Ξ 的特定选择，结果为

$$\begin{aligned} & \inf_{\lambda_0, \lambda_1, \lambda_2, \lambda_3} \lambda_3 \\ \text{s.t.} \quad & \lambda_0 + \lambda_1\mu + \lambda_2(\sigma^2 + \mu^2) \leq 0, \\ & \lambda_0 + \lambda_1x + \lambda_2x^2 \geq 0, \quad \forall x < t, \\ & \lambda_0 + \lambda_1x + \lambda_2x^2 + \lambda_3 \geq g(x), \quad \forall x \geq t. \end{aligned}$$

考虑标准条件期望（即函数 $g : x \mapsto x$ ）。接下来我们尝试找到对偶问题的可行解，并通过找到目标值匹配的原问题解来证明最优性。设 $t < \mu$ ，则

$$\sup_{P \in \mathcal{P}(\mu, \sigma)} \mathbb{E}[X | X \geq t]$$

的对偶问题为

$$\begin{aligned} & \inf_{\lambda_0, \lambda_1, \lambda_2, \lambda_3} \lambda_3 \\ \text{s.t.} \quad & \lambda_0 + \lambda_1\mu + \lambda_2(\sigma^2 + \mu^2) \leq 0, \\ & \lambda_0 + \lambda_1x + \lambda_2x^2 \geq 0, \quad \forall x < t, \\ & \lambda_0 + \lambda_1x + \lambda_2x^2 \geq x - \lambda_3, \quad \forall x \geq t. \end{aligned} \quad (13)$$

将约束左端定义为 $M(x) := \lambda_0 + \lambda_1x + \lambda_2x^2$ 。当 $M(x)$ 在 $x < t$ 时满足 $M(x) \geq 0$ ，且在 $t \leq x \leq b$ 时满足 $M(x) \geq x - \lambda_3$ ，则该函数 $M(x)$ 是对偶可行的。

第一个对偶函数 $M_1(x)$ 不存在可行解。由于 $\sigma > 0$ ，从 $\lambda_0 + \lambda_1\mu + \lambda_2(\sigma^2 + \mu^2) \leq 0$ 可得 $M(\mu) = \lambda_0 + \lambda_1\mu + \lambda_2\mu^2 < 0$ ，但对于极小点 $x^* = -\lambda_1/(2\lambda_2)$ ，有 $M(x^*) \geq 0$ 。因此此情况不可行。

第二个抛物线 $M_2(x)$ 存在可行解。该函数在点 t 和某点 x_0 处与函数 $g(\cdot)$ 相切。由于 $M_2(t) = 0$ ， $M_2(x_0) = x_0 - \lambda_3$ 且 $M_2'(x_0) = 1$ ，

$$\lambda_0 = -\frac{t(\lambda_3(t - 2x_0) + x_0^2)}{(t - x_0)^2}, \lambda_1 = \frac{t^2 + x_0(x_0 - 2\lambda_3)}{(t - x_0)^2}, \lambda_2 = \frac{\lambda_3 - t}{(t - x_0)^2}. \quad (14)$$




Figure 1: $M_1(x)$ 和 $M_2(x)$

因此，我们得到一个两变量的优化问题，即 $\min_{x_0, \lambda_3} \lambda_3$ ，附加约束为 $\lambda_0 + \lambda_1 \mu + \lambda_2(\sigma^2 + \mu^2) \leq 0$ ，其中代入了 (14)。若该约束取等号，则对偶问题可简化为

$$\min_{\lambda_3, x_0} \lambda_3 \equiv \min_{x_0} \frac{(t^2 + x_0^2)\mu - t(x_0^2 + \mu^2 + \sigma^2)}{(t - \mu)(t - 2x_0 + \mu) - \sigma^2}.$$

对 x_0 优化，得到

$$x_0^* = \mu + \frac{\sigma^2}{\mu - t}, \quad \lambda_3^* = \mu + \frac{\sigma^2}{\mu - t},$$

其中 λ_3^* 是 $\mathbb{E}[X|X \geq t]$ 的一个可行上界。为证明该界是最优的，我们构造一个（渐近）达到 λ_3^* 的分布。由互补松弛性（参见如 [?]），推断候选分布的概率质量集中在两个点： t^- 和 x_0^* 。解 (10) 中的矩约束系统，得概率

$$p_{t^-} = \frac{\sigma^2}{\sigma^2 + (\mu - t)^2}, \quad p_{x_0^*} = \frac{(\mu - t)^2}{\sigma^2 + (\mu - t)^2}.$$

事实上，对于该二点分布，

$$\mathbb{E}[X|X \geq t] = \frac{x_0^* \cdot p_{x_0^*}}{\mathbb{P}(X \geq t)} = \frac{x_0^* \cdot p_{x_0^*}}{p_{x_0^*}} = x_0^* = \mu + \frac{\sigma^2}{\mu - t},$$

保证了上界的紧性。因此，依据弱对偶性，

$$\sup_{\mathbb{P} \in \mathcal{P}_{(\mu, \sigma)}} \mathbb{E}[X|X \geq t] = \mu + \frac{\sigma^2}{\mu - t}. \quad (15)$$

注意该界实际上并未被直接达到，但通过极限可以实现；即对于序列 $t_k = t - \frac{1}{k}$ ，当 $k \rightarrow \infty$ ，此极端分布构造确实给出期望结果。当 $t \geq \mu$ 时，可证明

$$\sup_{\mathbb{P} \in \mathcal{P}_{(\mu, \sigma)}} \mathbb{E}[X|X \geq t] = \infty,$$

因为可以构造如下（极大化）测度序列：

$$\mathbb{P}_k = \frac{1}{k^2\sigma^2 + 1} \delta_{\mu+k\sigma^2} + \frac{\sigma^2}{\sigma^2 + \frac{1}{k^2}} \delta_{\mu-\frac{1}{k}}.$$

令 $k \rightarrow \infty$ 则得到 $\mathbb{E}_{\mathbb{P}_k}[X|X \geq t] \rightarrow \infty$ 。综上，得到如下结果。

PROPOSITION 1. 对于一个实值随机变量 X ，其分布为 $\mathbb{P} \in \mathcal{P}_{(\mu, \sigma)}$ ，有

$$\sup_{\mathbb{P} \in \mathcal{P}_{(\mu, \sigma)}} \mathbb{E}_{\mathbb{P}}[X|X \geq t] = \begin{cases} \mu + \frac{\sigma^2}{\mu-t}, & \text{当 } t < \mu \text{ 时,} \\ \infty, & \text{当 } t \geq \mu \text{ 时.} \end{cases} \quad (16)$$

该结果中可以得出若干有趣的观察。首先，注意第二种情况下的极大化序列 $\{\mathbb{P}_k\}$ 在弱收敛意义下收敛于 δ_μ ，而 δ_μ 不包括在不确定集中。还要注意第二种情况的解在 $t \geq \mu$ 时变得“无信息”，即发散。这种退化行为在不同的不确定集中也存在，后续示例中将展示。该结果确认了 [?] 中提出的基于均值-方差信息的条件期望 Mallows 和 Richter 界的紧性。此外，注意实现上界的极端分布与产生尾概率 Cantelli 下界的极端分布相匹配，这一点也在 [?] 中得到展示。后者作者通过构造实现 Cantelli 界的极端分布，证明了紧性。尽管命题 1 是已知结果，但这是首次通过对偶论证证明，且该方法可直接揭示极端分布的结构。

上述方法可应用于不同类型的离散度信息，不仅限于传统方差。例如，假设我们不考虑方差，而是考虑均值绝对偏差（MAD），即 $d := \mathbb{E}|X - \mu|$ ，作为离散度量。设 $\mathcal{P}_{(\mu, d)}$ 表示均值-MAD不确定集，且附加约束为 X 的支持是区间 $[a, b]$ 的（子集）。我们可以证明如下结果。

PROPOSITION 2. 对于实值随机变量 X ，其分布为 $\mathbb{P} \in \mathcal{P}_{(\mu, d)}$ ，有

$$\sup_{\mathbb{P} \in \mathcal{P}_{(\mu, d)}} \mathbb{E}_{\mathbb{P}}[X|X \geq t] = \begin{cases} \mu + \frac{d(\mu-t)}{2(\mu-t)-d}, & \text{当 } t < \mu - \frac{d(b-\mu)}{2(b-\mu)-d} \text{ 时,} \\ b, & \text{当 } t \geq \mu - \frac{d(b-\mu)}{2(b-\mu)-d} \text{ 时.} \end{cases} \quad (17)$$

同样，第二种情况变得无信息，因为它简化为鲁棒解（即与支持的上界一致）。此处值得注意的是不确定集的大小与描述随机事件/辅助信息的集合之间的相互作用。尽管可选分布数量有限，但若随机变量的取值限制在过小区间内，界变得过于保守，因为可以构造极端分布使矩约束满足，但支持点在 Ξ 上可以任意大，当然受支持集上界限制。对于均值-MAD不确定集，极端分布也与实现对应尾概率下界的分布一致 [?]。

命题 2 可以进一步推广。假设离散度信息通过随机变量 X 的凸函数 $d(\cdot)$ 的期望表示，定义为 $\bar{\sigma} := \mathbb{E}[d(X)]$ 。我们可以对这类任意凸离散度量陈述以下结果。

PROPOSITION 3. 假设存在一个解 $x_0^* \in (t, \infty)$ 满足以下方程

$$\frac{\bar{\sigma}t - \mu d(t)}{td(x_0) - x_0 d(t)} + \frac{\mu d(x_0) - \bar{\sigma}x_0}{td(x_0) - x_0 d(t)} = 1,$$

且对应的以 $\{t, x_0^*\}$ 为支撑点的两点分布是可行的。那么，对于分布为 $\mathbb{P} \in \mathcal{P}_{(\mu, \bar{\sigma})}$ 的实值随机变量 X ，有

$$\sup_{\mathbb{P} \in \mathcal{P}_{(\mu, \bar{\sigma})}} \mathbb{E}_{\mathbb{P}}[X|X \geq t] = x_0^*. \quad (18)$$

命题 3 涵盖了广泛的离散度量，不仅限于方差和 MAD，还包括非对称的离散度量，如半方差、半均差以及部分矩。更一般地，它涵盖了所有用分段凸函数建模的离散度量。由于实数域上的 p -范数是凸的，因此它们自然包含在凸离散度量类别中。另一个值得注意的函数是 Huber 损失函数，该函数在鲁棒统计领域有广泛研究。

如前所述，仅使用矩信息往往导致过于保守的界和病态的最坏情况分布。为了使界更紧且避免前述示例中的两点病态分布，需要关于分布形状的额外假设。接下来我们研究两种此类结构性质，即对称性和单峰性。若随机变量 X 关于点 m 具有对称分布，意味着对任意 $x \geq 0$ ，有 $\mathbb{P}(X \in [m-x, m]) = \mathbb{P}(X \in [m, m+x])$ 。若 X 具有单峰分布且峰值为 m ，则其分布函数在 $(-\infty, m]$ 上是凹函数，在 (m, ∞) 上是凸函数。两种定义均推广至允许存在 m 处点质量的概率分布。接下来考虑一个关于其均值 μ 对称的分布，已知均值和方差。利用原-对偶论证，得到如下结果。

PROPOSITION 4. 对于具有对称分布 $\mathbb{P} \in \mathcal{P}_{(\mu, \sigma)}^{\text{sym}}$ 的实值随机变量 X ，成立以下关系：

$$\sup_{\mathbb{P} \in \mathcal{P}_{(\mu, \sigma)}^{\text{sym}}} \mathbb{E}_{\mathbb{P}}[X | X \geq t] = \begin{cases} \mu + \frac{(\mu-t)\sigma^2}{2(t-\mu)^2 - \sigma^2}, & \text{当 } t < \mu - \sigma \text{ 时,} \\ \mu + \sigma, & \text{当 } \mu - \sigma \leq t < \mu \text{ 时,} \\ \infty, & \text{当 } t \geq \mu \text{ 时.} \end{cases} \quad (19)$$

注意这些界比命题 1 中的界更紧，但在 $t \geq \mu$ 时仍然无效。结合对称性和单峰性的概念，得到以下更紧的界：

PROPOSITION 5. 对于具有对称单峰分布 $\mathbb{P} \in \mathcal{P}_{(\mu, \sigma)}^{\text{uni}}$ 的实值随机变量 X ，有

$$\sup_{\mathbb{P} \in \mathcal{P}_{(\mu, \sigma)}^{\text{uni}}} \mathbb{E}_{\mathbb{P}}[X | X \geq t] = \begin{cases} \frac{4\mu(x_0^*)^3 - 3\sigma^2(t+x_0^*-\mu)(t-x_0^*+\mu)}{4(x_0^*)^3 - 6\sigma^2(t+x_0^*-\mu)}, & \text{当 } t < \mu - \frac{\sqrt{3}(2\sqrt{2}+1)}{7}\sigma, \\ \frac{1}{2}(\mu + t + \sqrt{3}\sigma), & \text{当 } \mu - \frac{\sqrt{3}(2\sqrt{2}+1)}{7}\sigma < t < \mu, \\ \infty, & \text{当 } t \geq \mu, \end{cases} \quad (20)$$

其中 x_0^* 是满足四次方程

$$6\sigma^2 x_0^2 (3(t-\mu)^2 - x_0^2) + 9\sigma^4 (\mu - t - x_0)^2 = 0,$$

且满足条件 $x_0^* \geq \sqrt{3}\sigma$ 的实数解。

虽然命题 5 未给出闭式解，但展示了用于推导该命题的原-对偶论证的灵活性。进一步表明结构性质可与矩信息结合处理，即使在条件边界问题中亦然。

3.2. 一个稳健定价示例

为了展示针对替代目标函数 $g(x)$ 的原始-对偶方法，我们接下来关注一个具体的极小极大问题。我们考虑稳健垄断定价问题的目标函数；参见例如 [??]。该问题涉及评估收益函数

$$\Pi(z) := \mathbb{E}[p \mathbb{1}_{\{X \geq p\}}] = p\mathbb{P}(X \geq p),$$

该函数模拟了当卖家设定的单件商品售价为 p 时，客户价值分布为 X ，卖家期望获得的收益。与 [?] 中的方法类似，我们试图通过发布极小极大销售价格 p^* 来最小化最大相对后悔值；即我们求解

$$\min_p \max_{P \in \mathcal{P}} \frac{\max_z E_P[\Pi(z)]}{E_P[\Pi(p)]}.$$

这里使用“min”和“max”操作符仅为避免符号繁杂，并不意味着最优值一定被取到。[?] 对稳健垄断定价问题给出了多种结果，也考虑了该相对后悔准则。在 [?] 中考虑了几乎相同的目标函数，即

$$\min_p \max_P \left\{ 1 - \frac{E_P[\Pi(p)]}{\max_z E_P[\Pi(z)]} \right\} = 1 - \max_p \min_P \frac{E_P[\Pi(p)]}{\max_z E_P[\Pi(z)]}.$$

然而，我们使用了其倒数形式

$$\min_p \max_P \frac{\max_z E_P[\Pi(z)]}{E_P[\Pi(p)]} = \min_p \max_P \max_z \frac{E_P[\Pi(z)]}{E_P[\Pi(p)]} = \min_p \max_z \max_P \frac{E_P[\Pi(z)]}{E_P[\Pi(p)]},$$

其中通过交换最大化操作符得到了最后的等式。与 [?] 中定理4的证明类似，关键在于求解半无限优化问题

$$\max_{P \in \mathcal{P}(\mu, \sigma)} \frac{E_P[z \mathbb{1}\{X \geq z\}]}{p P(X \geq p)}. \quad (21)$$

注意，该问题实际上模拟了条件期望 $E[\frac{z \mathbb{1}\{X \geq z\}}{p \mathbb{1}\{X \geq p\}} | X \in \Xi]$ ，其中随机事件为 $\Xi = \{X \geq p\}$ 。由于 [?] 直接尝试优化对偶问题，其证明需要多步冗长繁琐的论证以获得紧致界。我们将采用与前小节类似的原始-对偶论证简化其证明。我们假设 $p < \mu$ ，否则可以构造极端分布使得相对后悔比率发散；参见 [?]。对于 $z < p$ ，分子中的期望值将计算为 1。因此，

$$\max_{P \in \mathcal{P}(\mu, \sigma)} \frac{E_P[\frac{z}{p} \mathbb{1}\{X \geq z\}]}{P(X \geq p)} \leq \frac{z}{p} \max_{P \in \mathcal{P}(\mu, \sigma)} \frac{1}{P(X \geq p)} = \frac{z}{p} \frac{1}{\min_{P \in \mathcal{P}(\mu, \sigma)} P(X \geq p)}.$$

为了界定后者，我们可以使用切比雪夫不等式的一侧版本（通常称为 Cantelli 不等式）。由此得到

$$\max_{P \in \mathcal{P}(\mu, \sigma)} \frac{E_P[\frac{z}{p} \mathbb{1}\{X \geq z\}]}{P(X \geq p)} = \frac{z}{p} \frac{\sigma^2 + (\mu - p)^2}{(\mu - p)^2}.$$

因此，

$$\max_{z \leq p} \max_P \frac{E_P[\frac{z}{p} \mathbb{1}\{X \geq z\}]}{p P(X \geq p)} = \frac{\sigma^2 + (\mu - p)^2}{(\mu - p)^2}.$$

对于 $z \geq p$ ，有

$$\frac{E_P[\frac{z}{p} \mathbb{1}\{X \geq z\}]}{P(X \geq p)} = \frac{z}{p} \frac{P(X \geq z)}{P(X \geq p)} = \frac{z}{p} \frac{P(X \geq z \cap X \geq p)}{P(X \geq p)} = \frac{z}{p} P(X \geq z | X \geq p),$$

因此，我们需要对条件概率进行界定。利用原始-对偶论证，我们得到以下结果。

PROPOSITION 6. 假设 $z \geq p$ 且 $p < \mu$ 。对于服从分布 $P \in \mathcal{P}_{(\mu, \sigma)}$ 的非负随机变量 X , 有

$$\sup_{P \in \mathcal{P}_{(\mu, \sigma)}} P(X \geq z | X \geq p) = \begin{cases} \frac{\sigma^2}{(z-\mu)^2 + \sigma^2}, & \text{当 } z \geq \mu + \frac{2\sigma^2(\mu-p)}{(\mu-p)^2 + \sigma^2}, \\ \left(\frac{(\mu-p)^2 + \sigma^2}{\sigma^2 + \mu^2 - p^2 + 2z(\mu-p)} \right)^2, & \text{当 } \frac{\sigma^2 + \mu^2 - p\mu}{\mu-p} \leq z \leq \mu + \frac{2\sigma^2(\mu-p)}{(\mu-p)^2 + \sigma^2}, \\ 1, & \text{否则。} \end{cases} \quad (22)$$

利用这些界, 可以证明

$$\max_{z \geq p} \sup_P \frac{E_P[\pi(z, X)]}{pP(X \geq p)} = \frac{\sigma^2 + \mu(\mu-p)}{p(\mu-p)}.$$

因此, 结合上述结果, 最优价格应满足

$$\min_{p < \mu} \max \left\{ \frac{\sigma^2}{p(\mu-p)} + \frac{\mu}{p}, \frac{\sigma^2}{(\mu-p)^2} + 1 \right\}.$$

[?] 证明了最优价格即为使得最大算子两分支相等的 p 的取值。注意, 通过使用原始-对偶论证, 我们大大减少了获得期望结果所需的计算量。与 [?] 相反, 我们同时处理原始和对偶问题, 以更有效地验证建议解的最优性。毋庸置疑, 本节提出的对偶方法很可能也适用于其他分数目标的定价问题, 例如 [?] 中的个性化定价设置。

3.3. 数值界限

接下来我们展示如何将强对偶问题 (7) 在单变量情形下简化为半正定规划问题。因此, 可以始终通过求解一个 (计算上可行的) 优化问题数值地获得紧确界。数值实验在 Julia 编程语言中进行, 使用 MOSEK 求解器 [?], 以及 Julia 包 SumOfSquares.jl 和 PolyJuMP.jl [?]。

假设目标函数 $g(x)$ 是分段多项式, 且矩约束由传统的幂矩描述。然后, 通过应用例如 [???] 中讨论的标准 DRO 技术, 对偶问题可以进一步简化为半正定规划问题。特别地, 单变量矩问题简化为求解半正定规划, 前提是对偶可行集是半代数的; 即对偶约束涉及检查某些多项式函数在由事件集 Ξ 和支撑集 Ω 描述的区间上是否非负。众所周知, 单变量多项式非负当且仅当其为平方和。经典结果表明, 对偶可行集中的半无限约束 (7), 其中支撑集 Ω 是可能的无限区间, 可简化为一组多项式大小关于矩数 m 的线性矩阵不等式 (LMI) (参见例如 [???])。由于 $g(x)$ 是分段多项式, (7) 中对偶约束的支撑集可以细分为子区间, 使得这些约束可以简化为一组 LMI。如果这些矩由对偶问题中的分段多项式描述, 则可以包含广义矩信息。分段多项式目标函数的例子包括指标函数 $g(x) = \mathbb{1}_{[c, \infty)}(x)$ 和止损函数 $g(x) = \max\{x - c, 0\}$ 。这两个函数在例如金融、保险和库存控制等领域有多种相关应用。

图 2 给出了条件概率 $P(X \geq c | X \geq t)$ 的数值界限, 该条件概率对应分段函数 $g(x) = \mathbb{1}_{[c, \infty)}(x)$ 。我们假设真实分布为支撑在 $[0, 5]$ 上的均匀分布。我们确定了三种不确定集的界限, 其中可用的矩数分别为 $m = 2, 4$ 和 6 。显然, 当包含更多矩信息时, 界限变得更紧, 但此外, 由于不确定集的大小减小, 无信息解的显著性也降低。然而, 正如第 3.1 节已指出, 随着事件集 Ξ 大小的减小, 无信息解又变得更加明显。




Figure 2: 匹配区间 $[0, 5]$ 上均匀分布的歧义集条件尾部概率的紧界

即使不确定集加入了结构属性，得到的对偶问题仍然可以简化为半正定优化问题。考虑 $\mathcal{P}_0$ 仅




Figure 3: 匹配标准正态分布矩和性质的歧义集条件期望的紧界

包含对称分布的情形。利用由对称对的狄拉克测度生成的生成器类别，对偶问题 (9) 简化为

$$\begin{aligned}
 & \inf \quad \lambda_3 \\
 & \text{s.t.} \quad \sum_{j=0}^m \lambda_j q_j \leq 0, \quad 16 \\
 & \quad \sum_{j=0}^{m+1} \lambda_j (h_j(\mu - x) + h_j(\mu + x)) \geq \\
 & \quad g(\mu - x) \mathbb{1}_{\Xi}(\mu - x) + g(\mu + x) \mathbb{1}_{\Xi}(\mu + x), \quad \forall x \geq 0.
 \end{aligned} \tag{23}$$

同样地，如果考虑对称单峰分布（可由狄拉克测度 δ_μ 与矩形/均匀分布的凸组合生成，即 $\delta_{[\mu-z, \mu+z]}$, $z > 0$ ），则对偶问题变为

$$\begin{aligned}
& \inf \quad \lambda_3 \\
& \text{s.t.} \quad \sum_{j=0}^m \lambda_j q_j \leq 0, \\
& \quad \sum_{j=0}^{m+1} \lambda_j \int_{\mu-x}^{\mu+x} h_j(z) dz \geq \int_{\mu-x}^{\mu+x} g(z) \mathbb{1}_\Xi(z) dz, \forall x \geq 0, \\
& \quad \sum_{j=0}^{m+1} \lambda_j h_j(\mu) \geq g(\mu) \mathbb{1}_\Xi(\mu).
\end{aligned} \tag{24}$$

注意，得到的积分变换在 x 上仍然是分段多项式。因此，我们可以将 (23) 和 (24) 重构为半正定规划问题。

图 3 展示了不同结构假设下的结果。注意，结构信息的加入显著地收紧了界限，与可用矩信息无关。然而，即使界限因额外信息而收紧，当仅有均值-方差信息时，对于 $t \geq \mu$ ，界限仍存在发散现象。不过，从图中明显看出，通过添加更多的矩信息，这种界限上的保守性可以显著缓解。

4. 带有辅助信息的分布鲁棒优化

本节中，我们为基于广义矩的上下文分布鲁棒随机优化框架奠定基础。第 4.1 节介绍了基于矩的上下文分布鲁棒优化以及一类能导致可解问题的模糊集。在第 4.2 节中，我们给出了这些模糊集的示例，并推导出计算上可行的锥优化问题。最后，在第 4.3 节，我们展示了一个二维示例的部分数值结果。

4.1. 基于均值-离散度信息的条件DRO

给定以事件 $\mathbf{X} \in \Xi$ 形式存在的侧信息，条件DRO问题可以一般性地表述为

$$\inf_{\nu \in \mathcal{V}} \sup_{\mathbf{P} \in \mathcal{P}} \mathbb{E}_{\mathbf{P}}[f(\nu, \mathbf{X}) | \mathbf{X} \in \Xi], \tag{25}$$

其中 f 是待最小化的某个代价函数， $\nu \in \mathcal{V}$ 表示决策向量，且 $\mathcal{V} \subseteq \mathbb{R}^p$ 为闭合凸集。概率分布 $\mathbf{P}$ 是控制 $\mathbf{X}$ 的联合测度。令 $\mathbf{Y} \in \mathcal{Y} \subseteq \mathbb{R}^{n_y}$ 为建模直接影响决策问题的结果变量的随机向量， $\mathbf{Z} \in \mathcal{Z} \subseteq \mathbb{R}^{n_z}$ 为影响结果随机变量的协变量（或特征）。假设 $\mathbf{Y}$ 和 $\mathbf{Z}$ 的支持集相互独立，令 $\mathbf{X} = (\mathbf{Y}, \mathbf{Z}) \in \mathcal{Y} \times \mathcal{Z} =: \mathcal{X}$ 。此后，加粗小写字母表示随机向量的具体实现值。

此外，期望值 $\inf_{\nu} \sup_{\mathbf{P} \in \mathcal{P}} \mathbb{E}_{\mathbf{P}}[f(\nu, \mathbf{X}) | \mathbf{X} \in \Xi]$ 主要基于由协变量 $\mathbf{Z}$ 给出的信息进行条件化，其中 $\Xi_{\mathbf{Z}} \subseteq \mathcal{Z}$ 是由协变量 $\mathbf{Z}$ 信息构成的信息集。因此，侧信息被描述为 $\Xi := \{\mathbf{x} = (\mathbf{y}, \mathbf{z}) \in \mathcal{X} : \mathbf{z} \in \Xi_{\mathbf{Z}}\}$ 。这也包括 $\Xi_{\mathbf{Z}}$ 为单点集的情况，表示协变量的特定实现值。通常情况下，结果变量上不包含条件信息。因此，在本节余下部分，我们偶尔使用符号 $\mathbb{E}[f(\nu, \mathbf{X}) | \mathbf{Z} \in \Xi_{\mathbf{Z}}]$ 来表示给定侧信息的条件期望。

接下来我们介绍本节所用的一些额外技术符号。加粗小写字母表示向量，斜体字符 x_k 表示向量 $\mathbf{x}$ 的第 k 个元素， $\mathbf{x}^\top$ 表示其转置。除上述随机向量外，所有加粗大写字母均表示矩阵。对于

集合 $\mathcal{S}$, 令 $\text{conv}(\mathcal{S})$ 、 $\text{cl}(\mathcal{S})$ 和 $\text{int}(\mathcal{S})$ 分别表示其凸包、闭包和内部。对于适当锥 $\mathcal{K} \in \mathbb{R}^n$ (即 闭合、凸且尖锥, 且内部非空), 一般不等式 $\mathbf{x} \preceq_{\mathcal{K}} \mathbf{u}$ 等价于集合约束 $\mathbf{u} - \mathbf{x} \in \mathcal{K}$, 而严格变体 $\mathbf{x} \prec_{\mathcal{K}} \mathbf{u}$ 表示 $\mathbf{u} - \mathbf{x} \in \text{int}(\mathcal{K})$ 。函数 $\mathbf{h} : \mathbb{R}^n \mapsto \mathbb{R}^m$ 称为 $\mathcal{K}$ -凸, 如果对所有 $\mathbf{x}_1, \mathbf{x}_2$ 及 $\theta \in [0, 1]$, 都有 $\mathbf{h}(\theta\mathbf{x}_1 + (1 - \theta)\mathbf{x}_2) \preceq_{\mathcal{K}} \theta\mathbf{h}(\mathbf{x}_1) + (1 - \theta)\mathbf{h}(\mathbf{x}_2)$ 。我们用 $\mathcal{K}^*$ 表示锥 $\mathcal{K}$ 的对偶锥, 定义为 $\mathcal{K}^* = \{\mathbf{u} : \mathbf{u}^\top \mathbf{x} \geq 0, \forall \mathbf{x} \in \mathcal{K}\}$, 其中 $\mathbf{u}^\top \mathbf{x}$ 表示适当的内积。集合 $\mathbf{S}_+^n$ 表示 $\mathbb{R}^{n \times n}$ 中对称正半定矩阵的锥。最后, 对于矩阵 $\mathbf{A}, \mathbf{B}$, 我们用 $\mathbf{A} \preceq \mathbf{B}$ 简写表示 $\mathbf{A} \preceq_{\mathbf{S}_+^n} \mathbf{B}$ 。

为了推导 (28) 的可解重构, 我们将施加以下条件:

(C1) 辅助信息 Ξ 是一个闭合的凸集, 且满足 $\inf_{\mathbf{P} \in \mathcal{D}} \mathbb{P}(X \in \Xi) > 0$, 支持集为 $\mathcal{X} = \mathbb{R}^n$ 。

(C2) 离散度通过 $(\mathcal{D})$ -凸上图函数建模 (参见 [??])。

(C3) 函数 $f(\boldsymbol{\nu}, \mathbf{x})$ 可以表示为

$$f(\boldsymbol{\nu}, \mathbf{x}) = \max_{l \in \mathcal{L}} \{f_l(\boldsymbol{\nu}, \mathbf{x})\},$$

其中 $\mathcal{L}$ 是索引集合, 辅助函数 f_l 的形式为

$$f_l(\boldsymbol{\nu}, \mathbf{x}) = \mathbf{s}_l(\boldsymbol{\nu})^\top \mathbf{x} + t_l(\boldsymbol{\nu})$$

对所有 $l \in \mathcal{L}$, $\mathbf{s}_l(\cdot) \in \mathbb{R}^n$ 和 $t_l(\cdot) \in \mathbb{R}$ 是 $\boldsymbol{\nu}$ 的仿射函数。

(C4) 歧义集 $\mathcal{P}$ 满足 Slater 条件。

条件 (C1) 第一部分的理由有两点: (i) 它使得可以使用鲁棒优化方法对模型进行重构; (ii) 它保证了侧事件的测度不为零。条件第二部分 (封闭性和凸性) 并非必须, 仅用于便于本节的数学论述。

第二个条件说明离散度函数具有可通过凸锥描述的上图(epigraph)。我们用 $\mathbf{d} : \mathbb{R}^n \mapsto \mathbb{R}^m$ 表示离散度函数, 假设其具有可锥表示的 $\mathcal{D}$ -上图, 其中 $\mathcal{D} \subseteq \mathbb{R}^m$ 是适当锥, 这意味着集合 $\{(\mathbf{x}, \mathbf{u}) \in \mathbb{R}^n \times \mathbb{R}^m : \mathbf{d}(\mathbf{x}) \preceq_{\mathcal{D}} \mathbf{u}\}$ 可以用锥不等式描述, 可能使用除 $\mathcal{D}$ 外的其他锥及辅助变量。详见 [?] 关于锥表示的综合介绍。均值-离散度模糊集现在定义为

$$\mathcal{P}_{(\boldsymbol{\mu}, \boldsymbol{\sigma})} = \{\mathbf{P} \in \mathcal{P}_0(\mathcal{X}) : \mathbb{E}_{\mathbf{P}}[\mathbf{X}] = \boldsymbol{\mu}, \mathbb{E}_{\mathbf{P}}[\mathbf{d}(\mathbf{X})] \preceq_{\mathcal{D}} \boldsymbol{\sigma}\}, \quad (26)$$

其中 $\mathcal{P}_0$ 是支持集为 $\mathcal{X}$ 的概率分布集合, 向量 $\boldsymbol{\mu} \in \mathbb{R}^n$ 表示随机向量 $\mathbf{X}$ 的均值, $\boldsymbol{\sigma} \in \mathbb{R}^m$ 是离散度测度期望值 $\mathbb{E}[\mathbf{d}(\mathbf{X})]$ 的上界。虽然均值-离散度模糊集 $\mathcal{P}_{(\boldsymbol{\mu}, \mathbf{d})}$ 看似简单, 但通过选取合适的离散度函数 $\mathbf{d}(\cdot)$, 可以恢复许多实际相关的模糊集。例如, 取 $\mathbf{d} = \mathbf{0}$ 可得均值-支持集模糊集; 而取 $\mathbf{d}(\mathbf{X}) = (\mathbf{X} - \boldsymbol{\mu})(\mathbf{X} - \boldsymbol{\mu})^\top$ 可模拟随机向量 $\mathbf{X}$ 元素间的相关结构。其他 $(\mathcal{D})$ -凸离散度测度包括 Huber 损失函数、平均绝对偏差、 $\mathbb{R}^n$ 上的任意范数 $\|\cdot\|$ 以及适用于命题 3 的其它凸离散度测度。我们将在下一小节详细阐述部分离散度测度。

第三个条件指出, 对所有 $\boldsymbol{\nu} \in \mathcal{V}$, 目标函数 f 是关于不确定性 $\mathbf{x}$ 的凸分段仿射函数; 对所有 $\mathbf{x} \in \mathcal{X}$, f 关于决策向量 $\boldsymbol{\nu}$ 也是凸的。我们将重点关注分段仿射目标函数, 因为它们足以捕捉多个

有趣模型。例如，它们可捕捉新闻贩卖者模型中的最大运算符，以及常用于风险规避投资者金融组合优化的条件风险价值 (Conditional-Value-at-Risk)。该目标函数要求并非严格必要，可放宽为对所有 $\mathbf{x}$ 在 $\boldsymbol{\nu}$ 上凸，对所有可行 $\boldsymbol{\nu}$ 在 $\mathbf{x}$ 上凹的更丰富函数类 $f(\cdot, \cdot)$ 。关于计算可行性的详细讨论，请参见 [?]。

多元情况下 (25) 内层最大化问题的对偶问题为

$$\begin{aligned} & \inf_{\lambda_0, \boldsymbol{\lambda}_1, \boldsymbol{\lambda}_2, \lambda_3} \lambda_3 \\ \text{s.t.} \quad & \lambda_0 + \boldsymbol{\lambda}_1^\top \boldsymbol{\mu} + \boldsymbol{\lambda}_2^\top \boldsymbol{\sigma} \leq 0, \\ & \lambda_0 + \boldsymbol{\lambda}_1^\top \mathbf{x} + \boldsymbol{\lambda}_2^\top \mathbf{d}(\mathbf{x}) \geq (f(\boldsymbol{\nu}, \mathbf{x}) - \lambda_3) \mathbb{1}_{\Xi}(\mathbf{x}), \quad \forall \mathbf{x} \in \mathcal{X}, \end{aligned} \quad (27)$$

其中 $\lambda_0, \lambda_3 \in \mathbb{R}$, $\boldsymbol{\lambda}_1 \in \mathbb{R}^n$, $\boldsymbol{\lambda}_2 \in \mathcal{D}^*$ 。我们假设条件 (C4) 成立，使得 $\sup_{\mathbf{P} \in \mathcal{P}} \mathbb{E}_{\mathbf{P}}[f(\boldsymbol{\nu}, \mathbf{X}) | \mathbf{X} \in \Xi]$ 与 (27) 强对偶。具体而言，Slater 条件为 $\boldsymbol{\mu} \in \text{int}(\mathcal{X})$ 和 $\mathbf{d}(\boldsymbol{\mu}) \prec_{\mathcal{D}} \boldsymbol{\sigma}$ 。(27) 中的半无限约束可用标准鲁棒优化方法修正。由此得到以下结论。

THEOREM 3 (带均值-离散度信息的条件DRO). 设 $\mathbf{P}$ 是均值-离散度不确定集合 $\mathcal{P}_{(\boldsymbol{\mu}, \boldsymbol{\sigma})}$ 的成员。如果条件 (C1)–(C4) 成立，则条件DRO问题 (25) 的目标值与半无限线性规划的最优值一致

$$\begin{aligned} & \inf_{\boldsymbol{\nu}, \lambda_0, \boldsymbol{\lambda}_1, \boldsymbol{\lambda}_2, \lambda_3} \lambda_3 \\ \text{s.t.} \quad & \lambda_0 + \boldsymbol{\lambda}_1^\top \boldsymbol{\mu} + \boldsymbol{\lambda}_2^\top \boldsymbol{\sigma} \leq 0, \\ & \lambda_0 + \boldsymbol{\lambda}_1^\top \mathbf{x} + \boldsymbol{\lambda}_2^\top \mathbf{u} \geq 0, \quad \forall (\mathbf{x}, \mathbf{u}) \in \overline{\mathcal{C}}, \\ & \lambda_0 + \boldsymbol{\lambda}_1^\top \mathbf{x} + \boldsymbol{\lambda}_2^\top \mathbf{u} + \lambda_3 \geq \mathbf{s}_l(\boldsymbol{\nu})^\top \mathbf{x} + t_l(\boldsymbol{\nu}), \quad \forall (\mathbf{x}, \mathbf{u}) \in \mathcal{C}, \forall l \in \mathcal{L}, \\ & \boldsymbol{\nu} \in \mathcal{V}, \lambda_0 \in \mathbb{R}, \boldsymbol{\lambda}_1 \in \mathbb{R}^n, \boldsymbol{\lambda}_2 \in \mathcal{D}^*, \lambda_3 \in \mathbb{R}. \end{aligned} \quad (28)$$

其中，

$$\begin{aligned} \mathcal{C} &:= \{(\mathbf{x}, \mathbf{u}) \in \mathbb{R}^n \times \mathbb{R}^m : \mathbf{x} \in \Xi, \mathbf{d}(\mathbf{x}) \preceq_{\mathcal{D}} \mathbf{u}\}, \\ \overline{\mathcal{C}} &:= \text{conv}(\{(\mathbf{x}, \mathbf{u}) \in \mathbb{R}^n \times \mathbb{R}^m : \mathbf{x} \in \Xi, \mathbf{d}(\mathbf{x}) = \mathbf{u}\}), \end{aligned} \quad (29)$$

其中 $\Xi := \text{cl}(\mathbb{R}^n \setminus \Xi)$ 。此外，在额外的正则性条件下，问题 (28) 可重构为有限维锥优化问题。

Proof. 内层最大化问题的对偶问题为

$$\begin{aligned} & \inf_{\lambda_0, \boldsymbol{\lambda}_1, \boldsymbol{\lambda}_2, \lambda_3} \lambda_3 \\ \text{subject to} \quad & \lambda_0 + \boldsymbol{\lambda}_1^\top \boldsymbol{\mu} + \boldsymbol{\lambda}_2^\top \boldsymbol{\sigma} \leq 0, \\ & \lambda_0 + \boldsymbol{\lambda}_1^\top \mathbf{x} + \boldsymbol{\lambda}_2^\top \mathbf{d}(\mathbf{x}) \geq \mathbb{1}_{\Xi}(\mathbf{x})(f(\boldsymbol{\nu}, \mathbf{x}) - \lambda_3), \quad \forall \mathbf{x} \in \mathbb{R}^n. \end{aligned} \quad (30)$$

通过利用指标函数定义分解半无限约束，我们得到两个半无限约束，

$$\begin{aligned} & \lambda_0 + \boldsymbol{\lambda}_1^\top \mathbf{x} + \boldsymbol{\lambda}_2^\top \mathbf{d}(\mathbf{x}) \geq 0, \quad \forall \mathbf{x} \in \mathbb{R}^n \setminus \Xi, \\ & \lambda_0 + \boldsymbol{\lambda}_1^\top \mathbf{x} + \boldsymbol{\lambda}_2^\top \mathbf{d}(\mathbf{x}) + \lambda_3 \geq f(\boldsymbol{\nu}, \mathbf{x}), \quad \forall \mathbf{x} \in \Xi, \end{aligned} \quad (31)$$

其中 $\mathbb{R}^n \setminus \Xi$ 是 Ξ 的补集。由于 $\lambda \in \mathcal{D}^*$ 且假设 $\mathbf{d}(\mathbf{x})$ 是 $\mathcal{D}$ -凸函数，则 $\lambda_0 + \lambda_1^\top \mathbf{x} + \lambda_2^\top \mathbf{d}(\mathbf{x})$ 是 $\mathbf{x}$ 的凸函数（参见例如 [?, p. 110]），并且显然在 $\mathbf{x}$ 上连续。由标准连续性论证，允许我们将补集替换为其闭包 $\bar{\Xi}$ 。因条件 (C3) 中 $f(\nu, \mathbf{x})$ 是凸的分段仿射函数，(31) 等价于

$$\begin{aligned} \lambda_0 + \lambda_1^\top \mathbf{x} + \lambda_2^\top \mathbf{d}(\mathbf{x}) &\geq 0, & \forall \mathbf{x} \in \bar{\Xi}, \\ \lambda_0 + \lambda_1^\top \mathbf{x} + \lambda_2^\top \mathbf{d}(\mathbf{x}) + \lambda_3 &\geq f_l(\nu, \mathbf{x}), & \forall \mathbf{x} \in \Xi, \forall l \in \mathcal{L}. \end{aligned}$$

然后，通过将不确定性的非线性提升到不确定性集上，我们得到鲁棒对应形式

$$\begin{aligned} \lambda_0 + \lambda_1^\top \mathbf{x} + \lambda_2^\top \mathbf{u} &\geq 0, & \forall (\mathbf{x}, \mathbf{u}) : \mathbf{x} \in \bar{\Xi}, \mathbf{d}(\mathbf{x}) = \mathbf{u}, \\ \lambda_0 + \lambda_1^\top \mathbf{x} + \lambda_2^\top \mathbf{u} + \lambda_3 &\geq f_l(\nu, \mathbf{x}), & \forall (\mathbf{x}, \mathbf{u}) : \mathbf{x} \in \Xi, \mathbf{d}(\mathbf{x}) = \mathbf{u}, \forall l \in \mathcal{L}. \end{aligned} \quad (32)$$

由于约束在不确定参数上是线性的，我们可以等价地使用不确定性集的凸包

$$\begin{aligned} \lambda_0 + \lambda_1^\top \mathbf{x} + \lambda_2^\top \mathbf{u} &\geq 0, & \forall (\mathbf{x}, \mathbf{u}) \in \text{conv}(\{(\mathbf{x}, \mathbf{u}) : \mathbf{x} \in \bar{\Xi}, \mathbf{d}(\mathbf{x}) = \mathbf{u}\}), \\ \lambda_0 + \lambda_1^\top \mathbf{x} + \lambda_2^\top \mathbf{u} + \lambda_3 &\geq f_l(\nu, \mathbf{x}), & \forall (\mathbf{x}, \mathbf{u}) \in \text{conv}(\{(\mathbf{x}, \mathbf{u}) : \mathbf{x} \in \Xi, \mathbf{d}(\mathbf{x}) = \mathbf{u}\}), \forall l \in \mathcal{L}, \end{aligned} \quad (33)$$

由条件 (C1) 和 (C2) 可知，第二组鲁棒对应形式的不确定性集凸包等价于 $\mathcal{C}$ 。值得注意的是，对于第一组半无限约束，其凸包也构成凸集。由于 (33) 中的鲁棒对应形式是关于对偶变量 $\lambda_0, \lambda_1, \lambda_2, \lambda_3$ 和决策向量 ν 的（无限）半空间交集，故可推断其可行集是凸的，且 (28) 是一个凸优化问题。这反过来意味着，只要凸集 $\mathcal{C}$ 和 $\bar{\mathcal{C}}$ 允许满足 Slater 条件的可处理锥重构，问题 (28) 即可表述为锥优化问题。为支持第二个结论，我们在附录 ?? 中在这些附加条件下将 (28) 重构为有限维锥规划。证毕。 $\square$

现在的难点在于通过构造凸包 $\mathcal{C}$ 和 $\bar{\mathcal{C}}$ 的显式表达式，重构对偶问题中的半无限约束（或鲁棒对应形式）。为此，可以使用非线性不确定性类型的鲁棒优化技术；详见例如 [??]。值得指出的是，只要事件集和上图是（可处理的）锥可表示，通常优化 $\mathcal{C}$ 是计算可行的，但包含补集的半无限约束重构通常不可行——因为这涉及在非凸集上优化凸函数。为简化问题，合理考虑多面体事件集 Ξ 。该假设虽然牺牲了一般性，但提高了第一个半无限约束的可处理性。利用德摩根定律，涉及 $\bar{\Xi}$ 的半无限约束可分解为半空间上的优化。我们将在下一小节考虑此类事件集。此外值得一提的是，(28) 的无分布假设分析与基于不确定性量化的文献 [??] 及分布鲁棒凸优化 [?] 存在诸多相似之处。但与 [?] 中的定理5不同，我们在求解对偶问题时采用了提升论证，而非在构造模糊集时。下一节我们将展示定理 3 在适当选择 $\mathcal{D}$ 和 Ξ 时如何导出计算上可处理的模型。

4.2. 均值-离散度信息的一些示例

为了便于说明，我们将注意力限制在两类模糊集上，这两类模糊集类似于第 3.1 节中的命题 1 和命题 2。此外，为了简化起见，我们假设事件集由半空间定义；即，

$$\Xi_z = \{\mathbf{z} \in \mathbb{R}^{n_z} : \mathbf{c}^\top \mathbf{z} \leq \bar{c}\},$$

其中 $\mathbf{c} \in \mathbb{R}^{n_z}$, $\bar{c} \in \mathbb{R}$ 。由于 $\mathcal{Y} = \mathbb{R}^{n_y}$, 事件在结果空间中是不受限制的。我们选择这一特定设置, 以便在本节余下部分能够得到可计算的锥形重构。在此语境下, “可计算” 意指我们的优化问题可以被表述为线性、锥二次或在较小程度上为半正定规划, 从而能够使用成熟的现成锥优化求解器。这些锥形规划的推导详见附录。

我们首先构造一个Chebyshev型模糊集 [? ?], 它允许我们对随机向量 $\mathbf{X}$ 的协方差矩阵施加约束。设 $\mathbb{E}[\mathbf{X}] = \boldsymbol{\mu}$ 表示均值向量, 并定义离散度度量 $\mathbf{d}(\mathbf{x}) = (\mathbf{x} - \boldsymbol{\mu})(\mathbf{x} - \boldsymbol{\mu})^\top$ 。我们将 $\mathcal{D}$ 识别为半正定矩阵锥。Chebyshev模糊集包含所有均值为 $\boldsymbol{\mu} \in \mathbb{R}^n$ 且协方差矩阵上界为 $\boldsymbol{\Sigma} \in \mathbb{S}_+^n$ 的分布。其定义为

$$\mathcal{P}_{(\boldsymbol{\mu}, \boldsymbol{\Sigma})} = \{ \mathbf{P} \in \mathcal{P}_0(\mathbb{R}^n) : \mathbb{E}_{\mathbf{P}}[\mathbf{X}] = \boldsymbol{\mu}, \mathbb{E}_{\mathbf{P}}[(\mathbf{X} - \boldsymbol{\mu})(\mathbf{X} - \boldsymbol{\mu})^\top] \preceq \boldsymbol{\Sigma} \}.$$

当我们将该模糊集与半空间事件集结合考虑时, 约束 (28) 可由线性矩阵不等式 (LMI) 描述。因此, 定理 3 导出以下结果。

ii

COROLLARY 1 (切比雪夫不确定集). 假设满足条件 (C1)–(C4)。令 Ξ_z 由半空间定义。则对于 $\mathcal{D} = \mathcal{P}_{(\boldsymbol{\mu}, \boldsymbol{\Sigma})}$, 上下文 DRO 问题 (28) 可重写为半定规划问题。

ii

另一种选择是使用MAD作为离散度度量 [?]。设 $\mathbf{m} \in \mathbb{R}^n$ 表示某中心点, 在此处即均值。假设我们拥有分量均值偏差 $\mathbb{E}[|\mathbf{X} - \mathbf{m}|]$ 和成对均值偏差 $\mathbb{E}[|(X_i \pm X_j) - (m_i \pm m_j)|]$ 的界限, 分别由向量 $\mathbf{f} \in \mathbb{R}^{n^2}$ 给出。由此形成的模糊集为

$$\mathcal{P}_{(\mathbf{m}, \mathbf{f})} = \{ \mathbf{P} \in \mathcal{P}_0(\mathbb{R}^n) : \mathbb{E}_{\mathbf{P}}[\mathbf{X}] = \mathbf{m}, \mathbb{E}[|X_i - m_i|] \leq f_{i,i}, \forall i, \mathbb{E}[|(X_i \pm X_j) - (m_i \pm m_j)|] \leq f_{i,j}, \forall i \neq j \}.$$

对于该模糊集, 约束 (28) 可表示为线性不等式。因此, 定理 3 得出以下结论。

COROLLARY 2 (MAD 不确定性集). 假设条件 (C1)–(C4) 成立。令 Ξ_z 由一个半空间定义。则对于 $\mathcal{D} = \mathcal{P}_{(\mathbf{m}, \mathbf{f})}$, 上下文 DRO 问题 (28) 可以重写为一个线性优化问题。

具体的数学模型详见附录 ??。虽然我们已经获得了可计算的模型, 但尚不清楚模糊集和辅助信息如何相互作用, 或者在何种条件下上下文DRO问题简化为其鲁棒对应问题 $P_0(\mathbf{v}, \mathbf{y})$, 如第 3 节所述。与此相关, 我们想提及由 [?] 引入的广泛嵌套模糊集类别, 该类别涵盖了若干基于距离的模糊集, 作为广义矩的特殊类型。原因在于基于距离的模糊集可以通过有限数量的 (条件) 期望约束, 基于广义矩定义 [?]。基于距离的模糊集尤其有趣, 因为它们明确地关联了模糊集和事件集的 “大小”, 使得我们能够量化上下文DRO问题何时变得 “无信息”。关于基于最优传输的距离模糊集与事件集大小之间相互作用的精彩讨论, 见 [?]。由于我们的框架适用于广义矩, 定理 3 可扩展至包括嵌套及基于距离的模糊集。此外, 如第 3 节所述, 通过对基 $\mathcal{P}_0$ 施加结构性质, 可以得到更紧的界限。然而, 这两种扩展均涉及大量技术细节, 可能分散本说明性章节的主要关注点, 因此留待热心读者自行探究。

4.3. 新报贩示例

为了更好地理解我们的上下文分布鲁棒优化 (DRO) 框架，我们现在通过运筹学中一个著名的问题，即 (单品种) 新报贩模型，提供一个数值示例。与传统模型不同，我们将问题表述为 $\mathbb{E}_P[f(\nu, X)|Z \in \Xi_Z]$ 的形式，以便纳入辅助信息。欲了解更多内容，请参见 [?] 及其中引用的文献，这些文献讨论了带有特征信息的数据驱动新报贩模型。

假设新报贩交易单一产品。在观察到产品需求 D 之前，新报贩会为该产品下订单，订购数量为 q 单位。当需求实现后，新报贩将销售所有可用库存。任何未满足的需求将导致积压订单，每单位需支付罚款成本 p ，而任何剩余库存则需支付每单位持有成本 h 。新报贩旨在最小化总持有成本和罚款成本，该成本是订购量 $q \geq 0$ 和需求变量 D 的函数，

$$\begin{aligned} C(q, D) &= h(q - D)^+ + p(D - q)^+ \\ &= h(q - D) + (h + p)(D - q)^+, \end{aligned} \quad (34)$$

其中 $(x)^+ := \max\{x, 0\}$ 。显然，成本函数 C 是分段仿射的，与条件 (C3) 一致。与传统设定的主要区别在于，新报贩在做出订购决策前能够观察到影响需求变量 D 的协变量 Z 。因此，上下文 DRO 问题可以表述为

$$\inf_{q \geq 0} \sup_{P \in \mathcal{P}(\mu, \Sigma)} \mathbb{E}_P[C(q, D)|Z \in \Xi].$$

主要目标是在纳入关于特征信息 $Z \in \Xi_Z$ 的条件下，最小化新报贩产生的总成本。

为了考虑需求变量 D 与特征 Z 之间的依赖关系，我们引入协方差矩阵构建均值-方差不确定集。假设真实分布为二维正态分布，其均值向量为 $\mu = (5, 5)$ ，协方差矩阵为 Σ 。该矩阵的对角元素为 $\sigma_{1,1}^2 = 2.25$ ， $\sigma_{2,2}^2 = 1$ ，而非对角元素由相关系数 ρ 决定，表示需求与特征之间的依赖关系。我们区分两种相关水平：无相关，即 $\rho = 0$ ，以及高度正相关，即 $\rho = 0.95$ 。此外，持有成本设为 $h = 1$ ，罚款成本为 $p = 5$ 。关于特征的取值范围，我们考虑两个事件： $\{Z \geq 1\}$ 和 $\{Z \geq 4\}$ 。作为背景， Z 可以被视为另一种具有相似特征但在规划期内已部分观察到的替代品的需求。

图 4 展示了上述设置的数值结果，揭示了若干有趣的见解。图中包含了无相关设置下的 Scarf 界 [?]。这里需注意，该界仅对这些设置有效。这是因为如果真实分布为二维正态分布，当 $\rho = 0$ 时，需求 D 与特征 Z 独立。因此，仅考虑需求信息的分布鲁棒界限即足够。对于零相关情况，当事件集规模适中时，Scarf 界与我们的界表现相近。然而，随着事件集规模减小，观察到 Scarf 界优于我们的界。这背后的原因是，对 $\mathcal{P}(\mu, \Sigma)$ 进行优化所得的最坏情况分布仍允许更高阶的依赖性。因此， Z 的取值继续对条件期望的界限产生显著影响。此外，显而易见的是，条件期望界限与真实值之间的差异主要取决于事件集的大小，而非相关系数的大小。这是预期之内的，且与我们前文对该主题的讨论一致。最后，必须牢记，随着辅助信息集 $\{Z \geq z_0\}$ 规模的减小，条件期望的界限差异持续扩大。减少这种保守性的唯一实际方法似乎是通过在不确定集中包含更多信息来实现。

5. 结论与展望

让我们做一个总结。本文提出了一个用于界定条件期望的新颖框架，该框架与广义矩约束问题不同，可以显式地将附加信息纳入半无限规划的表述中。其关键思想是通过一个简单的变换，将




Figure 4: 具有相关和独立需求的不同订货量的新订货商成本界限

得到的半无限分式问题简化为半无限线性规划。对应的对偶问题与广义矩问题十分相似，但多了一个约束，用于对该随机事件的条件进行建模。幸运的是，这种复杂度的略微增加似乎并未显著影响所得模型的计算可行性。该广义条件界框架可以通过原始-对偶论证，针对不同的不确定集和一般目标（例如定价问题）得到单变量界限。此外，它还作为基于矩的上下文分布鲁棒优化框架的基础，可应用于带有附加信息的随机优化问题。

最后，我们提及若干潜在的有趣研究方向。首先，寻找单变量界限的更多应用似乎值得关注，比如稳健壟断定价问题。其次，可进一步探索第 4 节讨论的上下文分布鲁棒优化框架的替代应用。此外，将我们的研究成果扩展至嵌套不确定集也是有益的，因为此类不确定集包含基于距离的不确定集，从而为回答何时解变得“无信息化”（即在哪些实例中分布鲁棒优化问题简化为稳健优化问题）提供了更直接的途径。对嵌套不确定集以及不同类型附加信息和目标函数结构进行全面的

复杂度分析，也是一项值得探索的课题。总之，我们提出的框架为在纳入附加信息的情况下界定条件期望提供了一个有前景的方法。我们期待所建议的未来研究方向将促进该框架的发展和应用。

Acknowledgments

作者感谢 *Johan van Leeuwen*、*Pieter Kleer* 和 *Bas Verseveldt* 交流了他们独立通过更直接方法推导的命题 1、2 和 3，本质上是解决了原始问题。作者还感谢 *Dick den Hertog* 对本文初稿进行校对。

A. 证明

证明引理 1. 不失一般性地假设矩约束是一致的，因此 $\mathcal{P}$ 非空。否则，根据惯例定义，两个问题均无可行解，最优值为 $-\infty$ 。设 $\{\tilde{\tau}, \{\tilde{\mathbf{P}}_k\}_{k \geq 1}\}$ 和 $\{\tau^*, (\tau^*, \{\mathbf{P}_k^*\}_{k \geq 1})\}$ 分别为 (4) 和 (8) 的最优值及最优解（极大化序列）。我们可以假设为极大化序列，且若最优值由极端分布 $\mathbf{P}^*$ 精确达到，则可选取序列使得 $\lim_{k \rightarrow \infty} \mathbf{P}_k^* = \mathbf{P}^*$ 。为证明结果，充分展示 $\ddot{\imath}$

$$\tau^* = \lim_{k \rightarrow \infty} \frac{\mathbb{E}_{\mathbf{P}_k^*}[g(X)\mathbb{1}_{\Xi}(X)]}{\mathbb{E}_{\mathbf{P}_k^*}[\mathbb{1}_{\Xi}(X)]} = \lim_{k \rightarrow \infty} \frac{\mathbb{E}_{\tilde{\mathbf{P}}_k}[g(X)\mathbb{1}_{\Xi}(X)]}{\mathbb{E}_{\tilde{\mathbf{P}}_k}[\mathbb{1}_{\Xi}(X)]} = \sup_{\mathbf{P} \in \mathcal{P}} \frac{\mathbb{E}_{\mathbf{P}}[g(X)\mathbb{1}_{\Xi}(X)]}{\mathbb{E}_{\mathbf{P}}[\mathbb{1}_{\Xi}(X)]} =: \tilde{\tau}. \quad (35)$$

$\ddot{\imath}$ 最后的等式归因于 $\{\tilde{\mathbf{P}}_k\}$ 的最优性。注意所有值均为有限值，基于假设。进一步注意

$$\frac{\mathbb{E}_{\mathbf{P}}[g(X)\mathbb{1}_{\Xi}(X)]}{\mathbb{E}_{\mathbf{P}}[\mathbb{1}_{\Xi}(X)]} \leq \tilde{\tau},$$

对所有 $\mathbf{P} \in \mathcal{P}$ 成立。重写并对 $\mathcal{P}$ 取上确界，上述不等式等价于

$$\sup_{\mathbf{P} \in \mathcal{P}} \mathbb{E}_{\mathbf{P}}[g(X)\mathbb{1}_{\Xi}(X) - \tilde{\tau}\mathbb{1}_{\Xi}(X)] \leq 0,$$

这意味着 $\tilde{\tau}$ 对问题 (8) 是可行的。由于 τ^* 是 (8) 的可行解，故有

回忆 (??) 中的上确界由序列 $\{\mathbf{P}_k^*\}$ 达到。重写 (??)，得到

$$\lim_{k \rightarrow \infty} \mathbb{E}_{\mathbf{P}_k^*}[g(X)\mathbb{1}_{\Xi}(X) - \tau^*\mathbb{1}_{\Xi}(X)] \leq 0 \iff \tau^* \geq \lim_{k \rightarrow \infty} \frac{\mathbb{E}_{\mathbf{P}_k^*}[g(X)\mathbb{1}_{\Xi}(X)]}{\mathbb{E}_{\mathbf{P}_k^*}[\mathbb{1}_{\Xi}(X)]},$$

由此根据 τ^* 对问题 (8) 的最优性，得出 (35) 中第一条恒等式。由于 $\tilde{\tau}$ 对 (4) 最

接下来证明 (??)-t+ < PLACEHOLDERENV₅1 > s~v{P_k^{*}} 也是问题 (4) 的最优解。为反证，假设存在任意 $\epsilon > 0$ ，存在概率测度序列 $\{\tilde{\mathbf{P}}_k\}$ 使得

$$\frac{\mathbb{E}_{\tilde{\mathbf{P}}_k}[g(X)\mathbb{1}_{\Xi}(X)]}{\mathbb{E}_{\tilde{\mathbf{P}}_k}[\mathbb{1}_{\Xi}(X)]} > \tau^* + \epsilon,$$

当 k 充分大时成立。固定此时的 $\tilde{\mathbf{P}}_k$ ，得到

$$\mathbb{E}_{\tilde{\mathbf{P}}_k}[g(X)\mathbb{1}_{\Xi}(X) - \tau^*\mathbb{1}_{\Xi}(X)] > \epsilon \mathbb{E}_{\tilde{\mathbf{P}}_k}[\mathbb{1}_{\Xi}(X)].$$

由于 $\mathbb{E}_{\tilde{\mathbf{P}}_k}[\mathbb{1}_{\Xi}(X)] = \tilde{\mathbf{P}}_k(X \in \Xi) > 0$ 且 $\epsilon > 0$ ，该不等式与 (??) 矛盾。此外，若 $\mathbf{P}_k(X \in \Xi) = 0$ ，分式目标函数未定义，也导致矛盾。因此，将 (??) 与 (??) 结合，可知 (4) 与 (8) 的最优值一致，且存在概率分布序列在两个问题中共同达到该最优值。证毕。 $\square$

证明命题 2. 将二阶矩函数 x^2 替换为 $|x - \mu|$, 并在 (12) 中将 d 替换为 $(\sigma^2 + \mu^2)$, 得到 $\sup_{P \in \mathcal{P}_{(\mu, d)}} E[X|X \geq t] \approx v^* \beta < \text{PLACEHOLDERENV}_5 2 >$

记第二、第三个约束左侧分别为 $D(x) := \lambda_0 + \lambda_1 x + \lambda_2 |x - \mu|$. 当 $x < t$ 时, $D(x) \geq 0$, 且当 $t \leq x \leq b$ 时, $D(x) \geq x - \lambda_3$, 则函数 $D(x)$ 是对偶可行的. 首先考虑 $t < \mu$ 的情况. 为求解对偶问题, 我们考虑三种 $D(x)$ 的形态, 如图

首先讨论 $D(x)$ 为直线的情况 (即 $\lambda_2 = 0$). 若 $\lambda_1 = 0$, 则 $D_1(x)$ 为水平线, 由于通过适当选择 λ_3 , 该函数位于 $\mathbb{1}_{\{x \geq t\}}(x - \lambda_3)$ 之上, 因此对偶可行. 注意, 为使该解满足 $\lambda_0 + \lambda_1 \mu + \lambda_2 d \leq 0$, 常数项 $\lambda_0 = 0$. 由于我们最小化 λ_3 (或最大化 $-\lambda_3$), 将线性函数 $x - \lambda_3$ 向上推直到与水平线相交, 该对偶函数对应的最优目标值为 b . 若 $D_1(x)$ 具有正斜率, 则 $\lambda_0 + \lambda_1 \mu > 0$, 不满足条件. 注意, 负斜率 $\lambda_1 < 0$ 的直线会增加 λ_3 , 因此水平线 $\lambda_0 = 0$ 是最优的可行选项. 达到该值的原始解为支持点为

$$\left\{ \frac{b(d - 2\mu) + 2\mu^2}{-2b + d + 2\mu}, b \right\}$$

的分布, 概率为

$$p_1 = 1 - \frac{d}{2(b - \mu)}, \quad p_2 = \frac{d}{2(b - \mu)}.$$

利用互补松弛原理, 第二种情况 $D_2(x)$ 可省略. 从图 ?? 观察, 该原始解支持于点 a, b , 但一般无法构造满足矩约束的两点分布, 故该情况不提供有用的紧界解.

对于第三种情况 (楔形), 令 $D_3(x)$ 在 $x = t, \mu, b$ 处与 $\mathbb{1}_{\{x \geq t\}}(x - \lambda_3)$ 重合. 此时对偶变量满足

$$\lambda_0 = \frac{(t + \lambda_3)\mu - 2t\lambda_3}{2(t - \mu)}, \quad \lambda_1 = \frac{\lambda_3 + t - 2\mu}{2(t - \mu)}, \quad \lambda_2 = \frac{t - \lambda_3}{2(t - \mu)}.$$

将上述变量代入 $\lambda_0 + \lambda_1 \mu + \lambda_2 d \leq 0$, 得

$$-\lambda_3 + \mu + \frac{d(\lambda_3 - t)}{2(\mu - t)} \leq 0,$$

其中左侧为 λ_3 的递减 (线性) 函数, 当 $t < \mu - \frac{d(b - \mu)}{2(b - \mu) - d}$ 时成立. 由于目标是最小化 λ_3 , 令等号成立, 得最优解

$$\lambda_3^* = \mu + \frac{d(\mu - t)}{2(\mu - t) - d}.$$

支持点为

$$\{t^-, \lambda_3^*\},$$

概率为

$$p_1 = \frac{d}{2(\mu - t)}, \quad p_2 = 1 - \frac{d}{2(\mu - t)},$$

该分布渐近达到 λ_3^* . 结合两种可行情况, 并通过构造原始可行解使界限紧致, 得出所需结果. $\square$

证明命题 3. $\exists \alpha \beta \approx v^*$ 为 $\text{PLACEHOLDERENV}_5 4 > @IV(x) := \lambda_0 + \lambda_1 x + \lambda_2 d(x)$. $\text{MAD} \exists \beta \pi \Psi \cap : \neq \Pi V(x) \beta \wedge (x = t^-$ 处触及, 并在 $x_0 > t$ 处与 $x - \lambda_3$ 切线 (x_0 后验确定). 基于此, 求解以下方程组以确定 p_t, p_{x_0} 及对偶变量 $\lambda_0, \lambda_1, \lambda_2, \lambda_3$ (固定 x_0):

$$\begin{aligned} p_t t + p_{x_0} x_0 &= \mu, \quad p_t d(t) + p_{x_0} d(x_0) = \bar{\sigma}, \\ \lambda_0 + \lambda_1 t + \lambda_2 d(t) &= 0, \quad \lambda_0 + \lambda_1 x_0 + \lambda_2 d(x_0) = x_0 - \lambda_3 \\ \lambda_1 + \lambda_2 d'(x_0) &= 1, \quad \lambda_0 + \lambda_1 \mu + \lambda_2 (\mu^2 + \sigma^2) = 0, \end{aligned}$$

其中第一行为矩约束，第二、三行为 $V(x)$ 形状限制，最后假设对偶约束 $\lambda_0 + \lambda_1\mu + \lambda_2(\mu^2 + \sigma^2) \leq 0$ 紧绑定。 $d'(x)$ 取右导数，以允许非可微离散函数。注意该对偶解总是可行的，因为 $V(x)$ 是凸函数 ($\lambda_2 \geq 0$ 是对偶可行的必要条件)，且由约束 $V'(x_0) = 1$ 和 $V(t) = 0$ ，对所有 x 有

$$V(x) \geq (x - \lambda_3) \mathbb{1}_{\Xi}(x).$$

解方程组，得到

$$p_t = \frac{\bar{\sigma}t - \mu d(t)}{td(x_0) - x_0 d(t)}, p_{x_0} = \frac{\bar{\sigma}x_0 - \mu d(x_0)}{x_0 d(t) - td(x_0)}, \lambda_3 = \frac{-(t - \mu)(d(x_0) - x_0 d'(x_0)) - \mu d(t) + \bar{\sigma}t}{(t - \mu)d'(x_0) - d(t) + \bar{\sigma}},$$

和

$$\lambda_0 = \frac{\mu d(t) - \bar{\sigma}t}{(t - \mu)d'(x_0) - d(t) + \bar{\sigma}}, \lambda_1 = \frac{\bar{\sigma} - d(t)}{(t - \mu)d'(x_0) - d(t) + \bar{\sigma}}, \lambda_2 = \frac{t - \mu}{(t - \mu)d'(x_0) - d(t) + \bar{\sigma}}.$$

为保证强对偶性，选取 x_0 满足

$$x_0 = \frac{-(t - \mu)(d(x_0) - x_0 d'(x_0)) - \mu d(t) + \bar{\sigma}t}{(t - \mu)d'(x_0) - d(t) + \bar{\sigma}} = \lambda_3 \iff \frac{(t - x_0)\bar{\sigma} + (x_0 - \mu)d(t) + (\mu - t)d(x_0)}{(t - \mu)d'(x_0) - d(t) + \bar{\sigma}} = 0,$$

且归一化约束 $p_t + p_{x_0} = 1$ 成立。两条件等价于

$$(t - x_0)\bar{\sigma} + (x_0 - \mu)d(t) + (\mu - t)d(x_0) = 0.$$

因此， x_0^* 由方程

$$\frac{\bar{\sigma}t - \mu d(t)}{td(x_0) - x_0 d(t)} + \frac{\bar{\sigma}x_0 - \mu d(x_0)}{x_0 d(t) - td(x_0)} = 1,$$

确定，是最优解。由此结论成立。 $\square$

证明命题 4. 对称的 Dirac 测度对 (即 $\delta_{\mu-x}, \delta_{\mu+x}, x \geq 0$) 生成了以 μ 为中心的对称分布类。由定理 1, $\approx v^*: < \text{PLACEHOLDER}_{ENV58} > \Gamma \delta \Gamma a \dots \infty \mu$: $2\lambda_0 + 2\lambda_1\mu + 2\lambda_2(x^2 + \mu^2) \geq -2\lambda_3 + 2\mu, \quad \forall 0 \leq x < \mu - t, \quad \therefore \epsilon \beta 1 G \ddot{t} i$
 $2\lambda_0 + 2\lambda_1\mu + 2\lambda_2(x^2 + \mu^2) \geq x + \mu - \lambda_3, \quad \forall x \geq \mu - t.$
 μ , 故对所有 $x \geq 0$ 有 $\mathbb{1}_{\Xi}(\mu + x) = 1$ 。定义二次函数

$$M^{\text{sym}}(x) := 2\lambda_0 + 2\lambda_1\mu + 2\lambda_2(x^2 + \mu^2).$$

我们提出两个可能的对偶解。第一个解记为 $M_1^{\text{sym}}(x)$ ，在 $x = 0$ 处触及 $-2\lambda_3 + 2\mu$ ，在 $x = \mu - t$ 处触及 $x + \mu - \lambda_3$ 。第二个解 $M_2^{\text{sym}}(x)$ 为二次函数，在未知的最优点 x_0 处触及 $x + \mu - \lambda_3$ 。我们假设两解均满足对偶约束 $\lambda_0 + \lambda_1\mu + \lambda_2(\mu^2 + \sigma^2) \leq 0$ 紧绑定。为节省篇幅，图示略去，但易验证所提解对偶可行。对应原始解由互补松弛给出，是在 x 取 $M^{\text{sym}}(x)$ 与约束右端相等点的对称 Dirac 测度对 $\delta_{\mu-x}, \delta_{\mu+x}$ 。

对应 $M_1^{\text{sym}}(x)$ 的对偶变量为

$$\lambda_1 = \frac{-\lambda_0 + \frac{(t-\mu)(\mu^2+\sigma^2)}{2(t-\mu)^2-\sigma^2}}{\mu}, \quad \lambda_2 = \frac{\mu - t}{2(t - \mu)^2 - \sigma^2},$$

得到

$$\lambda_3^* = \frac{2(t - \mu)^2\mu - t\sigma^2}{2(t - \mu)^2 - \sigma^2}$$

作为对偶问题的最优猜测值。该解因 $M_1^{\text{sym}}(x)$ 凸 ($\lambda_2 \geq 0$)，且在 $x = 0$ 处与 $-2\lambda_3 + 2\mu$ 相切，且计算得知 $M_1^{\text{sym}'}(x)$ 在 $x = \mu - t$ 处导数大于 1，故 $M_1^{\text{sym}}(x) \geq x + \mu - \lambda_3^*$ ，对所有 $x \geq \mu - t$ 成立。由方差约束

$$(1-p)\mu^2 + \frac{1}{2}pt^2 + \frac{1}{2}p(2\mu-t)^2 = \mu^2 + \sigma^2,$$

可得

$$p = \frac{\sigma^2}{(t-\mu)^2}.$$

因此

$$\mathbb{E}[X | X \geq t] = \frac{\frac{\sigma^2}{2(t-\mu)^2}(2\mu-t) + \left(1 - \frac{\sigma^2}{(t-\mu)^2}\right)\mu}{\frac{\sigma^2}{2(t-\mu)^2} + \left(1 - \frac{\sigma^2}{(t-\mu)^2}\right)} = \frac{2\mu(t-\mu)^2 - \sigma^2 t}{2(t-\mu)^2 - \sigma^2} = \lambda_3^*,$$

由弱对偶性，该解为原始-对偶最优解。第二种情况先确定候选支持点 x_0 ，由矩约束及对称性得

$$x_0^* = \sigma,$$

故原始候选解为

$$\frac{1}{2}\delta_{\mu-\sigma} + \frac{1}{2}\delta_{\mu+\sigma}.$$

对应对偶解为

$$\lambda_1 = -\frac{4\lambda_0\sigma + \mu^2 + \sigma^2}{4\mu\sigma}, \quad \lambda_2 = \frac{1}{4\sigma}, \quad \lambda_3^* = \mu + \sigma.$$

因此

$$\mathbb{E}[X | X \geq t] = \mu + x_0^* = \mu + \sigma = \lambda_3^*.$$

当 $t \geq \mu$ ，存在以 $\{\mu, \mu-k, \mu+k\}$ 为支持的概率测度序列 $\{\mathbb{P}_k\}$ ，其在原始问题中可行，且条件期望随着 $k \rightarrow \infty$ 发散。该序列为

$$\mathbb{P}_k = \left(1 - \frac{\sigma^2}{k^2}\right)\delta_\mu + \frac{1}{2}\frac{\sigma^2}{k^2}\delta_{\mu-k} + \frac{1}{2}\frac{\sigma^2}{k^2}\delta_{\mu+k}.$$

易验证 $\lim_{k \rightarrow \infty} \mathbb{E}_{\mathbb{P}_k}[X | X \geq t]$ 发散。结合上述情况并检验原始解可行性，结论成立。 $\square$

证明命题 5. 以 μ 为众数的对称单峰分布可由矩形/均匀分布生成，可能包含 μ 处的 Dirac 测度 (即 $\delta_{[\mu-z, \mu+z]}$, $z \geq 0$)。由定理 $M^{\text{uni}}(x)$ ，对偶问题为 $\inf_{\lambda_0, \lambda_1, \lambda_2, \lambda_3} \frac{2}{3}x(3\lambda_0 + 3\mu(\lambda_1 + \lambda_2\mu) + \lambda_2x^2) \geq \int_{\mu-x}^{\mu+x} (z - \lambda_3) \mathbb{1}$ 约束拆分为两组不等式，得到系统

$$\begin{aligned} \frac{2}{3}x(3\lambda_0 + 3\mu(\lambda_1 + \lambda_2\mu) + \lambda_2x^2) &\geq 2x(\mu - \lambda_3), \quad \forall 0 < x < \mu - t, \\ \frac{2}{3}x(3\lambda_0 + 3\mu(\lambda_1 + \lambda_2\mu) + \lambda_2x^2) &\geq -\frac{1}{2}(t-x-\mu)(t+x-2\lambda_3+\mu), \quad \forall x \geq \mu - t. \end{aligned} \quad (36)$$

我们可以对最优对偶解进行合理猜测，并利用弱对偶，通过互补松弛构造匹配的原始解来证明最优性 $\Theta \approx n^{\frac{1}{2}} \Psi$ 次多项式函数

$$M^{\text{uni}}(x) := \inf_{\lambda_0, \lambda_1, \lambda_2, \lambda_3}$$

$$t(3$$

x_0 处触及，与 $M_1(x)$ 类似，且额外在 $x = p$ 处与 $(\mathbb{1}_{\{x \geq z\}}(x) - \lambda_3)\mathbb{1}_{\Xi}(x)$ 相等。利用类似条件找到三点分布的最优原始和对偶解，且

$$x_0 = \mu^2 +$$

$$\sigma^2 - \mu z \mu - z, \exists a \cong \text{得} \neq \Theta ds, * L \Theta : \Delta w \downarrow \beta \Delta e \text{ 详 } \overline{C} \Theta, \Psi \in \forall M_3(x)$$

$$/!\cong p\beta($$

$$z\Delta: \simeq [0, p] \rightsquigarrow \because \Delta \Theta \neq \beta \text{ 程 } \approx \neq, \Psi * \Omega L \beta \Gamma 8 p 1 \Theta \Sigma \Omega \text{ 述 } \forall \nmid \Phi \beta n | \div \in \Sigma \Lambda \sim L \beta \downarrow \delta \zeta.$$

□

$$\begin{aligned} & \inf_{\lambda_0, \lambda_1, \lambda_2, \lambda_3} \lambda_3 \\ & \text{subject to} \quad \lambda_0 + \lambda_1 \mu + \lambda_2 (\sigma^2 + \mu^2) \leq 0, \\ & \quad \int_{\mu-x}^{\mu+x} \lambda_0 + \lambda_1 z + \lambda_2 z^2 dz \geq \int_{\mu-x}^{\mu+x} (z - \lambda_3) \mathbb{1}_{\Xi}(z) dz, \quad \forall x > 0, \\ & \quad \lambda_0 + \lambda_1 \mu + \lambda_2 \mu^2 \geq (\mu - \lambda_3). \end{aligned} \tag{37}$$

$$\begin{aligned} & \inf_{\lambda_0, \lambda_1, \lambda_2, \lambda_3} \lambda_3 \\ & \text{subject to} \quad \lambda_0 + \lambda_1 \mu + \lambda_2 (\sigma^2 + \mu^2) \leq 0, \\ & \quad 2\lambda_0 + 2\lambda_1 \mu + 2\lambda_2 (x^2 + \mu^2) + \lambda_3 \mathbb{1}_{\Xi}(\mu - x) + \lambda_3 \mathbb{1}_{\Xi}(\mu + x) \\ & \quad \geq (\mu - x) \mathbb{1}_{\Xi}(\mu - x) + (\mu + x) \mathbb{1}_{\Xi}(\mu + x), \quad \forall x \geq 0. \end{aligned} \tag{38}$$




Figure 5: $D_1(x)$ 、 $D_2(x)$ 和 $D_3(x)$

$$\sup_{P \in \mathcal{G}} \frac{\mathbb{E}_P[g(X)\mathbb{1}_{\Xi}(X)]}{\mathbb{E}_P[\mathbb{1}_{\Xi}(X)]} \leq \tau^*. \tag{39}$$

$$\begin{aligned}
& \inf_{\lambda_0, \lambda_1, \lambda_2, \lambda_3} \lambda_3 \\
& \text{subject to } \lambda_0 + \lambda_1 \mu + \lambda_2 d \leq 0, \\
& \lambda_0 + \lambda_1 x + \lambda_2 d(x) \geq 0, \quad \forall x < t, \\
& \lambda_0 + \lambda_1 x + \lambda_2 d(x) \geq x - \lambda_3, \quad \forall x \geq t.
\end{aligned} \tag{40}$$

$$\tau^* = \lim_{k \rightarrow \infty} \frac{\mathbb{E}_{\mathbb{P}_k^*}[g(X)\mathbb{1}_{\Xi}(X)]}{\mathbb{E}_{\mathbb{P}_k^*}[\mathbb{1}_{\Xi}(X)]} \leq \lim_{k \rightarrow \infty} \frac{\mathbb{E}_{\tilde{\mathbb{P}}_k}[g(X)\mathbb{1}_{\Xi}(X)]}{\mathbb{E}_{\tilde{\mathbb{P}}_k}[\mathbb{1}_{\Xi}(X)]} = \tilde{\tau}. \tag{41}$$

$$\sup_{\mathbb{P} \in \mathcal{P}} \mathbb{E}_{\mathbb{P}}[g(X)\mathbb{1}_{\Xi}(X) - \tau^* \mathbb{1}_{\Xi}(X)] \leq 0. \tag{42}$$

$$\begin{aligned}
& \inf_{\lambda_0, \lambda_1, \lambda_2, \lambda_3} \lambda_3 \\
& \text{subject to } \lambda_0 + \lambda_1 \mu + \lambda_2 d \leq 0, \\
& \lambda_0 + \lambda_1 x + \lambda_2 |x - \mu| \geq 0, \quad \forall a \leq x < t, \\
& \lambda_0 + \lambda_1 x + \lambda_2 |x - \mu| \geq x - \lambda_3, \quad \forall t \leq x \leq b.
\end{aligned} \tag{43}$$

$$\mathbb{E}[X | X \geq t] = \frac{(1-p)\mu + p \int_t^{\mu+x_0} \frac{z}{2x_0} dz}{(1-p) + p \int_t^{\mu+x_0} \frac{1}{2x_0} dz} = \frac{4x_0\mu - p(t+x_0-\mu)(t-x_0+\mu)}{4x_0 - 2p(t+x_0-\mu)}. \tag{44}$$

$$\begin{aligned}
p_{x_0} + p_z &= 1, \quad p_{x_0}x_0 + p_z z = \mu, \quad p_{x_0}x_0^2 + p_z z^2 = \mu^2 + \sigma^2, \\
\lambda_0 + \lambda_1 x_0 + \lambda_2 x_0^2 &= -\lambda_3, \quad \lambda_0 + \lambda_1 z + \lambda_2 z^2 = 1 - \lambda_3, \\
\lambda_1 + 2\lambda_2 x_0 &= 0, \quad \lambda_0 + \lambda_1 \mu + \lambda_2(\mu^2 + \sigma^2) = 0,
\end{aligned}$$

$$\begin{aligned}
& \inf_{\lambda_0, \lambda_1, \lambda_2, \lambda_3} \lambda_3 \\
& \text{subject to } \lambda_0 + \lambda_1 \mu + \lambda_2(\sigma^2 + \mu^2) \leq 0, \\
& \lambda_0 + \lambda_1 x + \lambda_2 x^2 \geq (\mathbb{1}_{\{x \geq z\}}(x) - \lambda_3)\mathbb{1}_{\Xi}(x), \quad \forall x \geq 0.
\end{aligned} \tag{45}$$

$$\max_{x_0} \left\{ \frac{4\mu(x_0)^3 - 3\sigma^2(-\mu + t + x_0)(\mu + t - x_0)}{4(x_0)^3 - 6\sigma^2(-\mu + t + x_0)} : x_0 \geq \sqrt{3}\sigma \right\}. \tag{46}$$

B. 锥体重构

定理 3 中第二条断言的证明。我们将关注第二个半无限约束（第一个约束可以类似处理），该约束等价地可以写成鲁棒对应形式的集合

$$\lambda_0 + \boldsymbol{\lambda}_1^\top \mathbf{x} + \boldsymbol{\lambda}_2^\top \mathbf{u} + \lambda_3 \geq \mathbf{s}_l(\boldsymbol{\nu})^\top \mathbf{x} + t_l(\boldsymbol{\nu}), \quad \forall (\mathbf{x}, \mathbf{u}) \in \mathcal{C}, \forall l \in \mathcal{L}. \tag{47}$$

令“cl”表示集合的闭包。接下来我们从不确定性集合生成一个适当的锥。定义 $\mathcal{K} := \text{cl}(\{(\mathbf{x}, \mathbf{u}, w) \in \mathbb{R}^n \times \mathbb{R}^m \times \mathbb{R} : (\mathbf{z}/w, \mathbf{u}/w) \in \mathcal{C}, w > 0\})$ 其对偶锥为 $\mathcal{K}^*$ 。此后我们假设 $\mathcal{K}$ 及其对偶锥 $\mathcal{K}^*$ 都可表示为易处理的锥。半无限约束 (??) 成立当且仅当，

$$\begin{aligned}
& \inf \quad (\boldsymbol{\lambda}_1 - \mathbf{s}_l(\boldsymbol{\nu}))^\top \mathbf{x} + \boldsymbol{\lambda}_2^\top \mathbf{u} \\
& \text{s.t.} \quad (\mathbf{x}, \mathbf{u}, 1) \in \mathcal{K},
\end{aligned} \tag{48}$$

大于或等于 $t_l(\boldsymbol{\nu}) - \lambda_0 - \lambda_3$ 。假设该问题存在严格可行解，则根据锥对偶理论，(??) 的强对偶形式为

$$\begin{aligned}
& \sup \quad -w_l \\
& \text{s.t.} \quad \boldsymbol{\lambda}_1 - \mathbf{s}_l(\boldsymbol{\nu}) - \mathbf{a}_l = \mathbf{0}, \\
& \quad \quad \boldsymbol{\lambda}_2 - \mathbf{b}_l = \mathbf{0}, \\
& \quad \quad (\mathbf{a}_l, \mathbf{b}_l, w_l) \in \mathcal{K}^*.
\end{aligned} \tag{49}$$

因此，半无限约束 (??) 成立当且仅当存在 $(\mathbf{a}_l, \mathbf{b}_l, w_l) \in \mathcal{K}^*$ ，对所有 $l \in \mathcal{L}$ ，使得约束 (??) 满足且 $-w_l$ 不小于 $t_l(\boldsymbol{\nu}) - \lambda_0 - \lambda_3$ 。利用该对偶刻画，我们可以将 (28) 重新写成如下形式：

$$\begin{aligned}
& \inf \quad \lambda_3 \\
& \text{s.t.} \quad \lambda_0 + \boldsymbol{\lambda}_1^\top \boldsymbol{\mu} + \boldsymbol{\lambda}_2^\top \boldsymbol{\sigma} \leq 0, \\
& \quad \quad \lambda_0 + \boldsymbol{\lambda}_1^\top \mathbf{x} + \boldsymbol{\lambda}_2^\top \mathbf{u} \geq 0, \quad \forall (\mathbf{x}, \mathbf{u}) \in \overline{\mathcal{C}}, \\
& \quad \quad \lambda_0 + \lambda_3 - t_l(\mathbf{x}) - w_l \geq 0, \quad \forall l \in \mathcal{L}, \\
& \quad \quad \boldsymbol{\lambda}_1 - \mathbf{s}_l(\boldsymbol{\nu}) - \mathbf{a}_l = \mathbf{0}, \quad \forall l \in \mathcal{L}, \\
& \quad \quad \boldsymbol{\lambda}_2 - \mathbf{b}_l = \mathbf{0}, \quad \forall l \in \mathcal{L}, \\
& \quad \quad (\mathbf{a}_l, \mathbf{b}_l, w_l) \in \mathcal{K}^*, \quad \forall l \in \mathcal{L}, \\
& \quad \quad \boldsymbol{\nu} \in \mathcal{V}, \lambda_0 \in \mathbb{R}, \boldsymbol{\lambda}_1 \in \mathbb{R}^n, \boldsymbol{\lambda}_2 \in \mathcal{D}^*, \lambda_3 \in \mathbb{R}.
\end{aligned} \tag{50}$$

如果 $\overline{\mathcal{C}}$ 也可用锥表示且满足类似的 Slater 条件，则类似论证允许我们重构第一个半无限约束，从而将 (??) 转化为有限维锥优化问题。由此，第二条断言得证。 $\square$

我们利用以下结果推导切比雪夫不确定集 $\mathcal{P}_{(\boldsymbol{\mu}, \boldsymbol{\Sigma})}$ 的 LMI 重构。

LEMMA 2 (S-引理, [?]). 考虑两个关于 $\mathbf{x} \in \mathbb{R}^n$ 的二次函数， $q_i(\mathbf{x}) = \mathbf{x}^\top \mathbf{C}_i \mathbf{x} + 2\mathbf{c}_i^\top \mathbf{x} + \bar{c}_i$ ， $i = 0, 1$ ，且存在某个 $\bar{\mathbf{x}}$ 使得 $q_1(\bar{\mathbf{x}}) > 0$ 。则

$$q_0(\mathbf{x}) \geq 0 \quad \forall \mathbf{x} : q_1(\mathbf{x}) \geq 0$$

当且仅当存在 $\tau \geq 0$ 使得

$$\begin{pmatrix} \bar{c}_0 & \mathbf{c}_0^\top \\ \mathbf{c}_0 & \mathbf{C}_0 \end{pmatrix} - \tau \begin{pmatrix} \bar{c}_1 & \mathbf{c}_1^\top \\ \mathbf{c}_1 & \mathbf{C}_1 \end{pmatrix} \in \mathbb{S}_+^{n+1}.$$

推论 1 的证明。根据 S-引理，有

$$\lambda_0 + \boldsymbol{\lambda}_1^\top \mathbf{x} + \mathbf{x}^\top \boldsymbol{\Lambda} \mathbf{x} \geq 0, \forall \mathbf{x} : \mathbf{c}^\top \mathbf{x} \geq \bar{c} \iff \exists \tau \geq 0 : \begin{bmatrix} \lambda_0 + \tau \bar{c} & \frac{1}{2}(\boldsymbol{\lambda}_1 - \tau \mathbf{c})^\top \\ \frac{1}{2}(\boldsymbol{\lambda}_1 - \tau \mathbf{c}) & \boldsymbol{\Lambda} \end{bmatrix} \succcurlyeq \mathbf{0}.$$

类似地，对于第二个半无限约束，

$$\lambda_0 + (\boldsymbol{\lambda}_1 - \mathbf{s}(\boldsymbol{\nu}))^\top \mathbf{x} + \mathbf{x}^\top \boldsymbol{\Lambda} \mathbf{x} + \lambda_3 - t_l(\boldsymbol{\nu}) \geq 0, \forall \mathbf{x} : \mathbf{c}^\top \mathbf{x} \leq \bar{c} \iff \exists \chi_l \geq 0 : \begin{bmatrix} \lambda_0 + \lambda_3 - t_l(\boldsymbol{\nu}) - \chi_l \bar{c} & \frac{1}{2}(\boldsymbol{\lambda}_1 - \mathbf{s}_l(\boldsymbol{\nu}) + \chi_l \mathbf{c})^\top \\ \frac{1}{2}(\boldsymbol{\lambda}_1 - \mathbf{s}_l(\boldsymbol{\nu}) + \chi_l \mathbf{c}) & \boldsymbol{\Lambda} \end{bmatrix} \succcurlyeq \mathbf{0}.$$

这些 LMI 导出如下半正定规划问题：

$$\begin{aligned}
& \inf \quad \lambda_3 \\
& \text{s.t.} \quad \lambda_0 + \boldsymbol{\lambda}_1^\top \boldsymbol{\mu} + \langle \boldsymbol{\Lambda}, \boldsymbol{\Sigma} \rangle \leq 0, \\
& \quad \begin{bmatrix} \lambda_0 + \tau \bar{c} & \frac{1}{2} (\boldsymbol{\lambda}_1 - \tau \mathbf{c})^\top \\ \frac{1}{2} (\boldsymbol{\lambda}_1 - \tau \mathbf{c}) & \boldsymbol{\Lambda} \end{bmatrix} \succeq \mathbf{0}, \\
& \quad \begin{bmatrix} \lambda_0 + \lambda_3 - t_l(\boldsymbol{\nu}) - \chi_l \bar{c} & \frac{1}{2} (\boldsymbol{\lambda}_1 - \mathbf{s}_l(\boldsymbol{\nu}) + \chi_l \mathbf{c})^\top \\ \frac{1}{2} (\boldsymbol{\lambda}_1 - \mathbf{s}_l(\boldsymbol{\nu}) + \chi_l \mathbf{c}) & \boldsymbol{\Lambda} \end{bmatrix} \succeq \mathbf{0}, \quad \forall l \in \mathcal{L}, \\
& \quad \boldsymbol{\nu} \in \mathcal{V}, \lambda_0 \in \mathbb{R}, \boldsymbol{\lambda}_1 \in \mathbb{R}^n, \boldsymbol{\Lambda} \in \mathbb{S}_+^n, \lambda_3 \in \mathbb{R}, \tau \in \mathbb{R}_+, \boldsymbol{\chi} \in \mathbb{R}_+^{|\mathcal{L}|},
\end{aligned}$$

其中 $\langle \cdot, \cdot \rangle$ 表示迹内积。 □

推论 2 的证明。带有 MAD 信息的模型通过对绝对值项的正负部分分别定义约束得到。这产生

$$\begin{aligned}
& \inf_{\boldsymbol{\nu}, \lambda_0, \boldsymbol{\lambda}_1, \boldsymbol{\lambda}_2, \lambda_3} \quad \lambda_3 \\
& \text{s.t.} \quad \lambda_0 + \boldsymbol{\lambda}_1^\top \mathbf{m} + \boldsymbol{\lambda}_2^\top \mathbf{f} \leq 0, \\
& \quad \lambda_0 + \boldsymbol{\lambda}_1^\top \mathbf{x} + \boldsymbol{\lambda}_2^\top \mathbf{u} \geq 0, \quad \forall (\mathbf{x}, \mathbf{u}) : \mathbf{c}^\top \mathbf{x} \geq \bar{c}, \mathbf{u} \geq \pm \mathbf{d}(\mathbf{x}) \\
& \quad \lambda_0 + \boldsymbol{\lambda}_1^\top \mathbf{x} + \boldsymbol{\lambda}_2^\top \mathbf{u} + \lambda_3 \geq \mathbf{s}_l(\boldsymbol{\nu})^\top \mathbf{x} + t_l(\boldsymbol{\nu}), \quad \forall (\mathbf{x}, \mathbf{u}) : \mathbf{c}^\top \mathbf{x} \leq \bar{c}, \mathbf{u} \geq \pm \mathbf{d}(\mathbf{x}) \\
& \quad \boldsymbol{\nu} \in \mathcal{V}, \lambda_0 \in \mathbb{R}, \boldsymbol{\lambda}_1 \in \mathbb{R}^n, \boldsymbol{\lambda}_2 \in \mathbb{R}_+^{n^2}, \lambda_3 \in \mathbb{R},
\end{aligned}$$

其中 $\mathbf{d}(\mathbf{x}) = \mathbf{m}_0 + \mathbf{D}\mathbf{x}$ 描述了仿射函数 $X_i - m_i$ 和 $(X_i \pm X_k) - (m_i \pm m_k)$ ，且不等式 $\mathbf{u} \geq \pm \mathbf{d}(\mathbf{x})$ 按元素成立。我们关注第一个半无限约束。它可重写为

$$\lambda_0 + \min_{\mathbf{x}, \mathbf{u} : \mathbf{c}^\top \mathbf{x} \geq \bar{c}, \mathbf{u} \geq \pm \mathbf{d}(\mathbf{x})} \{ \boldsymbol{\lambda}_1^\top \mathbf{x} + \boldsymbol{\lambda}_2^\top \mathbf{u} \} \geq 0.$$

利用 $\mathbf{d}$ 是 $\mathbf{x}$ 的仿射向量值函数，标准线性规划对偶理论给出有限维线性重构，因为

$$\begin{aligned}
& \lambda_0 + \min_{\mathbf{x}, \mathbf{u} : \mathbf{c}^\top \mathbf{x} \geq \bar{c}, \mathbf{u} \geq \pm \mathbf{d}(\mathbf{x})} \{ \boldsymbol{\lambda}_1^\top \mathbf{x} + \boldsymbol{\lambda}_2^\top \mathbf{u} \} \geq 0 \\
& \iff \lambda_0 + \max_{\tau \in \mathbb{R}_+, \boldsymbol{\chi}_+, \boldsymbol{\chi}_- \in \mathbb{R}_+^{n^2}} \{ \bar{c}\tau + \boldsymbol{\chi}_+^\top \mathbf{m}_0 - \boldsymbol{\chi}_-^\top \mathbf{m}_0 : \tau \mathbf{c} - \mathbf{D}^\top \boldsymbol{\chi}_+ + \mathbf{D}^\top \boldsymbol{\chi}_- = \boldsymbol{\lambda}_1, \boldsymbol{\chi}_+ + \boldsymbol{\chi}_- = \boldsymbol{\lambda}_2 \} \geq 0 \\
& \iff \exists \tau \in \mathbb{R}_+, \boldsymbol{\chi}_+, \boldsymbol{\chi}_- \in \mathbb{R}_+^{n^2} : \lambda_0 + \bar{c}\tau + \boldsymbol{\chi}_+^\top \mathbf{m}_0 - \boldsymbol{\chi}_-^\top \mathbf{m}_0 \geq 0, \tau \mathbf{c} - \mathbf{D}^\top \boldsymbol{\chi}_+ + \mathbf{D}^\top \boldsymbol{\chi}_- = \boldsymbol{\lambda}_1, \boldsymbol{\chi}_+ + \boldsymbol{\chi}_- = \boldsymbol{\lambda}_2.
\end{aligned}$$

对另一个半无限约束也适用类似论证。因此，所有鲁棒对应形式均可重写为线性不等式，得证。 □

References

- [] Ban, G.-Y. and Rudin, C. (2019). *The big data newsvendor: Practical insights from machine learning*. Operations Research, 67(1):90–108.
- [] Ben-Tal, A., Den Hertog, D., De Waegenaere, A., Melenberg, B., and Rennen, G. (2013). *Robust solutions of optimization problems affected by uncertain probabilities*. Management Science, 59(2):341–357.
- [] Ben-Tal, A., Den Hertog, D., and Vial, J.-P. (2015). *Deriving robust counterparts of nonlinear uncertain inequalities*. Mathematical Programming, 149(1-2):265–299.

- [] Ben-Tal, A., El Ghaoui, L., and Nemirovski, A. (2009). *Robust Optimization*, volume 28. Princeton University Press, Princeton, NJ.
- [] Ben-Tal, A. and Nemirovski, A. (1998). *Robust convex optimization*. *Mathematics of Operations Research*, 23(4):769–805.
- [] Ben-Tal, A. and Nemirovski, A. (2001). *Lectures on Modern Convex Optimization: Analysis, Algorithms, and Engineering Applications*. SIAM, Philadelphia.
- [] Bertsimas, D. and Kallus, N. (2020). *From predictive to prescriptive analytics*. *Management Science*, 66(3):1025–1044.
- [] Bertsimas, D. and Popescu, I. (2002). *On the relation between option and stock prices: A convex optimization approach*. *Operations Research*, 50(2):358–374.
- [] Bertsimas, D. and Popescu, I. (2005). *Optimal inequalities in probability theory: A convex optimization approach*. *SIAM Journal on Optimization*, 15(3):780–804.
- [] Birge, J. R. and Dulá, J. H. (1991). *Bounding separable recourse functions with limited distribution information*. *Annals of Operations Research*, 30(1):277–298.
- [] Birge, J. R. and Wets, R. J.-B. (1987). *Computing bounds for stochastic programming problems by means of a generalized moment problem*. *Mathematics of Operations Research*, 12(1):149–162.
- [] Boyd, S. and Vandenberghe, L. (2004). *Convex Optimization*. Cambridge University Press, Cambridge, UK.
- [] Charnes, A. and Cooper, W. W. (1962). *Programming with linear fractional functionals*. *Naval Research Logistics Quarterly*, 9(3-4):181–186.
- [] Chebyshev, P. L. (1874). *Sur les valeurs limites des intégrales*. *Journal de Mathématiques Pures et Appliquées*, 12:177–184.
- [] Chen, H., Hu, M., and Perakis, G. (2022). *Distribution-free pricing*. *Manufacturing & Service Operations Management*, 24(4):1939–1958.
- [] Chen, Z., Sim, M., and Xiong, P. (2020). *Robust stochastic optimization made easy with RSOME*. *Management Science*, 66(8):3329–3339.
- [] Cozman, F. G. (1999). *Calculation of posterior bounds given convex sets of prior probability measures and likelihood functions*. *Journal of Computational and Graphical Statistics*, 8(4):824–838.
- [] de Klerk, E., Kuhn, D., and Postek, K. (2020). *Distributionally robust optimization with polynomial densities: Theory, models and algorithms*. *Mathematical Programming*, 181:265–296.
- [] Delage, E. and Ye, Y. (2010). *Distributionally robust optimization under moment uncertainty with application to data-driven problems*. *Operations Research*, 58(3):595–612.
- [] Dinkelbach, W. (1967). *On nonlinear fractional programming*. *Management Science*, 13(7):492–498.
- [] Dupačová, J. (1987). *The minimax approach to stochastic programming and an illustrative application*. *Stochastics: An International Journal of Probability and Stochastic Processes*, 20(1):73–88.
- [] Elmachtoub, A. N., Gupta, V., and Hamilton, M. L. (2021). *The value of personalized pricing*. *Management Science*, 67(10):6055–6070.
- [] Esteban-Pérez, A. and Morales, J. M. (2022). *Distributionally robust stochastic programs with side information based on trimmings*. *Mathematical Programming*, 195(1-2):1069–1105.

- [] Giannakopoulos, Y., Poças, D., and Tsigonias-Dimitriadis, A. (2020). *Robust revenue maximization under minimal statistical information*. In *International Conference on Web and Internet Economics*, pages 177–190, Cham, Switzerland. Springer.
- [] Gorissen, B. L. (2015). *Robust fractional programming*. *Journal of Optimization Theory and Applications*, 166(2):508–528.
- [] Gorissen, B. L., Blanc, H., den Hertog, D., and Ben-Tal, A. (2014). *Deriving robust and globalized robust solutions of uncertain linear programs with general convex uncertainty sets*. *Operations Research*, 62(3):672–679.
- [] Han, S., Tao, M., Topcu, U., Owhadi, H., and Murray, R. M. (2015). *Convex optimal uncertainty quantification*. *SIAM Journal on Optimization*, 25(3):1368–1387.
- [] Hanasusanto, G. A., Roitch, V., Kuhn, D., and Wiesemann, W. (2015). *A distributionally robust perspective on uncertainty quantification and chance constrained programming*. *Mathematical Programming*, 151(1):35–62.
- [] Hanasusanto, G. A., Roitch, V., Kuhn, D., and Wiesemann, W. (2017). *Ambiguous joint chance constraints under mean and dispersion information*. *Operations Research*, 65(3):751–767.
- [] Hettich, R. and Kortanek, K. O. (1993). *Semi-infinite programming: Theory, methods, and applications*. *SIAM Review*, 35(3):380–429.
- [] Isii, K. (1962). *On sharpness of Tchebycheff-type inequalities*. *Annals of the Institute of Statistical Mathematics*, 14(1):185–197.
- [] Ji, R. and Lejeune, M. A. (2021). *Data-driven optimization of reward-risk ratio measures*. *INFORMS Journal on Computing*, 33(3):1120–1137.
- [] Karlin, S. and Studden, W. J. (1966). *Tchebycheff Systems: With Applications in Analysis and Statistics*, volume 15. John Wiley and Sons, New York.
- [] Kemperman, J. H. (1968). *The general moment problem: A geometric approach*. *The Annals of Mathematical Statistics*, 39(1):93–122.
- [] Lasserre, J. B. (2001). *Global optimization with polynomials and the problem of moments*. *SIAM Journal on Optimization*, 11(3):796–817.
- [] Lavine, M. (1991). *Sensitivity in Bayesian statistics: The prior and the likelihood*. *Journal of the American Statistical Association*, 86(414):396–399.
- [] Liu, Y., Meskarian, R., and Xu, H. (2017). *Distributionally robust reward-risk ratio optimization with moment constraints*. *SIAM Journal on Optimization*, 27(2):957–985.
- [] Mallows, C. (1956). *Generalizations of Tchebycheff’s inequalities*. *Journal of the Royal Statistical Society: Series B (Methodological)*, 18(2):139–168.
- [] Mallows, C. L. and Richter, D. (1969). *Inequalities of Chebyshev type involving conditional expectations*. *The Annals of Mathematical Statistics*, 40(6):1922–1932.
- [] Markov, A. (1884). *On certain applications of algebraic continued fractions*. *Ph.D. thesis (in Russian)*, St Petersburg.
- [] Marshall, A. W. and Olkin, I. (1960). *Multivariate Chebyshev inequalities*. *The Annals of Mathematical Statistics*, pages 1001–1014.
- [] Mohajerin Esfahani, P. and Kuhn, D. (2018). *Data-driven distributionally robust optimization using the Wasserstein metric: Performance guarantees and tractable reformulations*. *Mathematical Programming*, 171(1-2):115–166.

- [] MOSEK (2019). MOSEK optimization software. Technical report, version 9.1.9., <http://docs.mosek.com/9.1/toolbox/index.html>.
- [] Nesterov, Y. et al. (1997). *Structure of non-negative polynomials and optimization problems*. Technical report, Université Catholique de Louvain, Center for Operations Research.
- [] Nguyen, V. A., Zhang, F., Blanchet, J., Delage, E., and Ye, Y. (2020). *Distributionally robust local non-parametric conditional estimation*. *Advances in Neural Information Processing Systems*, 33:15232–15242.
- [] Nguyen, V. A., Zhang, F., Blanchet, J., Delage, E., and Ye, Y. (2021). *Robustifying conditional portfolio decisions via optimal transport*. arXiv preprint arXiv:2103.16451.
- [] Parrilo, P. A. (2000). *Structured semidefinite programs and semialgebraic geometry methods in robustness and optimization*. Ph.D. thesis, California Institute of Technology.
- [] Parrilo, P. A. (2003). *Semidefinite programming relaxations for semialgebraic problems*. *Mathematical Programming*, 96(2):293–320.
- [] Pólik, I. and Terlaky, T. (2007). *A survey of the S-lemma*. *SIAM Review*, 49(3):371–418.
- [] Popescu, I. (2005). *A semidefinite programming approach to optimal-moment bounds for convex classes of distributions*. *Mathematics of Operations Research*, 30(3):632–657.
- [] Popescu, I. (2007). *Robust mean-covariance solutions for stochastic optimization*. *Operations Research*, 55(1):98–112.
- [] Postek, K., Ben-Tal, A., Den Hertog, D., and Melenberg, B. (2018). *Robust optimization with ambiguous stochastic constraints under mean and dispersion information*. *Operations Research*, 66(3):814–833.
- [] Rogosinski, W. W. (1958). *Moments of non-negative mass*. *Proceedings of the Royal Society of London. Series A. Mathematical and Physical Sciences*, 245(1240):1–27.
- [] Roos, E., Brekelmans, R., Van Eekelen, W., Den Hertog, D., and Van Leeuwaarden, J. S. (2022). *Tight tail probability bounds for distribution-free decision making*. *European Journal of Operational Research*, 299(3):931–944.
- [] Scarf, H. E. (1958). *A min-max solution of an inventory problem*. In Arrow, K. J., Karlin, S., and Scarf, H. E., editors, *Studies in the Mathematical Theory of Inventory and Production*. Stanford University Press, Stanford, CA.
- [] Shapiro, A. (2001). *On duality theory of conic linear problems*. In Goberna, M. A. and Lopez, M. A., editors, *Semi-Infinite Programming: Recent Advances*, pages 135–165. Kluwer Academic Publishers, Amsterdam.
- [] Shapiro, A. (2006). *Worst-case distribution analysis of stochastic programs*. *Mathematical Programming*, 107(1):91–96.
- [] Shapiro, A., Dentcheva, D., and Ruszczyński, A. (2009). *Lectures on Stochastic Programming: Modeling and Theory*. SIAM, Philadelphia, 3d edition.
- [] Shapiro, A. and Kleywegt, A. (2002). *Minimax analysis of stochastic problems*. *Optimization Methods and Software*, 17(3):523–542.
- [] Smith, J. E. (1995). *Generalized Chebychev inequalities: Theory and applications in decision analysis*. *Operations Research*, 43(5):807–825.
- [] Srivastava, P. R., Wang, Y., Hanasusanto, G. A., and Ho, C. P. (2021). *On data-driven prescriptive analytics with side information: A regularized Nadaraya-Watson approach*. arXiv preprint arXiv:2110.04855.
- [] Stieltjes, T.-J. (1894). *Recherches sur les fractions continues*. *Annales de la Faculté des Sciences de Toulouse: Mathématiques*, 8(4):1–122.

- [] Stieltjes, T.-J. (1895). *Recherches sur les fractions continues*. Annales de la Faculté des Sciences de Toulouse: Mathématiques, 9(1):5–47.
- [] Vandenberghe, L., Boyd, S., and Comanor, K. (2007). *Generalized Chebyshev bounds via semidefinite programming*. SIAM Review, 49(1):52–64.
- [] Weisser, T., Legat, B., Coey, C., Kapelevich, L., and Vielma, J. P. (2019). *Polynomial and moment optimization in Julia and JuMP*. <https://pretalx.com/juliacon2019/talk/QZBKAU/>.
- [] Wiesemann, W., Kuhn, D., and Sim, M. (2014). *Distributionally robust convex optimization*. Operations Research, 62(6):1358–1376.
- [] Yanıkoğlu, İ., Gorissen, B. L., and den Hertog, D. (2019). *A survey of adjustable robust optimization*. European Journal of Operational Research, 277(3):799–813.
- [] Žáčková, J. (1966). *On minimax solutions of stochastic linear programming problems*. Časopis pro Pěstování Matematiky, 91(4):423–430.