

利用贝叶斯方法对小角散射中样本结构的定量选择

YUI HAYASHI,^a SHUN KATAKAMI,^a SHIGEO KUWAMOTO,^b KENJI NAGATA,^c

MASAICHIRO MIZUMAKI^d AND MASATO OKADA ^{a*}

^a 东京大学前沿科学研究生院, 日本千叶县柏市 277-8561, ^b 日本同步辐射研究所, 日本
兵库县佐用町 679-5198, ^c 日本国立材料科学研究所, 日本茨城县筑波市 305-0047, and

^d 熊本大学先进科学技术学院, 日本熊本市 860-8555.

*E-mail: *okada@edu.k.u-tokyo.ac.jp*

小角 X 射线散射; 小角中子散射; 纳米结构分析; 模型选择; 贝叶斯推断

Abstract

小角散射 (SAS) 是一种分析各种材料中纳米尺度结构的关键实验技术。在 SAS 数据分析中, 选择适当的散射强度数学模型至关重要, 因为它构建了对实验样品结构的假设。传统的模型选择方法要么依赖于定性方法, 要么容易出现过拟合现象。本文引入了一种应用贝叶斯模型选择于 SAS 测量数据的分析方法, 实现了对数学模型有效性的定量评估。我们通过使用多组分球形材料的人工数据进行数值实验来评估该方法的性能, 结果表明我们提出的分析方法能够产生高度准确且具有解释性的结果。我们还讨论了该方法分析混合组分的不同混合比例和粒径比的能力, 以及其通过拟合程度进行模型评价的精度。我们提出的方法有效促进了对传统上难以实现的 SAS 纳米尺度样品结构的定量分析, 预计将在众多领域的发展中发挥重要作用。

1. 引言

近年来, 材料纳米尺度结构的分析在推动新材料开发和理解生物现象方面变得日益重要。小角散射 (SAS) 是一种用于分析此类纳米尺度结构的基础实验方法。该方法通过

用 X 射线或中子束照射物质，并分析在小角度（通常为 5 度或更小）（Guinier & Fournet, 1955）下产生的散射强度数据来实现。SAS 具有多功能性，适用于包括纳米粒子、高分子、软材料和纤维在内的多种异质材料，广泛应用于材料科学、化学和生物学等多个领域。

SAS 测量数据以对应散射矢量的散射强度形式表达，散射矢量是表征散射角的物理量。数据分析需要选择并估计包含样品结构信息的散射强度数学模型的参数。这一选择过程至关重要，因为它涉及对样品结构的假设。

传统上，SAS 数据分析中的模型选择通常通过基于理论或经验规则列出候选模型，针对测量数据进行参数拟合，并使用诸如 χ^2 平方误差等标准比较其适用性来完成（Da Vela & Svergun, 2020; Svergun et al., 1995; Kline, 2006; Schneidman-Duhovny et al., 2010; Breßler et al., 2015）。另一种方法是根据测量数据的一般形状来选择模型。然而，这些方法各有缺点：前者存在过拟合风险，可能导致模型自由度的高估（Rambo & Tainer, 2013），后者仅能得到定性模型选择。此外，使用传统方法难以对结果的可靠性进行定量评估。

本研究提出了一种新颖的 SAS 模型选择框架，该框架能够定量评估表示样品结构的数学模型在测量中的有效性。该方法利用贝叶斯推断框架内的贝叶斯模型选择，这一方法正逐渐应用于各种物理实验数据的分析中（Nagata et al., 2012; Nagata et al., 2019; Rappel et al., 2020; Machida et al., 2021; Nagai et al., 2021; Kashiwamura et al., 2022; Katakami et al., 2022; Ueda et al., 2023）。在 SAS 数据分析中，贝叶斯推断已被用于晶粒尺寸分布（Asahara et al., 2021）和参数估计（Hayashi et al., 2023）。该方法通过建立似然函数（即数据生成模型）和对应于先验知识的先验分布来解决逆问题，随后根据贝叶斯定理结合测得数据计算后验分布。在我们提出的方法中，利用交换蒙特卡洛方法（Hukushima & Nemoto, 1996），也称为并行退火法，计算测量数据下数据生成模型的后验概率，并在候选模型之间进行比较，同时获得模型参数的贝叶斯估计。此外，由于测量数据模型的有效性以后验概率的形式获得，结果的可靠性可以通过比较这些概率值进行量化。本研究通过数值实验评估所提方法的有效性。这些实验基于合成数据，用于估计样品中不同组分的数量，样品被建模为由两种不同半径、散射长度密度和体积分数的单分散球体混合而成。该问题具有挑战性，因为候选模型结构相似，存在过拟合风险；然而，结

果表明即使在存在测量噪声的情况下，我们的方法仍表现出高度的准确性、可解释性和稳定性。

本文结构如下：首先形式化提出的分析方法，然后描述用于数值实验的多组分单分散球体模型。第四节详细介绍使用所提方法估计合成数据中混合组分数量的实验设置及结果。随后讨论方法的分析能力以及基于拟合程度的传统方法性能。最后总结本方法的意义及潜在应用。

2. 所提框架的公式化

在本节中，我们详细介绍了用于选择 SAS 样品数学模型的贝叶斯模型选择算法的公式化过程。该算法的伪代码见算法 1。

2.1. 贝叶斯模型选择

实验测量数据的生成过程通常由包含噪声成分的概率模型描述。SAS 测量数据由对应于散射矢量的散射强度组成。由于散射强度是入射光子数在探测器上的测量，因此假设散射强度值服从泊松分布 (Durant et al., 2021, Katakami et al., 2022, Nagata et al., 2019, Straasø et al., 2013)。设 $I_K(q, \Theta)$ 是由参数 K 表征的样品参数 Θ 和散射矢量 q 的散射强度数学模型。生成测量值 y 的概率，即似然函数，表达为：

$$p(y|q, \Theta, K) = \frac{I_K(q, \Theta)^y \exp(-I_K(q, \Theta))}{y!}. \quad (1)$$

假设测量数据 $\mathcal{D} = \{q_i, y_i\}_{i=1}^N$ 包含 N 个数据点，是在 K 和 Θ 条件下独立同分布的样本，则似然函数表示为：

$$p(\mathcal{D}|\Theta, K) = \prod_{i=1}^N p(y_i|q_i, \Theta, K). \quad (2)$$

这里，我们引入泊松代价函数以转换式 (2) 中测量数据的似然函数为：

$$E(\Theta, K) = \frac{1}{N} \sum_{i=1}^N \left\{ I_K(q_i, \Theta) - y_i \log I_K(q_i, \Theta) + \sum_{j=1}^{y_i} \log j \right\}. \quad (3)$$

因此，似然函数可表达为：

$$p(\mathcal{D}|\Theta, K) = \exp(-NE(\Theta, K)). \quad (4)$$

设 $\varphi(K)$ 为表征模型的参数 K 的先验分布， $\varphi(\Theta|K)$ 为模型参数 Θ 的先验分布。根据贝叶斯定理，给定测量数据的参数后验分布可写为：

$$p(\Theta|\mathcal{D}, K) = \frac{p(\mathcal{D}|\Theta, K)\varphi(\Theta|K)\varphi(K)}{\int p(\mathcal{D}, \Theta, K)d\Theta} \quad (5)$$

$$= \frac{\exp(-NE(\Theta, K))\varphi(\Theta|K)}{Z(K)}, \quad (6)$$

$$Z(K) = \int \exp(-NE(\Theta, K))\varphi(\Theta|K)d\Theta. \quad (7)$$

其中 $Z(K)$ 是边际似然，对应于后验参数分布的归一化常数。此外，给定数据 $\mathcal{D}$ 的模型 K 的概率，即 $p(K|\mathcal{D})$ ，由下式给出：

$$p(K|\mathcal{D}) = \frac{\int p(\mathcal{D}, \Theta, K)d\Theta}{\sum_K \int p(\mathcal{D}, \Theta, K)d\Theta} \quad (8)$$

$$= \frac{\int \exp(-NE(\Theta, K))\varphi(\Theta|K)\varphi(K)d\Theta}{\sum_K \int \exp(-NE(\Theta, K))\varphi(\Theta|K)\varphi(K)d\Theta} \quad (9)$$

$$= \frac{\exp(-F(K))\varphi(K)}{\sum_K \exp(-F(K))\varphi(K)}, \quad (10)$$

$$F(K) = -\log Z(K). \quad (11)$$

$F(K)$ 被称为贝叶斯自由能，也称为随机复杂度。模型的后验概率 $p(K|\mathcal{D})$ 可重新表述为模型 K 对测量数据 $\mathcal{D}$ 的有效性。换言之，计算并比较所有候选模型 $\{K\}$ 的 $p(K|\mathcal{D})$ 值，即可实现定量的模型选择。注意，在贝叶斯模型选择中，参数 K 不必显式出现在样品的数学模型中。

2.2. 边际似然的计算

在我们的贝叶斯模型选择方法中，对于所有候选模型计算并比较贝叶斯自由能 $F(K)$ 和概率 $p(K|\mathcal{D})$ 。该计算依赖于确定边际似然 $Z(K)$ ，如式 (7) 所示。边际似然通常涉及多维积分，计算量大且不稳定。为了解决这一挑战，我们的框架采用 REMC 方法计算边际似然 (Hukushima & Nemoto, 1996)。该方法通过马尔可夫链蒙特卡洛方法 (MCMC) 在多个逆温度下采样所需的概率分布，这些逆温度被称为副本，并以任意间隔策略性地交换相邻逆温度的状态，从而避免陷入局部极小值。为了利用 REMC 计算边际似然，我们建立了一系列 L 个逆温度 $\{\beta_l\}_{l=1}^L$ ，它们满足关系：

$$0 = \beta_1 < \dots < \beta_L = 1. \quad (12)$$

在每个逆温度下，从联合概率分布中采样得到：

$$p(\Theta_1, \dots, \Theta_L | \mathcal{D}, K, \beta_1, \dots, \beta_L) = \prod_{l=1}^L p(\Theta_l | \mathcal{D}, K, \beta_l), \quad (13)$$

其中， Θ_l 表示在第 l 个逆温度 β_l 下的模型参数。后验分布 $p(\Theta_l | \mathcal{D}, K, \beta_l)$ 满足以下关系：

$$p(\Theta_l | \mathcal{D}, K, \beta_l) \propto \exp(-N\beta_l E(\Theta_l, K)) \varphi(\Theta_l | K). \quad (14)$$

这些分布通过 MCMC 在每个逆温度下采样，如式 (14) 所示，且相邻逆温度的状态以满足详细平衡条件的概率周期性交换。第 l 个与第 $(l+1)$ 个状态交换的概率 $p(\Theta_l \leftrightarrow \Theta_{l+1})$ 为：

$$p(\Theta_l \leftrightarrow \Theta_{l+1}) = \min \left[1, \frac{p(\Theta_{l+1} | \mathcal{D}, K, \beta_l) p(\Theta_l | \mathcal{D}, K, \beta_{l+1})}{p(\Theta_l | \mathcal{D}, K, \beta_l) p(\Theta_{l+1} | \mathcal{D}, K, \beta_{l+1})} \right] \quad (15)$$

$$= \min [1, \exp(N(\beta_{l+1} - \beta_l)(E(\Theta_{l+1}, K) - E(\Theta_l, K)))] \quad (16)$$

利用 REMC 从各逆温度采样的样本，可以有效确定式 (7) 中表达的边际似然。逆温度为 β 时的边际似然 $Z(K, \beta)$ 表达为：

$$Z(K, \beta) = \int \exp(-N\beta E(\Theta, K)) \varphi(\Theta|K) d\Theta. \quad (17)$$

此时，式 (7) 中的目标边际似然等价于 $Z(K, \beta = 1)$ 。利用式 (12)， $Z(K, \beta = 1)$ 可以表示为：

$$Z(K, \beta = 1) = \frac{Z(K, \beta_L)}{Z(K, \beta_{L-1})} \times \cdots \times \frac{Z(K, \beta_2)}{Z(K, \beta_1)} \quad (18)$$

$$= \prod_{l=1}^{L-1} \frac{Z(K, \beta_{l+1})}{Z(K, \beta_l)} \quad (19)$$

$$= \prod_{l=1}^{L-1} \langle \exp(-N(\beta_{l+1} - \beta_l)E(\Theta_l, K)) \rangle_{p(\Theta_l|\mathcal{D}, K, \beta_l)}. \quad (20)$$

式 (20) 中的符号 $\langle \cdot \rangle_{p(\Theta_l|\mathcal{D}, K, \beta_l)}$ 表示针对分布 $p(\Theta_l|\mathcal{D}, K, \beta_l)$ 的期望值。通过 REMC 采样计算式 (20)，即可得到式 (7) 中表达的边际似然。一旦确定了边际似然 $Z(K)$ ，即可计算式 (11) 中表达的贝叶斯自由能以及式 (10) 中表达的给定测量数据的模型 K 的后验概率。对于本文所展示的数值实验，我们采用了 Metropolis 方法 (Metropolis et al., 1953) 对式 (14) 中各逆温度下的后验分布进行 MCMC 采样。

2.3. 模型参数的估计

在边际似然计算过程中，获得了后验分布 $p(\Theta_L|\mathcal{D}, K, \beta_L = 1)$ ，它简单地表示模型参数的贝叶斯估计 (Hayashi et al., 2023)。因此，参数估计是在执行贝叶斯模型选择的同时进行的。此外，由于后验分布是通过 REMC 采样获得的，它能够提供全局的参数估计解。另外，可以从采样得到的后验分布的统计性质来评估估计的可靠性。

在贝叶斯估计中，最大后验概率 (MAP) 解提供了参数的点估计。模型 K 的参数的 MAP 解 Θ_{MAP} 由式 (14) 给出，表达式如下：

$$\Theta_{\text{MAP}} = \arg \max_{\Theta_L} \exp(-NE(\Theta_L, K)) \varphi(\Theta_L|K). \quad (21)$$

Algorithm 1 : Proposed framework for quantitative selection of specimen model.

Require: The measured data, $\mathcal{D} = \{q_i, y_i\}_{i=1}^N$. The number of replicas, L . The inverse temperature, $\{\beta_l\}_{l=1}^L$ where $0 = \beta_1 < \dots < \beta_L = 1$. The Burn-In, $\mathcal{T}_0$. The number of samples, $\mathcal{T}_1$. The step size for the Metropolis algorithm, $\{\epsilon_l\}_{l=1}^L$. Candidate Models, $\{K_m\}_{m=1}^M$. The prior distribution of Models, $\varphi(K)$. The prior distribution of parameters, $\varphi(\Theta|K)$.

Ensure: $\forall l \in \{1, \dots, L\}, \forall \tau \in \{\mathcal{T}_0 + 1, \dots, \mathcal{T}_1\}, \Theta_l^\tau \sim p(\Theta_l|\mathcal{D}, \beta_l), Z(K), F(K), p(K|\mathcal{D})$.

```

1: for  $m \in \{1, \dots, M\}$  do
2:   Initialize array of sampled parameters,  $\Psi = \{\}$ .
3:   for  $l \in \{1, \dots, L\}$  do
4:      $\Theta_l^0 \sim \varphi(\Theta|K_m)$ 
5:   end for
6:   for  $\tau \in \{1, \dots, \mathcal{T}_0 + \mathcal{T}_1\}$  do
7:     for  $l \in \{1, \dots, L\}$  do
8:       Propose the following state,  $\Theta' = \Theta_l^{\tau-1} + \epsilon \times \text{Uniform}(-1, 1)$ .
9:       Calculate the acceptance ratio,  $\alpha = p(\Theta'|\mathcal{D}, K_m, \beta_l)/p(\Theta_l^{\tau-1}|\mathcal{D}, K_m, \beta_l)$ .
10:      if  $\text{Uniform}(0, 1) < \alpha$  then
11:         $\Theta_l^\tau = \Theta'$ 
12:      else
13:         $\Theta_l^\tau = \Theta_l^{\tau-1}$ 
14:      end if
15:    end for
16:    for  $l \in \{1, \dots, L-1\}$  do
17:      Calculate the probability of exchanging states,  $p(\Theta_l^\tau \leftrightarrow \Theta_{l+1}^\tau)$ .
18:      if  $\text{Uniform}(0, 1) < p(\Theta_l^\tau \leftrightarrow \Theta_{l+1}^\tau)$  then
19:        Swap the  $\Theta_l^\tau$  for the  $\Theta_{l+1}^\tau$ .
20:      end if
21:    end for
22:    if  $\tau > \mathcal{T}_0$  then
23:      Append the  $\{\Theta_l^\tau\}_{l=1}^L$  to the  $\Psi$ .
24:    end if
25:  end for
26:  Calculate the marginal likelihood  $Z(K_m)$  and the Bayesian free energy  $F(K_m)$ .
27: end for
28: Calculate the likelihood of the model against the measured data  $\{p(K_m|\mathcal{D})\}_{m=1}^M$ .

```

3. 多组分单分散球模型的建立

本节中，我们描述了一个用于稀释样品中多组分单分散球散射强度的模型（Guinier & Fournet, 1955; Hashimoto, 2022）。该模型作为评估所提方法性能的基础。

设 $\mathbf{e}_i$ 和 $\mathbf{e}_s$ 分别表示入射波数矢量和散射波数矢量方向的单位向量。若 $\mathbf{e}_i$ 和 $\mathbf{e}_s$ 形成角度 2α ，且光束波长为 λ ，则散射矢量 $\mathbf{q}$ 表示为：

<PLACEHOLDER_{ENV18}> 假设散射各向同性，我们考虑散射矢量的大小 q 。

单分散球是半径均一的球形颗粒。对于单一类型的足够稀释的单分散球组成的样品，在散射矢量 q 处的散射强度 $I(q, \theta)$ 表达为：

其中 $V = \frac{4}{3}\pi R^3$ 。若样品中溶质与溶剂的散射长度密度差为 $\Delta\rho$ ，体积分数为 ϕ ，则 $S = (3\Delta\rho)^2\phi$ 。本模型的参数 θ 包括粒子尺寸 R 、比例系数 S 以及背景 B 。

为了建立由 K 种单分散球组成的样品的散射强度模型，假设体系稀释，令样品中第 k 种组分的粒子尺寸为 R_k ，比例系数为 S_k 。则由 K 种单分散球组成的样品的散射强度表示为：

其中假设 $V_k = \frac{4}{3}\pi R_k^3$ 。散射强度 $I_K(\cdot)$ 的模型参数为 $\Theta = \{\{R_k, S_k\}_{k=1}^K, B\}$ 。

$$I_K(q, \Theta) = \sum_{k=1}^K S_k V_k \left(\frac{(\sin(qR_k) - qR_k \cos(qR_k))}{(qR_k)^3} \right)^2 + B \quad (22)$$

$$\mathbf{q} = \frac{4\pi \sin \alpha}{\lambda} (\mathbf{e}_s - \mathbf{e}_i). \quad (23)$$

$$I(q, \theta) = SV \left(\frac{(\sin(qR) - qR \cos(qR))}{(qR)^3} \right)^2 + B, \quad (24)$$

4. 数值实验

在本节中，我们通过数值实验评估模型选择，比较成分数 K 从 1 到 4 的模型，以展示所提框架的能力。我们将该框架应用于合成数据，该数据由两种类型（ $K = 2$ ）的单分散球体组成，如式 (22) 所示。该实验设计对辨别样品的真实结构提出了挑战；尽管结构简单，但候选模型的相似性增加了过拟合的风险。

在典型的小角散射（SAS）实验中，式 (22) 中的尺度参数 S_k 往往较小。因此，我们对尺度参数 S_k 进行归一化处理：

$$\bar{S}_k = S_k \times 10^8. \quad (25)$$

因此，我们将模型参数表示为 $\Theta = \{\{R_k, \bar{S}_k\}_{k=1}^K, B\}$ 。

本节报告的数值实验中，REMC 的预热期设为 10^5 ，样本量为 10^5 。我们根据状态交换率和接受率设置了 REMC 的副本数、逆温度值以及 Metropolis 方法的步长。

4.1. 合成数据的生成

SAS 实验中的散射强度，通常以计数数据形式记录，受泊松噪声的影响，如公式 (1) 所示。因此，我们使用以下步骤生成合成数据 $\mathcal{D}$ ：

1. 将数据点数设置为 $N = 400$ ，并在区间 $[0.1, 3]$ 内的 N 个等距点处定义散射矢量，以获得 $\{q_i\}_{i=1}^{N=400} [\text{nm}^{-1}]$ 。
2. 假设 $K = 2$ 并将真实模型参数 Θ 设为 Θ^* 。
3. 使用步骤 1 中获得的散射矢量 $\{q_i\}_{i=1}^N$ ，基于方程 (22) 中的模型及 Θ^* 计算散射强度。引入伪测量时间 T 以调整数据中的噪声强度，得到 $\{I(q_i, \Theta^*, K) \times T\}_{i=1}^N$ 。
4. 生成测量值 $\{y_i\}_{i=1}^N$ ，其为均值为 $\{I(q_i, \Theta^*, K) \times T\}_{i=1}^N$ 的泊松分布随机数，从而创建合成数据集 $\mathcal{D} = \{q_i, y_i\}_{i=1}^N$ 。

本节中，我们考虑伪测量时间为 $T = 1$ 和 $T = 0.1$ 的情况。一般来说，较小的 T 值表明测量噪声的影响更大。

4.2. 设置先验分布

在贝叶斯模型选择框架中，关于参数 Θ 及表征模型的参数 K 的先验知识被设定为它们的先验分布。

在本数值实验中，参数 Θ 的先验分布基于数据生成过程中使用的伪测量时间 T 被设定为 Gamma 分布，而 K 的先验分布则是在区间 $[1, 4]$ 上的离散均匀分布。

$$\varphi(\Theta|K) = \varphi(B) \prod_{k=1}^K \varphi(R_k) \varphi(\bar{S}_k). \quad (26)$$

$$\varphi(R_k) = \text{Gamma}(R_k; \alpha = 1.2, \beta = 20) \quad (27)$$

$$= \frac{\exp(-x/\beta)}{\beta^\alpha \cdot \Gamma(\alpha)} \cdot x^{\alpha-1}, \quad (28)$$

$$\varphi(\bar{S}_k) = \begin{cases} \text{Gamma}(\bar{S}_k; 1.05, 300 \times T) & \text{(if } \{\bar{S}_k\}_{k=1}^K \text{ is in descending order),} \\ 0 & \text{(otherwise),} \end{cases} \quad (29)$$

$$\varphi(B) = \text{Gamma}(B; 1.05, 0.02 \times T), \quad (30)$$

$$\varphi(K) = \text{DiscreteUniform}(K; 1, 4). \quad (31)$$

4.3. 基于尺度比的双组分单分散球结果

在数据生成过程中，球体 1 和球体 2 的尺度参数 S_1, S_2 之比，记为 r_S ，定义如下：

$$r_S = \frac{\bar{S}_2}{\bar{S}_1}. \quad (32)$$

接下来，我们展示了将所提方法应用于分析通过改变 r_S 值生成的 6 种类型数据，在伪测量时间 $T = 1$ 和 0.1 下的分析结果。表 1 显示了用于生成合成数据的参数值。

Table 1. 用于不同 r_S 生成数据的参数值。

$\backslash$	Sphere1	Sphere2
Radius R (nm)	2	10
Scale $\bar{S}$	250	{250, 100, 20, 0.5, 0.1, 0.05}
Background B (cm^{-1})	0.01	
Pseudo measurement time T	{1, 0.1}	

图 1 展示了利用表 1 中给定参数值生成的合成数据，通过 MAP 解进行各模型的拟合结果。在图 1 (a) – (c)、(g) – (i) 中，显然 $K = 1$ 的模型无法准确表示数据。然而，我们也可以看到 $K = 2 - 4$ 模型的拟合曲线在形状上几乎一致。此外，图 1 (d) – (f)、(j) – (l) 所示的数据难以与众所周知的单一类型单分散球的散射数据 ($K = 1$) 区分开来，因此难以对 $K = 1 - 4$ 模型的拟合优度进行定性比较。




Fig. 1. 使用 MAP 解对在不同 r_s 值下生成的合成数据进行拟合。

面板 A 和 B 分别展示了伪测量时间为 $T = 1$ 和 $T = 0.1$ 的情况。在 (a)–(f) 和 (g)–(l) 情况中，尺度比 r_s 分别按降序排列，分别对应 $T = 1$ 和 $T = 0.1$ 。黑色圆点表示生成的数据，黑色虚线表示真实的散射强度曲线，实线的蓝色、红色、绿色和橙色分别表示使用 MAP 解对 $K = 1$ 、 $K = 2$ 、 $K = 3$ 和 $K = 4$ 进行拟合的曲线。

图 2 展示了基于我们提出框架的贝叶斯模型选择结果。图 2-A 为 $T = 1$ 情况下的结果，图 2-B 为 $T = 0.1$ 情况下的结果，分别显示了基于合成数据 $\mathcal{D}$ ，对于每个尺度比 r_S ，模型 K 的概率 $p(K|\mathcal{D})$ 。这里，对于每个参数值通过改变数据生成时的随机种子生成了 10 个数据集，条形图高度表示 $p(K|\mathcal{D})$ 的平均值，误差条表示最大值和最小值。对于图 2-A 中 (a) – (e) 的较大尺度比 r_S ，真实模型 $K = 2$ 的概率较高，而在 (f) 中 $p(K|\mathcal{D})$ 的平均值在 $K = 1$ 时最高。相反，在图 2-B 中，真实模型 $K = 2$ 在 (g) – (j) 中对应较高概率，而在 (k) 和 (l) 中， $K = 1$ 具有最高概率。




Fig. 2. 不同 r_S 值下模型 $K = 1 - 4$ 的贝叶斯模型选择结果。

面板 A 显示了使用伪测量时间 $T = 1$ 生成数据时每个模型的后验概率，面板 B 显示了 $T = 0.1$ 时的结果。在情况 (a)–(f) 和 (g)–(l) 中，比例尺 r_S 分别按降序排列，分别对应 $T = 1$ 和 $T = 0.1$ 。每个柱子的高度对应于使用不同随机种子生成的 10 组数据计算的平均值，误差棒表示最大值和最小值。红色高亮区域表示平均而言，真实模型 $K = 2$ 的概率最高的情况，蓝色背景表示平均概率最高的模型非 $K = 2$ 。

表 2 总结了在图 2 中使用 10 个独立数据集的数值实验中，各模型被判定为具有最高概率的次数。对于 $r_S = 0.0004$ 及以上的值（表 2-A），以及 $r_S = 0.002$ 及以上的值（表 2-B），模型 $K = 2$ 在所有 10 个数据集中均被判定为具有最高概率。这证明了所提方法的高准确性及其对测量噪声的鲁棒性。在 (f)、(k) 和 (l) 情况下，模型 $K = 1$ 几乎在所有 10 个数据集中被判定为具有最高概率。这些结果为下一节中关于利用所提方法分析

r_S 合适范围的讨论提供了依据。

Table 2. 在数值实验中，每个模型在以不同随机种子生成的 10 个数据集上，与最高概率相关联的次数，
针对每个 r_S 值。

在情况 (a)-(f) 和 (g)-(l) 中，比例尺比 r_S 分别以降序显示，分别对应 $T = 1$ 和 $T = 0.1$ 。每个 r_S 值
下计数最多的情况以加粗显示。

A. $T = 1$					B. $T = 0.1$				
$r_S \backslash K$	1	2	3	4	$r_S \backslash K$	1	2	3	4
(a) 1.0	0	10	0	0	(g) 1.0	0	10	0	0
(b) 0.4	0	10	0	0	(h) 0.4	0	10	0	0
(c) 0.08	0	10	0	0	(i) 0.08	0	10	0	0
(d) 0.002	0	10	0	0	(j) 0.002	0	10	0	0
(e) 0.0004	0	10	0	0	(k) 0.0004	9	1	0	0
(f) 0.0002	8	2	0	0	(l) 0.0002	10	0	0	0

4.4. 基于半径比的双组分分散球体结果

在合成数据生成过程中，球体 1 和球体 2 的半径 R_1 和 R_2 的比值，记为 r_R ，定义为：

$$r_R = \frac{R_1}{R_2}. \quad (33)$$

在此设置下，我们通过分别改变 r_R 的值，针对伪测量时间 $T = 1$ 和 $T = 0.1$ 生成了 7 种类型的数据。使用我们提出的方法的 MAP 解对这些数据集进行拟合的结果展示在图 3 中，而用于数据生成的参数值见表 3。

Table 3. 改变 r_R 时用于数据生成的参数值。

$\backslash$	Sphere1	Sphere2
Radius R (nm)	{9.9, 9.7, 9.5, 0.5, 0.5, 0.4, 0.3}	10
Scale $\tilde{S}$	250	100
Background B (cm ⁻¹)	0.01	
Pseudo measurement time T	{1, 0.1}	

除了 (d) 和 (k) 中 $r_R = 0.5$ 的情况外，图 3 中数据的轮廓与单一分散球体非常相似，且模型 $K = 1$ 到 $K = 4$ 的拟合曲线形状几乎相同。相比之下， $r_R = 0.5$ 的情况 (d) 和 (k) 的数据轮廓较为复杂，可以看出模型 $K = 1$ 对数据的表示较差。




Fig. 3. 使用 MAP 解对在不同 r_R 值下生成的合成数据进行拟合。

面板 A 和 B 分别展示了伪测量时间为 $T = 1$ 和 $T = 0.1$ 的情况。在情况 (a)–(g) 和 (h)–(n) 中，半径比 r_R 按降序排列，分别对应 $T = 1$ 和 $T = 0.1$ 。黑点表示生成的数据，黑色虚线表示真实的散射强度曲线，实线的蓝色、红色、绿色和橙色分别表示使用 MAP 解在 $K = 1$ 、 $K = 2$ 、 $K = 3$ 和 $K = 4$ 时的拟合曲线。

图 4 展示了通过改变半径比 r_R 生成的合成数据进行贝叶斯模型选择的结果。针对每个参数值，通过变化数据生成过程中的随机种子创建了 10 个数据集，条形图的高度表示 $p(K|\mathcal{D})$ 的平均值，误差线显示最大值和最小值。与图 2 中显示的尺度比变化结果不同，模型选择过程不仅在半径比 r_R 接近 0 时失败，而且在接近 1 的值时也失败，且 $K = 1$ 是支持度最高的模型。此外，在 $r_R = 0.04$ 的情况下， $T = 1$ 的 (f) 案例支持真实模型 $K = 2$ ，但 $T = 0.1$ 的 (m) 案例则支持备选模型 $K = 1$ 。然而，在 (b) – (f) 和 (i) – (l) 的情况下，真实模型 $K = 2$ 具有较高的平均概率（见图 4）。




Fig. 4. 不同 r_R 值下模型 $K = 1 - 4$ 的贝叶斯模型选择结果。

面板 A 显示了使用伪测量时间 $T = 1$ 生成数据时各模型的后验概率，面板 B 显示了 $T = 0.1$ 的结果。在情况 (a)–(g) 和 (h)–(n) 中，半径比 r_R 分别以降序排列，分别对应 $T = 1$ 和 $T = 0.1$ 。每个柱状的高度对应使用不同随机种子生成的 10 组数据计算得出的平均值，误差线表示最大值和最小值。红色高亮区域表示真实模型 $K = 2$ 获得最高支持的情况，蓝色背景表示除 $K = 2$ 外的其他模型的似然最高。

表 4 汇总了图 4 中显示的 10 个独立数据集的数值实验结果，列出了每个模型 $K = 1 - 4$ 被支持为最高的次数。在所提方法的解析极限附近，支持的模型会根据数据发生变化，如表 4 (a)、(f)、(i)、(l) 和 (m) 所示。

Table 4. 在通过改变 r_R 值生成的 10 个数据集的数值实验中，每个模型获得最高支持次数的统计。在 (a)–(g) 和 (h)–(n) 情况下，分别以降序显示半径比 r_R 对应于 $T = 1$ 和 $T = 0.1$ 的结果。每个 r_R 值对应的最高计数以粗体显示。

A. $T = 1$					
$r_R \backslash K$	1	2	3	4	
(a) 0.99	9	1	0	0	
(b) 0.97	0	10	0	0	
(c) 0.95	0	10	0	0	
(d) 0.5	0	10	0	0	
(e) 0.05	0	10	0	0	
(f) 0.04	1	9	0	0	
(g) 0.03	10	0	0	0	

B. $T = 0.1$					
$r_R \backslash K$	1	2	3	4	
(h) 0.99	10	0	0	0	
(i) 0.97	2	8	0	0	
(j) 0.95	0	10	0	0	
(k) 0.5	0	10	0	0	
(l) 0.05	1	9	0	0	
(m) 0.04	7	3	0	0	
(n) 0.03	10	0	0	0	

5. 讨论

在第 4 节中，我们通过对人工测量数据应用模型选择，利用所提方法对两组分单分散球体样品中的组分数 K 进行了数值实验。在本节中，我们将讨论在本研究设定下，样品两组分的尺度比 r_S 和半径比 r_R 的分析极限，以及基于拟合优度的传统模型选择方法，该方法常用于 SAS 数据分析。

5.1. 所提出方法的局限性

第 4 节中详述的实验使用所提出的贝叶斯方法，针对双组分单分散球体，探讨了成分数量 K 的选择。我们观察到对于不同的尺度参数 r_S 和半径比 r_R ，存在一定的分析局限性。在实际数据分析应用中，建议使用与测量数据噪声强度和预期参数值相似的合成数据进行初步测试。此步骤有助于确保更可靠的分析，具体如下所述。

尺度参数 S 是一个乘以溶剂与样品之间散射长度密度差的平方以及体积分数的数值。当溶剂与样品某组分的散射长度密度差异较小时，或组分混合比例差异较大时， r_S 可能变得极其小。图 2 和表 2 中伪测量时间 $T = 1$ （面板 A）的结果表明，在尺度比 $r_S = 0.0002$ 处，模型选择倾向于非真实模型。类似地，在 $T = 0.1$ （面板 B）时，尺度比 $r_S = 0.0004$ 和 $r_S = 0.0002$ 处也偏向非真实模型，表明这些情况超出了所提出方法的分

析能力。这些发现意味着在本研究的实验参数范围内，所提出的方法能够以较高概率可靠地识别真实模型，尺度比在 $T = 1$ 时可达 $r_S = 0.0004$ ，在 $T = 0.1$ 时可达 $r_S = 0.002$ 。

在第 4.2 节中，我们研究了半径比 r_R 的变化影响。当不同半径的组分混合时，不仅需要简单的混合物，还需考虑聚集样品的情况。图 4 和表 4 的结果表明，所提出的方法在 r_R 接近 1 和接近 0 时达到其分析极限。当 r_R 接近 1 时，双组分系统的散射曲线与单组分系统相似，导致单组分模型 ($K = 1$) 被选中。我们在 $T = 1$ 和 $T = 0.1$ 均确定了 $r_R = 0.99$ 处的分析极限。对于 $r_R = 0.97$ ，结果显示在噪声强度较高的 $T = 0.1$ 条件下，单组分模型 ($K = 1$) 的后验概率增加，导致分析不稳定。相反，当 r_R 接近 0 时， $T = 1$ 条件下的 $r_R = 0.03$ 以及 $T = 0.1$ 条件下的 $r_R = 0.04$ 和 $r_R = 0.03$ ，单组分模型 ($K = 1$) 均具有较高概率，表明分析极限。总体而言，所提出的方法能够在 $T = 1$ 时以高概率选择真实模型，适用半径比范围为 $r_R = 0.04$ 到 0.99，在 $T = 0.1$ 时适用范围为 $r_R = 0.05$ 到 0.99。

5.2. 基于代价函数值的模型选择

选择合适的数学模型是 SAS 数据分析中的关键步骤，但仍然具有挑战性。传统上，模型拟合涉及使用诸如 χ -平方误差等指标对一组候选模型进行比较，以辅助模型选择。然而， χ -平方误差假设测量噪声服从高斯分布。本研究中，我们假设测量噪声服从泊松分布，因此通过计算并比较基于测量数据和由 MAP 解得出的拟合曲线的泊松代价函数值（如公式 (3) 所示）在模型 $K = 1 - 4$ 中的表现，来讨论模型选择的结果。

表 5 报告了在模型 $K = 1$ 到 $K = 4$ 中，每个模型最小化泊松代价值的频率。这些结果基于第 4.4 节中描述的不同数据集，这些数据集通过改变随机种子生成，涉及由表 1 中参数确定的 6 个不同 r_S 值，每个 r_S 值在 $T = 1$ 时生成 10 个数据集。

Table 5. 基于泊松代价函数的模型选择结果。

情况 (a)–(f) 对应于第 4.4 节图 1–3 中的设置。表格显示了在 $T = 1$ 时，对于每个 r_S 值，使用不同随机种子生成的 10 个数据集里，每个模型被发现具有最低泊松代价值的次数。若唯一最受支持的模型，则以加粗形式显示。

$r_S \backslash K$	1	2	3	4
(a) 1.0	0	4	2	4
(b) 0.4	0	2	6	2
(c) 0.08	0	3	7	0
(d) 0.002	0	6	3	1
(e) 0.0004	0	5	5	0
(f) 0.0002	1	5	4	0

表 5 中基于泊松代价函数的模型选择结果表明，对于 (a) 和 (e) 两种情况，有两个模型获得了最多支持，表明难以获得可靠结果。在 (b) 和 (c) 两种情况下， $K = 3$ 模型获得最多支持，这可能是由于过拟合导致未能选择正确的模型 $K = 2$ 。此外，当真实模型为 $K = 2$ 时，在 (d) 和 (f) 两种情况下， $K = 3$ 模型获得的支持频率也相似。上述发现表明，基于残差值如泊松代价以及候选模型比较来评估模型对测量数据的拟合优度，并不能始终保证选择出真实模型。

相比之下，表 2-A 中提出方法的结果显示，在从 (a) 到 (e) 的所有 10 个案例中，正确模型 $K = 2$ 均获得支持。在前一小节描述的可分析范围内，模型选择结果对数据噪声表现出高度稳定性。

6. 结论

在本文中，我们引入了贝叶斯模型选择框架用于 SAS 数据分析，通过后验概率定量评估模型的有效性。我们使用单分散球体的两组分系统的合成数据进行了数值实验，以评估所提方法的性能。在本研究的设定下，我们确定了所提方法在两组分球形颗粒的尺度和半径比方面的解析极限。此外，我们将其性能与基于泊松代价函数的传统拟合模型选择方法进行了比较。数值实验及后续讨论揭示了使用所提方法可分析的参数范围。在该范围内，我们的方法即使在数据噪声较大或定性确定模型较为困难的情况下，也能提供稳定且

高度准确的模型选择。进一步地，与基于拟合曲线和数据残差的传统模型选择方法相比，结果表明所提方法在准确性和稳定性方面更具优势。

SAS 被用于研究除球体以外的各种结构样品，包括圆柱体、核壳结构、层状体等。所提方法应用于其他样品模型，以确定是否能够将分析范围从本文研究的案例扩展到更广泛的实验环境。未来的工作可以利用所提方法进行真实数据分析，预计通过我们更高效的分析方法，将获得新的见解。

7. 资助信息

本工作得到了日本科学技术振兴机构 (JST) CREST 项目 (项目编号 PMJCR1761 和 JPMJCR1861) 以及日本学术振兴会 (JSPS) 科学研究费助成项目 (A 类) (编号 23H00486) 的资助。

References

- Asahara, A., Morita, H., Ono, K., Yano, M., Mitsumata, C., Shoji, T. & Saito, K. (2021). 载于 *AAAI Spring Symposium: MLPS*.
- Breßler, I., Kohlbrecher, J. & Thünemann, A. F. (2015). *J. Appl. Crystallogr* **48.5**, 1587–1598.
- Da Vela, S. & Svergun, D. I. (2020). *Curr. Res. Struct. Biol* **2**, 164–170.
- Durant, J. H., Wilkins, L., Butler, K., & Cooper, J. F. (2021). *J. Appl. Crystallogr* **54(4)**, 1100–1110.
- Guinier, A. & Fournet, G. (1955). *X 射线小角散射*. 纽约: Wiley
- Hashimoto, T. (2022). *X 射线、光和中子散射的原理与应用*. 柏林: Springer Nature.
- Hayashi, Y., Katakami, S., Kuwamoto, S., Nagata, K., Mizumaki, M. & Okada, M. (2023). *J. Phys. Soc. Jpn.* **92**, 094002.
- Hukushima, K. & Nemoto, K. (1996). *J. Phys. Soc. Jpn.* **65**, 1604–1608.
- Kashiwamura, S., Katakami, S., Yamagami, R., Iwamitsu, K., Kumazoe, H., Nagata, K., Okajima, T., Akai, I. & Okada, M. (2022). *J. Phys. Soc. Jpn.* **91**, 074009.
- Katakami, S., Sakamoto, H., Nagata, K., Arima, T. H. & Okada, M. (2022). *Phys. Rev. E* **105**, 065301.

- Kline, S. R. (2006). *J. Appl. Crystallogr.* **39**, 895–900.
- Machida, A., Nagata, K., Murakami, R., Shinotsuka, H., Shouno, H., Yoshikawa, H. & Okada, M. (2021). *Sci. Technol. Adv. Mater.* **1**, 123–133.
- Metropolis, N., Rosenbluth, A. W., Rosenbluth, M. N., Teller, A. H. & Teller, E. (1953). *J. C. Phys.* **21**, 1087–1092.
- Moriguchi, R., Tsutsui, S., Katakami, S., Nagata, K., Mizumaki, M. & Okada, M. (2022). *J. Phys. Soc. Jpn.* **91**, 104002.
- Nagai, K., Anada, M., Nakanishi-Ohno, Y., Okada, M. & Wakabayashi, Y. (2021). *Appl. Crystallogr.* **54**, 1023–1023.
- Nagata, K., Muraoka, R., Mototake, Y. I., Sasaki, T. & Okada, M. (2019). *J. Phys. Soc. Jpn.* **88**, 044003.
- Nagata, K., Sugita, S. & Okada, M. (2012). *Neural Netw.* **28**, 82–89.
- Rambo, R. P., & Tainer, J. A. (2013). *Nature* **496**(7446), 477–481.
- Rappel, H., Beex, L. A., Hale, J. S., Noels, L. & Bordas, S. P. A. (2020). *Arch. Computat. Methods Eng.* **27**, 361–385.
- Schneidman-Duhovny, D., Hammel, M. & Sali, A. (2010). *Nucleic Acids Res.* **38**, W540–W544.
- Straasø, T., Mütter, D., Sørensen, H. O., & Als-Nielsen, J. (2013). *J. Appl. Crystallogr* **46**(3), 663–671.
- Svergun, D. I., Barberato, C. & Koch, M. H. J. (1995). *J. Appl. Crystallogr.* **28**, 768–773.
- Ueda, H., Katakami, S., Yoshida, S., Nakai, Y., Mito, T., Mizumaki, M. & Okada, M. (2023). *J. Phys. Soc. Jpn.* **92**, 054002

Synopsis

我们提出了一种贝叶斯方法，用于定量选择小角散射样品的数学模型，并通过对包含多种球形颗粒混合物的样品的人工数据进行数值实验，评估了该方法的性能。
