

用于一阶优化的组合框架

Tyler Hanks

Matthew Klawonn

Matthew Hale

Evan Patterson

James Fairbanks

摘要

优化分解方法是开发分布式求解算法的基本工具，适用于机器学习、最优控制和运筹学等领域中出现的大规模优化问题。本文提出了一个代数框架，用于在超图上分层组合定义的优化问题，并自动生成遵循给定分层结构的分布式求解算法。我们框架的核心抽象是 operads、operad 代数和代数态射，分别形式化了语法、语义和保持结构的语义变换的概念。这些抽象使我们能够形式化地将复合优化问题与解决它们的分布式算法联系起来。具体而言，我们展示了某些类别的优化问题构成 operad 代数，一组一阶求解方法，即梯度下降、Uzawa 算法（也称为梯度上升-下降）及其次梯度变体，产生了从这些问题代数到动力系统代数的代数态射。然后，通过将这些态射应用于某些类别的复合问题，即可恢复原始和对偶分解方法。利用该框架，我们还推导出一个新的充分条件，用于判断由组合数据定义的问题是否可由分解方法求解。我们证明了最小成本网络流问题满足该条件，从而使我们能够自动推导出用于在复合流网络上寻找最小成本流的分层对偶分解算法。我们在 Julia 包 AlgebraicOptimization.jl 中实现了我们的 operads、代数和代数态射，并通过实证演示，分层对偶分解在具有分层结构的流网络类别上优于标准对偶分解。

Keywords— optimization, convex optimization, decomposition methods, category theory

1 引言

分解方法，如原始分解和对偶分解，是为机器学习中出现的大规模优化问题开发分布式求解算法的基础工具 [1, 2]，最优控制 [3, 4] 和运筹学 [5, 6] 中的关键方法。这些方法通常通过将一个大问题拆分为若干个更简单的子问题，并反复求解这些子问题，从而得到原问题的解。因此，分解方法最自然地适用于那些本身是若干子问题的复合体的问题，在某种适当的复合意义上。我们称这类问题具有复合结构。通常情况下，问题层面的复合结构是隐含的，需要专业知识来判断是否可以应用分解方法。此外，将给定问题转换为可分解的等价问题也可能非平凡。

另一方面，当复合问题结构被明确提出时，分解方法通常可以更直接地应用。具有显式复合结构的常见示例是定义在图和超图上的问题，其中节点表示子问题，（超）边表示子问题之间的耦合。明确复合结构的好处在于，通过固定节点上可以存在的问题类型和子问题之间允许的耦合类型，可以推导出一种适用于定义在任意图或超图上的问题的分解方法 [7, 8, 9]。从这个意义上讲，图和超图上的问题可以被视为适合应用分解的标准形式。然而，将给定问题或定义问题实例的数据转换为这种标准形式仍然具有挑战性。

因此，我们的动机是开发一个通用的分解方法框架，该框架既能够显式地表示复合结构，又能提供一种有原则的方法将问题数据转换为这种显式结构。本文通过引入一种关于一阶优化分解方法的新颖代数/结构视角，迈出了实现这一目标的基础性一步。

该框架的核心抽象围绕着无向布线图（UWDs），它们是一类带有特殊边界节点的超图。无向布线图构成一种称为运算符的句法结构，允许通过递归替换分层构造 UWDs [10]。无向布线图的运算符上的代数，简称 UWD-代数，为 UWDs 提供尊重其分层结构的形式语义解释。直观地说，UWD-代数指定了如何构建互联系统，其中互联模式可以被 UWD 表示。因此，UWD-代数已被用于定义网络风格的组合操作，适用于一系列组合对象，如带标签的图 [11]、电路 [12] 和 Petri 网络 [13]，以及定量对象，如线性和凸关系 [14, 15]、马尔可夫过程 [16] 和动力系统 [17]。UWD-代数也为建模定义在超图上的优化问题提供了自然的抽象，本论文即采用此方法。

UWD-代数态射则提供了不同 UWD 语义解释之间的结构保持变换。利用这一机制，我们框架的核心思想可总结如下：如果一个一阶优化算法定义了从优化问题的 UWD-代数到动力系统的 UWD-代数的代数态射，则该算法能够分解定义在任意 UWD 上的问题。此外，将该态射应用于问题会生成一个动力系统，利用消息传递语义以分布式方式求解该问题。

具体到这一通用模式的示例，我们首先定义了一个一次可微（记为 C^1 ）、无约束最小化问题的 UWD-代数，记为 Opt ，并证明梯度下降是从 Opt 到离散动力系统的 UWD-代数 Dynam_D 的代数态射，即它是态射

$$\text{gd}^\gamma: \text{Opt} \rightarrow \text{Dynam}_D, \quad (1)$$

其中 $\gamma > 0$ 是固定步长。

借助梯度下降态射，我们进一步展示了通过将 gd^γ 应用于不同类型的复合问题，可以恢复梯度下降和原始分解的分布式消息传递版本。 gd^γ 的自然性意味着求解复合问题的分解求解算法等价于直接用梯度下降法求解整个复合问题。此外，梯度代数态射保持超图结构，意味着定义在任意 UWD 上的问题均可被分解。如图 1 所示。非正式地，我们可以将这些结果总结为：对于任意子问题和复合模式，以下图表交换：

$$\begin{array}{ccc} \text{Subproblems} & \xrightarrow{\text{compose}} & \text{Problem} \\ \downarrow \text{gradient descent} & & \downarrow \text{gradient descent} \\ \text{Subsystems} & \xrightarrow{\text{compose}} & \text{System} \end{array}$$

传统定义在图和超图上的分解方法的另一个缺点是结果分解是扁平的，即存在一个单一的主问题协调所有子问题。然而，许多实际问题展现出分层复合结构，其中子问题本身也可以是较低层子问题集合的主问题 [18][19] [20]。利用分层结构通常能进一步加快求解速度。因此，我们框架的另一优势是能够捕捉并利用此类分层结构。具体而言，以运算符代数表述我们的结果明确表明，我们可以通过递归替换 UWD 层次地组合优化问题，且梯度下降必须尊重这种分层复合。

迄今为止，我们仅讨论了梯度下降应用于非凸可微最小化问题。此外，本文还给出了一系列密切相关的结果，涵盖不同类型的问题，包括无约束和等式约束凸规划，以及各种一阶求解方法，如 Uzawa 算法 [21]（又称梯度上升-下降法）和原始-对偶亚梯度方法 [22]。具体而言，我们证明了每种问题类型定义了一个 UWD-代数，每种求解方法提供了到动力系统的代数态射。本文呈现的完整结果层次见图 2。这些扩展结果使得我们能够在同一通用框架内推导出 Uzawa 算法和对偶分解的消息传递版本。

这一关于分解算法的新颖视角使我们能够推导出一个新的充分条件判定问题是否可分解：即如果存在一个从定义问题数据的 UWD-代数到我们定义的优化问题代数的代数态射，将问题数据转换为优化问题，我们称之为复合数据条件。满足复合数据条件也是一种构造性证明，因为将问题转换态射与相应的（子）梯度态




图 1: A. 一个无向接线图 (UWD) 的示例, 它是一种特殊类型的超图。每个盒子都有一组有限的连接点, 我们称之为 端口。小圆圈称为 连接点, 连接端口与连接点的边称为 导线。重要的是, 每个 UWD 都有一个 边界, 通过大外框进行可视化。我们分别将内盒和外盒上的端口称为 内部端口 和 外部端口。B. 将 (A) 中的 UWD 解释为复合优化问题。子问题位于盒子内, 其优化变量位于导线上。由同一连接点连接的子问题共享该连接点处导线上对应的变量。C. 将 (A) 中的 UWD 解释为复合动态系统。子系统位于盒子内, 其状态变量位于导线上, 连接点指示哪些状态变量是共享的。共享状态变量的变化通过对贡献子系统的变化求和计算 (由矩阵 K^T 编码)。梯度下降提供了一个从目标函数语义到动态系统语义的结构保持映射。




图 2: 本文中展示结果的完整层次结构。节点表示各种构建的 UWD-代数, 包括用于组合鞍点问题、凸问题、凹问题的代数, 均涵盖有无可微性假设的情况, 以及组合确定性和非确定性动力系统的代数。带钩箭头表示一个代数包含于另一个代数中。无钩箭头表示代数态射, 包括梯度下降 (gd)、梯度上升-下降 (ga-d) 和原始-对偶次梯度方法 (pd-subg)。将包含关系与梯度代数态射组合, 可得凸问题的 (次) 梯度下降和凹问题的 (超) 梯度上升。

射组合即可得到分布式求解算法。该条件为将问题数据转换为可利用分解的显式复合问题结构提供了有原则的方法。为展示该充分条件的应用, 我们证明最小费用网络流 (MCNF) 问题定义了从流网络 UWD-代数到无约束凹优化问题 UWD-代数的代数态射, 与梯度上升态射组合后, 获得了求解 MCNF 的标准对偶分解算法的推广。

总而言之, 我们的贡献如下。

1. 我们构建了一族用于分层组合不同类型问题的 UWD-代数, 包括非凸的 C^1 问题以及无约束和等式约束的凸规划问题。
2. 我们证明了梯度下降法和 Uzawa 算法是从各自的问题代数到动力系统代数的代数态射。我们进一步证明了这些算法的次梯度变体也提供了到一种新颖的 非确定性 动力系统的 UWD-代数的代数态射。
3. 基于这些结果, 我们提出了一个新颖的充分条件, 用于判断问题在数据代数到问题代数的代数态射意义下的可分解性。
4. 作为该充分条件的一个示范, 我们构造了一个流网络的 UWD-代数, 并证明将流网络转换为其对应的最小费用网络流优化问题的过程产生一个代数态射。将该态射与梯度上升态射复合, 得到一个分层对偶分解求解算法。
5. 我们在 Julia 编程语言中实现了该框架的原型, 并通过实验演示了如何利用流网络的分层分解的高层次组合结构来提升求解时间效率。

我们希望该框架的呈现能从以下方面惠及优化领域的研究者和实践者:

- **实现.** 正如有纪律的凸规划 [23] 降低了指定和求解凸优化问题的门槛，我们的框架旨在降低 构建 优化问题并自动生成分布式求解算法的门槛。
- **性能.** 众所周知，利用问题结构可以提高性能，而我们的框架能够容纳多种结构以实现这一点。例如，我们展示了由我们的框架生成的算法在求解复合网络的最小成本网络流问题时，性能优于集中式求解方法和传统分布式算法，这一性能提升是通过利用流网络中的大规模组合结构实现的。
- **形式化可视化.** 无向布线图为构建问题提供了直观的图形语法。此外，UWD-代数为该图形语法赋予了形式且明确的语义，使得图可以自动编译为可执行代码。
- **泛化.** 在我们的框架中，原始分解和对偶分解都作为应用同一 UWD-代数态射的特例被恢复。因此，我们的框架还支持以分层方式结合原始分解和对偶分解。我们希望通过提供构建分布式优化算法的通用工具，能够更容易地发现和实现新的独特算法。
- **与其他领域的关系.** 用范畴论的语言表述我们的成果，使得优化分解方法置于更广泛的数学背景中。例如，监督学习 [24, 25]、最优控制 [26] 以及博弈论 [27, 28] 都已使用相关的范畴抽象进行研究。我们希望通过用相同语言框定优化分解方法，能够进一步阐明这些领域之间的联系。

本文余下部分结构安排如下。第 2 节介绍优化和范畴论相关的数学背景。具体地，第 2.3 节回顾运算符、运算符代数和运算符代数态射的定义，这些是我们构建框架的核心抽象。第 3 节证明梯度下降是从可微最小化问题的 UWD-代数到动力系统的 UWD-代数的代数态射这一基本结果。此时，框架核心已建立。后续章节聚焦扩展、推广及示例。

具体地，第 4 节将框架扩展至处理等式约束凸规划，证明 Uzawa 算法产生从可微鞍函数的 UWD-代数到动力系统的代数态射。第 5 节进一步推广至处理等式约束非可微凸问题的原始-对偶亚梯度方法。为实现此推广，我们引入了连续和离散非确定性动力系统的新 UWD-代数，并证明欧拉方法在非确定性环境下也是代数态射。

转向应用，第 6 节通过构造流网络的 UWD-代数并证明最小费用网络流问题定义了到凹优化问题代数的代数态射，展示了复合数据条件的示例应用。第 7 节展示了基于我们用 Julia 实现的框架所得的实验结果。最后，第 8 节给出结论性评论及未来工作方向。

2 预备知识

本文汇集了一阶优化和范畴论的概念。我们假设读者已了解范畴论的基本概念，如范畴、函子和自然变换。对对称幺半范畴和松幺半函子有一定了解也会有所帮助。为了方便起见，我们在附录 A 中整理了一些重要的范畴论定义。关于基础范畴论的更完整讲解，可以参考多本优秀的入门教材 [29, 30, 31]。关于幺半范畴论的介绍，推荐读者参考 [32]。凸分析和优化的标准参考书为 [33] 和 [34]。

2.1 符号说明

- 给定一个 $n \in \mathbb{N}$ ，我们用 $[n]$ 表示集合 $\{1, \dots, n\}$ 。
- 给定一个线性映射 $T: V \rightarrow W$ ，我们用 $\mathcal{M}(T)$ 表示 T 关于选定基的矩阵表示。
- 我们用 C^1 表示一次连续可微函数的集合。
- 我们用 $+$ 表示两个对象的余积，用 $\coprod$ 表示任意集合对象的余积。同样地，我们用 $\times$ 表示两个对象的笛卡尔积，用 $\prod$ 表示任意集合对象的笛卡尔积。

2.2 一阶优化

在本节中，我们回顾一阶优化的基础知识，例如用于求解无约束最小化问题的梯度下降法以及用于求解约束最小化问题的 Uzawa 算法。我们还简要介绍了次梯度和超梯度的概念，以及它们如何将一阶方法推广到不可微问题。

一阶优化方法仅利用目标函数的函数值（零阶信息）和目标函数的一阶导数（梯度，即一阶信息）来寻找实值目标函数的极值。回顾可微 **目标函数** $f: \mathbb{R}^n \rightarrow \mathbb{R}$ 在点 $x \in \mathbb{R}^n$ 处的梯度，它定义了从 x 出发能够最快增加函数值 f 的方向。因此，如果我们的任务是最小化 f ，最自然的方法是梯度下降，其迭代过程为

$$x_{k+1} := x_k - \gamma \nabla f(x_k) \quad (2)$$

从给定的起始值 x_0 开始，其中 $\gamma > 0$ 是一个称为 **步长** 或在机器学习中称为 **学习率** 的参数。我们称 x 为 **决策变量** 或 **优化变量**。一般而言，梯度下降优化方案可以被看作是一个由 $n \in \mathbb{N}$ 索引的映射族

$$\text{gd}_n: (\mathbb{R}^n \rightarrow \mathbb{R}) \rightarrow (\mathbb{R}^n \rightarrow \mathbb{R}^n) \quad (3)$$

它将可微目标函数 $f: \mathbb{R}^n \rightarrow \mathbb{R}$ 映射为光滑映射 $-\nabla f: \mathbb{R}^n \rightarrow \mathbb{R}^n$ [35]。该光滑映射隐式定义了连续和离散的动力系统。连续系统由常微分方程组（ODE）

$$\dot{x} := -\nabla f(x) \quad (4)$$

给出，称为梯度流，而离散系统可以通过对连续系统应用欧拉方法获得。具体来说，给定一个光滑映射 $d: \mathbb{R}^n \rightarrow \mathbb{R}^n$ 定义的 ODE $\dot{x} := d(x)$ ，欧拉方法对于给定步长 $\gamma > 0$ 给出离散系统 $x_{k+1} := x_k + \gamma d(x_k)$ 。因此，离散梯度下降算法是对梯度流应用欧拉方法的结果。

在合适选择步长并对 f 施加适度假设的条件下，梯度下降保证收敛至局部最小值。在对 f 施加更严格的凸性假设下，梯度下降可以证明收敛到全局最小值。回顾函数 $f: \mathbb{R}^n \rightarrow \mathbb{R}$ 是 **凸的**，如果它满足詹森不等式，即

$$f(tx + (1-t)y) \leq tf(x) + (1-t)f(y) \quad (5)$$

对所有 $x, y \in \mathbb{R}^n$ 和 $t \in [0, 1]$ 均成立。当 (5) 中的不等式严格成立时，称 f 为 **严格凸**。

梯度下降的基本思想同样可以推广到求解带约束的最小化问题。一个通用的等式约束最小化问题 P 具有标准形式

$$P: \begin{cases} \text{minimize} & f(x) \\ \text{subject to} & h(x) = 0. \end{cases}$$

函数 $h: \mathbb{R}^n \rightarrow \mathbb{R}^m$ 定义了 m 个 **等式约束**。如果 f 是凸函数且 $h(x) = Ax - b$ 是仿射的，则 P 是一个凸优化问题。在第 2 节的其余部分，我们考虑这种情况。求解 P 的标准方法是通过拉格朗日松弛，它将受约束问题在 $\mathbb{R}^n$ 中松弛为无约束问题在 $\mathbb{R}^{n+m}$ 中。具体地， P 的 **拉格朗日函数**为

$$L(x, \lambda) := f(x) + \lambda^T (Ax - b). \quad (6)$$

$\lambda \in \mathbb{R}^m$ 的分量称为 **拉格朗日乘子**，每个约束对应一个乘子。拉格朗日函数是一个 **鞍函数**，因为对于任意固定的 λ ，它在 x 上是凸的，而对于任意固定的 x ，它在 λ 上是凹的。拉格朗日的关键见解是， L 的鞍点，即点 $(\hat{x}, \hat{\lambda}) \in \arg \min_{x \in \mathbb{R}^n} \arg \max_{\lambda \in \mathbb{R}^m} L(x, \lambda)$ ，对应于约束问题 P 的受约束极小值。因此，寻找 L 的鞍点足以求解 P ([34], §5.4.2)。

Uzawa 算法是一种梯度下降法的直接推广，用于寻找鞍函数的鞍点。具体来说，它对鞍函数的凸部分执行梯度下降，对凹部分执行梯度上升。将其应用于拉格朗日函数 L ，得到算法

$$\begin{aligned} x_{k+1} &:= x_k - \gamma \nabla_x L(x_k, \lambda_k) \\ \lambda_{k+1} &:= \lambda_k + \gamma \nabla_\lambda L(x_k, \lambda_k). \end{aligned} \quad (7)$$

这同样可以看作是对连续系统应用欧拉离散化，我们称之为鞍流：

$$\begin{aligned}\dot{x} &:= -\nabla_x L(x, \lambda) \\ \dot{\lambda} &:= \nabla_\lambda L(x, \lambda).\end{aligned}\tag{8}$$

在与梯度下降相似条件下，Uzawa 算法收敛到 L 的鞍点。

最后，这些思想大多可以推广到 f 和 h 仍分别是凸函数和仿射函数，但不一定可微的情况。例如，绝对值函数是一个常见的凸但在零点不可微的目标函数。对这类函数的最小化通过梯度的推广，即凸函数的次梯度来实现。

Definition 2.1. 给定一个凸函数 $f: \mathbb{R}^n \rightarrow \mathbb{R}$ ，若向量 $v \in \mathbb{R}^n$ 满足对于任意 $y \in \mathbb{R}^n$ ，

$$f(y) - f(x) \geq v^T(y - x),\tag{9}$$

则称 v 是点 $x \in \mathbb{R}^n$ 处的一个**次梯度**。所有满足该条件的向量的集合称为 f 在 x 处的**次微分**。

类似地，当 f 为凹函数时，若向量 $w \in \mathbb{R}^n$ 满足对于任意 $y \in \mathbb{R}^n$ ，

$$f(y) - f(x) \leq w^T(y - x),\tag{10}$$

则称 w 是点 $x \in \mathbb{R}^n$ 处的一个**超梯度**。所有满足该条件的向量的集合称为 f 在 x 处的**超微分**。函数 f 在 x 处的超微分和次微分均记为 $\partial f(x)$ ；超微分与次微分的区别可由上下文明确区分。

凸函数 f 在点 x 处的次微分集是 f 在 x 处的仿射下近似的集合。当 f 在 x 处可微时， $\partial f(x)$ 是单元素集合 $\{\nabla f(x)\}$ ，这意味着次梯度是凸函数梯度的一个恰当推广。

次微分集是求解不可微凸函数极小值的迭代算法的基础，称为次梯度下降。对于凸目标函数 $f: \mathbb{R}^n \rightarrow \mathbb{R}$ ，其简单迭代为

$$x_{k+1} = x_k - \gamma \rho_k,\tag{11}$$

其中 ρ_k 是 f 在 x_k 处的任意一个次梯度¹。次梯度下降的连续时间对应物是次梯度微分包含，给定系统为

$$\dot{x} \in -\partial f(x).\tag{12}$$

需要注意的是，由于次微分集是点到集合的映射，这些动力系统是非确定性的，意味着在给定状态下，它们可能沿不同方向演化。尽管存在这种非确定性，次梯度下降仍能收敛到距离极小值的 ϵ -邻域内，其中 ϵ 随步长大小变化。通过结合次梯度和超梯度，这类方法可以扩展到寻找不可微鞍函数的极值。

2.3 无向接线图的代数

无向接线图 (UWD) 是一种组合对象，表示盒子和连接点之间的互连模式。具体来说，UWD 由有限集合的盒子和连接点组成。每个盒子都有与之关联的有限端口集合，每个端口连接到一个连接点。其中一个盒子被指定为外部盒子，内部盒子和外部盒子上的端口分别称为内部端口和外部端口。图

本节的目标是定义无向接线图的代数结构，并展示如何通过松弛对称幺半群函子 $(\mathbf{FinSet}, +) \rightarrow (\mathbf{Set}, \times)$ 来指定它们，我们称之为 **finset 代数**。同样，我们讨论 finset 代数之间的幺半群自然变换如何产生 UWD-代数的态射。这些将成为贯穿全文反复使用的核心抽象。我们 $P_1 + \dots + P_n \xrightarrow{l} J \xleftarrow{r} P'_2$ 中的连续和离散动力系统作为 UWD-代数的示例，以及 Euler 方法作为从连续到离散的代数态射为基础，来具体说明本节内容。

¹该次梯度方法不保证每次迭代都下降。但通过记录迄今为止找到的最优迭代点，可以使其成为一个下降方法。




图 3: 函数 $\phi: [2] + [3] \rightarrow [4]$ 、推前映射 ϕ_* 对输入对 (x, y) 的作用以及拉回映射 ϕ^* 对输入 z 的作用之间关系的可视化。推前映射根据 ϕ 对 (x, y) 的分量进行求和，而拉回映射根据 ϕ 复制 z 的分量。

直观来说，无向接线图提供了一种合成的语法，可以赋予各种语义。形式上，UWD 构成一个运算符范畴，而语义的特定选择则由一个运算符代数给出。

今后，我们将简写运算符范畴为指称对称有色运算符范畴。一个基本但重要的运算符范畴是集合的运算符范畴。

<PLACEHOLDER_ENV₂2>

为了说明 UWD 如何构成运算符范畴，首先注意任意带有 n 个内部盒子的 UWD 可由一对函数编码： $P_1 + \dots + P_n \xrightarrow{l} J \xleftarrow{r} P'$ ，其中 P_i 是第 i 个盒子的内部端口集合， J 是连接点集合， P' 是外部端口集合。函数 l 编码内部端口与连接点的连接模式，而 r 编码外部端口与连接点的连接模式。这样一对具有共同余域的态射称为 **余跨**。图 *Flicit_uwd* 显示了 UWD 与其余跨表示之间的对应关系示例。

<PLACEHOLDER_ENV₂3>

尽管 UWD 的合成在形式上定义较为复杂，但其直观解释十分明了。它取一个含有 n 个内部盒子的“目标”UWD 及 n 个“填充”UWD，并将每个填充 UWD 替代目标 UWD 中对应的内部盒子。该操作仅当每个填充 UWD 的外部端口数与其填充的内部盒子端口数相同才有定义。

定义了 UWD 的运算符范畴和集合的运算符范畴后，我们即可构造 UWD-代数，为 UWD 赋予语义解释。它们是运算符函子的特例，运算符函子是范畴函子的运算符范畴对应物。

<PLACEHOLDER_ENV₂4> 我们可以将 UWD-代数 F 应用于有限集 X ，理解为定义可填充具有 X 连接点的盒子的可能

<PLACEHOLDER_ENV₂5> 直观上， α 的自然性即表明先用 F 合成对象再将合成结果转换为 G 的对象，等价于先转换每个

上述运算符定义与 (i) 对称幺半群范畴 (SMCs)，(ii) 松弛对称幺半群函子，以及 (iii) 幺半群自然变换之间存在重要联系（这些定义详见附录 A.3）。具体而言，每个 SMC $(\mathcal{C}, \otimes)$ 都有一个基础运算符范畴 $\mathcal{O}(\mathcal{C})$ ，其对象与 $\mathcal{C}$ 相同，态射 $\mathcal{O}(\mathcal{C})(s_1, \dots, s_n; t)$ 即 $\mathcal{C}$ 中形如 $s_1 \otimes \dots \otimes s_n \rightarrow t$ 的态射。例如，**Sets** 是 SMC $(\mathbf{Set}, \times)$ 的基础运算符范畴。类似地，UWD 是 SMC $(\mathbf{Cospan}, +)$ 的基础运算符范畴，其中有限集的余跨构成范畴，合成由推挤给出，幺半群积由不交并给出。此外，每个松弛对称幺半群函子 $(F, \varphi): (\mathcal{C}, \otimes) \rightarrow (\mathcal{D}, \boxtimes)$ 都诱导一个运算符函子 $\mathcal{O}(F): \mathcal{O}(\mathcal{C}) \rightarrow \mathcal{O}(\mathcal{D})$ ，在对象上与 F 相同，对态射 $f: X_1 \otimes \dots \otimes X_n \rightarrow Y$ 的作用定义为

<PLACEHOLDER_ENV₂6> 因此，我们可以通过指定松弛对称幺半群函子 $(\mathbf{Cospan}, +) \rightarrow (\mathbf{Set}, \times)$ 来定义 UWD-代数，这些亦称为 **余跨代数**

Example 2.2 (Pushforwards and Pullbacks). Given a finite set N , the set of functions $\{N \rightarrow \mathbb{R}\} = \mathbb{R}^N$ is a vector space, which is called the **free vector space** generated by N . If we let $n := |N|$ be the cardinality of

N , then choosing an ordering $N \xrightarrow{\cong} [n]$ on N induces an isomorphism of vector spaces $\mathbb{R}^N \cong \mathbb{R}^n$. We can thus think of the free vector space $\mathbb{R}^N$ as standard n -dimensional Euclidean space, but where each basis vector is labelled by an element of N . This free vector space construction will be essential for creating UWD-algebras whose semantics are given by functions defined on $\mathbb{R}^n$ such as objective functions and dynamical systems. First, we consider two ways of constructing linear maps between free vector spaces that give rise to finset algebras.

Given a function $\phi: N \rightarrow M$ between finite sets, the **pushforward** along ϕ is the linear map $\phi_*: \mathbb{R}^N \rightarrow \mathbb{R}^M$ defined by

$$\phi_*(x)_j := \sum_{i \in \phi^{-1}(j)} x_i \quad (13)$$

for all $x \in \mathbb{R}^N$ and $j \in M$. This lets us define the *strong*² finset algebra $(-)_*: (\mathbf{FinSet}, +) \rightarrow (\mathbf{Set}, \times)$, which takes finite sets to their free vector spaces and functions between finite sets to their pushforwards. The product comparison is given by the isomorphisms $\varphi_{N,M}: \mathbb{R}^N \times \mathbb{R}^M \cong \mathbb{R}^{N+M}$, while the unit comparison $\varphi_0: 1 \rightarrow \mathbb{R}^0$ is unique because $\mathbb{R}^0$ contains only the zero vector.

Given a function $\phi: X + Y \rightarrow Z$, we can apply this finset algebra to produce a linear map which takes a pair of vectors $x \in \mathbb{R}^X$ and $y \in \mathbb{R}^Y$ as input, applies the product comparison isomorphism to concatenate x and y into a single vector, then applies the pushforward ϕ_* to the resultant vector.

A dual operation to the pushforward along ϕ is the **pullback** along ϕ , which is the linear map $\phi^*: \mathbb{R}^M \rightarrow \mathbb{R}^N$ defined by

$$\phi^*(y)_i := y_{\phi(i)} \quad (14)$$

for all $y \in \mathbb{R}^M$ and $i \in N$. It is straightforward to show that the pullback along ϕ is dual as a linear map to the pushforward along ϕ . The pullback operation defines a *contravariant* finset algebra $(-)^*: (\mathbf{FinSet}^{op}, +) \rightarrow (\mathbf{Set}, \times)$ taking finite sets to their free vector spaces and functions to their pullbacks. The product comparisons and unit comparison are the same as those of $(-)_*$, but in the opposite direction. This algebra takes a function $\phi: X + Y \rightarrow Z$ and a vector $z \in \mathbb{R}^Z$ and produces a pair of vectors in $\mathbb{R}^X \times \mathbb{R}^Y$ by copying components of z into the respective components of the results dictated by ϕ . This is illustrated in Figure 3.

直观上, finset 代数作用于态射 $\phi: X_1 + \dots + X_n \rightarrow Y$ 指定如何将定义在 $X_1, \dots, X_n$ 上的 n 元组对象合成为定义在 Y 上的单个对象。这样的作用足以指定一个 UWD-代数, 如下引理所述。


证明. 这是将 *maph2019* 中证明的超图范畴与余跨代数等价性应用于 [38] 中引入的 F -装饰余跨的超图范畴的例子。直接证明也很简单。□

我们可以通过重新以 UWD 视角思考来加深对该引理的直观理解。应用 $FCsp$ 于 X 得到的三元组集合 $(S, o, m: X \rightarrow S)$ 对应于填充具有 X 个端口的 UWD 盒子的填充物集合。然而, 填充盒子的对象允许有域 S , 不必与 X 相同, 且映射 $m: X \rightarrow S$ 确定盒子端口与填充对象域之间的关系。将余跨 $\Phi := X \xrightarrow{l} J \xleftarrow{r} Y$ 视为 UWD, 映射 $l: X \rightarrow J$ 指定内部端口与连接点的粘合方式。通过对 m 和 l 取推挤, 映射 $p_S: S \rightarrow S +_X J$ 指定了如何将填充每个盒子的对象的域粘合在一起: 若两个端口经 l 映射至同一连接点, 则它们经 m 映射后再经 p_S 也会映射至 $S +_X J$ 中的同一元素。

从该视角看, 基本操作是将 F 作用于函数 p_S , 它应指定如何根据 p_S 将域 S 上对象的各部分粘合成域为 $S +_X J$ 的对象。剩余操作本质上是保持账目一致以生成以此新对象为填充物的有效 UWD。

²A strong symmetric monoidal functor is one whose comparison maps are all isomorphisms (see Definition A.10).

Remark 2.3. 考虑一个由有限集代数 F 通过应用引理 2.6 生成的 UWD-代数 $FCsp$ 。如果我们将注意力限制在形如 $\Phi := (X \xrightarrow{\phi} J \cong Y)$ 的 UWD 上, 使得每个结合点映射到唯一的外部端口, 并且仅考虑形如 $(S, o \in F(S), X \xrightarrow{\cong} S)$ 的代数对象 $FCsp(X)$, 那么我们得到一个与有限集代数 F 直接对应的子代数。具体地, 定义函数 $FCsp(\Phi): FCsp(X) \rightarrow FCsp(Y)$ 所需的推出图为



并且 $FCsp(\Phi)(S, o, X \xrightarrow{\cong} S)$ 的结果是 $(J, F(\phi)(o), Y \xrightarrow{\cong} J)$ 。

因此, 在这个受限的情况下, 当外部端口集合与结合点集合同构, 且每个 UWD 填充器的定义域同构于其所填充盒子的端口集合时, 我们通过简单地将有限集代数 F 应用于将内端口映射到结合点的函数 ϕ , 即可得到所得到的复合对象。

我们将在部分例子中利用该简化, 但我们强调, 这些机制对一般的 UWD 和代数对象仍然适用。

类似地, 我们可以利用 finset 代数之间的幺半群自然变换定义余跨代数之间的幺半群自然变换。

$\langle \text{PLACEHOLDER}_{ENV_30} \rangle$

证明. 这是将[?]中证明的余跨代数态射与超图函子等价性应用于通过 [38] 定理 2.8 诱导的超图函子 α 的例子。□

总结, 我们可以通过对 finset 代数 F 应用引理 2.6 构造余跨代数 $FCsp$, 再取其基础运算符函子 $\mathcal{O}(FCsp)$, 从而构建 UWD-代数。类似地, 给定 finset 代数 F 与 G 及其幺半群自然变换 $\alpha: F \Rightarrow G$, 通过引理 2.10 构造幺半群自然变换 $\alpha': FCsp \Rightarrow GCsp$, 其分量也定义了代数态射 $\alpha': \mathcal{O}(FCsp) \Rightarrow \mathcal{O}(GCsp)$ 。

本文中定义的所有 UWD-代数均通过上述方式由 finset 代数生成。同理, 所有代数态射均由 finset 代数之间的幺半群自然变换诱导。因此, 在本文余下部分, 我们将省略 finset 代数与其对应 UWD-代数之间的区别。具体地, 每当定义一个 finset 代数 F , 其后对

$$F$$

的使用均隐含指代 $\mathcal{O}(F \bullet \omega \mathcal{F})$ 。 $\langle \text{PLACEHOLDER}_{ENV_31} \rangle$

Example 2.4 (动力系统的组合). 存在一个有限集代数 $\text{Dynam}: (\mathbf{FinSet}, +) \rightarrow (\mathbf{Set}, \times)$, 由以下映射定义:

- 在对象上, Dynam 将有限集 N 映射为光滑映射集合 $\{v: \mathbb{R}^N \rightarrow \mathbb{R}^N\}$ 。
- 给定 $\mathbf{FinSet}$ 中的态射 $\phi: N \rightarrow M$, $\text{Dynam}(\phi): \text{Dynam}(N) \rightarrow \text{Dynam}(M)$ 由映射 $v \mapsto \phi_* \circ v \circ \phi^*$ 定义。
- 给定有限集 N 和 M , 积比较映射 $\varphi_{N,M}: \text{Dynam}(N) \times \text{Dynam}(M) \rightarrow \text{Dynam}(N+M)$ 由函数

$$(v, \rho) \mapsto \iota_{N*} \circ v \circ \iota_N^* + \iota_{M*} \circ \rho \circ \iota_M^*, \quad (15)$$

给出, 其中 $\iota_N: N \rightarrow N+M$ 和 $\iota_M: M \rightarrow N+M$ 是自然包含映射。

- 单位比较映射 $\varphi_0: \{*\} \rightarrow \text{Dynam}(\emptyset)$ 唯一确定, 因为映射集合 $\{\mathbb{R}^0 \rightarrow \mathbb{R}^0\}$ 是单元集合。


该例子内容见文献 [13] 中的引理 15 和 16。

我们现在可以应用引理 2.6 来获得用于组合动力系统的 UWD-代数。对于一个具有 X 个端口的 **Dynam**-UWD，盒子的填充器是三元组 $(S, v: \mathbb{R}^S \rightarrow \mathbb{R}^S, m: X \rightarrow S)$ 。我们称这样的对象为开放动力系统，因为它仅指定系统的部分状态变量作为与其他系统共享的开放变量。这个决定由映射 $m: X \rightarrow S$ 确定。UWD 中端口到连接点的连接模式指定了一个系统的哪些开放状态变量与其他系统的哪些开放状态变量共享。通过 **Dynam** 得到的复合系统的整体直观图景是，共享状态变量的变化是贡献子系统变化的总和，而 UWD 指示哪些状态变量被共享。

现在，我们明确展开由 **Dynam** UWD-代数给出的复合定义。首先，给定一个 UWD $\Phi: X_1 + \dots + X_n \xrightarrow{l} J \xleftarrow{r} Y$ 及其组件开放动力系统 $(S_i, v_i: \mathbb{R}^{S_i} \rightarrow \mathbb{R}^{S_i}, m_i: X_i \rightarrow S_i)$ ，对于所有 $i \in [n]$ ，积比较应用于组件系统以生成一个单一系统，可以视为输入系统的无交集并集。具体来说，这是开放系统 $(S := S_1 + \dots + S_n, v: \mathbb{R}^S \rightarrow \mathbb{R}^S, m := m_1 + \dots + m_n)$ ，其中动力学 v 由

$$\sum_{i=1}^n \iota_{S_i*} \circ v_i \circ \iota_{S_i}^*. \quad (16)$$

给出。这里， ι_{S_i} 是 S_i 自然包含入 S 的映射，因此 (16) 可被视为简单地将 v_1 到 v_n 的动力学“堆叠”起来，子系统之间没有相互作用。然后，为完成组合，令 $X := X_1 + \dots + X_n$ 并构造如下推断图。



复合开放动力系统于是为

$$(S +_X J, p_{S*} \circ v \circ p_S^*, p_J \circ r). \quad (17)$$

该复合系统的动力学利用分配代数将当前状态向量分配到子系统，利用收集代数将各个子系统对其对应状态部分的结果收集起来。关键是，状态向量中属于 Φ 共享连接点的部分通过分配代数复制到与这些连接点相连的子系统，而各个相连子系统的结果通过收集代数求和得到连接点的状态更新。

此时，我们引入一些符号以便更容易书写复合系统。给定 m 个系统的集合 $\{v_j: \mathbb{R}^{N_j} \rightarrow \mathbb{R}^{N_j} \mid j \in [m]\}$ ，我们用符号表示 **Dynam** 的积比较作用 $\varphi_{N_1, \dots, N_m}(v_1, \dots, v_m)$ 为

$$\begin{bmatrix} v_1 \\ \vdots \\ v_m \end{bmatrix}. \quad (18)$$

使用此符号强调应用积比较得到的系统仅是将各个输入动力系统简单地“堆叠”起来。

我们可以稍作修改 **Dynam**，以产生用于组合离散动力系统的 UWD-代数，如文 **Dynam_D** 2 命题 3.1 所述。存在一个有限集代数 **Dynam_D**: **(FinSet, +)** $\rightarrow$ **(Set, $\times$)**，由以下映射定义：

- 在对象上，**Dynam_D** 将有限集 N 映射为离散动力系统集合 $\{v: \mathbb{R}^N \rightarrow \mathbb{R}^N\}$ 。
- 给定态射 $\phi: N \rightarrow M$ ，**Dynam_D**(ϕ): **Dynam_D**(N) $\rightarrow$ **Dynam_D**(M) 由映射 $v \mapsto \text{id}_{\mathbb{R}^M} + \phi_* \circ (v - \text{id}_{\mathbb{R}^N}) \circ \phi^*$ 定义，其中 id 表示 **Vect** 中的恒等映射。
- 比较映射与 **Dynam** 相同。




图 4: A. 一个包含两个内部框的示例 UWD。B. (A) 中 UWD 的余跨度表示。该 UWD 的签名为 $\{1, 2\} + \{3, 4\} \rightarrow \{a, b, c\} \leftarrow \{1', 2'\}$ 。

$\text{Euler}^\gamma: \text{Dynam} \Rightarrow \text{Dynam}_D$ 命题 3.3 表明, 给定步长 $\gamma > 0$ 的 Euler 方法定义了从连续系统到离散系统的代数态射的分量。具体地, 存在一个单体自然变换 $\text{Euler}^\gamma: \text{Dynam} \Rightarrow \text{Dynam}_D$, 其分量为

$$\text{Euler}_N^\gamma: \text{Dynam}(N) \rightarrow \text{Dynam}_D(N), v \mapsto \text{id}_{\mathbb{R}^N} + \gamma v. \quad (19)$$


Remark 2.5. 存在于 Dynam -UWDs 中的系统具有自然的消息传递语义。具体来说, 在每个时间点, “分发”步骤是通过将分发代数作用于当前状态向量, 以将相关组件投影到它们各自的子系统。并行计算步骤是通过应用每个子系统的动力学来完成的, 而 “收集” 步骤则是通过将收集代数作用于结果来完成的。这些步骤将使我们能够在后续章节中形式化分解方法。

Lemma 2.6. 给定一个松弛对称幺半函子 $(F, \varphi): (\mathbf{FinSet}, +) \rightarrow (\mathbf{Set}, \times)$, 存在一个由以下映射定义的松弛对称幺半函子 $(FCsp, \varphi'): (\mathbf{Cospan}, +) \rightarrow (\mathbf{Set}, \times)$:

- 在对象上, $FCsp$ 将有限集合 X 映射为形如 $(S \in \mathbf{FinSet}, o \in F(S), m: X \rightarrow S)$ 的三元组的集合。
- 对于一个余跨 $\Phi := (X \xrightarrow{l} J \xleftarrow{r} Y)$, 函数 $FCsp(\Phi): FCsp(X) \rightarrow FCsp(Y)$ 定义为

$$(S, o, m) \mapsto (S +_X J, F(p_S)(o), p_J \circ r), \quad (20)$$

其中 $S +_X J, p_S$ 和 p_J 由下图中的推断子定义:



- 给定对象 $N, M \in \mathbf{FinSet}$, 乘积比较映射

$$\varphi'_{N,M}: FCsp(N) \times FCsp(M) \rightarrow FCsp(N + M) \quad (21)$$

定义为

$$\varphi'_{N,M}((S_1, o_1, m_1), (S_2, o_2, m_2)) := (S_1 + S_2, \varphi_{S_1, S_2}(o_1, o_2), m_1 + m_2), \quad (22)$$

其中 φ_{S_1, S_2} 是 F 的乘积比较映射。

- 单位比较映射 $\varphi'_0: \{*\} \rightarrow FCsp(\emptyset)$ 选取三元组 $(\emptyset, \varphi_0, \emptyset \xrightarrow{l} \emptyset)$, 其中 φ_0 是 F 的单位比较映射。

Definition 2.7 (引用自 [10] 中的例 2.1.4). 集合的操作范畴, 记为 **Sets**, 其对象是集合。给定集合 $X_1, \dots, X_n, Y$, $\mathbf{Sets}(X_1, \dots, X_n; Y)$ 中的态射是函数 $X_1 \times \dots \times X_n \rightarrow Y$ 。给定可复合的态射 $g: Y_1 \times \dots \times Y_n \rightarrow Z$ 和对于所有 $i \in [n]$ 的 $f_i: X_{i,1} \times \dots \times X_{i,m_i} \rightarrow Y_i$, 复合态射是函数

$$(X_{1,1} \times \dots \times X_{1,m_1}) \times \dots \times (X_{n,1} \times \dots \times X_{n,m_n}) \xrightarrow{f_1 \times \dots \times f_n} Y_1 \times \dots \times Y_n \xrightarrow{g} Z. \quad (23)$$

Definition 2.8 (Definition 2.1.2 in [10]). 一个 **对称有色运算子** $\mathcal{O}$ 包含以下内容:

- 一组对象,
- 对于每个 $n \in \mathbb{N}^+$ 及对象集合 $s_1, \dots, s_n, t$ 在 $\mathcal{O}$ 中, 有一组态射 $\mathcal{O}(s_1, \dots, s_n; t)$,
- 对每个对象 t , 存在单位态射 $\text{id}_t \in \mathcal{O}(t; t)$,
- 形如下的复合映射

$$\mathcal{O}(s_1, \dots, s_n; t) \times \prod_{i=1}^n \mathcal{O}(r_{i,1}, \dots, r_{i,m_i}; s_i) \rightarrow \mathcal{O}(r_1, \dots, r_n; t), \quad (24)$$

其中 $r_i = r_{i,1}, \dots, r_{i,m_i}$ 。

- 形如下的置换映射

$$\mathcal{O}(s_1, \dots, s_n; t) \rightarrow \mathcal{O}(s_{\sigma(1)}, \dots, s_{\sigma(n)}; t) \quad (25)$$

对每个对称群 $\Sigma_{[n]}$ 中的置换 σ 。

这些数据满足适当的单位、结合性和对称性公理。

Definition 2.9 (定义 2.2.1, 见 [10]). 一个 **UWD-代数** 是一个算子范畴函子 $F: \mathbf{UWD} \rightarrow \mathbf{Sets}$ 。展开这个定义, F 包含一个对象映射, 将每个有限集 P 映射到一个集合 $F(P)$, 以及一个态射映射, 将每个形如 $\Phi: P_1 + \dots + P_n \rightarrow J \leftarrow P'$ 的 UWD 映射到一个函数 $F(\Phi): F(P_1) \times \dots \times F(P_n) \rightarrow F(P')$ 。这些映射必须满足以下公理:

1. F 保持恒等态射, 即对于所有对象 X , 有 $F(\text{id}_X) = \text{id}_{F(X)}$ 。
2. F 保持合成, 即对于所有可合成的 UWD, 下列图表交换:

$$\begin{array}{ccc} \mathbf{UWD}(Y_1, \dots, Y_n; Z) \times \prod_{i \in [n]} \mathbf{UWD}(X_i; Y_i) & \xrightarrow{\circ} & \mathbf{UWD}(X_1, \dots, X_n; Z) \\ \downarrow F & & \downarrow F \\ \mathbf{Sets}(FY_1, \dots, FY_n; FZ) \times \prod_{i \in [n]} \mathbf{Sets}(FX_i; FY_i) & \xrightarrow{\circ} & \mathbf{Sets}(FX_1, \dots, FX_n; FZ) \end{array}$$

其中 $X_i := X_{i,1}, \dots, X_{i,m_i}$, 而 FX_i 表示对每个 $X_{i,j}$ 逐个应用 F 。直观上, 该图表表明, 先替换 UWD 再应用代数的结果, 必须与先对每个组成部分的 UWD 应用代数然后作为函数合成的结果相同。

给定一个 UWD $\Phi \in \mathbf{UWD}(P_1, \dots, P_n; P')$ 以及所有 $i \in [n]$ 的填充值 $o_i \in F(P_i)$, 我们将通过 $F(\Phi)(o_1, \dots, o_n)$ 得到的结果 $o' \in F(P')$ 称为一个 **F-UWD**。

$$\mathcal{O}(F)(f) := F(X_1) \boxtimes \dots \boxtimes F(X_n) \xrightarrow{\varphi_{X_1, \dots, X_n}} F(X_1 \otimes \dots \otimes X_n) \xrightarrow{F(f)} F(Y). \quad (26)$$




图 5: A. 收集代数 作用于具有两个内部盒子的 UWD Φ 的示例。所得线性映射 Φ_* 以 $\mathbb{R}^2 \times \mathbb{R}^2$ 中的一对向量作为输入，通过对 Φ 中具有相同连接点的输入分量求和，生成 $\mathbb{R}^3$ 中的一个向量。箭头用于强调信息流从内部盒子指向边界盒子。B. 分配代数 作用于 Φ 的示例。所得线性映射 Φ^* 以 $\mathbb{R}^3$ 中的一个向量作为输入，通过复制 Φ 中具有相同连接点的输入分量，生成 $\mathbb{R}^2 \times \mathbb{R}^2$ 中的一对向量。箭头用于强调信息流从边界盒子指向内部盒子。矩阵表示均相对于标准基。注意，这些示例满足备注 2.3 中的简化假设。

Lemma 2.10. 假设给定两个 *lax* 对称么半群函子 $F, G: (\mathbf{FinSet}, +) \rightarrow (\mathbf{Set}, \times)$ 以及一个么半群自然变换 $\alpha: F \Rightarrow G$ 。令 $FCsp$ 和 $GCsp$ 分别是对 F 和 G 应用引理 2.6 所得到的余跨代数。那么存在一个么半群自然变换 $\alpha': FCsp \Rightarrow GCsp$ ，其分量 $\alpha'_N: FCsp(N) \rightarrow GCsp(N)$ 定义为

$$(S, v \in F(S), m: N \rightarrow S) \mapsto (S, \alpha_S(v), m). \quad (27)$$

Example 2.11 (Building Linear Maps with UWDs). We can apply Lemma 2.6 to the pushforward and pullback algebras defined in Example 2.2 to lift them to UWD-algebras. This lets us use the graphical syntax of UWDs to specify linear maps.

We call the UWD-algebra obtained by applying Lemma 2.6 to the pushforward algebra the **collect algebra** because it takes vectors for each inner box of a UWD and collects them into a vector for the outer box. Likewise, we call the UWD-algebra obtained by applying Lemma 2.6 to the pullback algebra the **distribute algebra** because it takes a vector for the outer box and distributes it to produce vectors for each inner box. Both these operations are shown in Figure 5.

Simple though they are, these algebras will be indispensable to defining the subsequent algebras of optimization problems and dynamical systems.

Definition 2.12 (定义 2.2.5, 见 [10]). 给定 UWD-代数 $F, G: \mathbf{UWD} \rightarrow \mathbf{Sets}$ ，一个代数态射 $\alpha: F \Rightarrow G$ 由对于每个有限集 X 的一个函数 $\alpha_X: F(X) \rightarrow G(X)$ 组成，称为 α 在 X 处的分量。这些分量必须满足以

下规律：给定一个 UWD $\Phi: P_1 + \dots + P_n \rightarrow J \leftarrow P'$ ，下列 自然性交换图 必须交换：

$$\begin{array}{ccc} \prod_{i \in [n]} F(P_i) & \xrightarrow{\prod_i \alpha_{P_i}} & \prod_{i \in [n]} G(P_i) \\ F(\Phi) \downarrow & & \downarrow G(\Phi) \\ F(P') & \xrightarrow{\alpha_{P'}} & G(P') \end{array}$$

Definition 2.13 (见 [10] 中的示例 2.1.7). UWD 的 operad, 记作 **UWD**, 以有限集作为对象。对于有限集 $P_1, \dots, P_n, P'$, **UWD**($P_1, \dots, P_n; P'$) 中的态射是具有这些端口的 UWD, 即选择一个有限集 J 和一个余跨度 $P_1 + \dots + P_n \xrightarrow{l} J \xleftarrow{r} P'$ 。给定可复合的 UWD

$$\prod_{i \in [n]} Y_i \xrightarrow{l'} J' \xleftarrow{r'} Z, \quad (28)$$

以及

$$\prod_{j \in [m_i]} X_{i,j} \xrightarrow{l_i} J_i \xleftarrow{r_i} Y_i, \quad i \in [n], \quad (29)$$

它们的复合通过以下的推出图定义：

$$\begin{array}{ccccc} & & & & Z \\ & & & & \downarrow r' \\ & & \prod_{i \in [n]} Y_i & \xrightarrow{l'} & J' \\ & & \downarrow \prod_i r_i & & \downarrow q \\ \prod_{i \in [n]} \prod_{j \in [m_i]} X_{i,j} & \xrightarrow{\prod_i l_i} & \prod_{i \in [n]} J_i & \xrightarrow{p} & J'' \\ & & \uparrow \lrcorner & & \end{array}$$

复合的 UWD 则由余跨度的左边腿 $p \circ \prod_i l_i$ 和右边腿 $q \circ r'$ 给出。X 上的恒等 UWD 是恒等余跨度 $X = X$ 。

3 梯度下降是一种代数同态

本节提出了本文的基本结果：梯度下降是一个从无约束可微分最小化问题的 Ω -代数到离散动力系统的 Ω -代数（例 2.4）的代数同态。

3.1 组合优化问题

为了证明梯度下降是一个代数同态，我们必须首先指定我们的 Ω -代数的优化问题。在该代数中，子问题将通过对其目标函数求和来组合，且受决策变量共享模式的约束，该模式由一个 Ω 决定。

Lemma 3.1. 存在一个有限集代数 $(\text{Opt}, \varphi): (\mathbf{FinSet}, +) \rightarrow (\mathbf{Set}, \times)$ ，定义如下。

- 在对象上，Opt 将有限集 N 映射为函数集 $\{f: \mathbb{R}^N \rightarrow \mathbb{R} \mid f \in C^1\}$ 。
- 在态射上，Opt 将函数 $\phi: N \rightarrow M$ 映射为函数 $\text{Opt}(\phi): \text{Opt}(N) \rightarrow \text{Opt}(M)$ ，定义为

$$\text{Opt}(\phi): f \mapsto f \circ \phi^*. \quad (30)$$

- 对于对象 $N, M \in \mathbf{FinSet}$ ，积比较映射 $\varphi_{N,M}: \mathbf{Opt}(N) \times \mathbf{Opt}(M) \rightarrow \mathbf{Opt}(N+M)$ 由实数上的逐点加法给出，即

$$\varphi_{N,M}(f, g)(z) := f(\iota_N^*(z)) + g(\iota_M^*(z)) \quad (31)$$

对所有 $z \in \mathbb{R}^{N+M}$ 成立。这里， $\iota_N: N \rightarrow N+M$ 和 $\iota_M: M \rightarrow N+M$ 是 N 和 M 向其不交并的包含映射。

- 单位比较映射 $\varphi_0: \{*\} \rightarrow \mathbf{Opt}(\emptyset)$ 选取零函数 $0 \mapsto 0$ 。

证明。我们构造协变函子 $\mathbf{Opt}$ 作为复合函子

$$\mathbf{Opt} := \mathbf{FinSet} \xrightarrow{(-)^*} \mathbf{Vect}^{\text{op}} \xrightarrow{O} \mathbf{Set}$$

由两个逆变函子组成，其中 $(-)^*$ 是示例 2.11 中的分配代数。逆变函子 O 将一个向量空间 V 映射到 C^1 函数集 $V \rightarrow \mathbb{R}$ 。与 $(-)^*$ 类似，函子 O 作用于线性映射 $T: V \rightarrow W$ 通过前复合定义： $O(T)(f) := f \circ T$ 。这明显是函子性的，因此 $\mathbf{Opt} := O \circ (-)^*$ 也是函子。并且显然， C^1 函数与线性映射的前复合仍是 C^1 函数。

现在我们需要验证乘积比较的自然性，即下图交换：

$$\begin{array}{ccc} \mathbf{Opt}(X) \times \mathbf{Opt}(Y) & \xrightarrow{\mathbf{Opt}(\phi) \times \mathbf{Opt}(\psi)} & \mathbf{Opt}(N) \times \mathbf{Opt}(M) \\ \varphi_{X,Y} \downarrow & & \downarrow \varphi_{N,M} \\ \mathbf{Opt}(X+Y) & \xrightarrow{\mathbf{Opt}(\phi+\psi)} & \mathbf{Opt}(N+M) \end{array}$$

对所有有限集 X, Y, N, M 及函数 $\phi: X \rightarrow N$ 和 $\psi: Y \rightarrow M$ 成立。为此，令 $(f, g) \in \mathbf{Opt}(X) \times \mathbf{Opt}(Y)$ 。沿上路径得到函数 $h_1 := f \circ \phi^* \circ \iota_N^* + g \circ \psi^* \circ \iota_M^*$ ，而沿下路径得到函数 $h_2 := (f \circ \iota_X^* + g \circ \iota_Y^*) \circ (\phi + \psi)^*$ 。要证明它们等价，首先注意到由于 $(-)^*$ 是强么半群函子，映射 $(\phi + \psi)^*$ 与映射 $\phi^* \oplus \psi^*$ 同构。类似地，因 $(-)^*$ 将 $\mathbf{FinSet}$ 中的余积映射为 $\mathbf{Vect}$ 中的积，我们知道 $\iota_X^*: \mathbb{R}^{X+Y} \rightarrow \mathbb{R}^X$ 等价于投影 $\pi_{\mathbb{R}^X}: \mathbb{R}^X \oplus \mathbb{R}^Y \rightarrow \mathbb{R}^X$ ，对上述所有 ι^* 亦是如此。因此，我们可以将 h_1 重写为 $f \circ \phi^* \circ \pi_{\mathbb{R}^N} + g \circ \psi^* \circ \pi_{\mathbb{R}^M}$ ，将 h_2 重写为 $(f \circ \pi_{\mathbb{R}^X} + g \circ \pi_{\mathbb{R}^Y}) \circ (\phi^* \oplus \psi^*)$ 。

最后，注意以下两个图对交换

$$\begin{array}{ccc} \mathbb{R}^N \oplus \mathbb{R}^M & \xrightarrow{\phi^* \oplus \psi^*} & \mathbb{R}^X \oplus \mathbb{R}^Y \\ \pi_{\mathbb{R}^N} \downarrow & & \downarrow \pi_{\mathbb{R}^X} \\ \mathbb{R}^N & \xrightarrow{\phi^*} & \mathbb{R}^X \end{array} \quad \begin{array}{ccc} \mathbb{R}^N \oplus \mathbb{R}^M & \xrightarrow{\phi^* \oplus \psi^*} & \mathbb{R}^X \oplus \mathbb{R}^Y \\ \pi_{\mathbb{R}^M} \downarrow & & \downarrow \pi_{\mathbb{R}^Y} \\ \mathbb{R}^M & \xrightarrow{\psi^*} & \mathbb{R}^Y \end{array} \quad (32)$$

证明了 h_1 与 h_2 等价。

乘积比较的结合性与对称性来自函数逐点加法的结合性与对称性，而么元性则来自零函数对逐点加法的么元性。 $\square$

Example 3.2 (Opt-UWDs). 回顾图 1.A 中的 UWD，我们称之为 Φ 。注意， Φ 的连接点与外部端口一一对应，因此我们将使用备注 2.3 中的简化方法。将 $\mathbf{Opt}$ 应用于该 UWD 得到一个函数 $\mathbf{Opt}(\Phi): \mathbf{Opt}([2]) \times \mathbf{Opt}([3]) \times \mathbf{Opt}([3]) \rightarrow \mathbf{Opt}([5])$ ，该函数指定了如何将三个适当维度的子问题目标组合起来，得到 $\mathbb{R}^5$ 上的复合目标。

给定 C^1 子问题 $f: \mathbb{R}^2 \rightarrow \mathbb{R}, g: \mathbb{R}^3 \rightarrow \mathbb{R}$ 和 $h: \mathbb{R}^3 \rightarrow \mathbb{R}$ ，结果 $\mathbf{Opt}(\Phi)(f, g, h)$ 是复合问题

$$\text{minimize } f(w, x) + g(u, w, y) + h(u, w, z), \quad (33)$$

对应于图 1.B 中的 Opt-UWD。之所以如此，首先注意分配代数将决策变量的各个分量复制到由内端口映射到连接点所决定的各自子问题中。然后，Opt 的乘积比较简单地对应用每个目标函数于其接收的决策变量分量的结果进行求和。

3.2 利用梯度下降法求解复合问题

我们现在可以证明梯度下降法定义了从 Opt 到 Dynam_D 的代数态射。我们的方法是首先证明梯度流给出了一个到连续系统的态射，然后通过与欧拉方法的代数态射复合，作为推论恢复梯度下降法。

Theorem 3.3. 回顾示例 2.4 中的对称单体函子 Dynam ，存在一个单体自然变换 $\text{flow}: \text{Opt} \Rightarrow \text{Dynam}$ ，其分量为

$$\text{flow}_N: \text{Opt}(N) \rightarrow \text{Dynam}(N)$$

定义为

$$\text{flow}_N(f) := x \mapsto -\nabla f(x). \quad (34)$$

证明. 我们首先需要验证自然性。为此，我们需要确保

$$\begin{array}{ccc} \text{Opt}(N) & \xrightarrow{\text{Opt}(\phi)} & \text{Opt}(M) \\ \text{flow}_N \downarrow & & \downarrow \text{flow}_M \\ \text{Dynam}(N) & \xrightarrow{\text{Dynam}(\phi)} & \text{Dynam}(M) \end{array}$$

对于任意选择的 $N, M \in \mathbf{FinSet}$ 和映射 $\phi: N \rightarrow M$ ，该图交换。固定任意优化问题 $f \in \text{Opt}(N)$ 。自然性正方形的上路径产生的向量场为

$$(y \in \mathbb{R}^M) \mapsto -\nabla(f(\phi^*(y))) = -\nabla(f(Ky)), \quad (35)$$

这里我们用 K 表示相对于标准基底的 ϕ^* 的矩阵表示。然后，应用链式法则，我们得到 (35) 等价于

$$y \mapsto -K^T \nabla f(Ky). \quad (36)$$

同样，沿下路径得到

$$y \mapsto \phi_*(-\nabla f(\phi^*(y))) = -\phi_*(\nabla f(\phi^*(y))). \quad (37)$$

注意到推前映射是拉回映射的对偶，说明 (35) 与 (37) 等价，达到预期。

为了验证自然变换是幺半群的，我们需要证明图

$$\begin{array}{ccc} \text{Opt}(N) \times \text{Opt}(M) & \xrightarrow{\text{flow}_N \times \text{flow}_M} & \text{Dynam}(N) \times \text{Dynam}(M) \\ \varphi_{N,M}^{\text{Opt}} \downarrow & & \downarrow \varphi_{N,M}^{\text{Dynam}} \\ \text{Opt}(N+M) & \xrightarrow{\text{flow}_{N+M}} & \text{Dynam}(N+M) \end{array}$$

和

$$\begin{array}{ccc} \{*\} & \xrightarrow{\varphi_0^{\text{Opt}}} & \text{Opt}(\emptyset) \\ & \searrow \varphi_0^{\text{Dynam}} & \downarrow \text{flow}(\emptyset) \\ & & \text{Dynam}(\emptyset) \end{array}$$

对于所有 $N, M \in \mathbf{FinSet}$ 都交换。单位比较图显然交换（注意常数零函数 $\mathbb{R}^0 \rightarrow \mathbb{R}$ 与唯一的向量场 $\mathbb{R}^0 \rightarrow \mathbb{R}^0$ 是相同的）。对于乘积比较图，设 $f \in \mathbf{Opt}(N)$ 和 $g \in \mathbf{Opt}(M)$ 是优化问题。沿上路径得到向量场

$$z \mapsto \iota_{N*}(-\nabla f(\iota_N^*(z))) + \iota_{M*}(-\nabla g(\iota_M^*(z))), \quad (38)$$

而沿下路径得到

$$z \mapsto -\nabla(f(\iota_N^*(z))) - \nabla(g(\iota_M^*(z))). \quad (39)$$

通过与验证自然性相同的推理，这些向量场被认为是等价的。 $\square$

Corollary 3.3.1. 给定一个正实数 γ ，存在一个幺半群自然变换 $\mathbf{gd}^\gamma: \mathbf{Opt} \Rightarrow \mathbf{Dynam}_D$ ，其分量 $\mathbf{gd}_N^\gamma: \mathbf{Opt}(N) \rightarrow \mathbf{Dynam}_D(N)$ 由函数

$$f \mapsto \text{id}_{\mathbb{R}^N} - \gamma \nabla f. \quad (40)$$

给出。

证明。所谓的幺半群变换是幺半群变换的复合

$$\mathbf{Opt} \xrightarrow{\text{flow}} \mathbf{Dynam} \xrightarrow{\mathbf{Euler}^\gamma} \mathbf{Dynam}_D,$$

其中欧拉变换在第 2.3 节末尾有描述。 $\square$

换句话说，变换 $\mathbf{gd}^\gamma$ 将可微最小化问题映射到实现该问题梯度下降的动力系统。梯度下降的自然性意味着，将子问题的梯度下降动力系统复合，等价于先复合子问题再取复合问题的梯度下降动力系统。这种等价性使得可以使用复合动力系统的分布式消息传递语义来求解复合问题，如下例所示。

Example 3.4 (Distributed Gradient Descent). Recall Problem (33):

$$\text{minimize } f(w, x) + g(u, w, y) + h(u, w, z).$$

Here, we assume that $f: \mathbb{R}^2 \rightarrow \mathbb{R}$, $g: \mathbb{R}^3 \rightarrow \mathbb{R}$, and $h: \mathbb{R}^3 \rightarrow \mathbb{R}$ are all C^1 functions. We showed in Example 3.2 that this problem is the composite produced by filling the UWD Φ in Figure 1.A with the component functions f, g , and h . This composite has the form In other words, the composite problem takes an input vector, distributes it to the subproblems, and sums the results. If we apply $\mathbf{gd}^\gamma$ to the composite problem P and let $s := (u, w, x, y, z)^T$, we get the discrete system

$$s_{k+1} = s_k - \gamma \nabla P(s_k), \quad (41)$$

for a chosen step-size $\gamma > 0$. This is a centralized gradient descent algorithm for minimizing P . However, by Theorem 3.3 and the fact that P is *decomposed* by the UWD Φ , we know that this system is equivalent to applying $\mathbf{gd}^\gamma$ to each individual subproblem and composing these discrete dynamical systems according to Φ , i.e.,

$$\mathbf{Dynam}_D(\Phi) \left((\text{id}_{\mathbb{R}^2} - \gamma \nabla f), (\text{id}_{\mathbb{R}^3} - \gamma \nabla g), (\text{id}_{\mathbb{R}^3} - \gamma \nabla h) \right). \quad (42)$$

Simplifying (42) results in the equivalent dynamical system

$$s_{k+1} = s_k - \gamma K^T \begin{bmatrix} \nabla f \\ \nabla g \\ \nabla h \end{bmatrix} K s, \quad (43)$$

where K is the pullback of the function mapping inner ports to junctions of Φ .

Note that naturality of $\mathbf{gd}^\gamma$ says that (41) and (43) are *extensionally equal*, meaning they produce the same output given the same input. This also implies that the trajectories of these systems from a given initial condition will be the same. However, these systems have very different *computational* properties. Specifically, unlike the system in (41), the system in (43) can be run using the distributed message passing semantics discussed in Remark 2.5. Explicitly, the system (43) yields Algorithm 1, which is a simple distributed gradient method for minimizing (33).

Algorithm 1: 消息传递梯度下降

Input: An initial state vector $s_0 \in \mathbb{R}^5$.

$s \leftarrow s_0$;

while a stopping criterion is not reached **do**

$t \leftarrow K * s$;	/* Duplicate shared states */
$t_1, t_2, t_3 \leftarrow \pi_1(t), \pi_2(t), \pi_3(t)$;	/* Project subvectors to subsystems */
$t_1, t_2, t_3 \leftarrow \nabla f(t_1), \nabla g(t_2), \nabla h(t_3)$;	/* This can be done in parallel */
$t \leftarrow \text{concatenate}(t_1, t_2, t_3)$;	
$\Delta s \leftarrow \gamma * K^T * t$;	/* Sum changes in shared states */
$s \leftarrow s - \Delta s$;	/* Update state */

end

return s ;

示例 3.4 中描述的从 Ω 和组件子问题出发生成分布式求解算法的过程，可以通过算法 2 中展示的元算法自动化完成。

Algorithm 2: 最小化算法生成器

Input: A UWD Φ with n inner boxes

Input: Open C^1 objectives $f_1, \dots, f_n$ to fill each inner box of Φ .

Input: A positive real step-size γ .

Output: A message passing dynamical system for minimizing $\text{Opt}(\Phi)(f_1, \dots, f_n)$.

for $i \leftarrow 1$ **to** n **do**

$v_i \leftarrow \mathbf{gd}^\gamma(f_i)$;
--

end

return $\text{Dynam}_D(\Phi)(v_1, \dots, v_n)$;

Example 3.5 (Recovering Primal Decomposition). Example 3.4 shows that applying the natural transformation $\mathbf{gd}^\gamma: \text{Opt} \Rightarrow \text{Dynam}$ gives a simple distributed gradient method that decomposes C^1 problems defined on arbitrary UWDs. However, this simple distributed gradient method still requires synchronization after each gradient step. Supposing that f, g , and h are C^1 , strictly convex functions, an alternative distributed




图 6: 在问题 (33) 上设置 Opt-UWD 的主分解。

solution method for (33) can be obtained by applying primal decomposition. At each iteration, primal decomposition fixes the values of shared variables to decouple the problem, finds minimizers of the subproblems in parallel, and uses these minimizers to compute gradient updates for the shared variables. We can implement primal decomposition in this framework by applying the same gradient descent natural transformation to a slightly modified UWD and component problems that fill it. Specifically, we apply gradient flow to the Opt-UWD shown in Figure 6.

Because f, g , and h are strictly convex, their infima are attained at unique points for any values of w and u . Thus, the gradient of $\inf_x f(w, x)$ can be computed as $\nabla_w f(w, x^*)$ where $x^* = \arg \min_x f(w, x)$. A similar computation produces gradients of the other subproblems with respect to w and u . Applying gd^γ to each subproblem and composing these systems results in the composite system

$$\begin{bmatrix} u_{k+1} \\ w_{k+1} \end{bmatrix} = \begin{bmatrix} u_k \\ w_k \end{bmatrix} - \gamma Q^T \begin{bmatrix} \nabla f(w_k, x^*) \\ \nabla g(u_k, w_k, y^*) \\ \nabla h(u_k, w_k, z^*) \end{bmatrix}, \quad (44)$$

where $x^* = \arg \min_x f(w_k, x)$, $y^* = \arg \min_y g(u_k, w_k, y)$, $z^* = \arg \min_z h(u_k, w_k, z)$, and Q^T is the matrix obtained by applying the collect algebra to the UWD in Figure 6. This system yields Algorithm 3.

This is primal decomposition applied to Problem (33). Naturality of gradient flow automatically proves that running this algorithm will produce the same result as running the equivalent synchronous dynamical system obtained by applying gd^γ to the original composite problem. Note that although Algorithm 1 and Algorithm 3 are different, they both result from applying meta-Algorithm 2 to different UWDs and component objectives.

3.3 组合数据条件

通常, 特定优化问题的一个实例是由一些数据决定的。例子包括神经网络架构如何被纳入机器学习目标, 或者特定图如何定义网络流目标。一般来说, 我们可以将这类将问题数据编码进目标函数的方式视为由有限集 N 索引的函数族 $p_N: D(N) \rightarrow \text{Opt}(t(N))$ 。我们将 $D(N)$ 视为定义在 N 上的所有可能问题数据的集合 (例如, 顶点集合为 N 的图的集合, 具有 $|N|$ 个权重的神经网络的集合等)。函数 t 则是将 N 转换成对应目标的决策变量集合的变换。有时, 问题数据本身可以组合。例如, 图可以沿其顶点粘合, 神经网络可以在不同

Algorithm 3: 消息传递主分解

Input: An initial state vector $s_0 \in \mathbb{R}^2$.

$s \leftarrow s_0$;

while a stopping criterion is not reached **do**

```
     $t \leftarrow Q * s$  ;                                /* Duplicate shared states */
     $t_1, t_2, t_3 \leftarrow \pi_1(t), \pi_2(t), \pi_3(t)$  ;    /* Project subvectors to subsystems */
    Compute the following argmins in parallel using an appropriate algorithm;
     $x^* \leftarrow \arg \min_x f(t_1, x)$ ;
     $y^* \leftarrow \arg \min_y g(t_2, y)$ ;
     $z^* \leftarrow \arg \min_z h(t_3, z)$ ;
     $t_1, t_2, t_3 \leftarrow \nabla f(t_1, x^*), \nabla g(t_2, y^*), \nabla h(t_3, z^*)$  ; /* This can be done in parallel */
     $t \leftarrow \text{concatenate}(t_1, t_2, t_3)$ ;
     $\Delta s \leftarrow \gamma * Q^T * t$  ;                      /* Sum changes in shared states */
     $s \leftarrow s - \Delta s$  ;                             /* Update state */
```

end

return s ;

组件之间共享权重（权重绑定）。我们将这类数据称为 **组合数据**。我们的组合数据条件本质上表明，如果问题数据的组合结构与 Opt 中目标的组合结构兼容，则该问题可以通过分解方法求解。形式上，这表述如下。

Definition 3.6 (组合数据条件). 设 $t: (\mathbf{FinSet}, +) \rightarrow (\mathbf{FinSet}, +)$ 和 $D: (\mathbf{FinSet}, +) \rightarrow (\mathbf{Set}, \times)$ 是松对称幺半群函子。给定一族函数 $p_N: D(N) \rightarrow \text{Opt}(t(N))$ ，其中 $N \in \mathbf{FinSet}$ ，若映射 p_N 构成了一个幺半群自然变换 $p: D \Rightarrow \text{Opt} \circ t$ 的各个分量，则称 p 满足 **组合数据条件**。

组合数据条件是定义由组合数据产生的问题可分解的充分条件。具体而言，当满足该条件时，我们通过后复合获得了从数据代数 D 到动力系统代数的幺半群自然变换，即

$$D \xRightarrow{p} \text{Opt} \circ t \xRightarrow{\text{gd}^\gamma * t} \text{Dynam}_D \circ t.$$

这提供了一个从问题数据到用于最小化由该数据定义的目标的系统的变换。该框架的优势在于，由该复合产生的系统将遵循任何可表示为无向布线图的输入数据的层级分解。作为示例，我们将在第 6 节看到最小成本网络流问题如何满足组合数据条件。

4 Uzawa 算法是一个代数态射

到目前为止，我们已经证明了梯度下降对于无约束最小化问题在复合运算下是自然的。为了将这一框架扩展到等式约束问题，我们证明了 算法 [21] 对于等式约束最小化问题也是自然的。该结果还将使我们能够将复合数据条件扩展到更广泛的问题类别。实现这一点首先需要有一个约束问题的复合概念。回顾 算法利用鞍点函数作为约束问题的表示。因此，我们通过指定如何复合对应的鞍点函数来具体说明如何复合约束问题。

4.1 组合鞍点问题

鞍点函数的组合应当类似于在 Opt 下无约束目标函数的组合，即通过对目标函数求和，受限由 Ω 决定的变量共享模式。鞍点问题的关键区别在于，我们需要保证鞍点问题的组合仍然是一个鞍点问题。一种实现方法是强制变量共享模式必须遵循被组合的子问题的鞍点性质。具体来说，我们只允许鞍点问题在某个变量上共享该变量，前提是它们在该变量上要么都是凸的，要么都是凹的。如果一个在该变量上是凸的而另一个是凹的，则不允许它们共享该变量。

因此，我们需要一种方法来追踪给定鞍点函数对其每个输入是以凸还是凹的方式依赖。为此，我们利用一种称为 $f\text{Slice}$ (切片范畴) 的范畴构造，它可以被看作是在一个范畴上施加一种“类型系统”。

Definition 4.1. 给定一个范畴 $\mathcal{C}$ 和一个对象 $c \in \mathcal{C}$ ，定义 **slice category** $\mathcal{C}/c$ 如下。

- $\mathcal{C}/c$ 的对象是 $\mathcal{C}$ 中以 c 为余域的态射 $f: x \rightarrow c$ 。
- 在 $\mathcal{C}/c$ 中，从 $f: x \rightarrow c$ 到 $g: y \rightarrow c$ 的态射是 $\mathcal{C}$ 中的态射 $h: x \rightarrow y$ ，使得下图三角形

$$\begin{array}{ccc} x & \xrightarrow{h} & y \\ & \searrow f & \swarrow g \\ & c & \end{array}$$

交换，即 $f = g \circ h$ 。

一个 slice category $\mathcal{C}/c$ 具有一个相关的遗忘函子 $U: \mathcal{C}/c \rightarrow \mathcal{C}$ ，它通过将 $\mathcal{C}/c$ 中的对象 $x \xrightarrow{f} c$ 映射到其定义域 $x \in \mathcal{C}$ ，并将交换三角形映射为使其交换的态射来定义。

凸和凹的区分是二元的，因此我们用来编码该区分的切片范畴是 $\mathbf{FinSet}/[2]$ 。我们可以将该范畴视为本质上与 $\mathbf{FinSet}$ 相同，但每个集合元素都被“标记”为 1 或 2，分别代表凸标记和凹标记的分量。我们注意到线性函数既是凸的也是凹的，原则上它们可以标记为任意一种。然而，在工程文献中，线性函数在被最小化时通常被视为凸函数，在被最大化时被视为凹函数，我们在这里也采用这一惯例。为了构造鞍点函数的代数，我们要求定义在这种标记集合上的目标函数在凸标记的分量上是凸的，而在凹标记的分量上是凹的。

$\mathbf{FinSet}/[2]$ 中的态射可以被看作是保持标记的函数，即将定义域中凸标记的元素映射到陪域中凸标记的元素，凹标记的元素同理。注意切片范畴中的余极限是作为原始范畴中的余极限构造的 (参见 [30], 命题 3.3.8)。特别地， $\mathbf{FinSet}/[2]$ 中两个对象 $N \xrightarrow{\tau} [2]$ 和 $M \xrightarrow{\sigma} [2]$ 的余积是 $\mathbf{FinSet}$ 中的余积 $N + M$ ，由余配对 $[\tau, \sigma]$ 标记。因此， $(\mathbf{FinSet}/[2], +, \emptyset \xrightarrow{!} [2])$ 从 $(\mathbf{FinSet}, +, \emptyset)$ 继承了一个余笛卡尔幺半群结构。

Remark 4.2. 给定一个对象 $\tau: N \rightarrow [2]$ 在 $\mathbf{FinSet}/[2]$ 中，集合 $N_1 := \tau^{-1}(1)$ 和 $N_2 := \tau^{-1}(2)$ 构成了 N 的一个划分。我们还有两个唯一的单射 $N_1 \xrightarrow{\text{cnvx}} N$ ，其定义为对所有 $n_1 \in N_1$ 满足 $(\tau \circ \text{cnvx})(n_1) = 1$ ，以及 $N_2 \xrightarrow{\text{cncv}} N$ ，其定义为对所有 $n_2 \in N_2$ 满足 $(\tau \circ \text{cncv})(n_2) = 2$ 。换句话说，‘cnvx’ 选出 N 中标记为凸的部分，而 ‘cncv’ 选出标记为凹的部分。

此外，利用函子 $(-)_*$ 生成 $\mathbb{R}^{N_1}$ 和 $\mathbb{R}^{N_2}$ ，并取 ‘cnvx’ 和 ‘cncv’ 的推前，我们定义同构 $u: \mathbb{R}^{N_1} \oplus \mathbb{R}^{N_2} \cong \mathbb{R}^N$ 为以下余积图中的唯一箭头：

$$\begin{array}{ccccc} & & \mathbb{R}^N & & \\ & \nearrow \text{cnvx}_* & \uparrow u & \nwarrow \text{cncv}_* & \\ \mathbb{R}^{N_1} & \xrightarrow{\iota_{\mathbb{R}^{N_1}}} & \mathbb{R}^{N_1} \oplus \mathbb{R}^{N_2} & \xleftarrow{\iota_{\mathbb{R}^{N_2}}} & \mathbb{R}^{N_2} \end{array}$$

此同构仅将一对 $(x, y) \in \mathbb{R}^{N_1} \oplus \mathbb{R}^{N_2}$ 重新排列成单一向量 $z \in \mathbb{R}^N$ ，其中凸和凹部分的顺序由 τ 给出。

Lemma 4.3. 存在一个有限集合代数 $\text{Saddle}: (\mathbf{FinSet}/[2], +) \rightarrow (\mathbf{Set}, \times)$, 定义如下。

- 给定 $\mathbf{FinSet}/[2]$ 中的一个对象 $\tau: N \rightarrow [2]$, 令 N_1, N_2 及 $u: \mathbb{R}^{N_1} \oplus \mathbb{R}^{N_2} \cong \mathbb{R}^N$ 如 Remark 4.2 中定义。则 Saddle 将 τ 映射到集合

$$\left\{ f: \mathbb{R}^N \rightarrow \mathbb{R} \mid f(u(\cdot, y)) \text{ 对任意固定的 } y \in \mathbb{R}^{N_2} \text{ 是凸函数, 且} \right. \\ \left. f(u(x, \cdot)) \text{ 对任意固定的 } x \in \mathbb{R}^{N_1} \text{ 是凹函数} \right\}. \quad (45)$$

- 在态射上, Saddle 将交换三角形

$$\begin{array}{ccc} N & \xrightarrow{\phi} & M \\ \searrow \tau_1 & & \swarrow \tau_2 \\ & [2] & \end{array}$$

映射为预合成定义的函数 $\text{Saddle}(\tau_1) \rightarrow \text{Saddle}(\tau_2): f \mapsto f \circ \phi^*$ 。

- 给定 $\mathbf{FinSet}/[2]$ 中的对象 $\tau_1: N \rightarrow [2]$ 和 $\tau_2: M \rightarrow [2]$, 乘积比较映射 $\varphi_{\tau_1, \tau_2}: \text{Saddle}(\tau_1) \times \text{Saddle}(\tau_2) \rightarrow \text{Saddle}(\tau_1 + \tau_2)$ 定义为

$$\varphi_{\tau_1, \tau_2}(f, g)(z) := f(\iota_N^*(z)) + g(\iota_M^*(z)), \quad (46)$$

对所有 $z \in \mathbb{R}^{N+M}$ 成立。

- 单位比较映射 $\varphi_0: \{*\} \rightarrow \text{Saddle}(\emptyset \xrightarrow{!} [2])$ 由常值 0 函数给出。

证明. 首先, 我们必须证明, 给定鞍点函数 $f \in \text{Saddle}(N \xrightarrow{\tau} [2])$ 和映射 $\phi: (N \xrightarrow{\tau} [2]) \rightarrow (M \xrightarrow{\sigma} [2])$, 其复合 $f \circ \phi^*$ 仍然是一个鞍点函数, 其凸和凹分量符合 σ 。鞍点函数与线性映射的预复合仍是鞍点函数 (参见 [39], §2.1), 因此因为 f 是鞍点函数且 ϕ^* 是线性的, 故 $f \circ \phi^*$ 也是鞍点函数。此外, 由于 ϕ 使得下图

$$\begin{array}{ccc} N & \xrightarrow{\phi} & M \\ \searrow \tau & & \swarrow \sigma \\ & [2] & \end{array}$$

交换, ϕ^* 必须将 $x \in \mathbb{R}^M$ 中凸标记的分量映射到 $\mathbb{R}^N$ 中凸标记的分量, 凹标记的分量亦然。因此 $f \circ \phi^*$ 的凸和凹分量符合 σ 。验证完毕后, Saddle 的函子性证明与 Opt 的函子性证明相同, 因为 $\text{Saddle}(\phi) = \text{Opt}(\phi)$ 。

同理, 因为 Saddle 的比较映射与 Opt 的行为一致, 所需的么元性、对称性和结合性图的证明均可照搬。我们只需验证比较映射应用后的结果仍是具有正确凸凹分量标记的鞍点函数。对于么元比较映射, 常数零函数是仿射的, 因此显然是鞍点函数。此外, 常数零函数无参数故无须遵守标记。

对于积比较映射, 考虑任意对象 $N \xrightarrow{\tau_1} [2], M \xrightarrow{\tau_2} [2]$ 于 $\mathbf{FinSet}/[2]$ 中, 以及任意鞍点函数 $f \in \text{Saddle}(\tau_1)$ 和 $g \in \text{Saddle}(\tau_2)$ 。记 $N_1, N_2, M_1, M_2, u_N: \mathbb{R}^{N_1} \oplus \mathbb{R}^{N_2} \cong \mathbb{R}^N$, 以及 $u_M: \mathbb{R}^{M_1} \oplus \mathbb{R}^{M_2} \cong \mathbb{R}^M$, 定义如备注 4.2。则我们知道

$$f(u_N(\cdot, y)) + g(u_M(\cdot, z)) \quad (47)$$

对所有 $(y, z) \in \mathbb{R}^{N_2} \oplus \mathbb{R}^{M_2}$ 是凸的, 因为凸函数之和是凸函数。同理,

$$f(u_N(x, \cdot)) + g(u_M(w, \cdot)) \quad (48)$$

对所有 $(x, w) \in \mathbb{R}^{N_1} \oplus \mathbb{R}^{M_1}$ 是凹的, 因为凹函数之和是凹函数。这证明了积比较映射应用结果的鞍点性质。 $\square$

4.2 优化问题的其他类别

函子 **Opt** 提供了一种组合无约束的 C^1 非凸最小化问题的方法，而 **Saddle** 则提供了一种组合不一定可微的鞍点问题的方法。通过对这些函子像中的函数集合施加额外的限制或限制其定义域，我们可以轻松地生成用于组合其他类型问题的新函子。本文中特别将使用以下限制：

- **DiffSaddle** 限制了 **Saddle** 的像中的函数为连续可微的，即

$$\text{DiffSaddle}(N) := \{L \in \text{Saddle}(N) \mid L \in C^1\}.$$

- 通过只考虑形如 $\tau: N \rightarrow [2]$ 且对所有 $n \in N$ 有 $\tau(n) = 1$ 的对象，我们得到一个同构于 **FinSet** 的 **FinSet**/[2] 的子范畴。将 **Saddle** 限制到该子范畴，得到一个有限集合代数 $\text{Conv}: \mathbf{FinSet} \rightarrow \mathbf{Set}$ ，定义了凸优化问题的组合。类似地，将 **Saddle** 限制到所有 $n \in N$ 满足 $\tau(n) = 2$ 的子范畴，得到一个有限集合代数 $\text{Conc}: \mathbf{FinSet} \rightarrow \mathbf{Set}$ ，定义了凹优化问题的组合。
- 最后，我们可以对 **DiffSaddle** 进行上述相同的限制，得到有限集合代数

$$\text{DiffConv}: \mathbf{FinSet} \rightarrow \mathbf{Set} \text{ 和 } \text{DiffConc}: \mathbf{FinSet} \rightarrow \mathbf{Set}$$

，分别用于组合连续可微的凸和凹问题。

引言中的图 2 展示了这些不同限制之间关系的图示视图。

4.3 用 Uzawa 算法求解复合鞍点问题

现在我们可以证明 **Uzawa** 算法，即对凸部分进行梯度下降而对凹部分进行梯度上升，符合鞍点问题的组合结构。这将使我们能够推导出 **Uzawa** 算法和对偶分解的分布式版本。

Theorem 4.4. 设 $U: \mathbf{FinSet}/[2] \rightarrow \mathbf{FinSet}$ 为片范畴中的遗忘函子。则存在一个单态自然变换 $\text{flow}: \text{DiffSaddle} \Rightarrow \text{Dynam} \circ U$ ，其分量为

$$\text{flow}_{N \xrightarrow{\tau} [2]}: \text{DiffSaddle}(\tau) \rightarrow \text{Dynam}(N) \quad (49)$$

逐点定义为

$$\text{flow}_{\tau}(f)(x)_i := \begin{cases} -\nabla f(x)_i & \tau(i) = 1 \\ \nabla f(x)_i & \tau(i) = 2 \end{cases} \quad (50)$$

对所有 $x \in \mathbb{R}^N$ 和 $i \in N$ 成立。

证明. 为了验证自然性，我们需要证明对所有 $N \xrightarrow{\tau} [2]$ ， $M \xrightarrow{\sigma} [2]$ 以及交换三角形

$$\begin{array}{ccc} \text{DiffSaddle}(\tau) & \xrightarrow{\text{DiffSaddle}(\phi)} & \text{DiffSaddle}(\sigma) \\ \text{flow}_{\tau} \downarrow & & \downarrow \text{flow}_{\sigma} \\ \text{Dynam}(N) & \xrightarrow{\text{Dynam}(\phi)} & \text{Dynam}(M) \end{array} \quad (51)$$

图表

$$\begin{array}{ccc} N & \xrightarrow{\phi} & M \\ & \searrow \tau \quad \swarrow \sigma & \\ & [2] & \end{array}$$

是交换的。

从概念上讲, 该证明将类似于定理 3.3 中自然性的证明, 关键区别在于我们还需要验证 $\text{Dynam}(\phi) \circ \text{flow}_\tau$ 在与 $\text{flow}_\sigma \circ \text{DiffSaddle}(\phi)$ 相同的部分执行梯度下降, 对于梯度上升同理。

首先, 令 $f \in \text{DiffSaddle}(\tau)$ 任意。沿着底部路径得到按分量定义的动力系统:

$$\text{Dynam}(\phi)(\text{flow}_\tau(f))(y)_j = \sum_{i \in \phi^{-1}(j)} \begin{cases} -[\nabla f(\phi^*(y))]_i & \tau(i) = 1 \\ [\nabla f(\phi^*(y))]_i & \tau(i) = 2, \end{cases} \quad (52)$$

对所有 $y \in \mathbb{R}^M$ 和 $j \in M$ 成立。式 (52) 中的求和来自推前映射的分量定义。同样, 沿底部路径得到系统

$$\text{flow}_\sigma(f \circ \phi^*)(y)_j = \begin{cases} -\nabla[f(\phi^*(y))]_j & \sigma(j) = 1 \\ \nabla[f(\phi^*(y))]_j & \sigma(j) = 2, \end{cases} \quad (53)$$

对所有 $y \in \mathbb{R}^M$ 和 $j \in M$ 成立。通过应用链式法则并注意推前映射是拉回映射的对偶 (与定理 3.3 中的推理相同), 我们有 (53) 等于

$$\sum_{i \in \phi^{-1}(j)} \begin{cases} -[\nabla f(\phi^*(y))]_i & \sigma(\phi(i)) = 1 \\ [\nabla f(\phi^*(y))]_i & \sigma(\phi(i)) = 2. \end{cases} \quad (54)$$

关键是, 因为 (51) 是交换三角形, 我们有对于所有 $i \in N$, $\tau(i) = \sigma(\phi(i))$ 。这表明 (52) 与 (53) 相等, 正是我们所需。

要证明 flow 是么半群态的, 同样只需将上述推理与定理 3.3 的推理结合即可。 $\square$

Corollary 4.4.1. 梯度上升-下降给出了一个么半群自然变换 $\text{ga-d}^\gamma: \text{DiffSaddle} \Rightarrow \text{Dynam}_D \circ U$, 其分量为

$$\text{ga-d}_{N \rightarrow [2]}^\gamma: \text{DiffSaddle}(\tau) \rightarrow \text{Dynam}_D(N) \quad (55)$$

定义为

$$\text{ga-d}_\tau^\gamma(f)(x)_i := \begin{cases} x_i - \gamma \nabla f(x)_i & \tau(i) = 1 \\ x_i + \gamma \nabla f(x)_i & \tau(i) = 2 \end{cases} \quad (56)$$

对所有 $x \in \mathbb{R}^N$ 和 $i \in N$ 成立。

证明. 该结论通过将 $\text{flow}: \text{DiffSaddle} \Rightarrow \text{Dynam} \circ U$ 与 Euler^γ 组合得到。 $\square$

展开该自然变换的定义, 它仅仅是在目标的凸部分上执行梯度下降, 在凹部分上执行梯度上升。证明完成后, 我们可以将组合数据条件扩展到由数据定义的目标属于 DiffSaddle 的情况, 即当 D, p 和 t 被选择使得

$$D \xRightarrow{p} \text{DiffSaddle} \circ t \xRightarrow{\text{ga-d}^\gamma * t} \text{Dynam}_D \circ U \circ t$$

是么半群态的自然变换时。

Example 4.5 (Distributed Uzawa's Algorithm and Dual Decomposition). Similar to how applying gd^γ to Opt-UWDs gave us distributed gradient and primal decomposition algorithms in Examples 3.4 and 3.5 respectively, we can apply ga-d^γ to DiffSaddle-UWDs to obtain distributed primal-dual and dual decomposition algorithms.




图 7: A. 一个 DiffSaddle-UWD，编码了受复杂等式约束的可分离目标函数和的结构。B. 一个 DiffSaddle-UWD，构建了图（A）中编码问题的对偶分解。由于这些是 DiffSaddle-UWD，我们用黑色结点表示凸标签变量，用白色结点表示凹标签变量。

A common scenario, which will be revisited in our network flow example in Section 6, is having a separable sum of objective functions subject to some complicating equality constraint. Following the discussion in Section 2.2 of [1], a general example is the problem

$$\begin{aligned} & \text{minimize} && \sum_{i=1}^N f_i(x_i) \\ & \text{subject to} && Ax = b, \end{aligned} \quad (57)$$

where the decision variable $x \in \mathbb{R}^n$ is partitioned into subvectors $x = [x_1, \dots, x_N]^T$ where $x_i \in \mathbb{R}^{n_i}$ and $\sum_i n_i = n$. Here, $A \in \mathbb{R}^{m \times n}$, $b \in \mathbb{R}^m$, and we assume that all the $f_i: \mathbb{R}^{n_i} \rightarrow \mathbb{R}$ are strictly convex. We can then partition A conformably to match the partition of x by using $A = [A_1, \dots, A_N]$ such that

$$Ax = \sum_{i=1}^N A_i x_i, \quad (58)$$

where $A_i \in \mathbb{R}^{m \times n_i}$. With this partitioning, the Lagrangian is also separable in x and can be written as

$$L(x, \lambda) = \sum_{i=1}^N \left(f_i(x_i) + \lambda^T A_i x_i \right) - \lambda^T b. \quad (59)$$

The separable structure of L can then be encoded as the DiffSaddle-UWD in Figure 7.A. Now, applying **ga-d^γ** to this UWD yields a distributed primal-dual solution algorithm which requires synchronization after each gradient step. Specifically, at every iteration, the gradient with respect to λ and the x_i 's are computed locally for each box. These local gradients are then collected and summed along junctions to produce a gradient update for the total system. Like Example 3.5 which modified a distributed gradient descent UWD to a primal decomposition UWD, we can perform a similar modification to convert our distributed primal-dual UWD to a dual decomposition UWD. For this, we take the dual function

$$q(\lambda) := \inf_x L(x, \lambda) = \sum_{i=1}^N \left(\inf_{x_i} f_i(x_i) + \lambda^T A_i x_i \right) - \lambda^T b, \quad (60)$$

which is again separable in x . The dual function can then be encoded as the DiffSaddle-UWD shown in Figure 7.B. Applying ga-d^γ to this UWD yields the standard dual decomposition algorithm for solving (57).

5 作为函子的次梯度下降

我们现在拥有代数态射，它们为无约束和等式约束的可微问题的组合提供分布式求解算法。本节的目标是将这些结果扩展到它们的不可微对应物，其中一个关键方面是从梯度推广到次梯度。为了将次梯度方法纳入我们的框架，我们需要证明它们也提供了从优化问题的 Ω -代数到动力系统的 Ω -代数的代数态射。我们可以使用凸不可微问题的 Conv Ω -代数作为该代数态射的定义域。然而，由于次梯度是一个点到集合的映射， Dynam 作为陪域将不再足够。因此，我们首先将 Dynam 和 Dynam_D 推广到非确定性连续和离散动力系统的代数，分别称为 NDD 和 NDD_D 。然后我们证明欧拉方法在这种非确定性环境下仍然是自然的。最后，这一结果使我们能够证明，次梯度方法给出了从 Conv 到 NDD_D 的代数态射。

5.1 非确定性动力系统

一般地，一个非确定性的连续动力系统由映射 $v: \mathbb{R}^N \rightarrow P\mathbb{R}^N$ 给出，其中 $P\mathbb{R}^N$ 表示 $\mathbb{R}^N$ 中向量集合的幂集。映射 v 可以被理解为将当前状态映射到可能的更新方向的集合，因此被识别为微分包含 $\langle \text{PLACEHOLDER}_{ENV_67} \rangle$

为了构造用于组合此类非确定性系统的代数，我们首先需要回顾幂集函子，它将函数 $X \rightarrow Y$ 升维为函数 $PX \rightarrow PY$ 。

证明. 参 $\{a + b \mid a \in A, b \in B\}$ 中的示例 1.3.2.i.

□

此后，当我们谈论作用于向量空间的幂集时，我们总是指向量空间基础向量集合的幂集。我们还需要下面的引理，它说明幂集函子作用于线性映射时，相对于 Minkowski 和仍然是线性的。回顾一下，两个集合 A 和 B 的 Minkowski 和定义为集合 $\{a + b \mid a \in A, b \in B\}$ 。为了避免与余积符号混淆，我们用 $A \boxplus B$ 表示 Minkowski 和。同样地，我们用 $A \boxminus B$ 表示 Minkowski 差 $A \boxplus (-B)$ 。

证明. 我们有以下等式 $\langle \text{PLACEHOLDER}_{ENV_70} \rangle$ 其中第二个等号来源于 T 的线性性，其余等号为定义。 □

非确定性系统的组合类似于确定性系统，但利用幂集函子和 Minkowski 和将确定性的 Dynam 部分提升为其非确定性对应物。

$\langle \text{PLACEHOLDER}_{ENV_71} \rangle$

证明. 函子性直接来自于 P 和 $(-)_*$ 是协变函子，而 $(-)^*$ 是逆变函子。特别地，对于恒等映射的保持，我们有 $\langle \text{PLACEHOLDER}_{ENV_72} \rangle$ 同样地，对于复合的保持，给定 $\phi: X \rightarrow Y$ 和 $\psi: Y \rightarrow Z$ ，我们有 $\langle \text{PLACEHOLDER}_{ENV_73} \rangle$

为了验证积比较的自然性，我们需要证明以下图表

$$\begin{array}{ccc} \text{NDD}(X) \times \text{NDD}(Y) & \xrightarrow{\text{NDD}(\phi) \times \text{NDD}(\psi)} & \text{NDD}(N) \times \text{NDD}(M) \\ \downarrow \varphi_{X,Y} & & \downarrow \varphi_{N,M} \\ \text{NDD}(X + Y) & \xrightarrow{\text{NDD}(\phi + \psi)} & \text{NDD}(N + M) \end{array}$$

对所有有限集 X, Y, N, M 以及函数 $\phi: X \rightarrow N$ 和 $\psi: Y \rightarrow M$ 皆交换。因此，固定任意系统 $(v, \rho) \in \text{NDD}(X) \times \text{NDD}(Y)$ 。沿着上路径得到系统 $\langle \text{PLACEHOLDER}_E NV_75 \rangle$ 其中等号来源于幂集函子的函子性。沿着下路径得到系统 $\langle \text{PLACEHOLDER}_E NV_76 \rangle$ 其中第一个等号来源于 $(-)_*$ 和 $(-)^*$ 是强么半群函子，第二个等号来源于引理 5.5，第三个等号来源于幂集函子的函子性。最后，以下图表的交换性

结合式 (32) 中图表的交换性，表明式 (78) 等价于 (73)，如预期所示。

结合律和单位元图表的证明虽繁琐但直接，唯一非平凡的步骤是再次应用引理 5.5。 $\square$

我们可以做类似的扩展来定义一个用于组合非确定性离散系统的代数。首先注意存在自然变换 $\eta: \text{id}_{\text{Set}} \Rightarrow P$ ，其分量为

$$\eta_X: X \rightarrow P$$

X ，定义为 $x \mapsto \{x\}$ (61) 对所有 $x \in X$ 成立。这对于将 Dynam_D 定义中的恒等函数（见示例

Lemma 5.1. 存在一个有限集代数 $\text{NDD}_D: (\mathbf{FinSet}, +) \rightarrow (\mathbf{Set}, \times)$ ，定义如下。

- 在对象上， NDD_D 将有限集 N 映射为从 $\mathbb{R}^N$ 到 $P\mathbb{R}^N$ 的函数集。
- 给定一个映射 $\phi: N \rightarrow M$ ，映射 $\text{NDD}_D(\phi): \text{NDD}_D(N) \rightarrow \text{NDD}_D(M)$ 由函数定义为

$$v \mapsto \eta_{\mathbb{R}^M} \boxplus P\phi_* \circ (v \boxplus \eta_{\mathbb{R}^N}) \circ \phi^*. \quad (62)$$

- 比较映射与 NDD 中的相同。

证明. 为证明 NDD_D 保持恒等映射，令 $X \in \mathbf{FinSet}$ 且 $v \in \mathbb{R}^X \rightarrow P\mathbb{R}^X$ 任意。则其中第一个等号来自幂集、推前和拉回函子保持复合，令 $\phi: X \rightarrow Y$ 和 $\psi: Y \rightarrow Z$ 是 $\mathbf{FinSet}$

$$\begin{aligned} \text{NDD}_D(\psi \circ \phi)(v) &:= \eta_{\mathbb{R}^Z} \boxplus P((\psi \circ \phi)_*) \circ (v \boxplus \eta_{\mathbb{R}^X}) \circ (\psi \circ \phi)^* \\ &= \eta_{\mathbb{R}^Z} \boxplus P(\psi_*) \circ (P(\phi_*) \circ (v \boxplus \eta_{\mathbb{R}^X}) \circ \phi^*) \circ \psi^* \\ &= \eta_{\mathbb{R}^Z} \boxplus P(\psi_*) \circ (\text{NDD}_D(\phi)(v) \boxplus \eta_{\mathbb{R}^Y}) \circ \psi^* \quad \text{其中第一个等号由幂集和自由向量空间函子对} \\ &= (\text{NDD}_D(\psi) \circ \text{NDD}_D(\phi))(v), \end{aligned}$$

中任意态射。则

由于比较映射与 NDD 中相同，证明类似。 $\square$

类似于确定性系统，我们同样可以对非确定性系统使用 *Euler* 方法，将连续系统映射为离散系统。

Lemma 5.2. 给定 $\gamma > 0$ ，存在一个单元自然变换 $\text{Euler}^\gamma: \text{NDD} \Rightarrow \text{NDD}_D$ ，其分量为 $\text{Euler}_N^\gamma: \text{NDD}(N) \rightarrow \text{NDD}_D(N)$ ，由函数给出

$$v \mapsto \eta_{\mathbb{R}^N} \boxplus \gamma v. \quad (63)$$

证明. 为验证自然性，我们需证明下图

$$\begin{array}{ccc} \text{NDD}(N) & \xrightarrow{\text{NDD}(\phi)} & \text{NDD}(M) \\ \text{Euler}_N^\gamma \downarrow & & \downarrow \text{Euler}_M^\gamma \\ \text{NDD}_D(N) & \xrightarrow{\text{NDD}_D(\phi)} & \text{NDD}_D(M) \end{array}$$

对所有 $N, M \in \mathbf{FinSet}$ 及 $\phi: N \rightarrow M$ 皆交换。令 $v \in \mathbb{R}^N \rightarrow P\mathbb{R}^N$ 任意。沿上路径得到系统 $\langle \text{PLACEHOLDER}_E NV_8 4 \rangle$

沿下路径得到系统 $\langle \text{PLACEHOLDER}_E NV_8 5 \rangle$ 该系统即等于式(76), 如预期所示。为验证变换的么半群性, 我们需验证图表

以及

$$\begin{array}{ccc} \{*\} & \xrightarrow{\varphi_0^{\text{NDD}}} & \text{NDD}(\emptyset) \\ & \searrow \varphi_0^{\text{NDD}_D} & \downarrow \text{Euler}_\emptyset^\gamma \\ & & \text{NDD}_D(\emptyset) \end{array}$$

对所有 $N, M \in \mathbf{FinSet}$ 皆交换。对于积比较图表, 令 $(v, \rho) \in \text{NDD}(N) \times \text{DD}(M)$ 任意。沿上路径得到系统 $\langle \text{PLACEHOLDER}_E NV_8 8 \rangle$ 其中等号来源于引理 ?? 的应用及项的重排。沿下路径得到系统

$$\eta_{\mathbb{R}^{N+M}} \boxplus P(\iota_{N*}) \circ \gamma v \circ \iota_N^* \boxplus P(\iota_{M*}) \circ \gamma \rho \circ \iota_M^*. \quad (64)$$

因此, 为完成本部分证明, 我们只需证明 $\eta_{\mathbb{R}^{N+M}} = P(\iota_{N*}) \circ \eta_{\mathbb{R}^N} \circ \iota_N^* \boxplus P(\iota_{M*}) \circ \eta_{\mathbb{R}^M} \circ \iota_M^*$ 。为此, 注意到 $\mathbb{R}^{N+M} \cong \mathbb{R}^N \times \mathbb{R}^M$, 令 $(x, y) \in \mathbb{R}^N \times \mathbb{R}^M$ 任意。则

$$\begin{aligned} (P(\iota_{N*}) \circ \eta_{\mathbb{R}^N} \circ \iota_N^* \boxplus P(\iota_{M*}) \circ \eta_{\mathbb{R}^M} \circ \iota_M^*)(x, y) = \\ \{(x, 0)\} \boxplus \{(0, y)\} = \{(x, y)\} = \eta_{\mathbb{R}^{N+M}}(x, y). \end{aligned} \quad (65)$$

最后, 对于单位元比较图表, 令 $z: \mathbb{R}^0 \rightarrow P\mathbb{R}^0$ 表示零函数 $0 \mapsto \{0\}$ 。则 $(\eta_{\mathbb{R}^0} \boxplus \gamma z)(0) = \{0\} \boxplus \gamma \{0\} = \{0\}$, 符合预期。 $\square$

Lemma 5.3. 存在一个有限集代数 $\text{NDD}: (\mathbf{FinSet}, +) \rightarrow (\mathbf{Set}, \times)$ 定义如下。

- 在对象上, NDD 将有限集 N 映射为函数集 $\{v: \mathbb{R}^N \rightarrow P\mathbb{R}^N\}$ 。
- 给定函数 $\phi: N \rightarrow M$, 映射 $\text{NDD}(\phi): \text{NDD}(N) \rightarrow \text{NDD}(M)$ 定义为

$$v \mapsto P\phi_* \circ v \circ \phi^*. \quad (66)$$

- 给定有限集 N 和 M , 乘积比较映射

$$\varphi_{N,M}: \text{NDD}(N) \times \text{NDD}(M) \rightarrow \text{NDD}(N + M)$$

由函数定义:

$$(v, \rho) \mapsto P\iota_{N*} \circ v \circ \iota_N^* \boxplus P\iota_{M*} \circ \rho \circ \iota_M^*. \quad (67)$$

- 单位比较 $\varphi_0: \{*\} \rightarrow \text{NDD}(\emptyset)$ 是函数 $\mathbb{R}^0 \rightarrow P\mathbb{R}^0$, 定义为 $0 \mapsto \{0\}$ 。

$$\text{NDD}(\psi \circ \phi)(v) := P((\psi \circ \phi)_*) \circ v \circ (\psi \circ \phi)^* \quad (68)$$

$$= P(\psi_* \circ \phi_*) \circ v \circ \phi^* \circ \psi^* \quad (69)$$

$$= P\psi_* \circ P\phi_* \circ v \circ \phi^* \circ \psi^* \quad (70)$$

$$= \text{NDD}(\psi) \circ \text{NDD}(\phi)(v). \quad (71)$$

Lemma 5.4. 存在一个函子 $P: \mathbf{Set} \rightarrow \mathbf{Set}$, 其定义如下映射:

- 在对象上, P 将一个集合 X 映射为其幂集 $P(X) := \{A : A \subseteq X\}$ 。
- 给定一个函数 $f: X \rightarrow Y$, 映射 $P(f): P(X) \rightarrow P(Y)$ 是像函数

$$A \mapsto \bigcup_{a \in A} f(a) \quad (72)$$

对于 $A \subseteq X$ 。

$$\begin{aligned} & P(\phi + \psi)_* \circ (P\iota_{X*} \circ v \circ \iota_X^* \boxplus P\iota_{Y*} \circ \rho \circ \iota_Y^*) \circ (\phi + \psi)^* \\ &= P(\phi_* \oplus \psi_*) \circ (P\iota_{X*} \circ v \circ \iota_X^* \boxplus P\iota_{Y*} \circ \rho \circ \iota_Y^*) \circ (\phi^* \oplus \psi^*) \\ &= (P(\phi_* \oplus \psi_*) \circ P\iota_{X*} \circ v \circ \iota_X^* \boxplus P(\phi_* \oplus \psi_*) \circ P\iota_{Y*} \circ \rho \circ \iota_Y^*) \circ (\phi^* \oplus \psi^*) \\ &= (P((\phi_* \oplus \psi_*) \circ \iota_{X*}) \circ v \circ \iota_X^* \boxplus P((\phi_* \oplus \psi_*) \circ \iota_{Y*}) \circ \rho \circ \iota_Y^*) \circ (\phi^* \oplus \psi^*), \end{aligned} \quad (73)$$

$$\text{NDD}(\text{id}_N)(v) := P(\text{id}_{N*}) \circ v \circ \text{id}_N^* = \text{id}_{P\mathbb{R}^N} \circ v \circ \text{id}_{\mathbb{R}^N} = v. \quad (74)$$

$$\eta_{\mathbb{R}^M} \boxplus P(\phi_*) \circ (\eta_{\mathbb{R}^N} \boxplus \gamma v \boxplus \eta_{\mathbb{R}^N}) \circ \phi^* = \eta_{\mathbb{R}^M} \boxplus P(\phi_*) \circ \gamma v \circ \phi^*, \quad (75)$$

$$\eta_{\mathbb{R}^M} \boxplus \gamma(P(\phi_*) \circ v \circ \phi^*), \quad (76)$$

$$P(\iota_{N*}) \circ (\eta_{\mathbb{R}^N} \boxplus \gamma v) \circ \iota_N^* \boxplus P(\iota_{M*}) \circ (\eta_{\mathbb{R}^M} \boxplus \gamma \rho) \circ \iota_M^* = \quad (77)$$

$$P(\iota_{N*}) \circ \eta_{\mathbb{R}^N} \circ \iota_N^* \boxplus P(\iota_{M*}) \circ \eta_{\mathbb{R}^M} \circ \iota_M^* \boxplus P(\iota_{N*}) \circ \gamma v \circ \iota_N^* \boxplus P(\iota_{M*}) \circ \gamma \rho \circ \iota_M^*,$$

$$P\iota_{N*} \circ P\phi_* \circ v \circ \phi^* \circ \iota_N^* \boxplus P\iota_{M*} \circ P\psi_* \circ \rho \circ \psi^* \circ \iota_M^* = P(\iota_{N*} \circ \phi_*) \circ v \circ \phi^* \circ \iota_N^* \boxplus P(\iota_{M*} \circ \psi_*) \circ \rho \circ \psi^* \circ \iota_M^*, \quad (78)$$

$$\begin{array}{ccc} \mathbb{R}^X & \xrightarrow{\phi_*} & \mathbb{R}^N \\ \iota_{X*} \downarrow & & \downarrow \iota_{N*} \\ \mathbb{R}^X \oplus \mathbb{R}^Y & \xrightarrow{\phi_* \oplus \psi_*} & \mathbb{R}^N \oplus \mathbb{R}^M \end{array} \quad \begin{array}{ccc} \mathbb{R}^Y & \xrightarrow{\psi_*} & \mathbb{R}^M \\ \iota_{Y*} \downarrow & & \downarrow \iota_{M*} \\ \mathbb{R}^X \oplus \mathbb{R}^Y & \xrightarrow{\phi_* \oplus \psi_*} & \mathbb{R}^N \oplus \mathbb{R}^M \end{array} \quad \dot{x} \in v(x). \quad (79)$$

Lemma 5.5. 给定向量空间 X 和 Y , 子集 $A, B \subseteq X$, 以及线性映射 $T: X \rightarrow Y$, 我们有 $(PT)(A \boxplus B) = (PT)(A) \boxplus (PT)(B)$ 。

$$\begin{aligned} (PT)(A \boxplus B) &= \{T(a+b) \mid a \in A, b \in B\} \\ &= \{Ta + Tb \mid a \in A, b \in B\} \\ &= (PT)(A) \boxplus (PT)(B), \end{aligned}$$

5.2 次梯度法和超梯度法的代数态射

在定义了非确定性动力系统的 UWD 代数之后, 我们可以转而证明次梯度法分解定义在 UWD 上的不可微凸优化问题。这将再次使我们能够以自然的方式扩展组合数据条件, 以涵盖不可微的凸问题。

Theorem 5.6. 存在一个单性自然变换 $\text{subg}: \text{Conv} \Rightarrow \text{NDD}$, 其分量为

$$\text{subg}_N: \text{Conv}(N) \rightarrow \text{NDD}(N), f \mapsto -\partial f. \quad (80)$$

证明. 我们首先需要检查自然性, 即检查对所有 $N, M \in \mathbf{FinSet}$ 及 $\phi: N \rightarrow M$, 图

$$\begin{array}{ccc} \text{Conv}(N) & \xrightarrow{\text{Conv}(\phi)} & \text{Conv}(M) \\ \text{subg}_N \downarrow & & \downarrow \text{subg}_M \\ \text{NDD}(N) & \xrightarrow{\text{NDD}(\phi)} & \text{NDD}(M) \end{array}$$

是否交换. 设 $f \in \text{Conv}(N)$ 任意, 令 $K = \mathcal{M}(\phi^*)$. 沿底部路径得到的是 $PK^T \circ -\partial f \circ K$, 而沿顶部路径得到的是 $-\partial(f \circ K)$. 关于次梯度的一个事实是, 给定线性变换 K , 恒等式 $\partial(f \circ K) = K^T \circ \partial f \circ K$ 成立 (参见 [40], §3.3). 在这类文献中, 隐含应用了幂集函子, 因此 $K^T \circ \partial f \circ K$ 实际上表示 $P(K^T) \circ \partial f \circ K$. 将该恒等式应用于沿顶部路径的结果, 表明这两条路径是等价的.

类似于定理 3.3, 么半群性 (monoidality) 的证明与自然性的证明思路相同, 注意到函数和的次梯度由加数的次梯度的 Minkowski 和给出 (参见 [40], §3.2). $\square$

对于凹函数和超梯度, 也存在对偶结果.

Corollary 5.6.1. 存在一个单么范自然变换 $\text{superg}: \text{Conc} \Rightarrow \text{NDD}$, 其分量 $\text{superg}_N: \text{Conc}(N) \rightarrow \text{NDD}(N)$ 定义为

$$\text{superg}_N(f) := \partial f. \quad (81)$$

Corollary 5.6.2. 存在一个单么自然变换 $\text{pd-subg}: \text{Saddle} \rightarrow \text{NDD} \circ U$, 其分量为 $\text{pd-subg}_{N \rightarrow [2]}: \text{Saddle}(\tau) \rightarrow \text{NDD}(N)$, 定义为

$$\text{pd-subg}_\tau(f)(x)_i := \begin{cases} -\partial_{x_i} f(x) & \tau(i) = 1 \\ \partial_{x_i} f(x) & \tau(i) = 2, \end{cases} \quad (82)$$

对所有 $x \in \mathbb{R}^N$ 和 $i \in N$ 成立.

注意, 通过将上述每个自然变换与非确定性欧拉变换组合以导出离散系统, 还可得到推论. 为简洁起见, 我们在此省略这些内容.

在确立了这些次梯度方法的自然性之后, 我们可以重复原始分解 (例 3.5) 和对偶分解 (例 4.5) 的示例, 同时将子问题严格凸性的假设放宽为仅需凸性. 此放宽意味着这些示例中的下确界可能在多个点处取得. 然而, 对于固定的 w , 任意满足 $x^* \in \arg \min f(w, x)$ 的点都能作为 $\inf_x f(w, x)$ 的一个次梯度, 即 $\partial f(w, x^*)$. 因此, 次梯度方法为子问题非严格凸的情形自然地扩展了原始和对偶分解.

6 扩展示例: 最小费用网络流

我们现在展示我们的框架如何为将问题数据转换为尊重数据组合结构的求解算法提供一种原则性的方法. 具体来说, 我们构造一个用于通过粘合顶点来组合流网络的 finset 代数, 并证明将给定流网络翻译为相应的最小费用网络流问题是一个么半范畴自然变换. 这满足了组合数据条件 (定义 3.6), 因此使我们能够推导出一种分布式算法来解决最小费用网络流 (MCNF) 问题, 该问题是工程应用中广泛研究的一类问题 [41, 42, 43, 44, 45]. 我们将看到, 结果是对尊重流网络任意层次分解的标准 MCNF 对偶分解算法的推广.

6.1 MCNF 的标准形式化及对偶分解

首先，我们回顾 MCNF 问题的标准非组合形式化。流网络是一个带有指定源点和汇点顶点（每个顶点分别具有相应的流入和流出）以及与每条边相关联的成本函数的有向图，该成本函数表示通过该边推动给定流量的成本。最小费用网络流问题则涉及在满足流入某顶点的流量必须等于该顶点流出的流量（对所有顶点均成立）的流量守恒约束的条件下，寻找对网络中各边的流量分配，使得总流量成本最小化。该约束称为流量守恒约束。网络流问题的应用范围广泛，从确定体育队伍是否已经被淘汰出冠军争夺战，到计算电阻网络中的电流流动 [46, 47]。

形式化地，定义在有限顶点集 V 上的流网络是一个五元组 (E, s, t, ℓ, b) ，其中

- E 是一个有限的边集合，
- $s: E \rightarrow V$ 将每条边映射到其起始顶点，
- $t: E \rightarrow V$ 将每条边映射到其目标顶点，
- $\ell: E \rightarrow K$ ，其中 $K := \{\kappa: \mathbb{R} \rightarrow \mathbb{R} \mid \kappa \in C^1 \text{ 且凸}\}$ ，定义了每条边的流量成本函数，
- $b: V \rightarrow \mathbb{R}$ 定义了每个顶点的流入或流出量：对于 $v \in V$ ，正值表示流入，负值表示流出，零表示无流量。图的总流入必须等于总流出，即 $\sum_{v \in V} b(v)$ 必须等于 0。将 b 视为 $\mathbb{R}^V$ 中的向量，我们可以简洁地写成 $\mathbf{1}^T b = 0$ 。

所有这些数据可以汇总为以下图示：

$$K \xleftarrow{\ell} E \xrightleftharpoons[t]{s} V \xrightarrow{b} \mathbb{R}. \quad (83)$$

注意，在 0 个顶点上存在唯一的流网络，由下式给出：

$$K \xleftarrow{!} \emptyset \xrightleftharpoons[!]{!} \emptyset \xrightarrow{!} \mathbb{R}.$$

因此，0 个顶点上的流网络集合是一个单元素集合，从而是范畴 **Set** 中的终对象。

假设我们有一个定义在顶点集 V 上的流网络 $G = (E, s, t, \ell, b)$ 。我们使用变量 $x \in \mathbb{R}^E$ 来跟踪每条边的流量。 $x_e > 0$ 表示边 e 方向上的流量，而 $x_e < 0$ 表示边 e 反方向上的流量。因此，最小费用流问题的目标是 minimized 函数

$$\sum_{e \in E} \ell(e)(x_e). \quad (84)$$

我们还必须强制执行流量守恒约束。为数学编码该约束，令 $A \in \mathbb{R}^{V \times E}$ 表示图 G 的节点关联矩阵³，即

$$A_{v,e} := \begin{cases} 0 & \text{if } s(e) = t(e) = v \\ 1 & \text{if } s(e) = v \\ -1 & \text{if } t(e) = v \\ 0 & \text{otherwise.} \end{cases} \quad (85)$$

那么，流量守恒可简洁地表述为要求 $Ax = b$ 。结合目标函数和约束，流网络 G 的最小费用网络流问题为

$$\begin{aligned} & \text{minimize} && \sum_{e \in E} \ell(e)(x_e) \\ & \text{subject to} && Ax = b. \end{aligned} \quad (86)$$

³定义中的第一个条件用于消除自环。

一种常用的一阶求解方法是构造拉格朗日函数并使用对偶分解。拉格朗日函数为

$$L(x, \lambda) := \sum_{e \in E} \ell(e)(x_e) + \lambda^T (Ax - b). \quad (87)$$

然后，对偶函数 $q_G: \mathbb{R}^V \rightarrow \mathbb{R}$ 是一个凹函数，定义为

$$q_G(\lambda) := \inf_{x \in \mathbb{R}^E} L(x, \lambda) = \inf_{x \in \mathbb{R}^E} \sum_{e \in E} \ell(e)(x_e) + \lambda^T (Ax - b). \quad (88)$$

对 q_G 施加超梯度上升法得到迭代算法

$$\begin{aligned} x^* &:= \arg \min L(x, \lambda_k) \\ \lambda_{k+1} &:= \lambda_k + \gamma(Ax^* - b). \end{aligned} \quad (89)$$

该方法有效是因为 $Ax^* - b$ 是 q_G 在 λ_k 处的超梯度。由于 L 在 x 上是可分的，计算 x^* 可分解为 $|E|$ 个标量最小化问题。

6.2 MCNF 的组合式构造

为了将该对偶分解算法推广到流网络的任意分层分解，我们必须首先定义一个用于组合流网络的有限集代数。

$\langle \text{PLACEHOLDER}_E \text{NV}_104 \rangle$

证明. FlowNet 是对文 $\mathbf{1}^T b = 02$ 中引入的带标记图函子的一种扩展，增加了由 b 向量定义的每个顶点上的标量，因此它们的大部分证明同样适用。我们只需验证态射映射和积比较保持性质 $\mathbf{1}^T b = 0$ 。积比较中的配对 $[b_1, b_2]$ 保持该性质，因为 $\mathbf{1}^T b_1 = 0$ 且 $\mathbf{1}^T b_2 = 0$ 。对于态射映射，注意对于推前映射 ϕ_* 的像中的向量 $v = \phi_*(b)$ ，其分量 v_i 要么是 0，要么是 b 的单个元素，或者是 b 的一个或多个元素的和。由于 b 的各分量之和为 0，且 b 的每个分量在 ϕ_* 下要么映射为其自身，要么与其他分量求和，因此 ϕ 像中的 v 的各分量之和必为零。此外，由于 v 中不在 ϕ 像中的分量为 0，故 v 的所有分量之和为 0。□

给定一个 UWD 以及适用于每个内部盒子节点数的子图， FlowNet 代数通过合并共享同一连接点的顶点构造复合图。如图 8 所示。

现在，我们的目标是证明将流网络翻译为其关联的 MCNF 目标函数构成一个幺半范畴自然变换，从而满足组合数据条件。首先注意，将顶点集为 V 的流网络 G 翻译为关联 MCNF 问题的对偶函数 q_G ，得到一个函数 $\text{netflow}_V: \text{FlowNet}(V) \rightarrow \text{Conc}(V)$ ，定义为 $G \mapsto q_G$ 。由于该翻译适用于任意 V ，我们拥有一个以有限集为指标的映射族，这些映射组成了自然变换的各个分量。

证明. 为验证自然性，我们需证明对所有 $N, M \in \mathbf{FinSet}$ 和态射 $\phi: N \rightarrow M$ ，下述图表

$$\begin{array}{ccc} \text{FlowNet}(N) & \xrightarrow{\text{FlowNet}(\phi)} & \text{FlowNet}(M) \\ \downarrow \text{netflow}_N & & \downarrow \text{netflow}_M \\ \text{Conc}(N) & \xrightarrow{\text{Conc}(\phi)} & \text{Conc}(M) \end{array}$$

交换。取任意 $(E, s, t, \ell, b) \in \text{FlowNet}(N)$ ，设 $K = \mathcal{M}(\phi^*)$ 。因推前映射与拉回映射对偶，故 $K^T = \mathcal{M}(\phi_*)$ 。沿上路径得到函数 $\langle \text{PLACEHOLDER}_E \text{NV}_108 \rangle$ 其中 $A \in \mathbb{R}^{M \times E}$ 定义为 $\langle \text{PLACEHOLDER}_E \text{NV}_109 \rangle$

同理,沿下 路径得到函数 $\langle \text{PLACEHOLDER}_{ENV_110} \rangle$ 其中 $e \in E$ 定义为 $\langle \text{PLACEHOLDER}_{ENV_111} \rangle$ 因此,为完成证明,足以证明 $A = K^T C$ 。为此,注意 A 与 C 均有 $|E|$ 列。选取任意 $e \in E$, 需证明 $a_e = K^T c_e := \phi_*(c_e)$, 其中 a_e 与 c_e 分别为 A 和 C 的第 e 列。令 $m \in M$ 任意, 根据推前定义, 有 $\langle \text{PLACEHOLDER}_{ENV_112} \rangle$ 现考虑 $a_e(m)$ 的三种可能值, 并证明在每种情况下都等于 $\phi_*(c_e)(m)$ 。

首先, 若 $a_e(m) = 1$, 由 A 的定义, 知 $\phi(s(e)) = m$ 且 $\phi(t(e)) \neq m$ 。该等式表明 $s(e) \in \phi^{-1}(m)$, $t(e) \notin \phi^{-1}(m)$, 因此由 (91) 可知 $\phi_*(c_e)(m) = 1$ 。类似地, 若 $a_e(m) = -1$, 则 $\phi_*(c_e)(m) = -1$ 。

最后考虑 $a_e(m) = 0$ 的情况。有两种可能: 要么 $s(e) \notin \phi^{-1}(m)$ 且 $G_2 := (E_2, s_2, t_2, \ell_2, b_2) \in \text{FlowNet}(M)(m)$

, 此时由(91)得

$\phi_*(c_e)(m) = 0$; 要么 $s(e) \in \phi^{-1}(m)$ 且 $G_1 \mathbf{1}(m)$, 此时根据 (91), $\phi_*(c_e)(m) := 1 - 1 = 0$, 符合预期。

为验证该变换是么半范畴的, 还需验证下列图表

$$\begin{array}{ccc} \text{FlowNet}(N) \times \text{FlowNet}(M) & \xrightarrow{\text{netflow}_N \times \text{netflow}_M} & \text{Conc}(N) \times \text{Conc}(M) \\ \downarrow \varphi_{N,M}^{\text{FlowNet}} & & \downarrow \varphi_{N,M}^{\text{Conc}} \\ \text{FlowNet}(N+M) & \xrightarrow{\text{netflow}_{N+M}} & \text{Conc}(N+M) \end{array}$$

和

$$\begin{array}{ccc} \{*\} & \xrightarrow{\varphi_0^{\text{FlowNet}}} & \text{FlowNet}(\emptyset) \\ & \searrow \varphi_0^{\text{Conc}} & \downarrow \text{netflow}_\emptyset \\ & & \text{Conc}(\emptyset) \end{array}$$

对所有 $N, M \in \mathbf{FinSet}$ 交换。

对第一个图, 令 $G_1 := (E_1, s_1, t_1, \ell_1, b_1) \in \text{FlowNet}(N)$, $G_2 := (E_2, s_2, t_2, \ell_2, b_2) \in \text{FlowNet}(M)$, A_{G_1} 和 A_{G_2} 分别为 G_1 与 G_2 的节点关联矩阵。沿上路径得到函数 同理, 沿下路径得到函数 $\langle \text{PLACEHOLDER}_{ENV_116} \rangle$ 注意 (95) 可沿着 $\mathbb{R}^{E_1}$ 和 $\mathbb{R}^{E_2}$ 中的分量分开, 因此等价于 (93)。

对第二个图, 空流网络的节点关联矩阵必为唯一的线性映射 $\mathbb{R}^0 \rightarrow \mathbb{R}^0$ 。同样, 空流网络中 b 必为 $\mathbb{R}^0$ 中的零向量。考虑此情况, 沿上、下路径均得到常零函数, 符合预期。

确立此代数态射后, 我们终于可以转向下述图表所示的复合: $\text{FlowNet} \xrightarrow{\text{netflow}} \text{Conc} \xrightarrow{\text{superg}} \text{NDD} \xrightarrow{\text{Euler}^\gamma} \text{NI}$ 该变换将流网络 G 映射为离散非确定性动态系统, 该系统通过在对偶问题 q_G 上进行超梯度上升来求解 G 上的最小费用网络流问题。本文中所证明的结果表明, 该复合变换尊重 G 的任意分解。特别地, 若使用每个内部盒子仅含单条边的 UWD 完全分解 G , 那么应用(90)中的复合变换将得到文献 [48] 第二节 A 部分中介绍的标准对偶分解算法。

该分解算法是扁平的, 即将问题分解为单一主问题和针对每条边的标量子问题。更有趣的是, 我们可以将 (90) 应用于 G 的其他分解结构。例如, 我们可以按密集连接分量分解 G , 然后对每个连通分量进一步通过边完全分解, 从而得到分层分解。后续章节将展示如何利用此类更高层次的组合结构带来益处。

$$\phi_*(c_e)(m) := \sum_{n \in \phi^{-1}(m)} c_e(n) = \sum_{n \in \phi^{-1}(m)} \begin{cases} 0 & \text{if } s(e) = t(e) = n \\ 1 & \text{if } s(e) = n \\ -1 & \text{if } t(e) = n \\ 0 & \text{otherwise.} \end{cases} \quad (91)$$




图 8: 利用 FlowNet UWD-代数构造流网络的示意图。FlowNet 作用于 UWD Φ 及组成子图 G_1, G_2 和 G_3 , 产生右侧的结果流网络。这里, 我们仅展示 FlowNet 在流网络的基础有向图结构上的作用。通过颜色区分被合并的顶点与未被合并的顶点, 以突出合成过程中的区别。

$$C_{e,n} := \begin{cases} 0 & \text{if } s(e) = t(e) = n \\ 1 & \text{if } s(e) = n \\ -1 & \text{if } t(e) = n \\ 0 & \text{otherwise.} \end{cases} \quad (92)$$

$$\lambda \mapsto \inf_{x \in \mathbb{R}^{E_1}} \sum_{e \in E_1} \ell_1(e)(x_e) + \pi_N(\lambda)^T (A_{G_1} x - b_1) + \inf_{x' \in \mathbb{R}^{E_2}} \sum_{e' \in E_2} \ell_2(e')(x'_{e'}) + \pi_M(\lambda)^T (A_{G_2} x' - b_2). \quad (93)$$

$$A_{e,m} := \begin{cases} 0 & \text{if } \phi(s(e)) = \phi(t(e)) = m \\ 1 & \text{if } \phi(s(e)) = m \\ -1 & \text{if } \phi(t(e)) = m \\ 0 & \text{otherwise.} \end{cases} \quad (94)$$

$$\lambda \mapsto \inf_{y \in \mathbb{R}^{E_1+E_2}} \sum_{e \in E_1+E_2} [\ell_1, \ell_2](e)(y_e) + \lambda^T \left(\begin{bmatrix} A_{G_1} & 0 \\ 0 & A_{G_2} \end{bmatrix} y - \begin{bmatrix} b_1 \\ b_2 \end{bmatrix} \right). \quad (95)$$

Lemma 6.1. 存在一个有限集代数⁴ $\text{FlowNet}: (\mathbf{FinSet}, +) \rightarrow (\mathbf{Set}, \times)$, 由以下映射定义:

- 在对象上, FlowNet 将有限集 N 映射为顶点集为 N 的流网络集合:

$$\{K \xleftarrow{\ell} E \xrightarrow[t]{s} N \xrightarrow{b} \mathbb{R} \mid \mathbf{I}^T b = 0\}. \quad (96)$$

⁴从技术上讲, 这只是一个松对称幺半范畴的伪函子, 因为某些所需的交换图仅在规范同构意义下成立。关于此技术细节, 详见 [11]。

- 给定 **FinSet** 中的态射 $\phi: N \rightarrow M$, 映射 $\text{FlowNet}(\phi): \text{FlowNet}(N) \rightarrow \text{FlowNet}(M)$ 由函数定义为

$$(E, s, t, \ell, b) \mapsto (E, \phi \circ s, \phi \circ t, \ell, \phi_*(b)). \quad (97)$$

- 单位比较态射 $\varphi_0: \{*\} \rightarrow \text{FlowNet}(\emptyset)$ 是唯一箭头, 因为 $\text{FlowNet}(\emptyset)$ 是 **Set** 中的终对象。
- 给定对象 $N, M \in \mathbf{FinSet}$, 积比较

$$\varphi_{N,M}: \text{FlowNet}(N) \times \text{FlowNet}(M) \rightarrow \text{FlowNet}(N + M) \quad (98)$$

将一对流网络 $(E_1, s_1, t_1, \ell_1, b_1)$ 和 $(E_2, s_2, t_2, \ell_2, b_2)$ 映射为它们的离散并, 即 $(E_1 + E_2, s_1 + s_2, t_1 + t_2, [\ell_1, \ell_2], [b_1, b_2])$ 。

Theorem 6.2. 存在一个单体自然变换 $\text{netflow}: \text{FlowNet} \Rightarrow \text{Conc}$, 其分量 $\text{netflow}_N: \text{FlowNet}(N) \rightarrow \text{Conc}(N)$ 将顶点数为 N 的流网络 $G := (E, s, t, \ell, b)$ 映射为凹函数

$$\lambda \mapsto \inf_{x \in \mathbb{R}^E} \sum_{e \in E} \ell(e)(x_e) + \lambda^T (Ax - b), \quad (99)$$

其中 A 是 G 的节点关联矩阵。

$$\lambda \mapsto \inf_{x \in \mathbb{R}^E} \sum_{e \in E} \ell(e)(x_e) + (K\lambda)^T (Cx - b) = \inf_{x \in \mathbb{R}^E} \sum_{e \in E} \ell(e)(x_e) + \lambda^T (K^T Cx - K^T b), \quad (100)$$

$$\lambda \mapsto \inf_{x \in \mathbb{R}^E} \sum_{e \in E} \ell(e)(x_e) + \lambda^T (Ax - K^T b), \quad (101)$$

7 实现与数值结果

本节讨论了我们在一个名为 `AlgebraicOptimization.jl` 的 Julia 包中实现该框架的原型⁵。我们使用该包进行了数值实验, 证明利用流网络的更高层次的组合结构能够比标准的对偶分解方法更快地求解多项式网络流问题 (MCNF)。

7.1 AlgebraicOptimization 软件架构

本文开发的框架由一组基于梯度的代数态射组成

$$g: O \Rightarrow D, \quad (102)$$

其中 O 是优化问题代数之一, D 是动力系统代数之一 (如图 2 所示)。这些代数态射以优化问题作为输入, 产生迭代求解算法作为输出。因此, 对于每个 $g: O \Rightarrow D$, 我们要求满足以下条件:

- 作为 UWD-代数的 O 的实现,
- 作为 UWD-代数的 D 的实现,
- g 的各个组成部分的实现。

⁵<https://github.com/AlgebraicJulia/AlgebraicOptimization.jl>

用于范畴计算的 Catlab.jl 软件包 [49] 提供了一个用于指定 UWD-代数的通用接口，而 AlgebraicDynamics.jl 实现了 Dynam 和 Dynam_D UWD-代数以及 Euler^γ 代数态射 [17]。因此，例如，要指定 $\text{gd}^\gamma: \text{Opt} \Rightarrow \text{Dynam}_D$ ，我们只需使用 Catlab 将 Opt 指定为 UWD-代数，并指定 $\text{flow}: \text{Opt} \Rightarrow \text{Dynam}$ 的组成部分，然后将其与 Euler^γ 组合以恢复 gd^γ 。得益于 Julia 对自动微分的广泛支持（如 ForwardDiff.jl 包 [50]），给定目标函数的梯度流动动力系统的实现非常直接。

我们能够轻松实现该框架，体现了用范畴论形式化这些优化问题的一个优势：借助 Catlab 这类范畴计算的软件包，数学定义到可用软件的转换变得非常简单。此外，得益于 UWD 的直观图形语法，面向应用的 AlgebraicOptimization 用户无需关心底层范畴论即可受益于这些成果。他们只需指定一个 UWD 及填充每个内部框的子问题，AlgebraicOptimization 就会自动为其问题生成一个分解的求解方法。用户还可以指定求解方法是串行的（分发到子系统，顺序更新子系统，然后从子系统收集结果），还是并行的（分发到子系统，并行更新子系统，然后从子系统收集结果）。

7.2 组合网络流实验

直观上，我们期望组合建模的 MCNF 问题在实际应用中具有实用价值，因为许多现实世界的网络流应用涉及具有多个密集连接组件且这些组件之间连接稀疏的流网络。例如，交通流网络可能模拟几个密集连接的城市区域，这些区域通过相对较少的州际公路和高速公路连接。这是一个层次组合结构的例子，其中第一层将每个城市区域彼此分解，第二层则分解每个城市区域内的边。

受此类应用的启发，我们进行了简要的实验研究，以衡量在求解最小费用网络流问题时，标准对偶分解与我们框架支持的层次对偶分解的性能表现。我们使用的流网络的组合结构由图 8 中的 UWD $\Phi: [3]+[2]+[2] \rightarrow \emptyset$ 给出。图是随机生成的，以避免隐含偏向任何特定的求解方法。更具体地说，为了生成该算法的测试数据，我们通过对三个连通的 Erdős-Rényi 随机图 [51] 开始，构建了三个组件流网络 (G_1, G_2, G_3) ，为每条边分配一个随机的凸二次成本函数，并为顶点分配一个流入流出向量，其和为 0。然后，我们随机指定了 G_1 的 3 个边界顶点，以及 G_2 和 G_3 各自的 2 个边界顶点。这样构造的 G_1 填充了 Φ 的具有三个端口的盒子， G_2 和 G_3 则填充了具有两个端口的盒子。给定 (G_1, G_2, G_3) ，我们考察了两种求解对应 MCNF 问题的方法：

1. （标准对偶分解）该算法首先通过 FlowNet 组合组成子图，然后对复合图取对偶分解优化器。
2. （分层对偶分解）该算法通过对每个组成子图取对偶分解优化器，然后用 Dynam_D 将这些系统组合起来。

标准对偶分解对应下图中的上路径，而层次对偶分解对应下路径。

$$\begin{array}{ccc}
 \text{FlowNet}([3]) \times \text{FlowNet}([2]) \times \text{FlowNet}([2]) & \xrightarrow{\text{FlowNet}(\Phi)} & \text{FlowNet}(\emptyset) \\
 \downarrow \text{netflow}_{[3]} \times \text{netflow}_{[2]} \times \text{netflow}_{[2]} & & \downarrow \text{netflow}_{\emptyset} \\
 \text{DiffConc}([3]) \times \text{DiffConc}([2]) \times \text{DiffConc}([2]) & & \text{DiffConc}(\emptyset) \\
 \downarrow \text{flow}_{[3]} \times \text{flow}_{[2]} \times \text{flow}_{[2]} & & \downarrow \text{flow}_{\emptyset} \\
 \text{Dynam}([3]) \times \text{Dynam}([2]) \times \text{Dynam}([2]) & & \text{Dynam}(\emptyset) \\
 \downarrow \text{Euler}_{[3]}^\gamma \times \text{Euler}_{[2]}^\gamma \times \text{Euler}_{[2]}^\gamma & & \downarrow \text{Euler}_{\emptyset}^\gamma \\
 \text{Dynam}_D([3]) \times \text{Dynam}_D([2]) \times \text{Dynam}_D([2]) & \xrightarrow{\text{Dynam}_D(\Phi)} & \text{Dynam}_D(\emptyset)
 \end{array}$$

注意，对于所有实验，我们均使用严格凸的边成本函数，这意味着由 netflow 变换生成的流网络的对偶函数是可微的。因此，我们能够使用标准梯度流而非超梯度流。还应回忆，本图中的代数表示本文定义的相应 finset




图 9: 标准双重分解与分层双重分解在随机复合流网络上的基准测试结果。左列报告了在保持连通性固定为 0.2 的情况下, 逐步变化每个组件子图的节点数从 10 到 150 的结果。右列报告了在保持每个子图节点数固定为 80 的情况下, 逐步变化子图的图连通性参数从 0.1 到 1.0 的结果。顶行比较了执行时间, 第二行比较了总内存使用量, 底行绘制了标准双重分解与分层双重分解在这些量上的比率。

代数的 UWD-代数。例如， $\text{FlowNet}(\emptyset)$ 表示所有边界为空的开放流网络的集合，而非空的流网络。由于上述图是自然变换复合的自然性方阵，通过沿上路径和下路径生成的动力系统是等价的，它们遵循相同的轨迹。

考虑到基于问题数据构建求解器的这两种方法，公平比较它们还必须考虑随机图的相关性质。特别地，组件图的规模（即节点数和边数）可能会影响每个算法的执行时间和内存使用。因此，我们尝试使用不同规模的图来比较标准对偶分解和层次对偶分解。具体来说，我们进行了两项实验来比较这两种方法。首先注意，Erdős-Rényi 随机图 $G(N, p)$ 由两个参数决定： $N \geq 0$ 是图中顶点的数量， $0 \leq p \leq 1$ 表示包含某条边的概率。因此，增加 p 会提高 $G(N, p)$ 的连通性。第一项实验中，我们将 p 固定为 0.2，改变每个组件子图的节点数。相反，第二项实验中，我们将每个组件子图的节点数固定为 80，改变 p 。对于每组参数，我们测量了运行 10 次对偶分解外层迭代的耗时和总内存消耗。我们使用 Optim.jl 包 [52] 来求解固定对偶变量下的边的最优流的内部问题。

这些实验结果总结于图 9。结果清楚地展示了在存在层次结构时，层次对偶分解相较于标准对偶分解的优势。请注意，我们并未与最先进的 MCNF 算法进行比较，而是旨在展示层次结构的实际效用。特别地，层次分解的优势在具有大量节点的稠密图上更为显著。这是预期之中的，因为虽然两种算法都必须解决相同数量的标量最小化问题（每条边一个），但在层次情况下，这些最小化问题只由其所属子图的对偶变量参数化，因此计算更高效；而标准对偶分解则需考虑所有对偶变量。

8 Conclusion

Summary

We have presented a novel algebraic/structural perspective on first-order optimization decomposition algorithms using the abstractions of undirected wiring diagrams (UWDs), operad algebras, and algebra morphisms. Specifically, we demonstrated that whenever a first-order method defines an algebra morphism from a UWD-algebra of problems to a UWD-algebra of dynamical systems, that method decomposes problems defined on arbitrary UWDs and provides distributed message-passing solution algorithms. We leveraged this paradigm to unify and generalize many known algorithms within a common framework, including gradient descent (Theorem 3.3), Uzawa’s algorithm (Theorem 4.4.1), primal and dual decomposition (Examples 3.5 and 4.5), and subgradient variants of each (Corollary 5.6.2). Working within this framework allowed the statement of the compositional data condition (Definition 3.6), which is a novel sufficient condition for when optimization problems parameterized by compositional data are decomposable. We subsequently showed that the minimum cost network flow problem satisfied the compositional data condition by defining an algebra morphism from a UWD-algebra of flow networks to the UWD-algebra of concave maximization problems. Experimental results using our implementation of this compositional framework highlighted the computational benefits afforded by the ability to exploit hierarchical and compositional problem structure.

Impacts

We believe this framework will have many positive impacts for both optimization theory and practice. Most immediately, our implementation of this framework provides a convenient tool for engineers to compositionally build complex optimization problems in a hierarchical fashion using the intuitive graphical syntax of undirected wiring diagrams. Such specifications are then automatically transformed into performant distributed solution algorithms by leveraging the algebra morphisms described in this paper. We also hope that

optimization researchers can utilize this general unified language for optimization decomposition methods to more easily build novel algorithms for specialized applications (e.g. by finding an application for a hierarchical combination of both primal and dual decomposition). Furthermore, the compositional data condition provides a principled way of proving when problems defined by compositional data are decomposable and generating appropriate distributed solution algorithms. We hope that this condition can be used to derive hierarchical decomposition methods for many more applications beyond the network flow example presented in the paper.

In terms of theoretical impacts, this work has situated optimization decomposition methods in the broad mathematical landscape of category theory. Seen in this light, the underlying mathematical structure of optimization decomposition methods is the same as or similar to the structures underlying entropy maximization of thermostatic systems [53] and equilibrium behavior of Markov processes [16] in that both also tell stories of operadic dynamical systems. Also of interest is that backpropagation in neural networks has been shown to exhibit semantics for *directed* wiring diagrams [24]. In making such connections we hope to facilitate the transfer of ideas amongst optimization and other disciplines. Additionally, we believe that the category theoretic point of view will lead to the expansion of problems considered by optimization researchers. Indeed constructs already exist that allow one to generalize gradient based optimization to settings beyond differentiable functions over the real numbers [54, 35], for example to polynomials over arbitrary finite fields or boolean circuits. Our work has the potential to add composition mechanisms to instances of such non-traditional optimization problems.

Limitations and Future Work

There are many directions for future work. The first natural question is whether other, more sophisticated decomposition methods such as the alternating direction method of multipliers (ADMM) or second-order methods such as Newton’s method can be expressed within our framework. We are hopeful that an affirmative answer can be given for both of these methods. For example, [8] defines a way to apply ADMM to decompose problems defined on factor graphs, which are similar to UWDs, and [48] defines a distributed Newton’s method for solving minimum cost network flow.

There are also some fundamental limitations of our approach which we aim to address in future work. For example, Euler’s method (and by extension gradient descent) is only an algebra morphism for a fixed step-size. However, many optimization algorithms use more sophisticated methods such as backtracking line search for computing appropriate step-sizes at each iteration. As such, we would like to develop a theory of *approximate* algebra morphisms and see if we can bound the approximation error based on the compositional structure of a given problem.

Another limitation of our framework is that the distributed solution algorithms generated by applying our algebra morphisms are *synchronous*, meaning they require a blocking synchronization step after every parallel computation step. In reality, many algorithms such as distributed gradient descent and Uzawa’s can be run asynchronously while still guaranteeing convergence [55]. We thus would like to extend the existing algebraic theory of composite dynamical systems to encompass such asynchrony.

Acknowledgements

Tyler Hanks was supported by the National Science Foundation Graduate Research Fellowship Program under Grant No. DGE-1842473. Any opinions, findings, and conclusions or recommendations expressed in this material are those of the author(s) and do not necessarily reflect the views of the NSF. Matthew Hale was supported by the Air Force Office of Scientific Research (AFOSR) under Grant No. FA9550-23-1-0120. Matthew Klawonn was funded by a SMART SEED grant. James Fairbanks was supported by DARPA under award no. HR00112220038.

参考文献

- [1] Stephen Boyd. Distributed Optimization and Statistical Learning via the Alternating Direction Method of Multipliers. *Foundations and Trends® in Machine Learning*, 3(1):1–122, 2010.
- [2] Neal Parikh and Stephen Boyd. Block splitting for distributed optimization. *Mathematical Programming Computation*, 6(1):77–102, March 2014.
- [3] Pontus Giselsson, Minh Dang Doan, Tamás Keviczky, Bart De Schutter, and Anders Rantzer. Accelerated gradient methods and dual decomposition in distributed model predictive control. *Automatica*, 49(3):829–833, March 2013.
- [4] Dinesh Krishnamoorthy, Bjarne Foss, and Sigurd Skogestad. A primal decomposition algorithm for distributed multistage scenario model predictive control. *Journal of Process Control*, 81:162–171, 2019.
- [5] J. F. Benders. Partitioning procedures for solving mixed-variables programming problems. *Numer. Math.*, 4(1):238 – 252, dec 1962.
- [6] Ragheb Rahmaniani, Teodor Gabriel Crainic, Michel Gendreau, and Walter Rei. The Benders decomposition algorithm: A literature review. *European Journal of Operational Research*, 259(3):801–817, June 2017.
- [7] Stephen Boyd, Lin Xiao, Almir Mutapcic, and Jacob Mattingly. Notes on decomposition methods. *Notes for EE364B, Stanford University*, 2015.
- [8] David Hallac, Christopher Wong, Steven Diamond, Abhijit Sharang, Rok Sosić, Stephen Boyd, and Jure Leskovec. SnapVX: A Network-Based Convex Optimization Solver. *Journal of Machine Learning Research*, 18:1–5, 2017.
- [9] Jordan Jalving, Sungho Shin, and Victor M. Zavala. A graph-based modeling abstraction for optimization: Concepts and implementation in plasmojl. *Mathematical Programming Computation*, 14:699 – 747, 2022.
- [10] David I. Spivak. The operad of wiring diagrams: formalizing a graphical language for databases, recursion, and plug-and-play circuits, May 2013. arXiv:1305.0297 [cs, math].
- [11] John C. Baez, Kenny Courser, and Christina Vasilakopoulou. Structured versus Decorated Cospans. *Compositionality*, 4:3, September 2022. arXiv:2101.09363 [math].
- [12] John C. Baez and Brendan Fong. A compositional framework for passive linear networks. *Theory and Applications of Categories*, 33(38):1158–1222, 2018.

- [13] John C. Baez and Blake S. Pollard. A Compositional Framework for Reaction Networks. *Reviews in Mathematical Physics*, 29(09):1750028, October 2017. arXiv:1704.02051 [math-ph].
- [14] John C. Baez and Jason Erbele. Categories in control. *Theory and Applications of Categories*, 30(24):836–881, 2015.
- [15] Dario Stein and Richard Samuelson. Towards a compositional framework for convex analysis (with applications to probability theory), 2023.
- [16] John C. Baez, Brendan Fong, and Blake S. Pollard. A compositional framework for markov processes. *Journal of Mathematical Physics*, 57(3), March 2016.
- [17] Sophie Libkind, Andrew Baas, Evan Patterson, and James Fairbanks. Operadic Modeling of Dynamical Systems: Mathematics and Computation. *Electronic Proceedings in Theoretical Computer Science*, 372:192–206, November 2022. arXiv:2105.12282 [math].
- [18] Riccardo Scattolini. Architectures for distributed and hierarchical model predictive control—a review. *Journal of process control*, 19(5):723–731, 2009.
- [19] Mihajlo D Mesarovic, Donald Macko, and Yasuhiko Takahara. *Theory of hierarchical, multilevel, systems*. Elsevier, 2000.
- [20] Wladyslaw Findeisen, Frederic N Bailey, Mieczyslaw Brdys, Krzysztof Malinowski, Piotr Tatjewski, and Adam Wozniak. *Control and coordination in hierarchical systems*. John Wiley & Sons, 1980.
- [21] K.J. Arrow, L. Hurwics, and H. Uzawa. *Studies in Linear and Non-linear Programming*. Stanford University Press, 1958.
- [22] Yuri Nesterov. Primal-dual subgradient methods for convex problems. *Mathematical Programming*, 120:221–259, 2009.
- [23] Michael Grant, Stephen Boyd, and Yinyu Ye. Disciplined Convex Programming. In Leo Liberti and Nelson Maculan, editors, *Global Optimization*, volume 84, pages 155–210. Kluwer Academic Publishers, Boston, 2006. Series Title: Nonconvex Optimization and Its Applications.
- [24] Brendan Fong, David Spivak, and Rémy Tuyéras. Backprop as functor: A compositional perspective on supervised learning. In *2019 34th Annual ACM/IEEE Symposium on Logic in Computer Science (LICS)*, pages 1–13. IEEE, 2019.
- [25] G. S. H. Cruttwell, Bruno Gavranović, Neil Ghani, Paul Wilson, and Fabio Zanasi. Categorical foundations of gradient-based learning, 2021.
- [26] Baike She, Tyler Hanks, James Fairbanks, and Matthew Hale. Characterizing compositionality of lqr from the categorical perspective. *Proceedings of the 62nd IEEE Conference on Decision and Control*, 2023.
- [27] Neil Ghani, Jules Hedges, Viktor Winschel, and Philipp Zahn. Compositional game theory. In *Proceedings of the 33rd annual ACM/IEEE symposium on logic in computer science*, pages 472–481, 2018.
- [28] Robert Atkey, Bruno Gavranović, Neil Ghani, Clemens Kupke, Jérémy Ledent, and Fredrik Nordvall Forsberg. Compositional game theory, compositionally. *arXiv preprint arXiv:2101.12045*, 2021.

- [29] Brendan Fong and David I Spivak. Seven sketches in compositionality: An invitation to applied category theory, 2018.
- [30] E. Riehl. *Category theory in context*. Aurora: Dover modern math originals. Dover Publications, 2017.
- [31] Steve Awodey. *Category theory*. Oxford university press, 2010.
- [32] John Baez and Mike Stay. *Physics, topology, logic and computation: a Rosetta Stone*. Springer, 2011.
- [33] R. Tyrrell Rockafellar. *Convex Analysis*. Princeton University Press, 1970.
- [34] Stephen Boyd and Lieven Vandenberghe. *Convex Optimization*. Cambridge University Press, March 2004.
- [35] Dan Shiebler. Generalized Optimization: A First Step Towards Category Theoretic Learning Theory. In Pandian Vasant, Ivan Zelinka, and Gerhard-Wilhelm Weber, editors, *Intelligent Computing & Optimization*, pages 525–535, Cham, 2022. Springer International Publishing.
- [36] Brendan Fong and David I. Spivak. Hypergraph Categories, January 2019. arXiv:1806.08304 [cs, math].
- [37] Claudio Hermida. Representable Multicategories. *Advances in Mathematics*, 151(2):164–225, 2000.
- [38] Brendan Fong. The Algebra of Open and Interconnected Systems, September 2016. arXiv:1609.05382 [math].
- [39] Philipp Schiele, Eric Luxenberg, and Stephen Boyd. Disciplined Saddle Programming, January 2023. arXiv:2301.13427 [cs, math].
- [40] S. Boyd, J. Duchi, M. Pilanci, and L. Vandenberghe. Subgradients. *Notes for EE364B, Stanford University*, 2022.
- [41] Mokhtar S Bazaraa, John J Jarvis, and Hanif D Sherali. *Linear programming and network flows*. John Wiley & Sons, 2011.
- [42] Lester Randolph Ford. *Flows in networks*. Princeton University Press, 2015.
- [43] Paul A. Jensen and J. Wesley Barnes. *Network flow programming*. R.E. Krieger Publishing Company, 1987.
- [44] Jeff L Kennington and Richard V Helgason. *Algorithms for network programming*. John Wiley & Sons, Inc., 1980.
- [45] James Evans. *Optimization algorithms for networks and graphs*. CRC Press, 2017.
- [46] Ravindra K Ahuja, Thomas L Magnanti, and James B Orlin. Network flows: Theory, applications and algorithms. *Prentice-Hall, Englewood Cliffs, New Jersey, USA Arrow, KJ (1963). Social Choice and Individual Values, Wiley, New York. Gibbard, A.(1973). “Manipulation of Voting Schemes: A general result” , Econometrica, 41:587–602, 1993.*
- [47] David P Williamson. *Network flow algorithms*. Cambridge University Press, 2019.
- [48] Ali Jadbabaie, Asuman Ozdaglar, and Michael Zargham. A distributed newton method for network optimization. In *Proceedings of the 48th IEEE Conference on Decision and Control (CDC) held jointly with 2009 28th Chinese Control Conference*, pages 2736–2741, Shanghai, China, December 2009. IEEE.

- [49] Micah Halter, Evan Patterson, Andrew Baas, and James Fairbanks. Compositional scientific computing with catlab and semanticmodels. *arXiv preprint arXiv:2005.04831*, 2020.
- [50] J. Revels, M. Lubin, and T. Papamarkou. Forward-mode automatic differentiation in Julia. *arXiv:1607.07892 [cs.MS]*, 2016.
- [51] Paul L. Erdős and Alfréd Rényi. On random graphs. i. *Publicationes Mathematicae Debrecen*, 1959.
- [52] Patrick Kofod Mogensen and Asbjørn Nilsen Riseth. Optim: A mathematical optimization package for Julia. *Journal of Open Source Software*, 3(24):615, 2018.
- [53] John C. Baez, Owen Lynch, and Joe Moeller. Compositional thermostatics. *Journal of Mathematical Physics*, 64(2), February 2023.
- [54] Geoffrey SH Cruttwell, Bruno Gavranović, Neil Ghani, Paul Wilson, and Fabio Zanasi. Categorical foundations of gradient-based learning. In *European Symposium on Programming*, pages 1–28. Springer International Publishing Cham, 2022.
- [55] Katherine Hendrickson and Matthew Hale. Totally asynchronous primal-dual convex optimization in blocks, 2022.

A 范畴论定义

A.1 范畴、函子与自然变换

Definition A.1. 一个范畴 $\mathcal{C}$ 由一组对象 $X, Y, Z, \dots$ 和一组态射（也称为箭头） $f, g, h, \dots$ 组成，并包含以下数据：

- 每个态射都有指定的定义域和陪域对象；符号 $f : X \rightarrow Y$ 表示 f 是一个定义域为 X 、陪域为 Y 的态射。
- 每个对象 $X \in \mathcal{C}$ 有一个特定的恒等态射 $\text{id}_X : X \rightarrow X$ 。
- 对于任意三个对象 $X, Y, Z \in \mathcal{C}$ 以及任意一对态射 $f : X \rightarrow Y$ 和 $g : Y \rightarrow Z$ ，存在一个指定的复合态射 $g \circ f : X \rightarrow Z$ 。

这些数据须满足以下两个公理：

- （单位性）对于任意态射 $f : X \rightarrow Y$ ，有 $f \circ \text{id}_X = f = \text{id}_Y \circ f$ ，
- （结合性）对于任意对象 $W, X, Y, Z \in \mathcal{C}$ 和态射 $f : W \rightarrow X$ ， $g : X \rightarrow Y$ ， $h : Y \rightarrow Z$ ，有 $h \circ (g \circ f) = (h \circ g) \circ f$ 。

Definition A.2. 给定一个范畴 $\mathcal{C}$ ，其对偶范畴，记作 $\mathcal{C}^{op}$ ，具有

- 与 $\mathcal{C}$ 相同的对象，
- 对于 $\mathcal{C}$ 中的每个态射 $f : X \rightarrow Y$ ，有一个态射 $f^{op} : Y \rightarrow X$ 。

恒等态射与 $\mathcal{C}$ 中的相同，复合由 $\mathcal{C}$ 中的复合定义：

$$g^{op} \circ f^{op} = (f \circ g)^{op}. \quad (103)$$

Definition A.3. 给定范畴 $\mathcal{C}$ 和 $\mathcal{D}$ ，一个（协变）函子 $F: \mathcal{C} \rightarrow \mathcal{D}$ 包含以下映射：

- 一个对象映射 $c \mapsto F(c)$ ，对所有 $c \in \text{Ob}(\mathcal{C})$ ，
- 一个态射映射，满足定义域和值域的对应关系，即对每个态射 $f: c \rightarrow c'$ 在 $\mathcal{C}$ 中，有 $(f: c \rightarrow c') \mapsto (F(f): F(c) \rightarrow F(c'))$ 。

这些映射必须满足以下等式：

- $F(\text{id}_c) = \text{id}_{F(c)}$ （恒等映射被保持），
- $F(g \circ f) = F(g) \circ F(f)$ （复合映射被保持），

对所有对象 c 和可复合的态射 f, g 在 $\mathcal{C}$ 中成立。一个 **逆变函子** 是定义域为对偶范畴的函子 $F: \mathcal{C}^{op} \rightarrow \mathcal{D}$ 。

Definition A.4. 给定一对函子 $F, G: \mathcal{C} \rightarrow \mathcal{D}$ ，它们具有相同的定义域和值域，从 F 到 G 的自然变换 θ ，记作 $\theta: F \Rightarrow G$ ，由一族 $\mathcal{D}$ 中的态射组成，该族以 $\mathcal{C}$ 中的对象为指标，即

$$\theta_X: F(X) \rightarrow G(X) \quad (104)$$

对所有 $X \in \mathcal{C}$ 成立。这些被称为 θ 的分量。这些分量要求使得对于所有对象 X, Y 及 $\mathcal{C}$ 中的态射 $f: X \rightarrow Y$ ，下列自然性交换图交换。

$$\begin{array}{ccc} F(X) & \xrightarrow{F(f)} & F(Y) \\ \theta_X \downarrow & & \downarrow \theta_Y \\ G(X) & \xrightarrow{G(f)} & G(Y) \end{array}$$

当 θ 的每个分量都是一个同构时，我们称 θ 为**自然同构**。

A.2 泛限构造

范畴论的核心优势之一是能够通过研究一个对象与范畴中其他对象的关系来理解该对象。这种推理方式导出了一些非常通用的构造，这些构造可以在任何范畴中被表述，并且在应用于熟悉的范畴时非常有用。

Definition A.5. 在范畴 $\mathcal{C}$ 中，**初对象** 是指一个对象 $i \in \mathcal{C}$ ，使得对于所有对象 $c \in \mathcal{C}$ ，在 $\mathcal{C}$ 中存在唯一的态射 $i \rightarrow c$ 。对偶地， $\mathcal{C}$ 中的**终对象** 是 $\mathcal{C}^{op}$ 中的初对象，即一个对象 $t \in \mathcal{C}$ ，使得对于所有对象 $c \in \mathcal{C}$ ，在 $\mathcal{C}$ 中存在唯一的态射 $c \rightarrow t$ 。


- 在 **Set** 中的初始对象是空集，而终端对象⁶ 在 **Set** 中是单元素集合 $\{*\}$ 。
- 向量空间 $\mathbb{R}^0$ 在 **Vect** 中既是初始对象也是终端对象。

在以下定义中，范畴中的一个 **span**（跨）指的是该范畴中一对具有公共定义域的态射。对偶地，范畴中的一个 **cospan**（共跨）是指一对具有公共陪域的态射。

Definition A.6. 在范畴 $\mathcal{C}$ 中，两个对象 X 和 Y 的**积**是形如 $X \xleftarrow{\pi_X} X \times Y \xrightarrow{\pi_Y} Y$ 的跨距，使得对于任何其他形如 $X \xleftarrow{f} Z \xrightarrow{g} Y$ 的跨距，存在唯一的态射 $Z \xrightarrow{!} X \times Y$ 满足 $\pi_X \circ ! = f$ 且 $\pi_Y \circ ! = g$ 。该唯一态射称为

⁶很容易验证初始对象和终端对象（更一般地，任何由普遍性质定义的对象）在同构意义下是唯一的，因此我们有理由使用“the 初始/终端对象”的术语


f 和 g 的**配对**，记作 $\langle f, g \rangle$ 。对偶地，范畴 $\mathcal{C}$ 中对象 X 和 Y 的**余积**是范畴 $\mathcal{C}^{op}$ 中 X 和 Y 的积。以下这一对图清晰地展示了这一对偶性质，其中左图表示 $\mathcal{C}$ 中的积，右图表示 $\mathcal{C}$ 中的余积。



余积图中的唯一箭头 $X + Y \rightarrow Z$ 称为 f 和 g 的**余配对**，记作 $[f, g]$ 。


- **Set** 中的积是集合的笛卡尔积以及自然的投影映射。**Set** 中的余积是集合的离散并集以及自然的包含映射。
- **Vect** 中的积是向量空间的笛卡尔积，而余积是向量空间的直和。在有限维情况下，积和直和是同构的，这意味着 **Vect** 是一种称为双积范畴的特殊类型范畴。

Definition A.7. 在范畴 $\mathcal{C}$ 中，余跨 $X \xrightarrow{f} Z \xleftarrow{g} Y$ 的**拉回**是一个跨 $X \xleftarrow{p_X} P \xrightarrow{p_Y} Y$ ，满足 $f \circ p_X = g \circ p_Y$ ，且对于任意其他跨 $X \xleftarrow{q_X} Q \xrightarrow{q_Y} Y$ ，存在唯一的态射 $Q \rightarrow P$ 使下列图表交换。



拉回对象 P 通常记作 $X \times_Z Y$ 。

对偶地，跨 $X \xleftarrow{f} Z \xrightarrow{g} Y$ 的**推余**是一个余跨 $X \xrightarrow{i_X} P \xleftarrow{i_Y} Y$ ，满足 $i_X \circ f = i_Y \circ g$ ，且对于任意其他余跨 $X \xrightarrow{q_X} Q \xleftarrow{q_Y} Y$ ，存在唯一的态射 $P \rightarrow Q$ 使下列图表交换。



推余对象 P 通常记作 $X +_Z Y$ 。

- 在 **Set** 中，余锥 $X \xrightarrow{f} Z \xleftarrow{g} Y$ 的拉回是集合 $X \times_Z Y := \{(x, y) \in X \times Y \mid f(x) = g(y)\}$ ，并附带从 $X \times Y$ 限制到 $X \times_Z Y$ 的投影映射。
- 在 **Set** 中，锥 $X \xleftarrow{f} Z \xrightarrow{g} Y$ 的推出是集合 $X +_Z Y := X + Y / \sim$ ，其中 $\sim$ 是等价关系，定义为对所有 $z \in Z$ 有 $f(z) \sim g(z)$ 。推出还包括映射 $i_X: X \rightarrow X +_Z Y$ 和 $i_Y: Y \rightarrow X +_Z Y$ ，使得 $i_X \circ f = i_Y \circ g$ 。

A.3 对称么半范畴

Definition A.8. 对称单范畴 (**symmetric monoidal category**) 由一个范畴 $\mathcal{C}$ 组成，该范畴配备了一个函子 $\otimes: \mathcal{C} \times \mathcal{C} \rightarrow \mathcal{C}$ ，称为**单范乘积**，以及一个对象 $1 \in \mathcal{C}$ ，称为**单范单位**，并且具备以下自然同构：

- (结合子) $\alpha_{X,Y,Z}: (X \otimes Y) \otimes Z \cong X \otimes (Y \otimes Z)$,
- (左单位子) $\lambda_X: 1 \otimes X \cong X$,
- (右单位子) $\rho_X: X \otimes 1 \cong X$ 。

这些数据必须满足两组交换图，称为三角恒等式和五边形恒等式，出于简洁起见此处省略。

Remark A.9. 当一个范畴 $\mathcal{C}$ 具有有限积和终对象时，通过将态射 $f: X \rightarrow Y$ 和 $g: W \rightarrow Z$ 的单体积定义为 $\langle f \circ \pi_X, g \circ \pi_W \rangle: X \times W \rightarrow Y \times Z$ ，它自动形成一个对称幺半范畴，如下图所示：

$$\begin{array}{ccccc}
 & & X & \xrightarrow{f} & Y \\
 & \nearrow \pi_X & & & \nearrow \pi_Y \\
 X \times W & \xrightarrow{\langle f \circ \pi_X, g \circ \pi_W \rangle} & Y \times Z & & \\
 & \searrow \pi_W & & & \searrow \pi_Z \\
 & & W & \xrightarrow{g} & Z
 \end{array}$$

这被称为笛卡尔幺半范畴。例如， $(\mathbf{Set}, \times, 1)$ 是笛卡尔幺半范畴。

对偶地，当一个范畴具有有限余积和初对象时，通过将态射 $f: X \rightarrow Y$ 和 $g: W \rightarrow Z$ 的单体积定义为 $[\iota_Y \circ f, \iota_Z \circ g]$ ，它自动形成一个对称幺半范畴，如下图所示：

$$\begin{array}{ccccc}
 X & \xrightarrow{f} & Y & & \\
 \searrow \iota_X & & & \searrow \iota_Y & \\
 & X + W & \xrightarrow{[\iota_Y \circ f, \iota_Z \circ g]} & Y + Z & \\
 \nearrow \iota_W & & & \nearrow \iota_Z & \\
 W & \xrightarrow{g} & Z & &
 \end{array}$$

这被称为余笛卡尔幺半范畴。例如， $(\mathbf{FinSet}, +, \emptyset)$ 是余笛卡尔幺半范畴。

Definition A.10. 给定对称单范畴 $(\mathcal{C}, \otimes, 1)$ 和 $(\mathcal{D}, \boxtimes, e)$ ，一个松对称单范畴函子 $(\mathcal{C}, \otimes, 1) \rightarrow (\mathcal{D}, \boxtimes, e)$ 由一个函子 $F: \mathcal{C} \rightarrow \mathcal{D}$ 以及以下比较映射组成：

- 一个态射 $\varphi_0: e \rightarrow F(1)$ ，称为单位比较，
- 一个称为乘积比较的自然变换，其分量为

$$\varphi_{X,Y}: F(X) \boxtimes F(Y) \rightarrow F(X \otimes Y) \quad (105)$$

对所有 $X, Y \in \mathcal{C}$ 成立。

这些数据必须满足以下公理。

1. (结合律) 对任意对象 $X, Y, Z \in \mathcal{C}$ ，下列交换图成立。

$$\begin{array}{ccc}
 (F(X) \boxtimes F(Y)) \boxtimes F(Z) & \xrightarrow{\alpha_{F(X), F(Y), F(Z)}^{\mathcal{D}}} & F(X) \boxtimes (F(Y) \boxtimes F(Z)) \\
 \varphi_{X,Y} \boxtimes \text{id} \downarrow & & \downarrow \text{id} \boxtimes \varphi_{Y,Z} \\
 F(X \otimes Y) \boxtimes F(Z) & & F(X) \boxtimes F(Y \otimes Z) \\
 \varphi_{X \otimes Y, Z} \downarrow & & \downarrow \varphi_{X, Y \otimes Z} \\
 F((X \otimes Y) \otimes Z) & \xrightarrow{F(\alpha_{X,Y,Z}^{\mathcal{C}})} & F(X \otimes (Y \otimes Z))
 \end{array}$$

2. (单位元性) 对任意 $X \in \mathcal{C}$, 下列一对交换图成立。

$$\begin{array}{ccc} e \boxtimes F(X) & \xrightarrow{\varphi_0 \boxtimes \text{id}} & F(1) \boxtimes F(X) \\ \lambda_{F(X)}^{\mathcal{D}} \downarrow & & \downarrow \varphi_{1,X} \\ F(X) & \xleftarrow{F(\lambda_X^{\mathcal{C}})} & F(1 \otimes X) \end{array} \quad \begin{array}{ccc} F(X) \boxtimes e & \xrightarrow{\text{id} \boxtimes \varphi_0} & F(X) \boxtimes F(1) \\ \rho_{F(X)}^{\mathcal{D}} \downarrow & & \downarrow \varphi_{X,1} \\ F(X) & \xleftarrow{F(\rho_X^{\mathcal{C}})} & F(X \otimes 1) \end{array}$$

3. (对称性) 对任意 $X, Y \in \mathcal{C}$, 下列交换图成立。

$$\begin{array}{ccc} F(X) \boxtimes F(Y) & \xrightarrow{\sigma_{F(X), F(Y)}^{\mathcal{D}}} & F(Y) \boxtimes F(X) \\ \varphi_{X,Y} \downarrow & & \downarrow \varphi_{Y,X} \\ F(X \otimes Y) & \xrightarrow{F(\sigma_{X,Y}^{\mathcal{C}})} & F(Y \otimes X) \end{array}$$

我们将这样的函子记为对 (F, φ) 。当比较映射是同构时, (F, φ) 称为 **强** 对称单范畴函子。

Definition A.11. 给定一对松对称单范畴函子 $(F, \varphi^F), (G, \varphi^G): (\mathcal{C}, \otimes, 1) \rightarrow (\mathcal{D}, \boxtimes, e)$, 一个从 (F, φ^F) 到 (G, φ^G) 的**单范畴自然变换** 是一个自然变换 $\theta: F \Rightarrow G$, 且对于所有 $X, Y \in \mathcal{C}$, 下列图表交换。

$$\begin{array}{ccc} F(X) \boxtimes F(Y) & \xrightarrow{\theta_X \boxtimes \theta_Y} & G(X) \boxtimes G(Y) \\ \varphi_{X,Y}^F \downarrow & & \downarrow \varphi_{X,Y}^G \\ F(X \otimes Y) & \xrightarrow{\theta_{X \otimes Y}} & G(X \otimes Y) \end{array} \quad \begin{array}{ccc} e & \xrightarrow{\varphi_0^F} & F(1) \\ & \searrow \varphi_0^G & \downarrow \theta_1 \\ & & G(1) \end{array}$$