

通过高分辨率微分方程理解 PDHG 算法

Bowen Li^{1,2} and Bin Shi^{* 1,2}

¹ 中国科学院数学与系统科学研究院, 北京 100190, 中国

² 中国科学院大学数学科学学院, 北京 100049, 中国

2026 年 2 月 26 日

摘要

广义的 最小绝对收缩和选择算子 (Lasso) 在数学和工程的多个领域中被广泛认可。其变体, 广义 Lasso, 在统计学、机器学习、图像科学及相关领域中有着广泛的应用。在解决这一问题的优化技术中, 鞍点方法尤为突出, 其中原始-对偶混合梯度 (PDHG) 算法成为一个特别流行的选择。然而, PDHG 的迭代行为仍然缺乏深入理解。本文采用量纲分析方法, 推导出一组适用于 PDHG 的高分辨率常微分方程 (ODE) 系统。该系统有效地捕捉了 PDHG 的一个关键特征, 即耦合的 x -修正和 y -修正, 这使其区别于近似的 Arrow-Hurwicz 算法。这个虽小但至关重要的扰动确保了 PDHG 始终收敛, 避免了近似 Arrow-Hurwicz 算法中观察到的周期性行为。通过李雅普诺夫分析, 我们研究了高分辨率 ODE 系统的收敛行为, 并将我们的见解扩展到离散的 PDHG 算法。我们的分析表明, 由隐式方案引起的数值误差是影响 PDHG 收敛速度和单调性的关键因素, 这一重要模式也在 交替方向乘子法 (ADMM) 中被发现, 如文献 [Li and Shi, 2024] 所指出。此外, 我们进一步发现, 当目标函数的一个组成部分是强凸的时, PDHG 的迭代平均值以速率 $O(1/N)$ 强收敛, 其中 N 为迭代次数。

1 引言

在本世纪之交, 人们发现稀疏表示在适当的基或字典中能够有效地对许多现实世界的信号进行建模 [Candès et al., 2006, Donoho, 2006]。这种用于信号重构的稀疏表示需要显著更少的样本量, 并且具有更强的鲁棒性。作为诱导稀疏性的范数, ℓ_1 -正则化开始被广泛认可。一个更通用的形式, 同时考虑观测信号 b 中的噪声, 出现了 最小绝对收缩和选择算子 (Lasso) [Tibshirani, 1996]。给定 $A \in \mathbb{R}^{m \times d_1}$ 表示一个 $m \times d_1$ 的矩阵, $b \in \mathbb{R}^m$ 表示一个 m 维向量, 该形式被表达为:

$$\min_{x \in \mathbb{R}^d} \Phi(x) := \frac{1}{2} \|Ax - b\|^2 + \lambda \|x\|_1,$$

*通讯作者: shibin@lsec.cc.ac.cn

其中正则化参数 $\lambda > 0$ 在测量的保真度与对噪声的敏感性之间起到权衡作用。¹ 然而，对于更广泛的应用，常用形式是广义 Lasso [Tibshirani, 2011]，其可写为

$$\min_{x \in \mathbb{R}^{d_1}} \Phi(x) := \frac{1}{2} \|Ax - b\|^2 + \lambda \|Fx\|_1,$$

其中 $F \in \mathbb{R}^{d_2 \times d_1}$ 用于替代 ℓ_1 范数，引入了全变差正则项。此推广极大地拓宽了其在机器学习和图像科学等领域的应用 [Tibshirani, 2011, Chambolle and Pock, 2016b]，特别支持诸如 全变差去噪 [Rudin et al., 1992]、融合 Lasso [Tibshirani et al., 2005]、 ℓ_1 趋势滤波 [Kim et al., 2009]、小波平滑 [Donoho and Johnstone, 1995] 等技术。

在处理广义 Lasso 时，全变差正则器中包含的 $m \times d$ 矩阵 F 对基本的近端梯度方法（如迭代收缩阈值算法（ISTA）和快速迭代收缩阈值算法（FISTA））构成了挑战。求解广义 Lasso 的一个合适优化方法是 交替方向乘子法（ADMM），该方法由 Glowinski and Marroco [1975] 和 Gabay and Mercier [1976] 于上世纪七十年代首创。由于其在分布式凸优化中的高效性及处理大规模优化问题的能力，ADMM 在机器学习领域广受欢迎 [Boyd et al., 2011]。然而，ADMM 实现过程中需要计算矩阵 $A^\top A + sF^\top F$ 的逆矩阵，其中 s 表示步长，如 [Li and Shi, 2024] 所述。随着矩阵规模的增大，计算该逆矩阵的难度也随之增加。

在探讨鞍点方法之前，首先将广义 Lasso 纳入一般优化问题框架，表示为：

$$\min_{x \in \mathbb{R}^{d_1}} \Phi(x) := f(x) + g(Fx), \quad (1.1)$$

其中 f 和 g 均为凸函数。利用共轭变换，也称为 Legendre-Fenchel 变换，我们可以将优化问题 (1.1) 重写为如下的极小极大形式：

$$\min_{y \in \mathbb{R}^{d_2}} \max_{x \in \mathbb{R}^{d_1}} \Phi(x, y) = \min_{x \in \mathbb{R}^{d_1}} \max_{y \in \mathbb{R}^{d_2}} \Phi(x, y) := f(x) + \langle Fx, y \rangle - g^*(y), \quad (1.2)$$

该形式最早由 [Arrow et al., 1958] 提出。极小极大形式 (1.2) 使得近端操作得以实际实现。近端 Arrow-Hurwicz 算法，如 [Zhu and Chan, 2008, Esser et al., 2010] 所介绍，包含对原变量 x 的下降迭代和对偶变量 y 的上升迭代，具体为：

$$\begin{cases} x_{k+1} = \operatorname{argmin}_{x \in \mathbb{R}^{d_1}} \left\{ f(x) + \langle Fx, y_k \rangle + \frac{1}{2s} \|x - x_k\|^2 \right\}, \end{cases} \quad (1.3a)$$

$$\begin{cases} y_{k+1} = \operatorname{argmax}_{y \in \mathbb{R}^{d_2}} \left\{ -g^*(y) + \langle Fx_{k+1}, y \rangle - \frac{1}{2s} \|y - y_k\|^2 \right\}. \end{cases} \quad (1.3b)$$

¹在本文中，符号 $\|\cdot\|$ 特指 ℓ_2 -范数或欧几里得范数，即 $\|\cdot\|_2$ ，而 ℓ_1 范数定义为

$$\|x\|_1 = \sum_{i=1}^d |x_i|,$$

对于任意 $x \in \mathbb{R}^d$ 。值得注意的是，除非特别说明，否则常省略下标 2。

然而，在某些情况下，近端 Arrow-Hurwicz 算法可能无法收敛，正如 [He et al., 2014] 中的反例所示。为提升其实用效果，引入动量步骤被证明是有益的。该改进算法最初由 [Chambolle and Pock, 2011] 提出，修改了近端 Arrow-Hurwicz 算法中的 (1.3a) 和 (1.3b)，具体为：

$$\begin{cases} x_{k+1} = \operatorname{argmin}_{x \in \mathbb{R}^{d_1}} \left\{ f(x) + \langle Fx, y_k \rangle + \frac{1}{2s} \|x - x_k\|^2 \right\}, & (1.4a) \\ \bar{x}_{k+1} = x_{k+1} + (x_{k+1} - x_k), & (1.4b) \\ y_{k+1} = \operatorname{argmax}_{y \in \mathbb{R}^{d_2}} \left\{ -g^*(y) + \langle F\bar{x}_{k+1}, y \rangle - \frac{1}{2s} \|y - y_k\|^2 \right\}, & (1.4c) \end{cases}$$

该算法也被称为 原始-对偶混合梯度 (PDHG) 算法。值得注意的是，近端 Arrow-Hurwicz 算法和 PDHG 可解决的优化问题与 ADMM 可解的问题等价，如 [Li and Shi, 2024] 所示。一般而言，当凸函数 g 是 ℓ_1 -范数或二次函数时，迭代中的隐式解 (1.3b) 或 (1.4c) 总是可以直接获得。然而，当假设凸函数 f 是 L -平滑时，迭代中的隐式解 (1.3a) 或 (1.4a) 需要借助基于梯度的算法进行近似。因此，本文仅关注 f 为广义 Lasso 的二次函数或 基追踪 (basis pursuit) [Bruckstein et al., 2009] 的指示函数的情形。在这些情况下，隐式解均可直接获得。关于遍历收敛的进一步理论见 [Chambolle and Pock, 2016a]。从收缩角度出发，PDHG 的收敛行为已在多项研究中探讨，包括 [He and Yuan, 2012, He et al., 2014, 2022]。

当简单比较上述两种算法，即近端 Arrow-Hurwicz 算法和 PDHG 时，自然而然地引出了以下两个问题：

- Why does PDHG always converge on the minimax problem (1.2) whereas the proximal Arrow-Hurwicz algorithm may fail to converge in certain scenarios?
- What are the fundamental differences between these two algorithms?

本文旨在借助常微分方程 (ODE) 和数值分析的技术来探讨这些问题。近期这方面的进展显著推动了对原始梯度下降收敛行为的理解，并揭示了加速算法的奥秘。通过利用李雅普诺夫分析和相空间表示，基于高分辨率 ODE 的综合框架已在诸多研究中建立 [Shi et al., 2022, 2019, Chen et al., 2022a,b, 2023, Li et al., 2023]。此外，该框架也被扩展到包括 ISTA 和 FISTA 等近端算法 [Li et al., 2022a,b, 2023]。最近，新的高分辨率 ODE 系统被提出以理解和分析 ADMM，详见 [Li and Shi, 2024]。这些进展为优化算法的深入研究和发开开辟了多条新路径。

1.1 x -修正和 y -修正：一个耦合的小而关键的扰动

在将近端 Arrow-Hurwicz 算法与 PDHG 进行比较以研究 PDHG 的迭代行为时，有必要假设目标函数 f 和 g 都是足够光滑的。该假设使我们能够消除 argmin 和 argmax 操作，从而展开迭代。对

于近端 Arrow-Hurwicz 算法，其迭代式 (1.3a) 和 (1.3b) 可以表示为

$$\begin{cases} \frac{x_{k+1} - x_k}{s} = -F^\top y_k - \nabla f(x_{k+1}), \\ \frac{y_{k+1} - y_k}{s} = F x_{k+1} - \nabla g^*(y_{k+1}). \end{cases} \quad (1.5a)$$

$$(1.5b)$$

如果两个函数 f 和 g 都是常数函数或线性函数，近端 Arrow-Hurwicz 算法 (1.5a) 和 (1.5b) 遵循一个前向-后向方案，并且类似于哈密顿系统的辛欧拉方案。特别地，当矩阵 A 对称时，这种相似性是精确的，将近端 Arrow-Hurwicz 算法 (1.5a) 和 (1.5b) 直接与哈密顿系统对应。更多细节在 Section 3.2 中进行了阐述，包括文献 [He et al., 2014] 中的反例。在继续探讨 PDHG 之前，我们首先将 $F^\top(y_{k+1} - y_k)$ 插入迭代式 (1.5a) 的两边，将其转化为隐式形式作为初步步骤。通过将 (1.4b) 代入 (1.4c)，我们展开迭代式 (1.4c)，将 PDHG，即 (1.4a) — (1.4c)，表示为

$$\begin{cases} \frac{x_{k+1} - x_k}{s} - \underbrace{F^\top(y_{k+1} - y_k)}_{y\text{-correction}} = -F^\top y_{k+1} - \nabla f(x_{k+1}), \\ \frac{y_{k+1} - y_k}{s} - \underbrace{F(x_{k+1} - x_k)}_{x\text{-correction}} = F x_{k+1} - \nabla g^*(y_{k+1}), \end{cases} \quad (1.6a)$$

$$(1.6b)$$

通过比较维度可以观察到， $F^\top(y_{k+1} - y_k)$ 作为第一步迭代 (1.6a) 中的扰动，被称为 y -修正，而 $F(x_{k+1} - x_k)$ 作为第二步迭代 (1.6b) 中的扰动，被称为 x -修正。重要的是，这两个修正，即 x -修正和 y -修正，并非独立存在，而是相互关联，形成耦合扰动，彼此交叉影响 PDHG 的迭代过程 (1.6a) 和 (1.6b)。最后，值得注意的是，PDHG 算法 (1.6a) 和 (1.6b) 也具有隐式方案的特征，其表现为一个小而关键的扰动，这与文献 [Li and Shi, 2024] 中描述的 ADMM 场景类似。

1.2 贡献概述

在本文中，我们借鉴了常微分方程 (ODEs) 和数值分析中的技术来理解和分析 PDHG 算法，并突出我们的贡献如下。

- (1) 我们利用维度分析方法，如文献 [Shi et al., 2022, 2023, Shi, 2021, Li and Shi, 2024] 中所提出的，建立了针对 PDHG 的高精度 ODE 系统，表示为

$$\begin{cases} \dot{X} - sF^\top \dot{Y} = -F^\top Y - \nabla f(X) \\ \dot{Y} - sF \dot{X} = F X - \nabla g^*(Y) \end{cases} \quad (1.7a)$$

$$(1.7b)$$

需要特别注意的是，该系统的隐式 (Euler) 离散格式，(1.7a) 和 (1.7b)，恰好对应于 PDHG 算法，(1.4a) — (1.4c)。此外，高精度 ODE 系统 (1.7a) 和 (1.7b) 有效地封装了耦合校正项， x -校正与 y -校正的影响。这是 PDHG 的显著特征，使其区别于近端 Arrow-Hurwicz 算法 (1.3a) 和 (1.3b)。该微小但关键的扰动保证了变量对 (X, Y) 持续收敛，避免了近端 Arrow-Hurwicz 算法中观察到的周期性行为。

(2) 从高精度 ODE 系统 (1.7a) 和 (1.7b) 出发, 我们可以设计一个二次 Lyapunov 函数, 并直接证明其在连续情况下单调递减。该分析自然地连续的高精度 ODE 系统 (1.7a) 和 (1.7b) 过渡到离散的 PDHG 算法, (1.4a) — (1.4c)。值得注意的是, 隐式离散化带来的数值误差导致 PDHG 的收敛速度为 $O(1/N)$, 这与文献 [Li and Shi, 2024] 中 ADMM 算法观察到的现象相呼应。此外, 该分析框架可推广至包含两个不同参数的 PDHG 一般形式。相比于先前在 [Chambolle and Pock, 2011, 2016a, He and Yuan, 2012, He et al., 2014, 2022] 中的结果, 我们的证明更具原则性、简洁且直观。

(3) 另外, 我们进一步发现, 若目标函数 f 是强凸的, PDHG 的迭代序列在均值意义下表现出强收敛性, 其收敛速率为

$$\|\bar{x}_N - x^*\|^2 \leq O\left(\frac{1}{N+1}\right)$$

其中 $\bar{x}_N$ 表示迭代平均值, 即 $1/N \sum_{k=1}^N x_k$ 。该强凸性假设在实际场景中具有适用性, 特别是对于广义的 Lasso 问题。

2 预备知识

本节中, 我们简要介绍凸优化中的基本定义和经典定理。这些定义和定理主要摘自经典文献, 如 [Rockafellar, 1970, Rockafellar and Wets, 2009, Nesterov, 1998, Boyd and Vandenberghe, 2004], 并将在后续章节的证明中作为参考。首先, 我们定义凸函数、其共轭函数以及次梯度和次微分的概念。

Definition 2.1. 函数 $f: \mathbb{R}^d \mapsto \mathbb{R}$ 被称为凸函数, 如果对于任意 $x, y \in \mathbb{R}^d$ 以及任意 $\alpha \in [0, 1]$, 满足以下不等式:

$$f(\alpha x + (1 - \alpha)y) \leq \alpha f(x) + (1 - \alpha)f(y).$$

函数 $f^*: \mathbb{R}^d \mapsto \mathbb{R}$ 被称为函数 f 的共轭函数, 如果对于任意 $y \in \mathbb{R}^d$, 满足以下定义:

$$f^*(y) := \sup_{x \in \mathbb{R}^d} (\langle y, x \rangle - f(x)).$$

Definition 2.2. 向量 v 称为函数 f 在点 x 处的次梯度, 如果对于任意 $y \in \mathbb{R}^d$, 下列不等式成立:

$$f(y) \geq f(x) + \langle v, y - x \rangle.$$

此外, 函数 f 在点 x 处所有次梯度的集合称为 f 在 x 处的次微分, 我们记作 $\partial f(x)$ 。

设 $\mathcal{C}(\mathbb{R}^d)$ 为定义在 $\mathbb{R}^d$ 上的连续函数类。我们可以定义 $\mathcal{F}^0(\mathbb{R}^d) \subset \mathcal{C}(\mathbb{R}^d)$ 为连续且凸函数的类, $\mathcal{F}^1(\mathbb{R}^d) \subset \mathcal{F}^0(\mathbb{R}^d)$ 为其子类, 即可微且凸函数的类。根据 Theorem 2.1, 我们可以直接得出对于任意 $f \in \mathcal{F}^1(\mathbb{R}^d)$, 其共轭函数属于 $\mathcal{F}^1(\mathbb{R}^d)$ 。正如 [Rockafellar, 1970, 命题 8.21] 中所述, 由于对于任何 $f \in \mathcal{F}^0(\mathbb{R}^d)$ 函数值在所有点均有限, 次梯度总是存在的。由此我们得到以下定理。

Theorem 2.3. 对于任意 $f \in \mathcal{F}^0(\mathbb{R}^d)$, 对于任意 $x \in \mathbb{R}^d$, 次微分 $\partial f(x)$ 非空。

此外, 我们可以建立一个点为任意连续凸函数极小点的充分且必要条件。

Theorem 2.4. 点 x^* 是 $f \in \mathcal{F}^0(\mathbb{R}^d)$ 的极小点, 当且仅当 $0 \in \partial f(x^*)$ 。

接下来, 我们列出从 [Rockafellar, 1970] 收集的次微分和次梯度的两个基本性质。

Theorem 2.5 (Theorem 23.8 in [Rockafellar, 1970]). 对于任意 $f_1, f_2 \in \mathcal{F}^0(\mathbb{R}^d)$, 次微分满足

$$\partial(f_1 + f_2)(x) = \partial f_1(x) + \partial f_2(x),$$

对于任意 $x \in \mathbb{R}^d$ 。

Theorem 2.6 (Theorem 25.1 in [Rockafellar, 1970]). 对于任意 $f \in \mathcal{F}^1(\mathbb{R}^d)$, 梯度 $\nabla f(x)$ 是 f 在点 x 处唯一的次梯度, 满足

$$f(y) \geq f(x) + \langle \nabla f(x), y - x \rangle,$$

对于任意 $y \in \mathbb{R}^d$ 。

对于光滑函数, 我们可以给出如下精确的刻画。

Definition 2.7. 令 $f \in \mathcal{F}^1(\mathbb{R}^d)$ 。对于任意 $x, y \in \mathbb{R}^d$,

(1) 如果函数 f 的梯度满足

$$\|\nabla f(x) - \nabla f(y)\| \leq L\|x - y\|,$$

则称 f 为 L -光滑;

(2) 如果函数 f 满足

$$f(y) \geq f(x) + \langle \nabla f(x), y - x \rangle + \frac{\mu}{2}\|y - x\|^2,$$

则称 f 为 μ -强凸。

我们记 $\mathcal{S}_{\mu, L}^1(\mathbb{R}^d) \subset \mathcal{F}^1(\mathbb{R}^d)$ 为 L -光滑且 μ -强凸函数的类。

鉴于迭代公式 (1.3a) 或 (1.4a) 中的隐式解可能无法总是直接获得, 特别是在函数 f 是 L -光滑的情况下, 有必要明确允许直接获得这些迭代中隐式解的目标函数 f 的类别。我们将该类别记为 $\mathcal{R}(\mathbb{R}^d)$ 。最后, 我们引入鞍点的定义, 如 [Rockafellar and Wets, 2009, 定义 11.49] 所示。

Definition 2.8. 如果向量对 $(x^*, y^*) \in \mathbb{R}^{d_1} \times \mathbb{R}^{d_2}$ 是凸凹函数 Φ 的鞍点 (关于变量 x 是凸的, 关于变量 y 是凹的), 则对于任意 $x \in \mathbb{R}^{d_1}$ 和 $y \in \mathbb{R}^{d_2}$, 以下不等式成立:

$$\Phi(x^*, y) \leq \Phi(x^*, y^*) \leq \Phi(x, y^*).$$

根据 Theorem 2.8, 我们可以直接推导出目标函数 $\Phi(x, y)$ 取凸凹形式 (1.2) 时鞍点的充分且必要条件。本节最后以以下定理作为总结。

Theorem 2.9. 设 $f \in \mathcal{F}^1(\mathbb{R}^{d_1})$, $g \in \mathcal{F}^1(\mathbb{R}^{d_1})$, 且 $F \in \mathbb{R}^{d_2 \times d_1}$ 是一个 $d_2 \times d_1$ 矩阵。给定目标函数 $\Phi(x, y)$ 取凸凹形式 (1.2), 点 (x^*, y^*) 是鞍点当且仅当以下不等式成立

$$\begin{cases} f(x) - f(x^*) + \langle F(x - x^*), y^* \rangle \geq 0, \\ g^*(y) - g^*(y^*) - \langle Fx^*, y - y^* \rangle \geq 0. \end{cases}$$

3 高分辨率常微分方程系统的视角

在本节中, 我们首先通过量纲分析推导了 PDHG 算法的高分辨率常微分方程系统, 公式为 (1.7a) 和 (1.7b)。随后, 我们说明了近端 Arrow-Hurwicz 算法, 公式为 (1.5a) 和 (1.5b), 本质上作为低分辨率常微分方程系统的数值离散化方法。通过哈密顿力学及其保持结构的辛方法视角, 我们深入剖析了近端 Arrow-Hurwicz 算法在 [He et al., 2014] 中给出的反例中无法收敛的原因, 并将该分析推广到一系列反例。最后, 我们运用 Lyapunov 分析阐明了高分辨率常微分方程系统的收敛行为。

3.1 高分辨率 ODE 系统的推导

为了推导高分辨率 ODE 系统, 有必要假设目标函数和解均具有足够的光滑性。参数 s 被设置为步长, 它作为 PDHG 算法与连续系统之间的桥梁。令 $t_k = ks$, ($k = 0, 1, 2, \dots$), 并取假设 $x_k = X(t_k)$ 和 $y_k = Y(t_k)$ 。通过对 s 进行泰勒展开, 可以得到

$$\begin{cases} x_k = X(t_k) = x_{k+1} - s\dot{X}(t_{k+1}) + \frac{s^2}{2}\ddot{X}(t_{k+1}) + O(s^3), \end{cases} \quad (3.1a)$$

$$\begin{cases} y_k = Y(t_k) = y_{k+1} - s\dot{Y}(t_{k+1}) + \frac{s^2}{2}\ddot{Y}(t_{k+1}) + O(s^3). \end{cases} \quad (3.1b)$$

对于任意 $f \in \mathcal{F}^1(\mathbb{R}^d) \cap \mathcal{R}(\mathbb{R}^d)$ 和 $g \in \mathcal{F}^1(\mathbb{R}^d)$, 我们可以将 PDHG 展开成两个迭代, 分别表示为 (1.6a) 和 (1.6b)。将 (3.1a) 代入 (1.6a), 将 (3.1b) 代入 (1.6b), 我们得到

$$\begin{cases} -\frac{s}{2}\ddot{X}(t_{k+1}) + \dot{X}(t_{k+1}) - sF^\top \dot{Y}(t_{k+1}) + O(s^2) = -F^\top Y(t_{k+1}) - \nabla f(X(t_{k+1})), \end{cases} \quad (3.2a)$$

$$\begin{cases} -\frac{s}{2}\ddot{Y}(t_{k+1}) + \dot{Y}(t_{k+1}) - sF \dot{X}(t_{k+1}) + O(s^2) = FX(t_{k+1}) - \nabla g^*(Y(t_{k+1})). \end{cases} \quad (3.2b)$$

通过关注 $O(s)$ 项并忽略 $O(s^2)$ 项, 可以导出如下的 ODE 系统:

$$\begin{cases} -\frac{s}{2}\ddot{X} + \dot{X} - sF^\top \dot{Y} = -F^\top Y - \nabla f(X), \\ -\frac{s}{2}\ddot{Y} + \dot{Y} - sF \dot{X} = FX - \nabla g^*(Y), \end{cases}$$

该系统对应于一个过阻尼系统, 因为步长 s 很小。在过阻尼系统中, 任何惯性效应都会被粘性、摩擦或其他阻尼力的作用迅速抑制, 因此可以忽略其影响, 如文献 [Adams et al., 2013] 所述。该概念

在文献 [Shi, 2021, 第 1.2 节] 中得到了进一步的说明。因此，高分辨率 ODE 系统 (1.7a) 和 (1.7b) 可作为 PDHG 算法，(1.6a) 和 (1.6b) 的合理近似。反过来，PDHG 算法，(1.6a) 和 (1.6b)，恰好对应于高分辨率 ODE 系统 (1.7a) 和 (1.7b) 的隐式离散化。

3.2 低阶 ODE 系统：辛欧拉格式与近端 Arrow-Hurwicz 算法

通过关注方程 (3.2a) 和 (3.2b) 中的 $O(1)$ 项并忽略 $O(s)$ 项，我们可以导出简化系统为

$$\begin{cases} \dot{X} = -F^T Y - \nabla f(X), \\ \dot{Y} = F X - \nabla g^*(Y), \end{cases} \quad (3.3a)$$

该系统被称为 PDHG 的低阶 ODE 系统，与由方程 (1.7a) 和 (1.7b) 给出的高阶 ODE 系统相对应。此外，低阶 ODE 系统 (3.3a) 和 (3.3b) 的混合显隐式欧拉离散化精确对应于近端 Arrow-Hurwicz 算法，(1.5a) 和 (1.5b)。

如文献 [He et al., 2014] 所述，目标函数是光滑的并表达为

$$\Phi(x, y) = x - xy + y, \quad (3.4)$$

我们可以观察到 $(x^*, y^*) = (1, 1)$ 是唯一的鞍点。将目标函数 (3.4) 代入近端 Arrow-Hurwicz 算法，(1.5a) 和 (1.5b)，得到

$$\begin{cases} \frac{x_{k+1} - x_k}{s} = y_k - 1, \\ \frac{y_{k+1} - y_k}{s} = -x_{k+1} + 1. \end{cases} \quad (3.5a)$$

当步长取 $s = 1$ 时，方程 (3.5a) 和 (3.5b) 对应于文献 [He et al., 2014] 中展示的反例。此情形如 Figure 1 所示，近端 Arrow-Hurwicz 算法的迭代轨迹，(1.5a) 和 (1.5b)，形成一个由六个点组成的闭环，未能收敛到唯一鞍点 $(x^*, y^*) = (1, 1)$ 。此外，方程 (3.5a) 和 (3.5b) 可被解释为以下哈密顿系统的辛欧拉格式：

$$\begin{cases} \dot{X} = Y - 1, \\ \dot{Y} = -X + 1. \end{cases} \quad (3.6a)$$

可以观察到，对于给定的目标函数 (3.4)，低阶 ODE 系统，(3.3a) 和 (3.3b)，与哈密顿系统，(3.6a) 和 (3.6b) 完全一致。

通过分析方程 (3.6a) 和 (3.6b) 中的哈密顿动力学，我们可以从哈密顿力学的视角更深入地理解近端 Arrow-Hurwicz 算法为何无法收敛。如 Figure 2 所示，哈密顿系统的轨迹由点 $(0, 1)$ 出发，沿着以 $(1, 1)$ 为圆心、半径 $r = 1$ 的完美圆形路径运动。其动态行为由哈密顿函数描述为

$$H(x, y) = \frac{1}{2}(x^2 + y^2) - x - y = -\frac{1}{2}.$$

本质上，哈密顿系统保持哈密顿函数的值不变。在起始点 $(0, 1)$ ，哈密顿函数的值为 $H = -\frac{1}{2}$ ，而




图 1: 文献 [He et al., 2014] 中展示的反例: 给定目标函数 (3.4), 由近端 Arrow-Hurwicz 算法 (1.5a) 和 (1.5b) 生成的轨迹, 从目标下的点 $(0, 1)$ 出发, 未能收敛到鞍点 $(1, 1)$ 。

在唯一鞍点 $(1, 1)$ 处, 值变为 $H = -1$ 。因此, 由方程 (3.6a) 和 (3.6b) 支配的哈密顿系统无法收敛到该鞍点。换言之, 针对目标函数 (3.4), 低阶 ODE 系统, (3.3a) 和 (3.3b) 不会趋近于鞍点。尽管数值误差可能导致哈密顿函数值的精确保持出现偏差, 但周期结构在拓扑意义上仍可维持。正如文献 [Feng, 1984, Hairer et al., 2006] 所详细讨论的, 辛欧拉格式采用前向迭代 (例如 (3.5a)) 和后向迭代 (例如 (3.5b)) 相结合的方式, 有效保持此结构。通过对二次方程判别式的分析, 可判定当步长位于区间 $0 < s < 2$ 内时, 周期结构在辛欧拉格式 (3.5a) 和 (3.6b) 下能够保持。基于上述解释, 可以推断, 近端 Arrow-Hurwicz 算法, 如 (1.5a) 和 (1.5b) 所述, 在应用于目标函数 (3.4) 时, 总是保持周期结构。因此, 对于任意步长 $0 < s < 2$, 它都无法收敛到鞍点 $(1, 1)$ 。此外, 值得注意的是, 近端 Arrow-Hurwicz 算法的收敛失败并非局限于单一反例, 如文献 [He et al., 2014] 所指出, 而是扩展到一系列反例。Figure 3 中通过两个例子展示了这一点, 凸显了该算法保持周期结构并难以实现收敛的更广泛影响和多样化场景。






图 2: 给定目标函数 (3.4), 低分辨率 ODE 系统 (3.3a) 和 (3.3b) 从点 (0, 1) 出发的轨迹。



(a) $s = 0.5$



(b) $s = 1.5$

图 3: 给定目标函数 (3.4), 从 (0, 1) 出发, 采用不同步长由近端 Arrow-Hurwicz 算法 (1.5a) 和 (1.5b) 生成的轨迹。

3.3 高分辨率 ODE 系统的收敛性

设 (X, Y) 是高分辨率 ODE 系统, (1.7a) 和 (1.7b) 的解, 且 (x, y) 是 $\mathbb{R}^{d_1} \times \mathbb{R}^{d_2}$ 中的任意点。为了分析高分辨率 ODE 系统的收敛性, 我们构造如下的李雅普诺夫函数:

$$\mathcal{E}(t) = \frac{1}{2s} \|X - x\|^2 + \frac{1}{2s} \|Y - y\|^2 - \langle F(X - x), Y - y \rangle, \quad (3.7)$$

其中李雅普诺夫函数 $\mathcal{E}(t) \geq 0$ 对于任意满足 $0 < s\|F\| \leq 1$ 的步长总是成立。²

Lemma 3.1. 设 $f \in \mathcal{F}^1(\mathbb{R}^{d_1}) \cap \mathcal{R}(\mathbb{R}^{d_1})$ 且 $g \in \mathcal{F}^1(\mathbb{R}^{d_2})$ 。对于任意步长 $s \in (0, \|F\|^{-1}]$, Lyapunov 函数 (3.7) 满足如下不等式:

$$\frac{d\mathcal{E}}{dt} \leq -\frac{1}{s} \langle F(X - x), y \rangle + \frac{1}{s} \langle Fx, Y - y \rangle + \frac{1}{s} (f(x) - f(X) + g^*(y) - g^*(Y)). \quad (3.8)$$

证明 Theorem 3.1. 根据高分辨率 ODE 系统, (1.7a) 与 (1.7b), 我们可以计算李雅普诺夫函数 (3.7) 的时间导数为

$$\begin{aligned} \frac{d\mathcal{E}}{dt} &= \frac{1}{s} \langle \dot{X}, X - x \rangle - \langle F^\top \dot{Y}, X - x \rangle + \frac{1}{s} \langle \dot{Y}, Y - y \rangle - \langle F \dot{X}, Y - y \rangle, \\ &= -\frac{1}{s} \langle X - x, F^\top Y \rangle + \frac{1}{s} \langle Fx, Y - y \rangle - \frac{1}{s} \langle \nabla f(X), X - x \rangle - \frac{1}{s} \langle \nabla g^*(Y), Y - y \rangle \\ &= -\frac{1}{s} \langle F(X - x), y \rangle + \frac{1}{s} \langle Fx, Y - y \rangle + \frac{1}{s} \langle \nabla f(X), x - X \rangle + \frac{1}{s} \langle \nabla g^*(Y), y - Y \rangle, \end{aligned} \quad (3.9)$$

其中最后的等式依据 $\langle X - x, F^\top(Y - y) \rangle = \langle F(X - x), Y - y \rangle$ 。由于 $f \in \mathcal{F}^1(\mathbb{R}^{d_1})$ 且 $g \in \mathcal{F}^1(\mathbb{R}^{d_2})$, 我们可以根据 Theorem 2.1 和 Theorem 2.6 推导出以下凸不等式:

$$\begin{cases} f(x) - f(X) \geq \langle \nabla f(X), x - X \rangle, & (3.10a) \\ g^*(y) - g^*(Y) \geq \langle \nabla g^*(Y), y - Y \rangle. & (3.10b) \end{cases}$$

通过将 (3.10a) 和 (3.10b) 代入 (3.9), 证明得以完成。□

在此背景下, 变量 X 在时间区间 $[0, t]$ 上的时间平均定义为

$$\bar{X} = \frac{1}{t} \int_0^t X(s) ds.$$

我们引入满足变分不等式的点集, 记为 VI, 定义如下:

$$\text{VI} = \{(x^\diamond, y^\diamond) | f(x^\diamond) - f(x) + g^*(y^\diamond) - g^*(y) + \langle F(x^\diamond - x), y \rangle - \langle Fx, y^\diamond - y \rangle \leq 0\}. \quad (3.11)$$

利用 Theorem 3.1, 我们可以推导出时间平均值以弱意义收敛于集合 VI 的收敛速率, 具体严谨表述如下定理。

²在此情境中, 矩阵范数 $\|\cdot\|$ 指的是谱范数, 它由向量的 ℓ_2 范数诱导, 定义为

$$\|F\| = \sqrt{\lambda_{\max}(F^\top F)}.$$

Theorem 3.2. 在 Theorem 3.1 的假设下, 时间平均 $(\bar{X}, \bar{Y})$ 弱收敛到集合 VI, 记作 (3.11), 其收敛速率由下式描述:

$$\begin{aligned} f(\bar{X}) - f(x) + g^*(Y) - g^*(y) + \langle F(\bar{X} - x), y \rangle - \langle Fx, \bar{Y} - y \rangle \\ \leq \frac{\|x_0 - x\|^2 + \|y_0 - y\|^2 - 2s \langle F(x_0 - x), y_0 - y \rangle}{2t} \end{aligned} \quad (3.12)$$

对于任意初始值 $(x_0, y_0) \in \mathbb{R}^{d_1} \times \mathbb{R}^{d_2}$ 成立。

当点 (x, y) 被指定为鞍点 (x^*, y^*) 时, 李雅普诺夫函数 (3.7) 变为

$$\mathcal{E}(t) = \frac{1}{2s} \|X - x^*\|^2 + \frac{1}{2s} \|Y - y^*\|^2 + \langle F(X - x^*), Y - y^* \rangle. \quad (3.13)$$

将鞍点 (x^*, y^*) 代入导数不等式 (3.9) 得到

$$\frac{d\mathcal{E}}{dt} \leq -\frac{1}{s} \langle F^\top y^*, X - x^* \rangle + \frac{1}{s} \langle Fx^*, Y - y^* \rangle + \frac{1}{s} (f(x^*) - f(X) + g^*(y^*) - g^*(Y)). \quad (3.14)$$

借助 Theorem 2.9, 可以证明李雅普诺夫函数单调递减。其严谨表述如下。

Theorem 3.3. 在 Theorem 3.1 的假设下, 由 (3.13) 给出的 Lyapunov 函数单调递减。

此外, 考虑广义 Lasso, 目标函数 f 可能是 μ -强凸的。假设目标函数 f 确实具有 μ -强凸性, 我们可以推断 X 在时间区间 $[0, t]$ 上的时间平均以 $O(1/t)$ 的速率强收敛。正式陈述如下。

Theorem 3.4. 在 Theorem 3.1 的假设下, 如果我们进一步假设目标函数满足 $f \in \mathcal{S}_{\mu, L}^1(\mathbb{R}^d)$, 则时间平均 $\bar{X}$ 以以下速率收敛:

$$\|\bar{X} - x^*\|^2 \leq \frac{\|x_0 - x^*\|^2 + \|y_0 - y^*\|^2 + 2s \langle F(X - x^*), Y - y^* \rangle}{\mu t} \quad (3.15)$$

证明 Theorem 3.4. 已知目标函数假设为 $f \in \mathcal{S}_{\mu, L}^1(\mathbb{R}^d)$, 我们可以将凸不等式 (3.10a) 精炼为

$$f(x) - f(X) \geq \langle \nabla f(X), x - X \rangle + \frac{\mu}{2} \|x - X\|^2. \quad (3.16)$$

利用精炼后的不等式 (3.16) 并沿用导出 Theorem 3.3 的过程, 可确定李雅普诺夫函数 (3.13) 的时间导数满足以下不等式:

$$\frac{d\mathcal{E}}{dt} \leq -\frac{\mu}{2s} \|X - x^*\|^2.$$

因此, 通过取 X 的时间平均并利用 ℓ_2 -范数平方的凸性, 证明得以完成。□

4 PDHG 的收敛速率

在 Section 3.3 中，我们深入探讨了高分辨率 ODE 系统 (1.7a) 和 (1.7b) 的收敛行为。现在，我们将探索从连续视角直接扩展到离散环境，重点关注 PDHG 算法，(1.4a) — (1.4c)。需要强调的是，PDHG 算法 (1.4a) — (1.4c) 展现了之前在 ADMM 中观察到的现象，正如 [Li and Shi, 2024, Section 1.2] 所指出，隐式离散化产生的数值误差对收敛速率具有显著影响。

考虑任意点 $(x, y) \in \mathbb{R}^{d_1} \times \mathbb{R}^{d_2}$ 以及由 PDHG 算法 (1.4a) — (1.4c) 生成的迭代序列 $\{(x_k, y_k)\}_{k=0}^\infty$ 。我们将连续的李雅普诺夫函数 (3.7) 扩展至其离散形式对应函数为

$$\mathcal{E}(k) = \frac{1}{2s} \|x_k - x\|^2 + \frac{1}{2s} \|y_k - y\|^2 - \langle F(x_k - x), y_k - y \rangle, \quad (4.1)$$

其中李雅普诺夫函数 $\mathcal{E}(k) \geq 0$ 对于任意满足 $0 < s\|F\| \leq 1$ 的步长始终成立。

Lemma 4.1. 设 $f \in \mathcal{F}^0(\mathbb{R}^{d_1}) \cap \mathcal{R}(\mathbb{R}^{d_1})$ 且 $g \in \mathcal{F}^0(\mathbb{R}^{d_1})$ 。对于任意步长 $s \in (0, \|F\|^{-1}]$ ，离散 Lyapunov 函数 (4.1) 满足以下不等式：

$$\begin{aligned} \mathcal{E}(k+1) - \mathcal{E}(k) &\leq -\langle F(x_{k+1} - x), y \rangle + \langle Fx, y_{k+1} - y \rangle + f(x) - f(x_{k+1}) + g^*(y) - g^*(y_{k+1}) \\ &\quad - \underbrace{\left(\frac{1}{2s} \|x_{k+1} - x_k\|^2 + \frac{1}{2s} \|y_{k+1} - y_k\|^2 - \langle F(x_{k+1} - x_k), y_{k+1} - y_k \rangle \right)}_{\text{NE}}, \end{aligned} \quad (4.2)$$

其中 **NE** 表示隐式格式产生的数值误差。

证明 *Theorem 4.1*. 我们从离散李雅普诺夫函数 (4.1) 入手，目标是计算其在连续迭代间的差值，即 $\mathcal{E}(k+1) - \mathcal{E}(k)$ 。该差值可表示为：

$$\begin{aligned} \mathcal{E}(k+1) - \mathcal{E}(k) &= \underbrace{\left\langle \frac{x_{k+1} - x_k}{s} - F^\top(y_{k+1} - y_k), x_{k+1} - x \right\rangle + \left\langle \frac{y_{k+1} - y_k}{s} - F(x_{k+1} - x_k), y_{k+1} - y \right\rangle}_{\mathbf{I}} \\ &\quad - \underbrace{\left(\frac{1}{2s} \|x_{k+1} - x_k\|^2 + \frac{1}{2s} \|y_{k+1} - y_k\|^2 - \langle F(x_{k+1} - x_k), y_{k+1} - y_k \rangle \right)}_{\text{NE}}, \end{aligned} \quad (4.3)$$

其中 **I** 对应于连续视角下的项，**NE** 则表示隐式离散化产生的数值误差。基于恒等式 $\langle x_{k+1} - x, F^\top(y_{k+1} - y) \rangle = \langle F(x_{k+1} - x), y_{k+1} - y \rangle$ ，我们可以将 **I** 重写为

$$\begin{aligned} \mathbf{I} &= \left\langle \frac{x_{k+1} - x_k}{s} - F^\top(y_{k+1} - y_k) + F^\top y_{k+1}, x_{k+1} - x \right\rangle \\ &\quad + \left\langle \frac{y_{k+1} - y_k}{s} - F(x_{k+1} - x_k) - Fx_{k+1}, y_{k+1} - y \right\rangle \end{aligned}$$

$$-\langle F(x_{k+1} - x), y \rangle + \langle Fx, y_{k+1} - y \rangle. \quad (4.4)$$

对于任意 $f \in \mathcal{F}^0(\mathbb{R}^{d_1}) \cap \mathcal{R}(\mathbb{R}^{d_1})$ 以及任意 $g \in \mathcal{F}^0(\mathbb{R}^{d_1})$, Theorem 2.4 和 Theorem 2.5 使我们得以跳过 argmin 和 argmax 操作, 进一步基于首次下降迭代 (1.4a) 与第三次上升迭代 (1.4c) 探索 PDHG, 表达为:

$$\begin{cases} \frac{x_{k+1} - x_k}{s} + F^\top y_k + \partial f(x_{k+1}) \ni 0, \\ \frac{y_{k+1} - y_k}{s} - F\bar{x}_{k+1} + \partial g^*(y_{k+1}) \ni 0. \end{cases} \quad (4.5a)$$

$$(4.5b)$$

通过在 x 更新 (4.5a) 中隔离项 $F^\top(y_{k+1} - y_k)$ 并将动量步骤 (1.4b) 融入 y 更新 (4.5b), 我们得到

$$\begin{cases} \frac{x_{k+1} - x_k}{s} - F^\top(y_{k+1} - y_k) + F^\top y_{k+1} + \partial f(x_{k+1}) \ni 0, \\ \frac{y_{k+1} - y_k}{s} - F(x_{k+1} - x_k) - Fx_{k+1} + \partial g^*(y_{k+1}) \ni 0. \end{cases} \quad (4.6a)$$

$$(4.6b)$$

利用这些更新, 我们基于 Theorem 2.2 和 Theorem 2.5 可推导出两个凸不等式:

$$\begin{cases} f(x) - f(x_{k+1}) \geq \left\langle \frac{x_{k+1} - x_k}{s} - F^\top(y_{k+1} - y_k) + F^\top y_{k+1}, x_{k+1} - x \right\rangle, \\ g^*(y) - g^*(y_{k+1}) \geq \left\langle \frac{y_{k+1} - y_k}{s} - F(x_{k+1} - x_k) - Fx_{k+1}, y_{k+1} - y \right\rangle. \end{cases} \quad (4.7a)$$

$$(4.7b)$$

将上述两个凸不等式 (4.7a) 和 (4.7b) 代入此前公式 (4.4), 我们能够建立迭代差值的上界:

$$\mathbf{I} \leq -\langle F(x_{k+1} - x), y \rangle + \langle Fx_{k+1}, y_{k+1} - y \rangle + f(x) - f(x_{k+1}) + g^*(y) - g^*(y_{k+1}). \quad (4.8)$$

最终, 将该不等式 (4.8) 代入迭代差值 (4.2), 完成证明. $\square$

在此情境下, 我们用符号表示迭代序列的平均值. 以 $\{x_k\}_{k=0}^\infty$ 为例, 其迭代平均定义为

$$\bar{x}_N = \frac{1}{N} \sum_{k=1}^N x_k.$$

利用 Theorem 4.1, 我们可以确定平均序列 $\{x_k\}_{k=0}^\infty$ 在弱意义下的收敛速率. 该结论严格表述如下。

Theorem 4.2. 在 Theorem 4.1 的假设下, 迭代序列的平均值 $\{\bar{x}_N\}_{N=1}^\infty$ 弱收敛于集合 VI, 即 (3.11), 其收敛速率由下式刻画:

$$\begin{aligned} f(\bar{x}_N) - f(x) + g^*(\bar{y}_N) - g^*(y) + \langle F(\bar{x}_N - x), y \rangle - \langle Fx, \bar{y}_N - y \rangle \\ \leq \frac{\|x_0 - x\|^2 + \|y_0 - y\|^2 - 2s\langle F(x_0 - x), y_0 - y \rangle}{2sN} \end{aligned} \quad (4.9)$$

对于任意初始点 $(x_0, y_0) \in \mathbb{R}^{d_1} \times \mathbb{R}^{d_2}$ 均成立。

当点 (x, y) 被确定为鞍点 (x^*, y^*) 时, 李雅普诺夫函数 (4.1) 重新表述为

$$\mathcal{E}(k) = \frac{1}{2s} \|x_k - x^*\|^2 + \frac{1}{2s} \|y_k - y^*\|^2 - \langle F(x_k - x^*), y_k - y^* \rangle. \quad (4.10)$$

此外, 迭代差值 (4.3) 可用下述不等式来概括:

$$\begin{aligned} & \mathcal{E}(k+1) - \mathcal{E}(k) \\ & \leq -\langle F(x_{k+1} - x^*), y^* \rangle + \langle Fx^*, y_{k+1} - y^* \rangle + f(x^*) - f(x_{k+1}) + g^*(y^*) - g^*(y_{k+1}) \\ & \quad - \underbrace{\left(\frac{1}{2s} \|x_{k+1} - x_k\|^2 + \frac{1}{2s} \|y_{k+1} - y_k\|^2 - \langle F(x_{k+1} - x_k), y_{k+1} - y_k \rangle \right)}_{\text{NE}}. \end{aligned} \quad (4.11)$$

基于 Theorem 2.9, 显然迭代差值 (由不等式 (4.11) 捕捉) 可以被隐式格式产生的数值误差负向界定, 而对应的时间导数 (由不等式 (3.14) 描述) 在连续情形下仅为非正。这一观察使我们能够建立离散 PDHG 算法的收敛速率, 严格表述如下。

Theorem 4.3. 在 Theorem 4.1 的假设下, 迭代序列 $\{(x_k, y_k)\}_{k=0}^\infty$ 以以下速率收敛到 (x^*, y^*) , 其特征为

$$\left\{ \begin{aligned} & \frac{1}{N+1} \sum_{k=0}^N (\|x_{k+1} - x_k\|^2 + \|y_{k+1} - y_k\|^2 - 2s \langle F(x_{k+1} - x_k), y_{k+1} - y_k \rangle) \\ & \leq \frac{\|x_0 - x^*\|^2 + \|y_0 - y^*\|^2 - 2s \langle F(x_0 - x^*), y_0 - y^* \rangle}{N+1}, \end{aligned} \right. \quad (4.12a)$$

$$\left\{ \begin{aligned} & \min_{0 \leq k \leq N} (\|x_{k+1} - x_k\|^2 + \|y_{k+1} - y_k\|^2 - 2s \langle F(x_{k+1} - x_k), y_{k+1} - y_k \rangle) \\ & \leq \frac{\|x_0 - x^*\|^2 + \|y_0 - y^*\|^2 - 2s \langle F(x_0 - x^*), y_0 - y^* \rangle}{N+1}, \end{aligned} \right. \quad (4.12b)$$

对于任意初始点 $(x_0, y_0) \in \mathbb{R}^{d_1} \times \mathbb{R}^{d_2}$ 。特别地, 当步长满足 $s \in (0, \|F\|^{-1})$ 时, 迭代序列 $\{(x_k, y_k)\}_{k=0}^\infty$ 以以下速率强收敛:

$$\left\{ \begin{aligned} & \frac{1}{N+1} \sum_{k=0}^N (\|x_{k+1} - x_k\|^2 + \|y_{k+1} - y_k\|^2) \leq \frac{(1 + s\|F\|) (\|x_0 - x^*\|^2 + \|y_0 - y^*\|^2)}{(1 - s\|F\|) (N+1)}, \end{aligned} \right. \quad (4.13a)$$

$$\left\{ \begin{aligned} & \min_{0 \leq k \leq N} (\|x_{k+1} - x_k\|^2 + \|y_{k+1} - y_k\|^2) \leq \frac{(1 + s\|F\|) (\|x_0 - x^*\|^2 + \|y_0 - y^*\|^2)}{(1 - s\|F\|) (N+1)}. \end{aligned} \right. \quad (4.13b)$$

对于任意初始点 $(x_0, y_0) \in \mathbb{R}^{d_1} \times \mathbb{R}^{d_2}$ 。

同样地, 若进一步假设目标函数满足 $f \in \mathcal{S}_{\mu, L}^1(\mathbb{R}^d)$, 则凸不等式 (4.7a) 可被细化, 得出更紧的下界为

$$f(x) - f(x_{k+1}) \geq \left\langle \frac{x_{k+1} - x_k}{s} - F^T(y_{k+1} - y_k) + F^\top y_{k+1}, x_{k+1} - x \right\rangle + \frac{\mu}{2} \|x_{k+1} - x\|^2. \quad (4.14)$$

沿用导致 Theorem 4.3 的过程，我们可推导出迭代差值亦满足以下不等式：

$$\mathcal{E}(k+1) - \mathcal{E}(k) \leq -\frac{\mu}{2}\|x_{k+1} - x^*\|^2 - \underbrace{\left(\frac{1}{2s}\|x_{k+1} - x_k\|^2 + \frac{1}{2s}\|y_{k+1} - y_k\|^2 - \langle F(x_{k+1} - x_k), y_{k+1} - y_k \rangle \right)}_{\text{NE}}. \quad (4.15)$$

结合 ℓ_2 范数平方的凸性，我们能够确定迭代序列平均的收敛速率，如下定理所述。

Theorem 4.4. 在 Theorem 4.1 的假设下，如果我们进一步假设目标函数 $f \in \mathcal{S}_{\mu,L}^1(\mathbb{R}^d)$ ，则迭代序列的平均值 $\{\bar{x}_N\}_{N=0}^\infty$ 强收敛到鞍点 (x^*, y^*) ，其收敛速度由下式给出

$$\|\bar{x}_N - x^*\|^2 \leq \frac{\|x_0 - x^*\|^2 + \|y_0 - y^*\|^2 - 2s\langle F(x_0 - x^*), y_0 - y^* \rangle}{\mu s N} \quad (4.16)$$

对于任意初始点 $(x_0, y_0) \in \mathbb{R}^{d_1} \times \mathbb{R}^{d_2}$ 均成立。

5 单调性

本节中，我们旨在探讨数值误差的单调行为，如式 (4.2) 所示。数值误差定义为

$$\text{NE} = \frac{1}{2s}\|x_{k+1} - x_k\|^2 + \frac{1}{2s}\|y_{k+1} - y_k\|^2 - \langle F(x_{k+1} - x_k), y_{k+1} - y_k \rangle. \quad (5.1)$$

我们的目标是研究该误差随着迭代次数 k 的变化趋势。数值误差 (NE) 随迭代的单调递减表明，参考 Theorem 4.3 所述的收敛速率 $O(1/N)$ ，对于最后一次迭代而言，可以得到改善。这种潜在的提升具有重要意义，尤其是与通过平均和最小化策略获得的收敛速率相比。

为了开始我们的研究，先考虑数值误差 (5.1) 的连续对应形式，将其视为一个李雅普诺夫函数，记为

$$\mathcal{E}(t) = \frac{1}{2s}\|\dot{X}\|^2 + \frac{1}{2s}\|\dot{Y}\|^2 - \langle F\dot{X}, \dot{Y} \rangle. \quad (5.2)$$

利用经典的李雅普诺夫分析，对 (5.2) 取时间导数，得到

$$\frac{d\mathcal{E}}{dt} = \frac{1}{s}\langle \ddot{X} - sF^\top \ddot{Y}, \dot{X} \rangle + \frac{1}{s}\langle \ddot{Y} - sF\ddot{X}, \dot{Y} \rangle. \quad (5.3)$$

假设函数 $f \in \mathcal{F}^2(\mathbb{R}^{d_1}) \cap \mathcal{R}(\mathbb{R}^{d_1})$ 和 $g \in \mathcal{F}^2(\mathbb{R}^{d_1})$ 都具有充分的光滑性，我们对高分辨率系统中的每个 ODE，(1.7a) 和 (1.7b)，取时间导数，得到

$$\begin{cases} \ddot{X} - sF^\top \ddot{Y} = -F^\top \dot{Y} - \nabla^2 f(X)\dot{X}, \\ \ddot{Y} - sF\ddot{X} = F\dot{X} - \nabla^2 g^*(Y)\dot{Y}. \end{cases} \quad (5.4a)$$

$$\ddot{Y} - sF\ddot{X} = F\dot{X} - \nabla^2 g^*(Y)\dot{Y}. \quad (5.4b)$$

将这些表达式，(5.4a) 和 (5.4b)，代入导数不等式 (5.3)，可得时间导数满足

$$\frac{d\mathcal{E}}{dt} = -\langle \nabla^2 f(X)\dot{X}, \dot{X} \rangle - \langle \nabla^2 g^*(Y)\dot{Y}, \dot{Y} \rangle \leq 0, \quad (5.5)$$

这表明李雅普诺夫函数 (5.3) 单调递减。

基于高分辨率 ODE 系统, (1.7a) 和 (1.7b) 的洞见, 我们接下来分析离散的 PDHG 算法, (1.4a) — (1.4c)。如式 (5.2) 所示, 数值误差 **NE** 在此框架下被视作离散李雅普诺夫函数, 表达式为

$$\mathcal{E}(k) = \frac{1}{2s} \|x_{k+1} - x_k\|^2 + \frac{1}{2s} \|y_{k+1} - y_k\|^2 - \langle F(x_{k+1} - x_k), y_{k+1} - y_k \rangle. \quad (5.6)$$

为了分析李雅普诺夫函数 (5.6) 在迭代过程中的变化, 我们观察其迭代间的差值为

$$\begin{aligned} & \mathcal{E}(k+1) - \mathcal{E}(k) \\ & \leq \left\langle \frac{x_{k+2} - 2x_{k+1} + x_k}{s} - F^\top[y_{k+2} - 2y_{k+1} + y_k], x_{k+2} - x_{k+1} \right\rangle \\ & \quad + \left\langle \frac{y_{k+2} - 2y_{k+1} + y_k}{s} - F[x_{k+2} - 2x_{k+1} + x_k], y_{k+2} - y_{k+1} \right\rangle \\ & = \left\langle \frac{x_{k+2} - 2x_{k+1} + x_k}{s} - F^\top[y_{k+2} - 2y_{k+1} + y_k] + F^\top(y_{k+2} - y_{k+1}), x_{k+2} - x_{k+1} \right\rangle \\ & \quad + \left\langle \frac{y_{k+2} - 2y_{k+1} + y_k}{s} - F[x_{k+2} - 2x_{k+1} + x_k] - F(x_{k+2} - x_{k+1}), y_{k+2} - y_{k+1} \right\rangle. \end{aligned} \quad (5.7)$$

调用 Theorem 2.2 及两个关系式, (4.6a) 和 (4.6b), 我们可以推导出以下两个不等式

$$\left\langle \frac{x_{k+2} - 2x_{k+1} + x_k}{s} - F^\top[y_{k+2} - 2y_{k+1} + y_k] + F^\top(y_{k+2} - y_{k+1}), x_{k+2} - x_{k+1} \right\rangle \geq 0, \quad (5.8a)$$

$$\left\langle \frac{y_{k+2} - 2y_{k+1} + y_k}{s} - F[x_{k+2} - 2x_{k+1} + x_k] - F(x_{k+2} - x_{k+1}), y_{k+2} - y_{k+1} \right\rangle \geq 0. \quad (5.8b)$$

随后, 通过将这些不等式, (5.8a) 和 (5.8b), 代入迭代差分不等式 (5.7), 我们得出李雅普诺夫函数 (5.6) 满足

$$\mathcal{E}(k+1) - \mathcal{E}(k) \leq 0,$$

这证明了数值误差 **NE** (5.1) 单调递减。该结果使我们能够改进 Theorem 4.3, 更精确地描述收敛速率, 特别是针对最后一次迭代。其严谨表述如下。

Theorem 5.1. 在 Theorem 4.1 的假设下, 迭代序列 $\{(x_k, y_k)\}_{k=0}^\infty$ 以以下速率收敛到 (x^*, y^*) , 其特征为

$$\begin{aligned} & \|x_{k+1} - x_k\|^2 + \|y_{k+1} - y_k\|^2 - 2s \langle F(x_{k+1} - x_k), y_{k+1} - y_k \rangle \\ & \leq \frac{\|x_0 - x^*\|^2 + \|y_0 - y^*\|^2 - 2s \langle F(x_0 - x^*), y_0 - y^* \rangle}{N+1}, \end{aligned} \quad (5.9)$$

对于任意初始点 $(x_0, y_0) \in \mathbb{R}^{d_1} \times \mathbb{R}^{d_2}$ 。特别地, 当步长满足 $s \in (0, 1/\|F\|)$ 时, 迭代序列 $\{(x_k, y_k)\}_{k=0}^\infty$ 以强收敛速率收敛, 具体为

$$\|x_{k+1} - x_k\|^2 + \|y_{k+1} - y_k\|^2 \leq \frac{(1 + s\|F\|)(\|x_0 - x^*\|^2 + \|y_0 - y^*\|^2)}{(1 - s\|F\|)(N+1)}, \quad (5.10)$$

对于任意初始点 $(x_0, y_0) \in \mathbb{R}^{d_1} \times \mathbb{R}^{d_2}$ 。

6 扩展：PDHG 的一般形式

从 Section 3 到 Section 5，我们详细阐述了高分辨率 ODE 框架以解析离散 PDHG 算法，(1.4a) — (1.4c) 的收敛行为。显然，其有效性依赖于耦合修正，即 x -修正和 y -修正。尤其是，我们利用了 Lyapunov 函数，(4.1) 和 (5.6)，来推导其收敛速率。在本节中，我们将该框架扩展到包含 PDHG 的一般形式，其表达为

$$\begin{cases} x_{k+1} = \operatorname{argmin}_{x \in \mathbb{R}^{d_1}} \left\{ f(x) + \langle Fx, y_k \rangle + \frac{1}{2\tau} \|x - x_k\|^2 \right\}, \end{cases} \quad (6.1a)$$

$$\begin{cases} \bar{x}_{k+1} = x_{k+1} + (x_{k+1} - x_k), \end{cases} \quad (6.1b)$$

$$\begin{cases} y_{k+1} = \operatorname{argmax}_{y \in \mathbb{R}^{d_2}} \left\{ -g^*(y) + \langle F\bar{x}_{k+1}, y \rangle - \frac{1}{2\sigma} \|y - y_k\|^2 \right\}. \end{cases} \quad (6.1c)$$

其中两个参数 τ 和 σ 满足条件 $0 < \tau\sigma\|F\|^2 \leq 1$ 。换言之，一般形式，(6.1a) — (6.1c)，引入了两个不同的参数 τ 和 σ 用于近端更新，区别于使用单一步长 s 的 PDHG (1.4a) — (1.4c)。

设步长为 $s = \sqrt{\tau\sigma}$ 。按照 Section 3.1 中相同的过程，我们可以推导出一般形式 PDHG，(6.1a) — (6.1c) 的高分辨率 ODE 系统为

$$\begin{cases} \alpha \dot{X} - sF^\top \dot{Y} = -F^\top Y - \nabla f(X) \end{cases} \quad (6.2a)$$

$$\begin{cases} \beta \dot{Y} - sF \dot{X} = FX - \nabla g^*(Y) \end{cases} \quad (6.2b)$$

其中两个参数 α 和 β 满足条件 $\alpha\beta = 1$ 。该条件表明项 $(\alpha\dot{X}, \beta\dot{Y})^\top$ 表示主项，至少为 $O(1)$ 量级，因此在动力学中起主导作用。值得注意的是， $O(s)$ 项 $(-sF^\top \dot{Y}, -sF \dot{X})^\top$ 作为耦合扰动存在于高分辨率系统，(6.2a) 和 (6.2b) 中。

相应地，Lyapunov 函数 (3.13) 被调整为以下形式：

$$\mathcal{E}(t) = \frac{1}{2\tau} \|X - x^*\|^2 + \frac{1}{2\sigma} \|Y - y^*\|^2 - \langle F(X - x^*), Y - y^* \rangle. \quad (6.3)$$

借助 Theorem 2.6 和 Theorem 2.9，我们很容易证明其时间导数非正。进一步地，离散 Lyapunov 函数最初在 (4.10) 中构造，被修改为

$$\mathcal{E}(k) = \frac{1}{2\tau} \|x_k - x^*\|^2 + \frac{1}{2\sigma} \|y_k - y^*\|^2 - \langle F(x_k - x^*), y_k - y^* \rangle. \quad (6.4)$$

采用与建立 Theorem 4.3 类似的方法，我们推导出迭代差异在迭代次数中被数值误差所界定：

$$\mathbf{NE} = \frac{1}{2\tau} \|x_{k+1} - x_k\|^2 + \frac{1}{2\sigma} \|y_{k+1} - y_k\|^2 - \langle F(x_{k+1} - x_k), y_{k+1} - y_k \rangle. \quad (6.5)$$

因此，我们可以将 Theorem 4.3 强化为以下陈述。

Theorem 6.1. 设 $f \in \mathcal{F}^0(\mathbb{R}^{d_1}) \cap \mathcal{R}(\mathbb{R}^{d_1})$ 且 $g \in \mathcal{F}^0(\mathbb{R}^{d_1})$ 。若两个参数 τ 和 σ 满足 $\tau\sigma \in (0, \|F\|^{-2}]$, 则迭代序列 $\{(x_k, y_k)\}_{k=0}^\infty$ 以以下速率收敛到 (x^*, y^*) , 其特征为

$$\left\{ \begin{aligned} & \frac{1}{N+1} \sum_{k=0}^N (\sigma \|x_{k+1} - x_k\|^2 + \tau \|y_{k+1} - y_k\|^2 - 2\tau\sigma \langle F(x_{k+1} - x_k), y_{k+1} - y_k \rangle) \\ & \leq \frac{\sigma \|x_0 - x^*\|^2 + \tau \|y_0 - y^*\|^2 - 2\tau\sigma \langle F(x_0 - x^*), y_0 - y^* \rangle}{N+1}, \quad (6.6a) \\ & \min_{0 \leq k \leq N} (\sigma \|x_{k+1} - x_k\|^2 + \tau \|y_{k+1} - y_k\|^2 - 2\tau\sigma \langle F(x_{k+1} - x_k), y_{k+1} - y_k \rangle) \\ & \leq \frac{\sigma \|x_0 - x^*\|^2 + \tau \|y_0 - y^*\|^2 - 2\tau\sigma \langle F(x_0 - x^*), y_0 - y^* \rangle}{N+1}, \quad (6.6b) \end{aligned} \right.$$

对于任意的初始值 $(x_0, y_0) \in \mathbb{R}^{d_1} \times \mathbb{R}^{d_2}$ 。特别地, 当两个参数 τ 和 σ 满足 $\tau\sigma \in (0, \|F\|^{-2})$ 时, 迭代序列 $\{(x_k, y_k)\}_{k=0}^\infty$ 以强收敛的速率收敛, 其速率为

$$\left\{ \begin{aligned} & \frac{1}{N+1} \sum_{k=0}^N (\|x_{k+1} - x_k\|^2 + \|y_{k+1} - y_k\|^2) \leq \frac{(1 + \sqrt{\tau\sigma}\|F\|) (\|x_0 - x^*\|^2 + \|y_0 - y^*\|^2)}{(1 - \sqrt{\tau\sigma}\|F\|) (N+1)}, \quad (6.7a) \\ & \min_{0 \leq k \leq N} (\|x_{k+1} - x_k\|^2 + \|y_{k+1} - y_k\|^2) \leq \frac{(1 + \sqrt{\tau\sigma}\|F\|) (\|x_0 - x^*\|^2 + \|y_0 - y^*\|^2)}{(1 - \sqrt{\tau\sigma}\|F\|) (N+1)}. \quad (6.7b) \end{aligned} \right.$$

对于任意的初始值 $(x_0, y_0) \in \mathbb{R}^{d_1} \times \mathbb{R}^{d_2}$ 。

最后, 我们确认数值误差 (6.5) 的单调递减性, 这与 Section 5 中描述的过程一致。该过程始于考虑高分辨率 ODE 连续系统, (6.2a) 和 (6.2b)。将数值误差 (6.5) 的连续对应视为 Lyapunov 函数, 记为

$$\mathcal{E}(t) = \frac{1}{2\tau} \|\dot{X}\|^2 + \frac{1}{2\sigma} \|\dot{Y}\|^2 - \langle F\dot{X}, \dot{Y} \rangle, \quad (6.8)$$

我们可以轻松推导出 (6.8) 中 $\mathcal{E}(t)$ 的时间导数不超过零。该结论通过对高分辨率 ODE 系统, (6.2a) 和 (6.2b), 进行时间导数运算得出。接着对离散 Lyapunov 函数采取类似方法

$$\mathcal{E}(k) = \frac{1}{2\tau} \|x_{k+1} - x_k\|^2 + \frac{1}{2\sigma} \|y_{k+1} - y_k\|^2 - \langle F(x_{k+1} - x_k), y_{k+1} - y_k \rangle. \quad (6.9)$$

通过一些基础分析, 我们可以辨别出数值误差确实单调递减。该见解使我们能够相应地完善 Theorem 5.1。

Theorem 6.2. 设 $f \in \mathcal{F}^0(\mathbb{R}^{d_1}) \cap \mathcal{R}(\mathbb{R}^{d_1})$ 且 $g \in \mathcal{F}^0(\mathbb{R}^{d_1})$ 。若两个参数 τ 和 σ 满足 $\tau\sigma \in (0, \|F\|^{-2}]$, 则迭代序列 $\{(x_k, y_k)\}_{k=0}^\infty$ 以如下速率收敛到 (x^*, y^*) , 其特征为

$$\begin{aligned} & \sigma \|x_{k+1} - x_k\|^2 + \tau \|y_{k+1} - y_k\|^2 - 2\tau\sigma \langle F(x_{k+1} - x_k), y_{k+1} - y_k \rangle \\ & \leq \frac{\sigma \|x_0 - x^*\|^2 + \tau \|y_0 - y^*\|^2 - 2\tau\sigma \langle F(x_0 - x^*), y_0 - y^* \rangle}{N+1}, \quad (6.10) \end{aligned}$$

对任意初始点 $(x_0, y_0) \in \mathbb{R}^{d_1} \times \mathbb{R}^{d_2}$ 成立。特别地，当两个参数 τ 和 σ 满足 $\tau\sigma \in (0, \|F\|^{-2})$ 时，迭代序列 $\{(x_k, y_k)\}_{k=0}^\infty$ 以如下速率强收敛：

$$\sigma\|x_{k+1} - x_k\|^2 + \tau\|y_{k+1} - y_k\|^2 \leq \frac{(1 + \sqrt{\tau\sigma}\|F\|)(\sigma\|x_0 - x^*\|^2 + \tau\|y_0 - y^*\|^2)}{(1 - \sqrt{\tau\sigma}\|F\|)(N + 1)}, \quad (6.11)$$

对任意初始点 $(x_0, y_0) \in \mathbb{R}^{d_1} \times \mathbb{R}^{d_2}$ 成立。

7 结论与讨论

在本研究中，我们利用维度分析方法，这一方法曾在 [Shi et al., 2022, 2023, Shi, 2021, Li and Shi, 2024] 中被采用，推导出了离散 PDHG 算法的高分辨率 ODE 系统。该系统有效捕捉了 PDHG 的一个关键特征，即耦合的 x -校正和 y -校正，这使其区别于近端 Arrow-Hurwicz 算法。虽小但关键的扰动保证了 PDHG 的一致收敛，避免了近端 Arrow-Hurwicz 算法中观察到的周期性行为。从技术上讲，我们利用 Lyapunov 分析来研究从连续的高分辨率系统到离散 PDHG 算法的收敛行为转变。该分析指出，由隐式数值格式产生的数值误差是导致离散 PDHG 算法收敛速度和单调性的重要因素，这一重要观察也在 [Li and Shi, 2024] 中关于 ADMM 算法的研究里得到体现。此外，我们进一步发现，如果目标函数 f 是强凸的，则 PDHG 的迭代平均值得到提升并且强收敛。

通过高分辨率 ODE 系统来理解和分析离散 PDHG 算法为进一步研究开辟了若干令人振奋的方向。与 [Li and Shi, 2024, (1.16a) — (1.16c)] 中描述的 ADMM 的高分辨率 ODE 系统相比，PDHG 的高分辨率系统 (1.7a) 和 (1.7b) 展现出更加简洁且直观的动力学结构。探究 PDHG 在不同范数和收敛速率下的表现将是非常有意义的。此外，鉴于模拟重球加速下山以加快梯度流动的二阶梯度系统，其运动类似于液滴的运动，因此存在较大潜力设计一种算法，以提升 PDHG 的收敛速率，达到凸优化问题的下界 $O(1/N^2)$ ，正如 [Nemirovski and Yudin, 1983] 所指出的那样。回到目标函数 (1.2)，除去两个单变量函数，主凸凹函数为二次函数。基于 PDHG 高分辨率系统 (1.7a) 和 (1.7b) 的直观动力学，扩展该框架至非二次函数，尤其是探索 PDHG 算法在非二次凸凹目标函数上的收敛行为，也极具吸引力。此外，一个非常有趣的研究方向是通过高分辨率 ODE 系统，探讨传统的极小极大优化算法，如 *optimal gradient descent ascent* (OGDA) 算法 [Popov, 1980] 和 Extragradient 方法 [Korpelevich, 1976]，以及它们与 PDHG 算法之间的关系。

Acknowledgements

Bowen Li was partially supported by the Hua Loo-Keng scholarship of CAS. Bin Shi was partially supported by Grant No.YSBR-034 of CAS.

参考文献

- S. Adams, N. Dirr, M. Peletier, and J. Zimmer. Large deviations and gradient flows. *Philosophical Transactions of the Royal Society A: Mathematical, Physical and Engineering Sciences*, 371(2005):20120341, 2013.
- K. J. Arrow, L. Hurwicz, and H. Uzawa. *Studies in linear and non-linear programming*. Stanford mathematical studies in the social sciences. Stanford University Press, 1958.
- S. Boyd, N. Parikh, E. Chu, B. Peleato, J. Eckstein, et al. Distributed optimization and statistical learning via the alternating direction method of multipliers. *Foundations and Trends® in Machine learning*, 3(1):1–122, 2011.
- S. P. Boyd and L. Vandenberghe. *Convex optimization*. Cambridge University Press, 2004.
- A. M. Bruckstein, D. L. Donoho, and M. Elad. From sparse solutions of systems of equations to sparse modeling of signals and images. *SIAM review*, 51(1):34–81, 2009.
- E. J. Candès, J. Romberg, and T. Tao. Robust uncertainty principles: Exact signal reconstruction from highly incomplete frequency information. *IEEE Transactions on information theory*, 52(2):489–509, 2006.
- A. Chambolle and T. Pock. A first-order primal-dual algorithm for convex problems with applications to imaging. *Journal of mathematical imaging and vision*, 40:120–145, 2011.
- A. Chambolle and T. Pock. On the ergodic convergence rates of a first-order primal-dual algorithm. *Mathematical Programming*, 159(1):253–287, 2016a.
- A. Chambolle and T. Pock. An introduction to continuous optimization for imaging. *Acta Numerica*, 25:161–319, 2016b.
- S. Chen, B. Shi, and Y.-x. Yuan. Gradient norm minimization of Nesterov acceleration: $\mathcal{O}(1/k^3)$. *arXiv preprint arXiv:2209.08862*, 2022a.
- S. Chen, B. Shi, and Y.-x. Yuan. Revisiting the acceleration phenomenon via high-resolution differential equations. *arXiv preprint arXiv:2212.05700*, 2022b.
- S. Chen, B. Shi, and Y.-x. Yuan. On underdamped Nesterov’s acceleration. *arXiv preprint arXiv:2304.14642*, 2023.
- D. L. Donoho. Compressed sensing. *IEEE Transactions on information theory*, 52(4):1289–1306, 2006.

- D. L. Donoho and I. M. Johnstone. Adapting to unknown smoothness via wavelet shrinkage. *Journal of the American statistical association*, 90(432):1200–1224, 1995.
- E. Esser, X. Zhang, and T. F. Chan. A general framework for a class of first order primal-dual algorithms for convex optimization in imaging science. *SIAM Journal on Imaging Sciences*, 3(4):1015–1046, 2010.
- K. Feng. On difference schemes and symplectic geometry. In *Proceedings of the 5th international symposium on differential geometry and differential equations*, 1984.
- D. Gabay and B. Mercier. A dual algorithm for the solution of nonlinear variational problems via finite element approximation. *Computers & mathematics with applications*, 2(1):17–40, 1976.
- R. Glowinski and A. Marroco. On the approximation, by éfinite elements of order one, and the resolution, by pénalization-dualité of a class of nonlinear dirichlet problems. *French journal of automation, computer science, operational research. Numerical analysis*, 9(R2):41–76, 1975.
- E. Hairer, C. Lubich, and G. Wanner. *Geometric numerical integration: Structure-Preserving Algorithms for Ordinary Differential Equations*, volume 31 of *Springer Series in Computational Mathematics*. Springer, 2nd edition, 2006.
- B. He and X. Yuan. Convergence analysis of primal-dual algorithms for a saddle-point problem: from contraction perspective. *SIAM Journal on Imaging Sciences*, 5(1):119–149, 2012.
- B. He, Y. You, and X. Yuan. On the convergence of primal-dual hybrid gradient algorithm. *SIAM Journal on Imaging Sciences*, 7(4):2526–2537, 2014.
- B. He, F. Ma, S. Xu, and X. Yuan. A generalized primal-dual algorithm with improved convergence condition for saddle point problems. *SIAM Journal on Imaging Sciences*, 15(3):1157–1183, 2022.
- S.-J. Kim, K. Koh, S. Boyd, and D. Gorinevsky. ℓ_1 trend filtering. *SIAM review*, 51(2):339–360, 2009.
- G. M. Korpelevich. The extragradient method for finding saddle points and other problems. *Matecon*, 12:747–756, 1976.
- B. Li and B. Shi. Understanding the admm algorithm via high-resolution differential equations. *arXiv preprint arXiv:2401.07096*, 2024.
- B. Li, B. Shi, and Y.-x. Yuan. Linear convergence of ISTA and FISTA. *arXiv preprint arXiv:2212.06319*, 2022a.

- B. Li, B. Shi, and Y.-x. Yuan. Proximal subgradient norm minimization of ISTA and FISTA. *arXiv preprint arXiv:2211.01610*, 2022b.
- B. Li, B. Shi, and Y.-x. Yuan. Linear convergence of Nesterov-1983 with the strong convexity. *arXiv preprint arXiv:2306.09694*, 2023.
- A. S. Nemirovski and D. B. Yudin. *Problem complexity and method efficiency in optimization*. Wiley-Interscience, 1983.
- Y. Nesterov. *Introductory Lectures on Convex Optimization: A Basic Course*, volume 87. Springer Science & Business Media, 1998.
- L. D. Popov. A modification of the Arrow-Hurwicz method for search of saddle points. *Mathematical notes of the Academy of Sciences of the USSR*, 28:845–848, 1980.
- R. T. Rockafellar. *Convex Analysis*, volume 18. Princeton University Press, 1970.
- R. T. Rockafellar and R. J.-B. Wets. *Variational analysis*, volume 317. Springer Science & Business Media, 2009.
- L. I. Rudin, S. Osher, and E. Fatemi. Nonlinear total variation based noise removal algorithms. *Physica D: nonlinear phenomena*, 60(1-4):259–268, 1992.
- B. Shi. On the hyperparameters in stochastic gradient descent with momentum. *arXiv preprint arXiv:2108.03947*, 2021.
- B. Shi, S. S. Du, W. Su, and M. I. Jordan. Acceleration via symplectic discretization of high-resolution differential equations. *Advances in Neural Information Processing Systems*, 32, 2019.
- B. Shi, S. S. Du, M. I. Jordan, and W. J. Su. Understanding the acceleration phenomenon via high-resolution differential equations. *Mathematical Programming*, 195(1-2):79–148, 2022.
- B. Shi, W. Su, and M. I. Jordan. On learning rates and Schrödinger operators. *Journal of Machine Learning Research*, 24(379):1–53, 2023.
- R. Tibshirani. Regression shrinkage and selection via the lasso. *Journal of the Royal Statistical Society Series B: Statistical Methodology*, 58(1):267–288, 1996.
- R. Tibshirani, M. Saunders, S. Rosset, J. Zhu, and K. Knight. Sparsity and smoothness via the fused lasso. *Journal of the Royal Statistical Society Series B: Statistical Methodology*, 67(1):91–108, 2005.

R. J. Tibshirani. *The solution path of the generalized lasso*. PhD thesis, Stanford University, Palo Alto, CA, 2011. PhD thesis.

M. Zhu and T. Chan. An efficient primal-dual hybrid gradient algorithm for total variation image restoration. *Ucla Cam Report*, 34(2), 2008.