

线性病态逆问题的随机方差约简梯度方法

QINIAN JIN AND LIUHONG CHEN

摘要. 本文将随机方差缩减梯度 (SVRG) 方法应用于希尔伯特空间中求解大规模线性病态系统。SVRG 是一种在优化中广泛使用的方差缩减方法，用于加速随机梯度方法。在先验停机指标的选择下，我们推导出当目标解满足基准源条件时的收敛速率结果，并建立了不依赖任何源条件的收敛性结果。为了以后验方式终止算法，我们考虑了差异性原则，并证明该原则几乎必然在有限次迭代后终止算法。文中还报告了多种数值实验结果以测试该方法的性能。

1. 引言

考虑由线性系统控制的病态逆问题 $\{PLACEHOLDER_{ENV_2}\}$ 其中，对于每个 $i = 1, \dots, N$ ， $A_i : X \rightarrow Y_i$ 是从固定的希尔伯特空间 X 到希尔伯特空间 Y_i 的有界线性算子。这里，病态性意味着方程 (1.1) 的解对数据的不连续依赖。此类问题广泛出现在包括各种断层成像和离散数据逆问题等应用中（见 [2, 14]）。令 $Y := Y_1 \times \dots \times Y_N$ 为 $Y_1, \dots, Y_N$ 的乘积空间，其内积由各 Y_i 的自然内积继承。定义算子 $A : X \rightarrow Y$ 为

$$Ax := (A_1x, \dots, A_Nx), \quad \forall x \in X.$$

则 A 是有界线性算子，且 (1.1) 可写为 $Ax = y$ 其中 $y := (y_1, \dots, y_N) \in Y$ 。注意， A 的伴随算子 $A^* : Y \rightarrow X$ 由

$$A^*z = \sum_{i=1}^N A_i^*z_i, \quad \forall z = (z_1, \dots, z_N) \in Y,$$

给出，其中 $A_i^* : Y_i \rightarrow X$ 表示 A_i 的伴随算子。下文中我们始终假设 (1.1) 有解，即 $y \in \text{Ran}(A)$ ， A 的值域。通过取初始猜测 $x_0 \in X$ ，我们旨在寻找满足

$$\|x^\dagger - x_0\| = \min\{\|x - x_0\| : A_i x = y_i, i = 1, \dots, N\}$$

的方程 (1.1) 的解 $x^\dagger$ 。易见此解 $x^\dagger$ 存在且唯一；我们将称 $x^\dagger$ 为方程 (1.1) 的以 x_0 为基准的最小范数解。已知当且仅当 $Ax^\dagger = y$ 且 $x^\dagger - x_0 \in \text{Null}(A)^\perp$ 时， $x^\dagger$ 是 (1.1) 的 x_0 -最小范数解，其中 $\text{Null}(A)$ 表示 A 的零空间，即 $\text{Null}(A) := \{x \in X : Ax = 0\}$ 。

在实际应用中，数据通常通过测量获得。因此，取代精确数据 $y = (y_1, \dots, y_N)$ ，我们只有满足

的带噪声数据 $y^\delta := (y_1^\delta, \dots, y_N^\delta)$, 其中 $\delta > 0$ 表示噪声水平。因此, 开发算法利用带噪声数据 y^δ 近似计算 $x^\dagger$ 具有重要意义。文献中已提出许多正则化方法以实现此目的, 见 [5]。最著名的迭代正则化方法是 Landweber

其中 $x_0^\delta := x_0 \in X$ 为初始猜测, $\gamma > 0$ 为步长。已知若 $0 < \gamma \leq 2/\|A\|^2$, 则 Landweber 方法在基于不匹配原则终止时是阶最优的正则化方法。由于其实现简单且每步计算复杂度低, Landweber 方法在求解病态逆问题中广受欢迎。

注意, Landweber 方法 (1.2) 每次迭代都需要计算

$$A^*(Ax_n^\delta - y^\delta) = \sum_{i=1}^N A_i^*(A_i x_n^\delta - y_i^\delta).$$

当 N 很大时, 计算所有 $A_i^*(A_i x_n^\delta - y_i^\delta)$ 需要大量计算时间。为解决此问题, 近年来将随机梯度下降 (SGD) 方法应用于形式如 (1.1) 的病态逆问题求解, 这种方法在大规模优化问题中广为流行, 具 `Sbfn: < PLACEHOLDER_E NV_5 > v-i_n \in \{1, \dots, N\}` 以均匀分布随机选择, γ_n 表示第 n 次迭代的步长。该方法在 [8] 中针对递减步长进行了分析, 在 [12] 中针对常步长进行了分析。然而, 随机梯度噪声的存在可能导致 SGD 迭代剧烈振荡, 进而难以正确终止迭代。为减小振荡, 有必要设计方法降低梯度噪声的方差。在 [12] 中, 将不匹配原则纳入步长选择, 有效减少了振荡。

在大规模优化 `off < PLACEHOLDER_E NV_6 > v-*f_i` 是凸且连续可微的, 已有多种方差减少方法被提出以加速随机梯度方法, 见 [4, 13, 16, 15, 17, 21, 22]。其中最流行的方法之一是随机方差减少梯度 (SVRG) 方法 ([13, 21]), 其受到了广泛关注 ([1, 7, 18, 19, 20])。SVRG 是一种用于迭代求解最小化问题 (1.5) 的随机算法。它从初始猜测 x_0 和更新频率 m 开始。在第 n 步确定快照点 x_n 后, SVRG 计算函数 f 在 x_n 处的全梯度 $\nabla f(x_n)$, 并执行 m 步 SGD, 得到 $\{x_{n,k} : k = 0, \dots, m\}$, 其中 $x_{n,0} = x_n$, 使用无偏梯度

$$g_{n,k} = \nabla f_{i_{n,k}}(x_{n,k}) - \nabla f_{i_{n,k}}(x_n) + \nabla f(x_n),$$

其中 $i_{n,k} \in \{1, \dots, N\}$ 以均匀分布随机选择。即

$$x_{n,k+1} = x_{n,k} - \gamma g_{n,k}, \quad k = 0, \dots, m-1$$

使用常步长 γ 。接下来快照点 x_{n+1} 由 $x_{n,k}, k = 0, \dots, m$ 以多种方式定义, 例如可以定义为最后一次迭代点、随机选择点或加权平均点。当 SVRG 用于利用带噪声数据 y^δ 求解 (1.1) 时, 我们可考虑带有 $f_i(x) = \frac{1}{2}\|A_i x - y_i^\delta\|^2$ 的 (1.5)。对应地,

$$\nabla f(x) = \frac{1}{N} A^*(Ax - y^\delta), \quad \nabla f_i(x) = A_i^*(A_i x - y_i^\delta).$$

因此, 若在 SVRG 方法中将快照点取为最后的迭代点, 则得到用于求解线性病态逆问题的算法 2, 该算法已在 [9] 中的有限 $b\Lambda Q\Theta$

`iPLACEHOLDER_E NV_7 >`

SVRG 方法在求解形式如 (1.5) 的大规模优化问题中已被广泛分析, 且所有已建立的收敛结果均要求目标函数 f 强凸或误差估计以目标函数值形式给出。然而, 这些结果不适用于算法 2 处理病态问题, 因为对应的目标函数为残差 $f(x) = \frac{1}{2N} \|Ax - y^\delta\|^2$, 该函数不强凸, 且由于基础问题的病态性, 残差的误差估计不能直接推出迭代点的误差估计。因此, 需要新的理论分析来理解算法 2 在病态问题上的表现。与其他迭代正则化方法类似, 当算法 2 用于求解病态问题时, 表现出半收敛现象, 即迭代初期迭代点趋近于目标解, 随后随着迭代继续远离目标解。因此, 合理终止迭代对于产生可接受的近似解至关重要。基于偏差-方差分解, 文献 [9] 在 A 具有特殊结构时通过精细的谱理论论证给出了算法 2 的收敛分析。证明了当求解 $x^\dagger$ 满足 Hölder 源条件 $x^\dagger - x_0 = (A^*A)^\nu \omega$, 其中 $\omega \in X$, $\nu > 0$, 则对于先验选定的停止指标 n_δ , 可建立阶最优误差界关于 $x_{n_\delta}^\delta$ 。然而, [9] 中的收敛 $\Sigma X(f; w\Theta$

PLACEHOLDER_{ENV}₈ >

本文将针对 SVRG 用于求解线性病态问题提供一种完全不同且新颖的分析, 并消除上述所有缺陷。注意, 算法 2 中从 x_n^δ 定义 $x_{n,1}^\delta$ 是一步 Landweber 方法, 且不涉及随机性, 因为尽管选择了随机索引 $i_{n,0}$, 但 $g_{n,0}^\delta = g_n^\delta$ 。这与 $x_{n,k+1}^\delta$ 对于 $1 \leq k \leq m-1$ 的更新形成鲜明对比, 后者高度依赖随机选取的索引 $i_{n,k}$ 。因此, 合理的做法是修改算法 2, 将这两部分拆分并引入两个步长参数 γ_0 和 γ_1 。这导致了本文将考虑的算法 alg:SVRG。

PLACEHOLDER_{ENV}₉ >

注意, 一旦固定了 $x_0 \in X$ 、 m 、 γ_0 和 γ_1 , 算法 1 中的序列 $\{x_n^\delta\}$ 完全由样本路径 $\{i_{n,k} : n \geq 0, k = 0, \dots, m-1\}$ 决定; 改变样本路径将导致不同的迭代序列, 因此 $\{x_n^\delta\}$ 是随机序列。故此, 我们需要对算法 1 进行随机分析。对于任意整数 $n \geq 0$ 和 $k \in \{0, \dots, m-1\}$, 令 $\mathcal{F}_{n,k}$ 表示由随机变量 $i_{n',k'}$ 生成的 σ -代数, 其中 $(n', k') \in \{(n', k') : 0 \leq n' \leq n-1, 0 \leq k' \leq m-1\} \cup \{(n, k') : 0 \leq k' < k\}$ 。则 $\{\mathcal{F}_{n,k} : n \geq 0 \text{ 且 } k = 0, \dots, m-1\}$ 构成与算法 1 相适应的滤波族。我们还定义 $\mathcal{F}_n := \mathcal{F}_{n-1, m-1}$, $n \geq 1$ 。令 $\mathbb{E}$ 表示与此滤波族相关的期望, 见 [3]。塔式性质

$$\mathbb{E}[\mathbb{E}[\varphi | \mathcal{F}_{n,k}]] = \mathbb{E}[\varphi] \quad \text{对任意随机变量 } \varphi$$

将在分析中频繁使用。我们对算法 1 的分析基于变分方法。无需对求解 $x^\dagger$ 施加任何源条件, 我们证明当停止指标 n_δ 选择满足 $n_\delta \rightarrow \infty$ 且 $\delta^2 n_\delta \rightarrow 0$ (当 $\delta \rightarrow 0$) 时, 有 $\mathbb{E}[\|x_{n_\delta}^\delta - x^\dagger\|^2] \rightarrow 0$ 。当 $x^\dagger$ 满足基准源条件 $x^\dagger - x_0 = A^* \lambda^\dagger$, 其中 $\lambda^\dagger \in Y$, 则对于选择 $n_\delta \sim \delta^{-1}$ 的停止指标, 有收敛速率 $\mathbb{E}[\|x_{n_\delta}^\delta - x^\dagger\|^2] = O(\delta)$ 。与 [9] 中的结果形成鲜明对比的是, 我们的结果适用于一般有界线性算子 A , 不要求 A 具有特殊结构。此外, 我们的分析允许使用较大步长。特别地, 我们的收敛结果适用于

$$\gamma_0 = \frac{1}{\|A\|^2} \quad \text{和} \quad \gamma_1 = \beta \min \left\{ \frac{1}{L}, \frac{1}{\|A\|} \sqrt{\frac{N}{2mL}} \right\}$$

其中

$$0 < \beta < 1$$

, 且 $\text{PLACEHOLDER}_{ENV_1} 0 > S m = N \beta \gamma_0$ 和 γ_1 均为不依赖于 m, N 的常数, 且可远大于 [9] 中要求的步长。最后, 我们还考虑在算法 1 中采用 后验 停止规则, 证明不匹配原则几乎必然在有限步内终止迭代。这表明我们可将不匹配原则纳入算法 1, 使其成为可实际实现的线性病态逆问题求解方法。

本文结构如下。第 2 节首先证明关于算法 1 的稳定性结果。第 3 节推导在求解满足基准源条件时的收敛速率结果。基于第 2 和第 3 节的结果, 第 4 节通过密度论证证明不使用任何源条件的收敛结果。第 5 节考虑将不匹配原则纳入算法 1 并证明该方法几乎必然在有限步内终止。最后, 第 6 节提供多组数值结果以测试算法 1 的性能。

$$A_i x = y_i, \quad i = 1, \dots, N, \quad (1.1)$$

Algorithm 1 线性病态问题的 SVRG

input: update frequency m , initial guess x_0 , step-sizes γ_0 and γ_1 . Set $x_0^\delta := x_0$.
for $n = 0, 1, \dots$ **do**
 $g_n^\delta = A^*(Ax_n^\delta - y^\delta)$;
 $x_{n,0}^\delta = x_n^\delta - \gamma_0 g_n^\delta$;
 for $k = 0, \dots, m-1$ **do**
 pick $i_{n,k} \in \{1, \dots, N\}$ randomly via uniform distribution;
 $g_{n,k}^\delta = A_{i_{n,k}}^* A_{i_{n,k}} (x_{n,k}^\delta - x_n^\delta) + \frac{1}{N} g_n^\delta$;
 $x_{n,k+1}^\delta = x_{n,k}^\delta - \gamma_1 g_{n,k}^\delta$;
 end for
 $x_{n+1}^\delta = x_{n,m}^\delta$;
end

- 文献 [9] 中的分析是在对所求解的解满足 Hölder 型源条件的假设下进行的。这类源条件在实际应用中可能过于严格, 难以满足。是否有可能在不使用源条件的情况下建立收敛性结果?
- 文献 [9] 中的分析要求 m 足够大且步长 $\gamma > 0$ 足够小, 参见 [9, Theorem 2.1]; 但未给出选择 γ 的明确公式。文献 [9] 中的数值模拟采用了 $\gamma = O(1/m)$, 当 m 选择为 $m = \rho N$, 其中常数 $\rho > 0$ 且 N 很大时, γ 会非常小。使用较小步长会降低方法的收敛速度, 因此需要大量计算时间。我们能否开展一种允许使用较大步长的收敛性分析?
- 最严重的缺陷是文献 [9] 中的论证要求算子 A 具有分解结构 $A = \Sigma V^t$, 其中 Σ 是带有非负元素的对角矩阵, V 是列正交矩阵。不幸的是, 线性病态问题中出现的正向算子通常不具备这种结构。有人可能会认为, 通过奇异值分

解 $A = U\Sigma V^t$, 可将方程 $Ax = y$ 等价转化为 $\Sigma V^t x = U^t y$, 然后应用文献 [9] 中的收敛结果。然而, 获得奇异值分解需要大量计算时间, 甚至在问题规模极大时不可行。因此, 对于线性病态逆问题中 SVRG 的理解仍然存在很大空白。希望能够开展一种不依赖于文献 [9] 中假设的 A 的分解结构的收敛性分析。

$$x_{n+1}^\delta = x_n^\delta - \gamma A^*(Ax_n^\delta - y^\delta) \quad (1.2)$$

$$L := \max\{\|A_i\| : i = 1, \dots, N\}. \quad (1.3)$$

$$\|y^\delta - y\| := \left(\sum_{i=1}^N \|y_i^\delta - y_i\|^2 \right)^{1/2} \leq \delta, \quad (1.4)$$

Algorithm 2 用于线性病态问题的 SVRG [9]

input: update frequency m , initial guess x_0 , and step-size γ . Set $x_0^\delta := x_0$.
for $n = 0, 1, \dots$ **do**
 $g_n^\delta = \frac{1}{N} A^*(Ax_n^\delta - y^\delta)$; $x_{n,0}^\delta = x_n^\delta$;
 for $k = 0, \dots, m-1$ **do**
 pick $i_{n,k} \in \{1, \dots, N\}$ randomly via uniform distribution;
 $g_{n,k}^\delta = A_{i_{n,k}}^* A_{i_{n,k}} (x_{n,k}^\delta - x_n^\delta) + g_n^\delta$;
 $x_{n,k+1}^\delta = x_{n,k}^\delta - \gamma g_{n,k}^\delta$;
 end for
 $x_{n+1}^\delta = x_{n,m}^\delta$;
end

$$\min_{x \in X} \left\{ f(x) := \frac{1}{N} \sum_{i=1}^N f_i(x) \right\} \quad (1.5)$$

$$x_{n+1}^\delta = x_n^\delta - \gamma_n A_{i_n}^* (A_{i_n} x_n^\delta - y_{i_n}^\delta), \quad (1.6)$$

2. 稳定性估计

令 $\{x_n^\delta\}$ 由算法 1 定义。我们首先考虑对于每个固定的 n , 随着 $\delta \rightarrow 0$, x_n^δ 的行为。为此, 我们考虑算法 1 的对应版本, 其中带噪声的数据 y_i^δ 被精确数据 y_i 替代, 并且去除所有量上的上标 δ ; 例如, 我们将 x_n^δ 写为 x_n , $x_{n,k}^\delta$ 写为 $x_{n,k}$, 等等。根据 x_n^δ 和 x_n 的定义, 可以很容易看出, 对于任何固定的整数 $n \geq 0$, 沿任意样本路径均有 $\|x_n^\delta - x_n\| \rightarrow 0$ 当 $\delta \rightarrow 0$, 因此有 $\mathbb{E}[\|x_n^\delta - x_n\|^2] \rightarrow 0$ 当 $\delta \rightarrow 0$ 。以下结果给出了这类稳定性的定量估计。

Lemma 2.1. 设 L 如式 (1.3) 所定义。若 $\gamma_0 > 0$ 且 $\gamma_1 > 0$ 选取满足

$$1 - \gamma_1 L > 0 \quad \text{且} \quad 2\gamma_0 - \gamma_0^2 \|A\|^2 - \frac{2m\gamma_1^2 L}{N} > 0, \quad (2.1)$$

则对于所有整数 $n \geq 0$, 有

$$\mathbb{E} [\|x_n^\delta - x_n\|^2] \leq C_0 n \delta^2,$$

其中

$$C_0 := \frac{\gamma_0^2}{2\gamma_0 - \gamma_0^2 \|A\|^2 - 2m\gamma_1^2 L/N} + \frac{m\gamma_1^2}{2N(1 - \gamma_1 L)}.$$

证明. 我们采用归纳法。对于 $n = 0$, 结论显然成立, 因为 $x_0^\delta = x_0$ 。现假设对于某个整数 $n \geq 0$, 有 $\mathbb{E} [\|x_n^\delta - x_n\|^2] \leq C_0 n \delta^2$, 并证明该结论对 $n + 1$ 也成立。为此, 沿任意样本路径定义

$$u_n^\delta := x_n^\delta - x_n \quad \text{和} \quad u_{n,k}^\delta := x_{n,k}^\delta - x_{n,k}.$$

注意到

$$u_{n,0}^\delta = u_n^\delta - \gamma_0 A^*(Au_n^\delta - y^\delta + y).$$

因此

$$\begin{aligned} \|u_{n,0}^\delta\|^2 - \|u_n^\delta\|^2 &= -2\gamma_0 \langle u_n^\delta, A^*(Au_n^\delta - y^\delta + y) \rangle + \gamma_0^2 \|A^*(Au_n^\delta - y^\delta + y)\|^2 \\ &= -2\gamma_0 \langle Au_n^\delta, Au_n^\delta - y^\delta + y \rangle + \gamma_0^2 \|A^*(Au_n^\delta - y^\delta + y)\|^2 \\ &\leq -2\gamma_0 \|Au_n^\delta - y^\delta + y\|^2 - 2\gamma_0 \langle y^\delta - y, Au_n^\delta - y^\delta + y \rangle \\ &\quad + \gamma_0^2 \|A\|^2 \|Au_n^\delta - y^\delta + y\|^2 \\ &\leq -(2\gamma_0 - \gamma_0^2 \|A\|^2) \|Au_n^\delta - y^\delta + y\|^2 \\ &\quad + 2\gamma_0 \delta \|Au_n^\delta - y^\delta + y\|. \end{aligned} \quad (2.2)$$

接下来, 通过注意到

$$u_{n,k+1}^\delta = u_{n,k}^\delta - \gamma_1 \left(A_{i_{n,k}}^* A_{i_{n,k}} (u_{n,k}^\delta - u_n^\delta) + \frac{1}{N} A^*(Au_n^\delta - y^\delta + y) \right),$$

我们因此得到

$$\begin{aligned} \|u_{n,k+1}^\delta\|^2 - \|u_{n,k}^\delta\|^2 &= -2\gamma_1 \left\langle u_{n,k}^\delta, A_{i_{n,k}}^* A_{i_{n,k}} (u_{n,k}^\delta - u_n^\delta) + \frac{1}{N} A^*(Au_n^\delta - y^\delta + y) \right\rangle \\ &\quad + \gamma_1^2 \left\| A_{i_{n,k}}^* A_{i_{n,k}} (u_{n,k}^\delta - u_n^\delta) + \frac{1}{N} A^*(Au_n^\delta - y^\delta + y) \right\|^2. \end{aligned}$$

进而, 通过对条件 $\mathcal{F}_{n,k}$ 下取期望, 可以得到

$$\begin{aligned}
& \mathbb{E} [\|u_{n,k+1}^\delta\|^2 | \mathcal{F}_{n,k}] - \|u_{n,k}^\delta\|^2 \\
&= -\frac{2\gamma_1}{N} \sum_{i=1}^N \left\langle u_{n,k}^\delta, A_i^* A_i (u_{n,k}^\delta - u_n^\delta) + \frac{1}{N} A^* (Au_n^\delta - y^\delta + y) \right\rangle \\
&\quad + \frac{\gamma_1^2}{N} \sum_{i=1}^N \left\| A_i^* A_i (u_{n,k}^\delta - u_n^\delta) + \frac{1}{N} A^* (Au_n^\delta - y^\delta + y) \right\|^2 \\
&= -\frac{2\gamma_1}{N} \langle u_{n,k}^\delta, A^* (Au_{n,k}^\delta - y^\delta + y) \rangle \\
&\quad + \frac{\gamma_1^2}{N} \sum_{i=1}^N \left\| A_i^* A_i (u_{n,k}^\delta - u_n^\delta) + \frac{1}{N} A^* (Au_n^\delta - y^\delta + y) \right\|^2.
\end{aligned}$$

利用不等式 $\|a+b\|^2 \leq 2(\|a\|^2 + \|b\|^2)$ 和极化恒等式, 我们有

$$\begin{aligned}
& \mathbb{E} [\|u_{n,k+1}^\delta\|^2 | \mathcal{F}_{n,k}] - \|u_{n,k}^\delta\|^2 \\
&\leq -\frac{2\gamma_1}{N} \langle Au_{n,k}^\delta, Au_{n,k}^\delta - y^\delta + y \rangle + \frac{2\gamma_1^2}{N} \sum_{i=1}^N \|A_i^* (A_i u_{n,k}^\delta - y_i^\delta + y_i)\|^2 \\
&\quad + \frac{2\gamma_1^2}{N} \sum_{i=1}^N \left\| A_i^* (A_i u_n^\delta - y_i^\delta + y_i) - \frac{1}{N} A^* (Au_n^\delta - y^\delta + y) \right\|^2 \\
&= -\frac{2\gamma_1}{N} \|Au_{n,k}^\delta - y^\delta + y\|^2 - \frac{2\gamma_1}{N} \langle y^\delta - y, Au_{n,k}^\delta - y^\delta + y \rangle \\
&\quad + \frac{2\gamma_1^2}{N} \sum_{i=1}^N \|A_i^* (A_i u_{n,k}^\delta - y_i^\delta + y_i)\|^2 + \frac{2\gamma_1^2}{N} \sum_{i=1}^N \|A_i^* (A_i u_n^\delta - y_i^\delta + y_i)\|^2 \\
&\quad - \frac{4\gamma_1^2}{N^2} \sum_{i=1}^N \langle A_i^* (A_i u_n^\delta - y_i^\delta + y_i), A^* (Au_n^\delta - y^\delta + y) \rangle \\
&\quad + \frac{2\gamma_1^2}{N^2} \|A^* (Au_n^\delta - y^\delta + y)\|^2.
\end{aligned}$$

利用柯西-施瓦茨不等式, $\|y^\delta - y\| \leq \delta$ 以及 L 的定义, 我们得到

$$\begin{aligned}
& \mathbb{E} [\|u_{n,k+1}^\delta\|^2 | \mathcal{F}_{n,k}] - \|u_{n,k}^\delta\|^2 \\
&\leq -\frac{2\gamma_1}{N} \|Au_{n,k}^\delta - y^\delta + y\|^2 + \frac{2\gamma_1}{N} \delta \|Au_{n,k}^\delta - y^\delta + y\| \\
&\quad + \frac{2\gamma_1^2}{N} \sum_{i=1}^N \|A_i\|^2 \|A_i u_{n,k}^\delta - y_i^\delta + y_i\|^2 + \frac{2\gamma_1^2}{N} \sum_{i=1}^N \|A_i\|^2 \|A_i u_n^\delta - y_i^\delta + y_i\|^2 \\
&\quad - \frac{2\gamma_1^2}{N^2} \|A^* (Au_n^\delta - y^\delta + y)\|^2
\end{aligned}$$

$$\begin{aligned} &\leq -\frac{2\gamma_1(1-\gamma_1L)}{N}\|Au_{n,k}^\delta - y^\delta + y\|^2 + \frac{2\gamma_1}{N}\delta\|Au_{n,k}^\delta - y^\delta + y\| \\ &\quad + \frac{2\gamma_1^2L}{N}\|Au_n^\delta - y^\delta + y\|^2. \end{aligned}$$

鉴于不等式

$$\frac{2\gamma_1}{N}\delta\|Au_{n,k}^\delta - y^\delta + y\| \leq \frac{2\gamma_1(1-\gamma_1L)}{N}\|Au_{n,k}^\delta - y^\delta + y\|^2 + \frac{\gamma_1}{2N(1-\gamma_1L)}\delta^2,$$

我们进一步得到

$$\mathbb{E}[\|u_{n,k+1}^\delta\|^2|\mathcal{F}_{n,k}] - \|u_{n,k}^\delta\|^2 \leq \frac{\gamma_1\delta^2}{2N(1-\gamma_1L)} + \frac{2\gamma_1^2L}{N}\|Au_n^\delta - y^\delta + y\|^2.$$

因此

$$\mathbb{E}[\|u_{n,k+1}^\delta\|^2|\mathcal{F}_n] - \mathbb{E}[\|u_{n,k}^\delta\|^2|\mathcal{F}_n] \leq \frac{\gamma_1\delta^2}{2N(1-\gamma_1L)} + \frac{2\gamma_1^2L}{N}\|Au_n^\delta - y^\delta + y\|^2$$

对 k 从 0 到 $m-1$ 求和, 得到

$$\mathbb{E}[\|u_{n+1}^\delta\|^2|\mathcal{F}_n] - \|u_{n,0}^\delta\|^2 \leq \frac{m\gamma_1\delta^2}{2N(1-\gamma_1L)} + \frac{2m\gamma_1^2L}{N}\|Au_n^\delta - y^\delta + y\|^2.$$

结合式 (2.2), 可得

$$\begin{aligned} \mathbb{E}[\|u_{n+1}^\delta\|^2|\mathcal{F}_n] - \|u_n^\delta\|^2 &\leq -\left(2\gamma_0 - \gamma_0^2\|A\|^2 - \frac{2m\gamma_1^2L}{N}\right)\|Au_n^\delta - y^\delta + y\|^2 \\ &\quad + 2\gamma_0\delta\|Au_n^\delta - y^\delta + y\| + \frac{m\gamma_1\delta^2}{2N(1-\gamma_1L)}. \end{aligned}$$

利用不等式

$$\begin{aligned} 2\gamma_0\delta\|Au_n^\delta - y^\delta + y\| &\leq \left(2\gamma_0 - \gamma_0^2\|A\|^2 - \frac{2m\gamma_1^2L}{N}\right)\|Au_n^\delta - y^\delta + y\|^2 \\ &\quad + \frac{\gamma_0^2\delta^2}{2\gamma_0 - \gamma_0^2\|A\|^2 - 2m\gamma_1^2L/N} \end{aligned}$$

我们可以得出结论

$$\begin{aligned} &\mathbb{E}[\|u_{n+1}^\delta\|^2|\mathcal{F}_n] - \|u_n^\delta\|^2 \\ &\leq \left(\frac{\gamma_0^2}{2\gamma_0 - \gamma_0^2\|A\|^2 - 2m\gamma_1^2L/N} + \frac{m\gamma_1}{2N(1-\gamma_1L)}\right)\delta^2 = C_0\delta^2. \end{aligned}$$

对整体期望取值并利用归纳假设, 得到

$$\mathbb{E}[\|u_{n+1}^\delta\|^2] \leq \mathbb{E}[\|u_n^\delta\|^2] + C_0\delta^2 \leq C_0(n+1)\delta^2.$$

证毕。 $\square$

Remark 2.1. 可以很容易地看出, 如果我们选择 γ_0 和 γ_1 满足

$$\gamma_0 = \frac{\alpha}{\|A\|^2} \quad \text{和} \quad \gamma_1 = \beta \min \left\{ \frac{1}{L}, \frac{1}{\|A\|} \sqrt{\frac{(2-\alpha)\alpha N}{2mL}} \right\} \quad (2.3)$$

其中 $0 < \alpha < 2$ 且 $0 < \beta < 1$, 则 (2.1) 成立。

3. 收敛速度

本节中, 我们将在基准源条件下推导关于 $\mathbb{E}[\|x_n^\delta - x^\dagger\|^2]$ 的误差估计。

$$x^\dagger - x_0 = A^* \lambda^\dagger \quad \text{for some } \lambda^\dagger \in Y. \quad (3.1)$$

根据引理 2.1, 我们只需估计 $\mathbb{E}[\|x_n - x^\dagger\|^2]$ 。为此, 我们首先证明以下结果。

Lemma 3.1. 考虑算法 1, 假设 $\gamma_0 > 0$ 且 $\gamma_1 > 0$ 满足式 (2.1)。则有

$$\begin{aligned} \mathbb{E}[\|x_{n+1} - x^\dagger\|^2 | \mathcal{F}_n] - \|x_n - x^\dagger\|^2 &\leq -\frac{2\gamma_1(1-\gamma_1 L)}{N} \sum_{k=0}^{m-1} \mathbb{E}[\|Ax_{n,k} - y\|^2 | \mathcal{F}_n] \\ &\quad - \left(2\gamma_0 - \gamma_0^2 \|A\|^2 - \frac{2m\gamma_1^2 L}{N} \right) \|Ax_n - y\|^2 \end{aligned}$$

对所有整数 $n \geq 0$ 成立。

证明. 我们首先利用极化恒等式以及 $x_{n,k+1}$ 的定义写出

$$\begin{aligned} &\|x_{n,k+1} - x^\dagger\|^2 - \|x_{n,k} - x^\dagger\|^2 \\ &= 2\langle x_{n,k+1} - x_{n,k}, x_{n,k} - x^\dagger \rangle + \|x_{n,k+1} - x_{n,k}\|^2 \\ &= -2\gamma_1 \left\langle A_{i_{n,k}}^* A_{i_{n,k}}(x_{n,k} - x_n) + \frac{1}{N} A^*(Ax_n - y), x_{n,k} - x^\dagger \right\rangle \\ &\quad + \gamma_1^2 \left\| A_{i_{n,k}}^* A_{i_{n,k}}(x_{n,k} - x_n) + \frac{1}{N} A^*(Ax_n - y) \right\|^2. \end{aligned}$$

对 $\mathcal{F}_{n,k}$ 取条件期望得到

$$\begin{aligned} &\mathbb{E}[\|x_{n,k+1} - x^\dagger\|^2 | \mathcal{F}_{n,k}] - \|x_{n,k} - x^\dagger\|^2 \\ &= -\frac{2\gamma_1}{N} \sum_{i=1}^N \left\langle A_i^* A_i(x_{n,k} - x_n) + \frac{1}{N} A^*(Ax_n - y), x_{n,k} - x^\dagger \right\rangle \\ &\quad + \frac{\gamma_1^2}{N} \sum_{i=1}^N \left\| A_i^* A_i(x_{n,k} - x_n) + \frac{1}{N} A^*(Ax_n - y) \right\|^2 \\ &= -\frac{2\gamma_1}{N} \langle A^*(Ax_{n,k} - y), x_{n,k} - x^\dagger \rangle \\ &\quad + \frac{\gamma_1^2}{N} \sum_{i=1}^N \left\| A_i^* A_i(x_{n,k} - x_n) + \frac{1}{N} A^*(Ax_n - y) \right\|^2. \end{aligned}$$

利用不等式 $\|a + b\|^2 \leq 2(\|a\|^2 + \|b\|^2)$ 以及极化恒等式, 我们有

$$\begin{aligned}
& \mathbb{E} [\|x_{n,k+1} - x^\dagger\|^2 | \mathcal{F}_{n,k}] - \|x_{n,k} - x^\dagger\|^2 \\
& \leq -\frac{2\gamma_1}{N} \|Ax_{n,k} - y\|^2 + \frac{2\gamma_1^2}{N} \sum_{i=1}^N \|A_i^*(A_i x_{n,k} - y_i)\|^2 \\
& \quad + \frac{2\gamma_1^2}{N} \sum_{i=1}^N \left\| A_i^*(A_i x_n - y_i) - \frac{1}{N} A^*(Ax_n - y) \right\|^2 \\
& = -\frac{2\gamma_1}{N} \|Ax_{n,k} - y\|^2 + \frac{2\gamma_1^2}{N} \sum_{i=1}^N \|A_i^*(A_i x_{n,k} - y_i)\|^2 + \frac{2\gamma_1^2}{N} \sum_{i=1}^N \|A_i^*(A_i x_n - y_i)\|^2 \\
& \quad - \frac{4\gamma_1^2}{N^2} \sum_{i=1}^N \langle A_i^*(A_i x_n - y_i), A^*(Ax_n - y) \rangle + \frac{2\gamma_1^2}{N^2} \|A^*(Ax_n - y)\|^2 \\
& \leq -\frac{2\gamma_1}{N} \|Ax_{n,k} - y\|^2 + \frac{2\gamma_1^2}{N} \sum_{i=1}^N \|A_i\|^2 (\|A_i x_{n,k} - y_i\|^2 + \|A_i x_n - y_i\|^2) \\
& \quad - \frac{2\gamma_1^2}{N^2} \|A^*(Ax_n - y)\|^2 \\
& \leq -\frac{1}{N} (2\gamma_1 - 2\gamma_1^2 L) \|Ax_{n,k} - y\|^2 + \frac{2\gamma_1^2 L}{N} \|Ax_n - y\|^2.
\end{aligned}$$

因此, 利用条件期望的塔式性质, 我们可以得到

$$\begin{aligned}
& \mathbb{E} [\|x_{n,k+1} - x^\dagger\|^2 | \mathcal{F}_n] - \mathbb{E} [\|x_{n,k} - x^\dagger\|^2 | \mathcal{F}_n] \\
& \leq -\frac{1}{N} (2\gamma_1 - 2\gamma_1^2 L) \mathbb{E} [\|Ax_{n,k} - y\|^2 | \mathcal{F}_n] + \frac{2\gamma_1^2 L}{N} \|Ax_n - y\|^2.
\end{aligned}$$

对 k 从 0 到 $m-1$ 累加该不等式, 注意到 $x_{n+1} = x_{n,m}$ 且 $\mathbb{E}[\|x_{n,0} - x^\dagger\|^2 | \mathcal{F}_n] = \|x_{n,0} - x^\dagger\|^2$, 我们得到

$$\begin{aligned}
\mathbb{E} [\|x_{n+1} - x^\dagger\|^2 | \mathcal{F}_n] - \|x_{n,0} - x^\dagger\|^2 & \leq -\frac{2\gamma_1(1 - \gamma_1 L)}{N} \sum_{k=0}^{m-1} \mathbb{E} [\|Ax_{n,k} - y\|^2 | \mathcal{F}_n] \\
& \quad + \frac{2m\gamma_1^2 L}{N} \|Ax_n - y\|^2. \tag{3.2}
\end{aligned}$$

接下来, 根据 $x_{n,0}$ 的定义, 我们有

$$\begin{aligned}
\|x_{n,0} - x^\dagger\|^2 - \|x_n - x^\dagger\|^2 & = 2\langle x_{n,0} - x_n, x_n - x^\dagger \rangle + \|x_{n,0} - x_n\|^2 \\
& = -2\gamma_0 \langle A^*(Ax_n - y), x_n - x^\dagger \rangle + \gamma_0^2 \|A^*(Ax_n - y)\|^2 \\
& \leq -(2\gamma_0 - \gamma_0^2 \|A\|^2) \|Ax_n - y\|^2.
\end{aligned}$$

将此不等式与 (3.2) 相加, 即完成证明. $\square$

为了进一步推进, 我们需要对带有精确数据的算法 1 给出等价的表达式. 从算法 1 的定义可知, $x_n, x_{n,k} \in x_0 + \text{Ran}(A^*)$, 因此存在 $\lambda_n, \lambda_{n,k} \in Y$ 使得 $x_n =$

$x_0 + A^* \lambda_n$ 和 $x_{n,k} = x_0 + A^* \lambda_{n,k}$ 。我们需要一个构造 λ_n 和 $\lambda_{n,k}$ 的过程, 并利用它们达到我们的目的。这启发我们引入以下算法 3, 它显然与带有精确数据的算法 1 等价, 即算法 3 生成的随机序列 $\{x_n\}$ 和 $\{x_{n,k}\}$ 与带有精确数据的算法 1 生成的完全相同。

Algorithm 3

input: update frequency m , initial guess $\lambda_0 = 0 \in Y$, $x_0 \in X$, step-sizes γ_0, γ_1 .
for $n = 0, 1, \dots$ **do**
 $\mu_n = Ax_n - y$;
 $\lambda_{n,0} = \lambda_n - \gamma_0 \mu_n$; $x_{n,0} = x_0 + A^* \lambda_{n,0}$;
 for $k = 0, \dots, m-1$ **do**
 pick $i_{n,k} \in \{1, \dots, N\}$ randomly via uniform distribution;
 $\mu_{n,k} = (0, \dots, 0, A_{i_{n,k}}(x_{n,k} - x_n), 0, \dots, 0) + \frac{1}{N} \mu_n$;
 $\lambda_{n,k+1} = \lambda_{n,k} - \gamma_1 \mu_{n,k}$; $x_{n,k+1} = x_0 + A^* \lambda_{n,k+1}$;
 end for
 $\lambda_{n+1} = \lambda_{n,m}$; $x_{n+1} = x_0 + A^* \lambda_{n+1}$;
end

在算法 3 的表达式中, $(0, \dots, 0, A_{i_{n,k}}(x_{n,k} - x_n), 0, \dots, 0)$ 表示 Y 中的元素, 其第 $i_{n,k}$ 个分量为 $A_{i_{n,k}}(x_{n,k} - x_n)$, 其他分量为 0。

Lemma 3.2. 假设源条件 (3.1) 成立。对于任意整数 $n \geq 0$, 有

$$\begin{aligned} \mathbb{E}[\|\lambda_{n+1} - \lambda^\dagger\|^2] - \mathbb{E}[\|\lambda_n - \lambda^\dagger\|^2] &\leq -2\gamma_0 \mathbb{E}[\|x_n - x^\dagger\|^2] - \frac{2\gamma_1}{N} \sum_{k=0}^{m-1} \mathbb{E}[\|x_{n,k} - x^\dagger\|^2] \\ &\quad + \frac{2\gamma_1^2}{N} \sum_{k=0}^{m-1} \mathbb{E}[\|Ax_{n,k} - y\|^2] \\ &\quad + \left(\gamma_0^2 + \frac{2m\gamma_1^2}{N} \right) \mathbb{E}[\|Ax_n - y\|^2] \end{aligned}$$

证明. 由 $\lambda_{n,0}$ 的定义, $x_n = x_0 + A^* \lambda_n$, 以及 (3.1), 我们首先有

$$\begin{aligned} \|\lambda_{n,0} - \lambda^\dagger\|^2 - \|\lambda_n - \lambda^\dagger\|^2 &= 2\langle \lambda_{n,0} - \lambda_n, \lambda_n - \lambda^\dagger \rangle + \|\lambda_{n,0} - \lambda_n\|^2 \\ &= -2\gamma_0 \langle Ax_n - y, \lambda_n - \lambda^\dagger \rangle + \gamma_0^2 \|Ax_n - y\|^2 \\ &= -2\gamma_0 \langle x_n - x^\dagger, A^*(\lambda_n - \lambda^\dagger) \rangle + \gamma_0^2 \|Ax_n - y\|^2 \\ &= -2\gamma_0 \|x_n - x^\dagger\|^2 + \gamma_0^2 \|Ax_n - y\|^2. \end{aligned} \quad (3.3)$$

接着利用 $\lambda_{n,k+1}$ 的定义, 我们得到

$$\begin{aligned} \|\lambda_{n,k+1} - \lambda^\dagger\|^2 - \|\lambda_{n,k} - \lambda^\dagger\|^2 &= 2\langle \lambda_{n,k+1} - \lambda_{n,k}, \lambda_{n,k} - \lambda^\dagger \rangle + \|\lambda_{n,k+1} - \lambda_{n,k}\|^2 \\ &= -2\gamma_1 \langle \mu_{n,k}, \lambda_{n,k} - \lambda^\dagger \rangle + \gamma_1^2 \|\mu_{n,k}\|^2 \\ &= -2\gamma_1 \langle A_{i_{n,k}}(x_{n,k} - x_n), (\lambda_{n,k} - \lambda^\dagger)_{i_{n,k}} \rangle \end{aligned}$$

$$- \frac{2\gamma_1}{N} \langle \mu_n, \lambda_{n,k} - \lambda^\dagger \rangle + \gamma_1^2 \|\mu_{n,k}\|^2,$$

其中用 $(\lambda_{n,k} - \lambda^\dagger)_i$ 表示 $\lambda_{n,k} - \lambda^\dagger$ 的第 i 个分量。因此，对 $\mathcal{F}_{n,k}$ 取条件期望，并利用 $x_{n,k} = x_0 + A^* \lambda_{n,k}$ 和 (3.1)，我们可以得到

$$\begin{aligned} & \mathbb{E}[\|\lambda_{n,k+1} - \lambda^\dagger\|^2 | \mathcal{F}_{n,k}] - \|\lambda_{n,k} - \lambda^\dagger\|^2 \\ &= -\frac{2\gamma_1}{N} \sum_{i=1}^N \langle A_i(x_{n,k} - x_n), (\lambda_{n,k} - \lambda^\dagger)_i \rangle - \frac{2\gamma_1}{N} \langle \mu_n, \lambda_{n,k} - \lambda^\dagger \rangle + \gamma_1^2 \mathbb{E}[\|\mu_{n,k}\|^2 | \mathcal{F}_{n,k}] \\ &= -\frac{2\gamma_1}{N} \langle A(x_{n,k} - x_n), \lambda_{n,k} - \lambda^\dagger \rangle - \frac{2\gamma_1}{N} \langle Ax_n - y, \lambda_{n,k} - \lambda^\dagger \rangle + \gamma_1^2 \mathbb{E}[\|\mu_{n,k}\|^2 | \mathcal{F}_{n,k}] \\ &= -\frac{2\gamma_1}{N} \langle Ax_{n,k} - y, \lambda_{n,k} - \lambda^\dagger \rangle + \gamma_1^2 \mathbb{E}[\|\mu_{n,k}\|^2 | \mathcal{F}_{n,k}] \\ &= -\frac{2\gamma_1}{N} \langle x_{n,k} - x^\dagger, A^*(\lambda_{n,k} - \lambda^\dagger) \rangle + \gamma_1^2 \mathbb{E}[\|\mu_{n,k}\|^2 | \mathcal{F}_{n,k}] \\ &= -\frac{2\gamma_1}{N} \|x_{n,k} - x^\dagger\|^2 + \gamma_1^2 \mathbb{E}[\|\mu_{n,k}\|^2 | \mathcal{F}_{n,k}]. \end{aligned}$$

接下来需要估计 $\mathbb{E}[\|\mu_{n,k}\|^2 | \mathcal{F}_{n,k}]$ 。根据 $\mu_{n,k}$ 的定义有

$$\begin{aligned} \|\mu_{n,k}\|^2 &= \frac{1}{N^2} \sum_{j \neq i_{n,k}} \|A_j x_n - y_j\|^2 \\ &\quad + \left\| (A_{i_{n,k}} x_{n,k} - y_{i_{n,k}}) - \frac{N-1}{N} (A_{i_{n,k}} x_n - y_{i_{n,k}}) \right\|^2. \end{aligned}$$

由此

$$\begin{aligned} & \mathbb{E}[\|\mu_{n,k}\|^2 | \mathcal{F}_{n,k}] \\ &= \frac{1}{N^3} \sum_{i=1}^N \sum_{j \neq i} \|A_j x_n - y_j\|^2 + \frac{1}{N} \sum_{i=1}^N \left\| (A_i x_{n,k} - y_i) - \frac{N-1}{N} (A_i x_n - y_i) \right\|^2 \\ &\leq \frac{N-1}{N^3} \sum_{i=1}^N \|A_i x_n - y_i\|^2 + \frac{2}{N} \sum_{i=1}^N \|A_i x_{n,k} - y_i\|^2 \\ &\quad + \frac{2}{N} \left(\frac{N-1}{N} \right)^2 \sum_{i=1}^N \|A_i x_n - y_i\|^2 \\ &\leq \frac{2}{N} \|Ax_n - y\|^2 + \frac{2}{N} \|Ax_{n,k} - y\|^2 \end{aligned}$$

因此

$$\begin{aligned} & \mathbb{E}[\|\lambda_{n,k+1} - \lambda^\dagger\|^2 | \mathcal{F}_{n,k}] - \|\lambda_{n,k} - \lambda^\dagger\|^2 \\ &\leq -\frac{2\gamma_1}{N} \|x_{n,k} - x^\dagger\|^2 + \frac{2\gamma_1^2}{N} \|Ax_{n,k} - y\|^2 + \frac{2\gamma_1^2}{N} \|Ax_n - y\|^2 \end{aligned}$$

故

$$\begin{aligned} & \mathbb{E}[\|\lambda_{n,k+1} - \lambda^\dagger\|^2 | \mathcal{F}_n] - \mathbb{E}[\|\lambda_{n,k} - \lambda^\dagger\|^2 | \mathcal{F}_n] \\ & \leq -\frac{2\gamma_1}{N} \mathbb{E}[\|x_{n,k} - x^\dagger\|^2 | \mathcal{F}_n] + \frac{2\gamma_1^2}{N} \mathbb{E}[\|Ax_{n,k} - y\|^2 | \mathcal{F}_n] + \frac{2\gamma_1^2}{N} \|Ax_n - y\|^2 \end{aligned}$$

对 k 从 0 累加至 $m-1$ ，再加上 (3.3)，我们得到

$$\begin{aligned} \mathbb{E}[\|\lambda_{n+1} - \lambda^\dagger\|^2 | \mathcal{F}_n] - \|\lambda_n - \lambda^\dagger\|^2 & \leq -2\gamma_0 \|x_n - x^\dagger\|^2 - \frac{2\gamma_1}{N} \sum_{k=0}^{m-1} \mathbb{E}[\|x_{n,k} - x^\dagger\|^2 | \mathcal{F}_n] \\ & \quad + \frac{2\gamma_1^2}{N} \sum_{k=0}^{m-1} \mathbb{E}[\|Ax_{n,k} - y\|^2 | \mathcal{F}_n] \\ & \quad + \left(\gamma_0^2 + \frac{2m\gamma_1^2}{N} \right) \|Ax_n - y\|^2 \end{aligned}$$

取满期望后，即得所需结果。 $\square$

Lemma 3.3. 考虑带有精确数据的算法 1，并假设 $\gamma_0 > 0$ 和 $\gamma_1 > 0$ 的选取满足不等式 (2.1)。如果 $x^\dagger$ 满足源条件 (3.1)，则对于所有整数 $n \geq 0$ ，有

$$\mathbb{E}[\|x_n - x^\dagger\|^2] \leq \frac{\|x_0 - x^\dagger\|^2 + \eta \|\lambda^\dagger\|^2}{2\gamma_0 \eta (n+1)}$$

其中

$$\eta := \min \left\{ \frac{1 - \gamma_1 L}{\gamma_1}, \frac{2\gamma_0 - \gamma_0^2 \|A\|^2 - 2m\gamma_1^2 L/N}{\gamma_0^2 + 2m\gamma_1^2/N} \right\}.$$

证明. 根据引理 3.1，我们有

$$\begin{aligned} \mathbb{E}[\|x_{n+1} - x^\dagger\|^2] - \mathbb{E}[\|x_n - x^\dagger\|^2] & \leq -\left(2\gamma_0 - \gamma_0^2 \|A\|^2 - \frac{2m\gamma_1^2 L}{N}\right) \mathbb{E}[\|Ax_n - y\|^2] \\ & \quad - \frac{2\gamma_1(1 - \gamma_1 L)}{N} \sum_{k=0}^{m-1} \mathbb{E}[\|Ax_{n,k} - y\|^2]. \end{aligned} \quad (3.4)$$

考虑序列

$$\Delta_n := \|x_n - x^\dagger\|^2 + \eta \|\lambda_n - \lambda^\dagger\|^2, \quad n = 0, 1, \dots$$

结合 (3.4) 和引理 3.2，可得

$$\begin{aligned} \mathbb{E}[\Delta_{n+1}] - \mathbb{E}[\Delta_n] & \leq -2\gamma_0 \eta \mathbb{E}[\|x_n - x^\dagger\|^2] - \frac{2\gamma_1 \eta}{N} \sum_{k=0}^m \mathbb{E}[\|x_{n,k} - x^\dagger\|^2] \\ & \leq -2\gamma_0 \eta \mathbb{E}[\|x_n - x^\dagger\|^2]. \end{aligned}$$

因此

$$2\gamma_0 \eta \sum_{l=0}^n \mathbb{E}[\|x_l - x^\dagger\|^2] \leq \mathbb{E}[\Delta_0] = \Delta_0.$$

由于 (3.4) 和 (2.1) 表明 $\mathbb{E}[\|x_l - x^\dagger\|]$ 单调递减, 我们因此有

$$2\gamma_0\eta(n+1)\mathbb{E}[\|x_n - x^\dagger\|^2] \leq \Delta_0$$

这即推出了所需结果。 $\square$

Theorem 3.4. 考虑算法 1, 其中 $\gamma_0 > 0$ 和 $\gamma_1 > 0$ 的选择满足条件 (2.1)。假设 $x^\dagger$ 满足源条件 (3.1)。如果整数 n_δ 的选择满足 $n_\delta \sim \delta^{-1}$, 则有

$$\mathbb{E}[\|x_{n_\delta}^\delta - x^\dagger\|^2] \leq C_1\delta,$$

其中 C_1 是一个常数, 仅依赖于 γ_0 、 γ_1 、 $\|A\|$ 、 L 、比例 m/N 、 $\|x_0 - x^\dagger\|$ 和 $\|\lambda^\dagger\|$ 。

证明. 由三角不等式, 有

$$\|x_n^\delta - x^\dagger\|^2 \leq (\|x_n^\delta - x_n\| + \|x_n - x^\dagger\|)^2 \leq 2\|x_n^\delta - x_n\|^2 + 2\|x_n - x^\dagger\|^2.$$

因此

$$\mathbb{E}[\|x_n^\delta - x^\dagger\|^2] \leq 2\mathbb{E}[\|x_n^\delta - x_n\|^2] + 2\mathbb{E}[\|x_n - x^\dagger\|^2].$$

由引理 3.3 和引理 2.1, 我们接着得到

$$\mathbb{E}[\|x_n^\delta - x^\dagger\|^2] \leq \frac{\|x_0 - x^\dagger\|^2 + \eta\|\lambda^\dagger\|^2}{2\gamma_0\eta(n+1)} + C_0n\delta^2$$

对所有整数 $n \geq 0$ 均成立。选择 $n_\delta \sim \delta^{-1}$, 即可得到所需收敛速度。 $\square$

4. 收敛性

在定理 3.4 中, 我们已经建立了当 x_0 -最小范数解 $x^\dagger$ 满足源条件 (3.1) 时, 算法 1 的收敛速率结果。该源条件在实际应用中可能过于严格, 难以满足。因此, 有必要建立算法 1 在不对 $x^\dagger$ 施加任何源条件情况下的收敛性结果。考虑到引理 2.1 中给出的稳定性估计, 我们将通过证明 $\mathbb{E}[\|x_n - x^\dagger\|^2] \rightarrow 0$ 当 $n \rightarrow \infty$ 时, 来达到目标。我们将采用文献 [10, 11] 中提出的扰动论证方法。具体而言, 作为 x_0 -最小范数解, 有 $x^\dagger - x_0 \in \text{Null}(A)^\perp = \overline{\text{Ran}(A^*)}$, 因此我们可以选择 $\hat{x}_0 \in X$, 使其距离 x_0 任意接近, 且满足 $x^\dagger - \hat{x}_0 \in \text{Ran}(A^*)$ 。然后, 我们用算法 1 定义 $\{\hat{x}_n, \hat{x}_{n,k}\}$, 数据为精确数据, 且初始猜测 x_0 替换为 $\hat{x}_0$ 。我们将通过对 $\mathbb{E}[\|\hat{x}_n - x^\dagger\|^2]$ 和 $\mathbb{E}[\|x_n - \hat{x}_n\|^2]$ 的估计, 来证明 $\mathbb{E}[\|x_n - x^\dagger\|^2] \rightarrow 0$ 当 $n \rightarrow \infty$ 。

对于 $\mathbb{E}[\|\hat{x}_n - x^\dagger\|^2]$, 我们可以将引理 3.3 证明中的相同论证应用于序列 $\{\hat{x}_n\}$, 从而得到以下结果。

`PLACEHOLDERENV47`

接下来我们推导 $\mathbb{E}[\|x_n - \hat{x}_n\|^2]$ 关于 $\|x_0 - \hat{x}_0\|^2$ 的估计。下述稳定性结果说明了 x_n 关于初始猜测 x_0 扰动的稳定性。

证明. 令 $z_n := x_n - \hat{x}_n$, $z_{n,k} = x_{n,k} - \hat{x}_{n,k}$ 。由 $\{x_n, x_{n,k}\}$ 和 $\{\hat{x}_n, \hat{x}_{n,k}\}$ 的定义, 我们有

对所有 $n = 0, 1, \dots$ 和 $k = 0, \dots, m-1$ 均成立。 $d < \text{PLACEHOLDER}_{ENV_5}1 >$ 以及 $\text{PLACEHOLDER}_{ENV_5}2 >$ 由此可得 $\text{PLACEHOLDER}_{ENV_5}3 >$ $(\|a\| + \|b\|)^2 \leq 2(\|a\|^2 + \|b\|^2) \leq \text{PLACEHOLDER}_{ENV_5}4 > 1/L(1-\gamma_1) \leq \text{PLACEHOLDER}_{ENV_5}5 > d < \text{PLACEHOLDER}_{ENV_5}6 > k0$

0

m-1B0

$$\mathbb{E}[\|z_{n+1}\|^2 | \mathcal{F}_n] - \|z_{n,0}\|^2 \leq \frac{2m\gamma_1^2 L}{N} \|Az_n\|^2.$$

结合式 (2.11), 得到 $\mathbb{E}[\|z_{n+1}\|^2] \leq \mathbb{E}[\|z_n\|^2]$. 递归使用该不等式, 我们得到 $\mathbb{E}[\|z_n\|^2] \leq \|z_0\|^2 = \|x_0 - \hat{x}_0\|^2$. 证毕。□

基于引理 4.3 和引理 4.4, 我们现在可以证明带有精确数据的算法 1 收敛性。

Theorem 4.1. 考虑由算法 1 使用精确数据定义的序列 $\{x_n\}$ 。假设 $\gamma_0 > 0$ 和 $\gamma_1 > 0$ 被选取使得式 (2.1) 成立。设 $x^\dagger$ 表示方程 (1.1) 的唯一的以 x_0 为基准的最小范数解。那么

$$\lim_{n \rightarrow \infty} \mathbb{E}[\|x_n - x^\dagger\|^2] = 0.$$

证明. 由于 $x^\dagger$ 是方程 (1.1) 的 x_0 -最小范数解, 故有 $x^\dagger - x_0 \in \overline{\text{Ran}(A^*)}$ 。因此, 对任意 $\varepsilon > 0$, 我们可以找到 $\hat{x}_0 \in X$, 使得 $\|x_0 - \hat{x}_0\| < \varepsilon$ 且 $x^\dagger - \hat{x}_0 \in \text{Ran}(A^*)$ 。定义 $\{\hat{x}_n\}$ 为使用精确数据且初始点为 $\hat{x}_0$ 的算法 1 生成的序列。由引理 4.4 可得

$$\mathbb{E}[\|x_n - \hat{x}_n\|^2] \leq \|x_0 - \hat{x}_0\|^2 < \varepsilon^2.$$

此外, 由引理 4.3 有

$$\mathbb{E}[\|\hat{x}_n - x^\dagger\|^2] \leq C(n+1)^{-1}$$

其中常数 $C \leq \varepsilon$, 但与 n 无关。由 $\limsup_{n \rightarrow \infty} \mathbb{E}[\|x_n - x^\dagger\|^2] \leq 2\varepsilon^2$ 。任意 $\varepsilon > 0$, 故必有 $\mathbb{E}[\|x_n - x^\dagger\|^2] \rightarrow 0$ 当 $n \rightarrow \infty$ 。□

利用定理 4.1 和引理 2.1, 我们现准备证明算法 1 在 *itapriori* 主要收敛结果。

$\text{PLACEHOLDER}_{ENV_6}1 >$

首先有

$$\mathbb{E}[\|x_{n_\delta}^\delta - x^\dagger\|^2] \leq 2\mathbb{E}[\|x_{n_\delta}^\delta - x_{n_\delta}\|^2] + 2\mathbb{E}[\|x_{n_\delta} - x^\dagger\|^2].$$

由于 $n_\delta \rightarrow \infty$, 利用定理 4.1 可得

$$\mathbb{E}[\|x_{n_\delta} - x^\dagger\|^2] \rightarrow 0 \quad \text{当 } \delta \rightarrow 0.$$

利用引理 2.1 及条件 $\delta^2 n_\delta \rightarrow 0$, 还有

$$\mathbb{E}[\|x_{n_\delta}^\delta - x_{n_\delta}\|^2] \leq C_0 \delta^2 n_\delta \rightarrow 0 \quad \text{当 } \delta \rightarrow 0.$$

因此有 $\mathbb{E}[\|x_{n_\delta}^\delta - x^\dagger\|^2] \rightarrow 0$ 当 $\delta \rightarrow 0$ 。

$$z_{n,k+1} = z_{n,k} - \gamma_1 A_{i_{n,k}}^* A_{i_{n,k}} (z_{n,k} - z_n) - \frac{\gamma_1}{N} A^* A z_n$$

Theorem 4.2. 考虑算法 1, 其中 $\gamma_0 > 0$ 和 $\gamma_1 > 0$ 的选择满足 (2.1)。令 $x^\dagger$ 表示 (1.1) 的唯一的 x_0 -最小范数解。则对于整数 n_δ , 当 $\delta \rightarrow 0$ 时满足 $n_\delta \rightarrow \infty$ 且 $\delta^2 n_\delta \rightarrow 0$, 有

$$\mathbb{E}[\|x_{n_\delta}^\delta - x^\dagger\|^2] \rightarrow 0 \quad \text{当 } \delta \rightarrow 0 \text{ 时}.$$

$$\begin{aligned} \|z_{n,0}\|^2 &= \|z_n\|^2 - 2\gamma_0 \langle z_n, A^* A z_n \rangle + \gamma_0^2 \|A^* A z_n\|^2 \\ &= \|z_n\|^2 - 2\gamma_0 \|A z_n\|^2 + \gamma_0^2 \|A^* A z_n\|^2 \\ &\leq \|z_n\|^2 - (2\gamma_0 - \gamma_0^2 \|A\|^2) \|A z_n\|^2 \end{aligned} \quad (4.1)$$

$$\begin{aligned} \mathbb{E}[\|z_{n,k+1}\|^2 | \mathcal{F}_{n,k}] - \|z_{n,k}\|^2 &= -\frac{2\gamma_1}{N} \sum_{i=1}^N \left\langle z_{n,k}, A_i^* A_i (z_{n,k} - z_n) + \frac{1}{N} A^* A z_n \right\rangle \\ &\quad + \frac{\gamma_1^2}{N} \sum_{i=1}^N \left\| A_i^* A_i (z_{n,k} - z_n) + \frac{1}{N} A^* A z_n \right\|^2 \\ &= -\frac{2\gamma_1}{N} \langle z_{n,k}, A^* A z_{n,k} \rangle \\ &\quad + \frac{\gamma_1^2}{N} \sum_{i=1}^N \left\| A_i^* A_i (z_{n,k} - z_n) + \frac{1}{N} A^* A z_n \right\|^2. \end{aligned}$$

$$\mathbb{E}[\|z_{n,k+1}\|^2 | \mathcal{F}_n] - \mathbb{E}[\|z_{n,k}\|^2 | \mathcal{F}_n] \leq \frac{2\gamma_1^2 L}{N} \|A z_n\|^2.$$

$$\begin{aligned} \mathbb{E}[\|z_{n,k+1}\|^2 | \mathcal{F}_{n,k}] - \|z_{n,k}\|^2 &\leq -\frac{2\gamma_1}{N} \|A z_{n,k}\|^2 + \frac{2\gamma_1^2}{N} \sum_{i=1}^N \|A_i^* A_i z_{n,k}\|^2 \\ &\quad + \frac{2\gamma_1^2}{N} \sum_{i=1}^N \left\| A_i^* A_i z_n - \frac{1}{N} A^* A z_n \right\|^2 \\ &= -\frac{2\gamma_1}{N} \|A z_{n,k}\|^2 + \frac{2\gamma_1^2}{N} \sum_{i=1}^N \|A_i^* A_i z_{n,k}\|^2 \\ &\quad + \frac{2\gamma_1^2}{N} \sum_{i=1}^N \|A_i^* A_i z_n\|^2 + \frac{2\gamma_1^2}{N^2} \|A^* A z_n\|^2 \\ &\quad - \frac{4\gamma_1^2}{N^2} \sum_{i=1}^N \langle A_i^* A_i z_n, A^* A z_n \rangle \end{aligned}$$

$$\begin{aligned}
&\leq -\frac{2\gamma_1}{N} \|Az_{n,k}\|^2 + \frac{2\gamma_1^2}{N} \sum_{i=1}^N \|A_i\|^2 \|A_i z_{n,k}\|^2 \\
&\quad + \frac{2\gamma_1^2}{N} \sum_{i=1}^N \|A_i\|^2 \|A_i z_n\|^2 - \frac{2\gamma_1^2}{N^2} \|A^* A z_n\|^2.
\end{aligned}$$

$$\begin{aligned}
&\mathbb{E}[\|z_{n,k+1}\|^2 | \mathcal{F}_{n,k}] - \|z_{n,k}\|^2 \\
&\leq -\frac{2\gamma_1(1-\gamma_1 L)}{N} \|Az_{n,k}\|^2 + \frac{2\gamma_1^2 L}{N} \|Az_n\|^2 \leq \frac{2\gamma_1^2 L}{N} \|Az_n\|^2.
\end{aligned}$$

Lemma 4.3. 考虑由算法 1 定义的序列 $\{\hat{x}_n\}$, 其使用精确数据且将 x_0 替换为 $\hat{x}_0$, 其中 $\hat{x}_0$ 的选择满足 $x^\dagger - \hat{x}_0 \in \text{Ran}(A^*)$ 。假设 $\gamma_0 > 0$ 和 $\gamma_1 > 0$ 被选取使得 (2.1) 成立。则对任意整数 $n \geq 0$, 有

$$\mathbb{E}[\|\hat{x}_n - x^\dagger\|^2] \leq \frac{\|\hat{x}_0 - x^\dagger\|^2 + \eta \|\hat{\lambda}^\dagger\|^2}{2\gamma_0 \eta (n+1)},$$

其中 $\eta > 0$ 是引理 3.3 中定义的常数, 且 $\hat{\lambda}^\dagger \in Y$ 满足 $x^\dagger - \hat{x}_0 = A^* \hat{\lambda}^\dagger$ 。

$$z_{n,0} = z_n - \gamma_0 A^* A z_n$$

Lemma 4.4. 假设 $\gamma_0 > 0$ 和 $\gamma_1 > 0$ 被选择使得 (2.1) 得到满足。则对于所有整数 $n \geq 0$, 有

$$\mathbb{E}[\|x_n - \hat{x}_n\|^2] \leq \|x_0 - \hat{x}_0\|^2$$

$$\begin{aligned}
\|z_{n,k+1}\|^2 - \|z_{n,k}\|^2 &= -2\gamma_1 \left\langle z_{n,k}, A_{i_{n,k}}^* A_{i_{n,k}} (z_{n,k} - z_n) + \frac{1}{N} A^* A z_n \right\rangle \\
&\quad + \gamma_1^2 \left\| A_{i_{n,k}}^* A_{i_{n,k}} (z_{n,k} - z_n) + \frac{1}{N} A^* A z_n \right\|^2.
\end{aligned}$$

5. 失配原则

定理 3.4 和定理 4.2 中关于算法 1 的收敛结果是在先验停止规则下建立的。在实际应用中, 我们通常期望通过后验规则来终止迭代。注意到 $r_n^\delta := Ax_n^\delta - y^\delta$ 在算法的每个周期中都会涉及, 因此自然考虑通过失配原则来终止迭代, 其确定 n_δ 为第一个满足 $\|r_{n_\delta}^\delta\| \leq \tau\delta$ 的整数, 其中 $\tau > 1$ 是给定的常数。将失配原则结合到算法 1 中, 得到如下算法。

`PLACEHOLDERENV63i`

算法 4 是以结合失配原则的方式构造的, 用以定义无限序列 $\{x_n^\delta\}$, 这对于下面的分析十分方便。在数值模拟中, 迭代实际上一旦满足 $\|r_n^\delta\| \leq \tau\delta$ 就终止, 因为此时迭代变量不再更新。需要强调的是, 停止索引关键依赖于样本路径, 因此是一

个随机整数。另请注意，算法 4 中的步长 $\gamma_0\mu_n$ 和 $\gamma_1\mu_n$ 是随机数；这与算法 1 中步长 γ_0 和 γ_1 为确定性数值形成鲜明对比。下面的结果表明，失配原则几乎必然在有限步内终止 SVRG 方法。

证明. 通过对引理 3.1 的证明进行细微修改，我们可以

以及

由 μ_n 的定义可知 $\mu_n\delta \leq \frac{\mu_n}{\tau}\|Ax_n^\delta - y^\delta\|$ 。因此 $\mathbb{P}(\|Ax_n^\delta - y^\delta\| > \tau\delta \text{ 对所有整数 } n \geq 0) = 0$ 。

接下来我们证明该方法几乎必然在有限步内终止。为此，考虑事件

$$\mathcal{E} := \{\|Ax_n^\delta - y^\delta\| > \tau\delta \text{ 对所有整数 } n \geq 0\}$$

只需证明 $\mathbb{P}(\mathcal{E}) = 0$ 。利用不等式 (

命题 5.1 表明，在概率为一的事件的任意样本路径上，总存在有限整数 n_δ 使得

$$\|Ax_{n_\delta}^\delta - y^\delta\| \leq \tau\delta < \|Ax_n^\delta - y^\delta\|, \quad 0 \leq n < n_\delta,$$

即只要合理选择 τ 、 γ_0 和 γ_1 ，失配原则几乎必然终止 SVRG 方法。在第 6 节中，我们将提供各种数值结果来测试失配原则用于终止 SVRG 方法时的性能。

$$\begin{aligned} \|x_{n,0}^\delta - x^\dagger\|^2 - \|x_n^\delta - x^\dagger\|^2 &\leq -(2\gamma_0 - \gamma_0^2\|A\|^2)\mu_n\|Ax_n^\delta - y^\delta\|^2 \\ &\quad + 2\mu_0\gamma_0\delta\|Ax_n^\delta - y^\delta\| \end{aligned}$$

$$c_1\mathbb{E}[\mu_n\|Ax_n^\delta - y^\delta\|^2] \leq \mathbb{E}[\|x_n^\delta - x^\dagger\|^2] - \mathbb{E}[\|x_{n+1}^\delta - x^\dagger\|^2]$$

Proposition 5.1. 考虑算法 4。如果 $\tau > 1$ ， $\gamma_0 > 0$ 和 $\gamma_1 > 0$ 被选择满足 $0 < \gamma_1 < 1/L$ 且

$$c_1 := 2\gamma_0 - \frac{2\gamma_0}{\tau} - \gamma_0^2\|A\|^2 - \frac{2m\gamma_1^2L}{N} - \frac{m\gamma_1}{2N(1-\gamma_1L)\tau^2} > 0,$$

则对于所有整数 $n \geq 0$ ，有

$$\mathbb{E}[\|x_{n+1}^\delta - x^\dagger\|^2] \leq \mathbb{E}[\|x_n^\delta - x^\dagger\|^2] - c_1\mathbb{E}[\mu_n\|Ax_n^\delta - y^\delta\|^2]. \quad (5.1)$$

此外，算法 4 必须几乎确定地在有限步内终止。

$$\mathbb{E}[\|x_{n+1}^\delta - x^\dagger\|^2 | \mathcal{F}_n] - \|x_n^\delta - x^\dagger\|^2 \leq -c_1\mu_n\|Ax_n^\delta - y^\delta\|^2$$

$$c_1 \sum_{n=0}^l \mathbb{E}[\mu_n\|Ax_n^\delta - y^\delta\|^2] \leq \mathbb{E}[\|x_0^\delta - x^\dagger\|^2] = \|x_0 - x^\dagger\|^2 < \infty. \quad (5.2)$$

Algorithm 4 基于差异原则的 SVRG

input: update frequency m , initial guess $x_0 \in X$, numbers $\tau > 1$, $\gamma_0 > 0$, $\gamma_1 > 0$.
for $n = 0, 1, \dots$ **do**
 Calculate $r_n^\delta := Ax_n^\delta - y^\delta$
 Set $\mu_n := \begin{cases} 1 & \text{if } \|r_n^\delta\| > \tau\delta \\ 0 & \text{if } \|r_n^\delta\| \leq \tau\delta; \end{cases}$
 $g_n^\delta = A^*r_n^\delta$;
 $x_{n,0}^\delta = x_n^\delta - \gamma_0\mu_n g_n^\delta$;
 for $k = 0, \dots, m-1$ **do**
 pick $i_{n,k} \in \{1, \dots, N\}$ randomly via uniform distribution;
 $g_{n,k}^\delta = A_{i_{n,k}}^* A_{i_{n,k}}(x_{n,k}^\delta - x_n^\delta) + \frac{1}{N}g_n^\delta$;
 $x_{n,k+1}^\delta = x_{n,k}^\delta - \gamma_1\mu_n g_{n,k}^\delta$;
 end for
 $x_{n+1}^\delta = x_{n,m}^\delta$;
end

$$\mathbb{E} [\mu_n \|Ax_n^\delta - y^\delta\|^2] \geq \mathbb{E} [\mu_n \|Ax_n^\delta - y^\delta\|^2 \chi_{\mathcal{E}}] \geq \tau^2 \delta^2 \mathbb{E}[\chi_{\mathcal{E}}] = \tau^2 \delta^2 \mathbb{P}(\mathcal{E}).$$

$$\begin{aligned} \mathbb{E}[\|x_{n+1}^\delta - x^\dagger\|^2 | \mathcal{F}_n] - \|x_{n,0}^\delta - x^\dagger\|^2 &\leq -\frac{2\mu_n\gamma_1(1-\mu_n\gamma_1L)}{N} \sum_{k=0}^{m-1} \mathbb{E}[\|Ax_{n,k}^\delta - y^\delta\|^2 | \mathcal{F}_n] \\ &\quad + \frac{2\mu_n\gamma_1}{N} \delta \sum_{k=0}^{m-1} \mathbb{E}[\|Ax_{n,k}^\delta - y^\delta\| | \mathcal{F}_n] \\ &\quad + \frac{2m\mu_n\gamma_1^2L}{N} \|Ax_n^\delta - y^\delta\|^2 \\ &\leq \frac{m\gamma_1\mu_n\delta^2}{2N(1-\mu_n\gamma_1L)} + \frac{2m\mu_n\gamma_1^2L}{N} \|Ax_n^\delta - y^\delta\|^2 \\ &= \frac{m\gamma_1\mu_n\delta^2}{2N(1-\gamma_1L)} + \frac{2m\mu_n\gamma_1^2L}{N} \|Ax_n^\delta - y^\delta\|^2 \end{aligned}$$

6. 数值模拟

本节中，我们提供数值模拟以测试 SVRG 方法的性能。所有计算均在由一维 Fredholm 第一类积分方程通过在 $[c, d]$ 上以 $s_i \in [c, d]$ 采样， $i = 1, \dots, N$ 得到的线性病态系统 `PLACEHOLDERENV71` 上进行，其中核函数 $K(s, t)$ 在 $[c, d] \times [a, b]$ 上连续，且 $s_i = (i - 0.5)(d - c)/N$ ， $i = 1, \dots, N$ 。我们采用文献 [6] 中描述的三种模型问题，分别称为 **phillips**、**gravity** 和 **shaw**。其中，第一个问题为轻度病态问题，后两个为严重病态问题。以下简要介绍这三种模型问题的信息。

接下来，我们通过考虑这三个模型示例来测试算法 1 和算法 4 的性能。我们使用含噪声数据 $y^\delta = (y_1^\delta, \dots, y_N^\delta)$ 代替精确数据 $y := (y_1, \dots, y_N)$ ，其中 $y_i := A_i x^\dagger$

对于每个 i , 噪声数据 $y_i = \text{PLACEHOLDER}_{ENV_5} + v - \delta_{rel}$ 表示相对噪声水平, ϵ_i , $i = 1, \dots, N$ 为标准高斯噪声。计算中涉及的积分通过基于 $[a, b]$ 区间划分为 $M := N$ 个等长子区间的中点法进行近似。所有模拟均在搭载 Apple M1 处理器、8GB DDR4 内存及 512GB SSD 的 Mac Air 上, 使用 MATLAB R2022a 完成。

在计算示例中, 我们利用了三种不同相对噪声水平 $\delta_{rel} = 10^{-1}, 10^{-2}$ 和 10^{-3} 的噪声数据 y^δ , 并以初始猜测 $x_0 = 0$ 执行 SVRG $(\alpha, \beta) = (0.5, 0.99), (1.0, 0.99)$, $stepsize = 1/(2.3)\Theta^* L_{\text{eff}}/\Psi G^2$ 次独立运行计算。

PLACEHOLDER_{ENV_6}

我们首先通过考虑 $N = 5000$ 的系统 (6.1) 来测试算法 1 的性能。对于给定的离散模型, 步长依赖于更新频率 m 、 α 和 β 。我们采用 $m = 0.1N$ 。为说明收敛对步长大小的依赖, 我们考虑三组参数值: $(\alpha, \beta) = (0.5, 0.99), (1.0, 0.99)$ 和 $(1.9, 0.99)$ 。图 3 展示了三个模型问题对应的重建相对均方误差 $\mathbb{E}[\|x_n^\delta - x^\dagger\|^2/\|x^\dagger\|^2]$, 其中 n 表示迭代轮数。这些数值图表明, SVRG 方法表现出半收敛现象, 即迭代初期收敛至目标解, 随后在迭代次数达到临界值后开始发散。此外, 当步长按 (2.3) 中 $(\alpha, \beta) = (1.0, 0.99)$ 选取时, 半收敛现象更早出现, 表明该参数配置使迭代快速产生误差最小的重建结果, 但也更快偏离目标解。半收敛行为使得确定何时终止迭代以获得满意重建结果成为挑战。因此, 有必要考虑 sit 事后停止规则。

PLACEHOLDER_{ENV_7}

接下来, 假设噪声水平信息 $\delta := \|y^\delta - y\|$ 可用, 考虑按算法 4 中描述的差值原则终止的 SVRG 方法。我们展示算法 4 在三个模型问题上的数值性能, γ_0 和 γ_1 采用公式 (2.3), 参数设为 $\alpha = 1.0, \beta = 0.99$ 。本研究中以 Landweber 方法作为基准。比较时, Landweber 方法 (1.2) 初始值为 $x_0 = 0$, 步长常数为 $\gamma = 1/\|A\|^2$, 两种方法均以差值原则 $u = 1.01b\Theta$

PLACEHOLDER_{ENV_8}

SVRG 算法包含一个超参数, 即计算全梯度的更新频率 m , 该参数对算法性能和效率至关重要。为评估不同规模下 m 的影响, 我们对三个不同离散水平 $N = 1000, 5000, 10000$ 分别进行 $m = N$ 和 $m = 0.1N$ 的数 $\Theta\Psi^*!Gh$

数值结果揭示了若干重要观察。首先, 结果表明算法 4 能在有限次迭代后终止, 并产生可接受的近似解。同时, 随着噪声水平 δ 下降, 相对误差稳步减小, 体现了所提方法的收敛性。在准确度 (以相对均方误差衡量) 方面, SVRG 方法在三个模型问题上均与经典 Landweber 方法竞争力相当。在大多数情况下, 两种方法的相对误差相当接近, 且偶尔 SVRG 方法的误差甚至低于 Landweber 方法。这些观察适用于所有示例, 尽管它们在病态程度和解的光滑性上差异显著。

注意, 算法 4 中每个 epoch 包含一步 Landweber 迭代, 复杂度为 $O(NM)$, 以及一个包含 m 次迭代的内循环, 复杂度为 $O(mM)$ 。因此, 算法每个 epoch 的总体复杂度为 $O((N+m)M)$ 。若算法执行 n 个外循环, 总计算复杂度为 $\mathcal{O}(n(N+m)M)$ 。

表 1. **shaw** 模型的数值结果, 使用 SVRG 方法, 即算法 4, 其中 γ_0 和 γ_1 按照式 (2.3) 选择, 参数为 $\alpha = 1$ 和 $\beta = 0.99$, 以及 Landwber 方法 (1.2), 其中 $\gamma = 1/\|A\|^2$, 通过不一致性原理以 $\tau = 1.01$ 终止。

N	δ_{rel}	method	iteration	time (s)	relative error
1000	0.1	Landweber	56	0.0183	3.3729e-02
		SVRG: $m = N$	4.82	0.0242	3.2753e-02
		SVRG: $m = 0.1N$	11.94	0.0136	3.3493e-02
	0.01	Landweber	1732	0.5525	1.8242e-02
		SVRG: $m = N$	137.64	0.6567	1.8157e-02
		SVRG: $m = 0.1N$	369.43	0.4109	1.8258e-02
	0.001	Landweber	27018	6.9767	2.5595e-03
		SVRG: $m = N$	2134.6	9.5064	2.5599e-03
		SVRG: $m = 0.1N$	5761.6	6.3493	2.5602e-03
5000	0.1	Landweber	57	0.5280	3.5610e-02
		SVRG: $m = N$	2.75	0.6069	3.2465e-02
		SVRG: $m = 0.1N$	6.53	0.2047	3.4849e-02
	0.01	Landweber	2743	25.450	1.4948e-02
		SVRG: $m = N$	102.45	22.853	1.4832e-02
		SVRG: $m = 0.1N$	299.36	9.1962	1.4919e-02
	0.001	Landweber	29136	283.34	2.4354e-03
		SVRG: $m = N$	1077.3	240.26	2.4347e-03
		SVRG: $m = 0.1N$	3152.11	100.75	2.4353e-03
10000	0.1	Landweber	58	1.9163	3.4329e-02
		SVRG: $m = N$	2.13	2.4791	3.0960e-02
		SVRG: $m = 0.1N$	5.02	0.7598	3.3105e-02
	0.01	Landweber	3185	109.54	1.3195e-02
		SVRG: $m = N$	84.47	100.94	1.3165e-02
		SVRG: $m = 0.1N$	252.86	41.515	1.3138e-02
	0.001	Landweber	29962	1048.3	2.4488e-03
		SVRG: $m = N$	792.24	924.37	2.4479e-03
		SVRG: $m = 0.1N$	2366.75	371.18	2.4488e-03

$m)M$)。具体而言, 当 $m = N$ 时, 算法 4 的一个 epoch 等价于执行 Landweber 方法的 2 次迭代; 当 $m = 0.1N$ 时, 等效于执行 1.1 倍的 Landweber 步数。因此, 从计算复杂度视角看, SVRG 方法远比 Landweber 方法高效。例如, 在重力模型中, $\delta_{rel} = 10^{-3}$, $N = 10000$, $m = 0.1N$ 时, SVRG 方法执行约 $288.95 \times 1.1 \approx 318$ 次 Landweber 迭代, 约为 Landweber 方法所需 4614 次迭代的 $1/14.5$ 。然而, 由于 MATLAB 内部对矩阵操作进行了高效优化, 直接使用矩阵操作通常比逐元素循环计算更高效。因此, 在样本量较小 ($N = 1000$) 时, 尽管理论计算复杂度较低, SVRG 方法的执行时间略高于 Landweber 方法。即便如此, 在处理大规模问题 ($N = 5000, 10000$) 时, SVRG 方法相较传统 Landweber 方法表现出显著性能优势, 后者在此类场景下往往需要更多迭代以达到相同收敛标准。

此外，从执行时间角度看，超参数 m 对 SVRG 算法整体效率影响显著。特别地，较大 m 值意味着每个循环中需执行更多内循环迭代，直接导致每个 epoch 的计算成本显著增加，尤其在处理大规模问题时更为明显。再者，过大的 m 导致内循环末期的方差减小效果不佳，因为迭代点可能远离快照点，这不利于算法整体性能。通过分析三个不同模型在相同相对噪声水平 δ_{rel} 和离散水平下的实验结果，我们发现相比 $m = N$ ，将 m 设置为 $0.1N$ 显著降低执行时间，实现了两到三倍的加速效率，同时保持与传统 Landweber 方法相当的准确度。这凸显了合理降低 m 以减少计算开销并获得满意重建结果的重要性，而不损失 Θ

为进一步展示单次样本的表现，图 1 展示了模型问题中相对误差 $\|x_{n_\delta}^\delta - x^\dagger\|^2 / \|x^\dagger\|^2$ 和停止指标 n_δ 的箱线图， $N = 10000$ 。自上而下的行分别对应 phillips、gravity 和 shaw。图中展示了在不同相对噪声水平 δ_{rel} 下的性能表现。随着 δ_{rel} 增大，误差分布变宽，而满足停止指标所需的迭代轮数 n_δ 显著减少，这与理论预期一致。




图 1. 模型问题中相对误差 $\|x_{n_\delta}^\delta - x^\dagger\|^2 / \|x^\dagger\|^2$ 和停止指标 n_δ 的箱线图， $N = 10000$ 。自上而下的行分别对应 phillips、gravity 和 shaw。

为直观展示性能，图 2 绘制了部分单次运行的重建结果。图中展示了在不同相对噪声水平 δ_{rel} 下的重建效果。随着 δ_{rel} 增大，重建结果的质量下降，这反映了噪声对重建性能的影响。




图 2. 所求解 $x^\dagger$ 以及使用带有不同相对噪声水平的噪声数据通过 SVRG 重建的结果。自上而下的行分别对应 **phillips**、**gravity** 和 **shaw**。

Example 6.1 (gravity). 该测试问题来源于重力测量中一维模型问题的离散化 $y(s) = \int_0^1 K(s, t)x(t)dt$, 其中 $s \in [0, 1]$, 旨在从测量的重力场垂直分量 $y(s)$ 反演位于深度 d 处的质量分布 $x(t)$ 。核函数和待求解的解为

$$K(s, t) = d [d^2 + (s - t)^2]^{-\frac{3}{2}}, \quad x^\dagger(t) = \sin(\pi t) + \frac{1}{2} \sin(2\pi t).$$

在我们的计算中使用 $d = 0.25$ 。

$$A_i x := \int_a^b K(s_i, t)x(t)dt = y(s_i), \quad i = 1, \dots, N \quad (6.1)$$

Example 6.2 (phillips). 该测试问题是通过离散化 Fredholm 积分方程 $y(s) = \int_{-6}^6 K(s, t)x(t)dt$, $s \in [-6, 6]$ 得到的, 其中核函数和待求解的解分别为 $K(s, t) =$




图 3. 使用不同参数 α, β 及相对噪声水平 δ_{rel} 的 SVRG 重建误差。
自上而下的行分别对应 **phillips**、**gravity** 和 **shaw**。

$\rho(s-t)$ 和 $x^\dagger(t) = \rho(t)$, 其中

$$\rho(t) = \begin{cases} 1 + \cos(\frac{\pi t}{3}), & |t| < 3, \\ 0, & |t| \geq 3. \end{cases}$$

$$y_i^\delta = y_i + \delta_{rel}|y_i|\epsilon_i, \quad i = 1, \dots, N, \quad (6.2)$$

Example 6.3 (shaw). 这个一维图像恢复模型使用 $y(s) = \int_{-\pi/2}^{\pi/2} K(s,t)x(t)dt$, $s \in [-\pi/2, \pi/2]$, 其中核函数和待求解的解为

$$K(s,t) = (\cos(s) + \cos(t))^2 \left(\frac{\sin(u)}{u} \right)^2, \quad u = \pi(\sin(s) + \sin(t)),$$

$$x^\dagger(t) = 2 \exp\left(-6(t-0.8)^2\right) + \exp\left(-2(t+0.5)^2\right).$$

表 2. 通过 SVRG 算法, 即算法 4, 对 **phillips** 模型的数值结果, 其中 γ_0 和 γ_1 由式 (2.3) 选取, 参数为 $\alpha = 1$ 和 $\beta = 0.99$, 以及使用 $\gamma = 1/\|A\|^2$ 的 Landwber 方法 (式 (1.2)), 通过偏差准则以 $\tau = 1.01$ 终止。

N	δ_{rel}	method	iteration	time (s)	relative error
1000	0.1	Landweber	19	0.0101	4.1590e-03
		SVRG: $m = N$	2.72	0.0156	2.4393e-03
		SVRG: $m = 0.1N$	5.37	0.0080	3.4368e-03
	0.01	Landweber	102	0.0385	7.9908e-04
		SVRG: $m = N$	9.14	0.0525	1.1483e-03
		SVRG: $m = 0.1N$	22.21	0.0277	1.0987e-03
	0.001	Landweber	3059	1.1237	9.6454e-05
		SVRG: $m = N$	245.77	1.2181	1.1943e-04
		SVRG: $m = 0.1N$	638.62	0.6945	1.1686e-04
5000	0.1	Landweber	16	0.1570	5.9102e-03
		SVRG: $m = N$	2.03	0.4533	1.9841e-03
		SVRG: $m = 0.1N$	3.11	0.1041	3.9575e-03
	0.01	Landweber	114	1.0965	6.5804e-04
		SVRG: $m = N$	5.28	1.1646	9.2306e-04
		SVRG: $m = 0.1N$	13.41	0.4330	9.6879e-04
	0.001	Landweber	2690	25.294	1.5558e-04
		SVRG: $m = N$	93.57	20.208	1.6958e-04
		SVRG: $m = 0.1N$	283.17	9.1490	1.6979e-04
10000	0.1	Landweber	16	0.6462	6.3237e-03
		SVRG: $m = N$	2.01	2.4825	1.7839e-03
		SVRG: $m = 0.1N$	2.7	0.4334	3.6413e-03
	0.01	Landweber	116	3.9144	6.3945e-04
		SVRG: $m = N$	3.85	4.6586	7.9873e-04
		SVRG: $m = 0.1N$	10.41	1.6302	8.7121e-04
	0.001	Landweber	3449	116.48	9.0028e-05
		SVRG: $m = N$	95.05	111.98	1.1096e-04
		SVRG: $m = 0.1N$	268.72	44.136	1.0459e-04

7. 结论

随机方差缩减梯度 (SVRG) 方法是在机器学习中解决大规模良态优化问题的一个重要方法, 并且在算法设计中引入了方差缩减策略以加速随机梯度方法。在本文中, 我们将 SVRG 方法应用于希尔伯特空间中的大规模线性病态系统求解。在对所求解的解施加基准源条件的前提下, 我们获得了当适当选择停止指标时该方法的收敛速度结果。基于该结果和扰动论证, 我们建立了在不使用任何源条件的情况下的收敛结果。此外, 我们考虑了差异原则来选择停止指标, 并证明该原则几乎必然在有限多次迭代步骤内终止 SVRG 方法。报告了多种数值结果, 说明 SVRG 方

表 3. **gravity** 模型的数值结果, 使用 SVRG 方法, 即算法 4, 其中 γ_0 和 γ_1 按照式子 (2.3) 选择, 参数为 $\alpha = 1$ 和 $\beta = 0.99$, 以及 Landwber 方法 (1.2), 其中 $\gamma = 1/\|A\|^2$, 并以偏差准则终止, 参数为 $\tau = 1.01$ 。

N	δ_{rel}	method	iteration	time (s)	relative error
1000	0.1	Landweber	23	0.0091	6.8214e-03
		SVRG: $m = N$	2.52	0.0136	6.2835e-03
		SVRG: $m = 0.1N$	4.54	0.0055	7.5344e-03
	0.01	Landweber	178	0.0618	2.0434e-03
		SVRG: $m = N$	12.72	0.0625	2.0389e-03
		SVRG: $m = 0.1N$	34.03	0.0388	2.0621e-03
	0.001	Landweber	3774	1.0686	3.1782e-04
		SVRG: $m = N$	208.28	0.9407	3.1532e-04
		SVRG: $m = 0.1N$	649.56	0.7182	3.2604e-04
5000	0.1	Landweber	22	0.2075	7.7204e-03
		SVRG: $m = N$	1.98	0.4385	5.6416e-03
		SVRG: $m = 0.1N$	2.89	0.0938	7.4545e-03
	0.01	Landweber	249	2.2940	1.5475e-03
		SVRG: $m = N$	8.71	1.9899	1.5585e-03
		SVRG: $m = 0.1N$	24.2	0.7469	1.6239e-03
	0.001	Landweber	4588	42.369	2.7350e-04
		SVRG: $m = N$	120.48	27.256	2.7895e-04
		SVRG: $m = 0.1N$	377.31	12.120	2.7368e-04
10000	0.1	Landweber	22	0.7390	8.0617e-03
		SVRG: $m = N$	1.97	2.2943	4.6782e-03
		SVRG: $m = 0.1N$	2.38	0.3695	6.5503e-03
	0.01	Landweber	275	9.0302	1.3574e-03
		SVRG: $m = N$	6.53	7.6368	1.4864e-03
		SVRG: $m = 0.1N$	17.73	2.6020	1.4652e-03
	0.001	Landweber	4614	153.75	2.7504e-04
		SVRG: $m = N$	89.83	107.45	2.7817e-04
		SVRG: $m = 0.1N$	288.95	43.520	2.7620e-04

法在大规模病态逆问题上能够优于经典的 Landweber 方法。还有若干问题值得进一步探讨:

- 在我们使用的 SVRG 方法中, 采用了常数步长 γ_0 和 γ_1 。是否有可能发展出一种基于自适应步长的 SVRG 方法的收敛理论, 从而允许更大的步长以减少迭代次数, 进而加快方法的收敛速度?
- 我们针对 SVRG 方法的收敛理论是用于确定 x_0 -最小范数解。在实际应用中, 所求解可能具有其他 *a priori* 已知的特征, 例如非负性、稀疏性等。是否有可能在理论基础扎实的前提下, 修改 SVRG 方法以捕捉这些期望的特征?
- 非线性病态系统可能源自各种断层成像问题。我们能否将 SVRG 方法推广到非线性环境下求解这类病态系统?

Acknowledgement

The work of Q. Jin is partially supported by the Future Fellowship of the Australian Research Council (FT170100231). The work of L. Chen is supported by the China Scholarship Council program (Project ID: 202106160067).

REFERENCES

- [1] Z. ALLEN-ZHU AND Y. YUAN, *Improved SVRG for non-strongly-convex or sum-of-non-convex Objectives*, International Conference on Machine Learning, pp. 1080–1089, 2016.
- [2] M. Bertero, C. De Mol and E. R. Pike, *Linear inverse problems with discrete data. I: General formulation and singular system analysis*, Inverse Problems, 1 (1985), 301–330.
- [3] P. Brémaud, *Probability theory and stochastic processes*, Universitext, Springer, Cham, 2020.
- [4] A. Defazio, F. Bach and S. Lacoste-Julien, *Saga: a fast incremental gradient method with support for non-strongly convex composite objectives*, Proc. 27th Int. Conf. Adv. Neural Inf. Process. Syst., pp. 1646–1654, 2014.
- [5] H. W. Engl, M. Hanke and A. Neubauer, *Regularization of Inverse Problems*, Dordrecht, Kluwer, 1996.
- [6] P. C. Hansen, *Regularization tools version 4.0 for Matlab 7.3*, Numer. Algorithms, 46 (2007), 189–194.
- [7] R. Harikandeh, M. O. Ahmed, A. Virani, M. Schmidt, J. Konecny and S. Sallinen, *Stop wasting my gradients: practical SVRG*, Proc. 28th Int. Conf. Adv. Neural Inf. Process. Syst., pp. 2251–2259, 2015.
- [8] B. Jin and X. Lu, *On the regularizing property of stochastic gradient descent*, Inverse Problems, 35 (2019), no. 1, 015004, 27 pp.
- [9] B. Jin, Z. Zhou and J. Zou, *An analysis of stochastic variance reduced gradient for linear inverse problems*, Inverse Problems, 38 (2022), no. 2, 025009, 34 pp.
- [10] Q. Jin, *On a regularized Levenberg-Marquardt method for solving nonlinear inverse problems*, Numer. Math., 115 (2010), no. 2, 229–259.
- [11] Q. Jin, *A general convergence analysis of some Newton-type methods for nonlinear inverse problems*, SIAM J. Numer. Anal., 49 (2011), no. 2, 549–573.
- [12] Q. Jin, X. Lu and L. Zhang, *Stochastic mirror descent method for linear ill-posed problems in Banach spaces*, Inverse Problems, 39 (2023), no. 6, 065010, 39 pp.
- [13] R. Johnson and T. Zhang, *Accelerating stochastic gradient descent using predictive variance reduction*, Advances in Neural Information Processing Systems, 315–323, 2013.
- [14] F. Natterer, *The Mathematics of Computerized Tomography*, SIAM, Philadelphia, 2001.
- [15] L. M. Nguyen, J. Liu, K. Scheinberg and M. Takác, *SARAH: a novel method for machine learning problems using stochastic recursive gradient*, Proc. 34th Int. Conf. Machine Learning, PMLR, 70 (2017), 2613–2621.
- [16] N. Le Roux, M. Schmidt and F. Bach, *A stochastic gradient method with an exponential convergence rate for strongly-convex optimization with finite training sets*, Advances in Neural Information Processing System, 2663–2671, 2012.
- [17] S. Shalev-Shwartz and T. Zhang, *Stochastic dual coordinate ascent methods for regularized loss minimization*, J. Mach. Learn. Res., 14 (2013), 567–599.

- [18] C. Tan, S. Ma, Y. H. Dai and Y. Qian, *Barzilai–Borwein step size for stochastic gradient descent*, Proc. 29th Int. Conf. Adv. Neural Inf. Process. Syst., 685–693, 2016.
- [19] L. Xiao and T. Zhang, *A proximal stochastic gradient method with progressive variance reduction*, SIAM Journal on Optimization, 24 (2014), no. 4, 2057–2075.
- [20] T. Yu, X. Liu, Y. H. Dai and J. Sun, *Stochastic variance reduced gradient methods using a trust-region-like scheme*, J. Sci. Comput., 87 (2021), no. 1, Paper No. 5, 24 pp.
- [21] L. Zhang, M. Mahdavi and R. Jin, *Linear convergence with condition number independent access of full gradients*, Advances in Neural Information Processing Systems, 980–988, 2013.
- [22] Y. Zhang and L. Xiao, *Stochastic primal-dual coordinate method for regularized empirical risk minimization*, Proc. Int. Conf. Mach. Learn., 2015, 353–361.

MATHEMATICAL SCIENCES INSTITUTE, AUSTRALIAN NATIONAL UNIVERSITY, CANBERRA, ACT
2601, AUSTRALIA

Email address: `qinian.jin@anu.edu.au`

SCHOOL OF MATHEMATICS AND STATISTICS, HUAZHONG UNIVERSITY OF SCIENCE AND TECH-
NOLOGY, WUHAN 430074, CHINA

Email address: `liuhong_c@hust.edu.cn`