

用于低剂量泊松相位恢复的 Wirtinger 梯度下降方法

Benedikt Diederichs^{1,2}, Frank Filbir^{1,3} and Patricia Römer^{1,3*}

¹ 生物与医学成像研究所 数学成像与数据分析, 慕尼黑亥姆霍兹中心.

² 化学系与纳米科学中心, 慕尼黑路德维希马克西米利安大学.

³ 数学系, 慕尼黑工业大学.

*Corresponding author (patricia.roemer@tum.de)

摘要

相位恢复问题在光学成像领域有着广泛的应用。受生物样本成像实验的启发, 我们主要考虑低剂量照明条件下的情形, 此时泊松噪声起主导作用。本文讨论了基于不同损失函数的梯度下降算法, 这些损失函数针对受泊松噪声影响的数据进行了调整, 特别是在低剂量条件下。我们从泊松分布的最大对数似然函数出发, 研究了问题的不同正则化和近似方法, 以设计满足实际应用需求的算法。在此过程中, 我们重点关注低计数测量。对于所有提出的损失函数, 我们研究了相应梯度下降算法收敛到驻点的性质, 并确定了保证每次迭代损失函数下降的常数步长。通过低剂量条件下的数值实验验证了理论分析结果。

Keywords: phase retrieval, Poisson noise, low-dose imaging, optimization, gradient descent.

MSC Classification: 78A46 , 78M50 , 90C26 , 65K10.

1 引言

相位恢复是衍射成像技术中一个基础性的问题, 该技术中记录了物体多个衍射图样的强度测量值。在许多情况下, 这些测量是在远场距离进行的。可以证明, 这种远场强度测量由物体的傅里叶变换的模方给出。为了更具体地说明, 假设一个具有 N 个像素的探测器被放置在远场距离处。探

测器平面信号的离散形式由离散傅里叶变换给出<

$$\sum_{n=0}^{N-1} x_n e^{-2\pi i k n/N} = \langle x, u_k \rangle,$$

> 向量 $u_k = (e^{2\pi i k n/N})_{n=0}^{N-1}$ 和 $x = (x_n)_{n=0}^{N-1}$ 。后者是物体的离散表示, 我们希望对其进行重建。根据该模型, 向量 u_k 可以对应为第 k 个频率, 或者等价地, 对应探测器的第 k 个像素。如上所述, 探测器本身仅测量强度, 即仅记录 $\langle x, u_k \rangle$ 的模方。因此, 我们面临着从形式为 $|\langle x, u_k \rangle|^2, k = 0, \dots, N-1$ 的数据中重建 x 的挑战性问题。

然而, 已知该数据集不包含足够信息使逆问题唯一可解 [1], 即仅用纯态 $u_k, k = 0, \dots, N-1$ 探测物体 x 并不充分。为避免这些困难, 我们必须在数据集中引入一定程度的冗余。为了引入足够的冗余, 将测量向量集合 u_k 替换为过完备的向量系统 $a_k \in \mathbb{C}^N, k = 1, \dots, m$, 其中 $m \gg N$, 并测量 $|\langle x, a_k \rangle|^2, k = 1, \dots, m$, 而非仅测量 $|\langle x, u_k \rangle|^2, k = 0, \dots, N-1$ 。该方法的一个重要实现是所谓的远场扫描衍射成像 (ptychography)。该方法利用形式为 $a_{k,\ell} = (w_{n,\ell} e^{-2\pi i k n/N})_{n=0}^{N-1}$ 的测量向量, 其中的掩码 $w_{n,\ell}$ 是向量 $w = (w_n)_{n=0}^{N-1}$ 的平移 $(w_{n-\ell \bmod N})_{n=0}^{N-1}$, 该向量具有较短的支撑。平移次数被安排成物体通过掩码扫描, 使得相邻扫描位置的掩码支撑以一定比例相互重叠。我们不会进一步讨论扫描衍射成像, 相关内容可参见 [2–4]。

受扫描衍射成像的启发, 我们考虑以下重建问题。给定形式为

的数据, 我们需要重建向量 $x \in \mathbb{C}^n$ 。这就是相位恢复问题的数学抽象形式。该问题在过去几十年引起了广泛关注, 并取得了一系列基础性成果 [5, 8? ?]。首要的基础性问题是唯一性, 即映射 $\mathbb{C}^n \rightarrow \mathbb{C}^m, x \mapsto (|\langle x, a_i \rangle|^2)_{i=1}^m$ 要成为单射, m 至少要多大。该问题在不同假设下由多位作者进行了研究, 关于 x 和向量 a_i 的不同假设。有关进一步讨论, 可参见基础论文 [6, 9]。我们的重点是给定 $\hat{y}_i, i = 1, \dots, m$ 之后重建向量 x , 我们将在特定数据集假设下考虑该问题, 这些假设同样由实验装置的具体限制所驱动。在进入具体细节之前, 先回顾基于变分方法的重建技术。变分方法尝试通过以下最小化来恢复 x < $PLACEHOLDER_{ENV_3}$ > 其中使用合适的损失函数 $L: \mathbb{C}^n \rightarrow \mathbb{R}$ 。为了确定 x , 或至少得到一个良好的近似, 通常应用梯度下 $\ell: \mathbb{R}^m \rightarrow \mathbb{R}$ $\text{pr} \varphi: \mathbb{C}^n \rightarrow \mathbb{R}^m, z \mapsto (|\langle a_i, z \rangle|^2)_{i=1}^m$ $LDER_{ENV_4}$ > 其中学习率为 $\mu > 0$, 初始向量为适当选择的 z_0 。对于相位恢复问题, 损失函数形式为 $\mathcal{L}(z) =$

$\ell \circ \varphi(z)$, 其中 $\ell: \mathbb{R}^m \rightarrow \mathbb{R}$ 是适当函数, 且 $\varphi: \mathbb{C}^n \rightarrow \mathbb{R}^m, z \mapsto (|\langle a_i, z \rangle|^2)_{i=1}^m$ 。还需注意, 函数 φ 通常使问题变为非凸。

一种常用的用于重建 x 的损失函数是最小二乘损失 $\langle \text{PLACEHOLDER}_{ENV_5} \rangle$ 或其某些正则化变体。针对对应最小化问题的梯度下降算法 [19]。这些工作研究了随机与非随机梯度下降算法中包含 Wirtinger 导数的不同损失函数。除随机测量的收敛性保证外, 文献 [20] 和 [21] 还分析了梯度下降算法对任意类型测量向量 (随机或确定性) 基于幅度的损失函数的驻点收敛性。

在所有实际相关的测量场景中, 数据 $\hat{y}_i$ 都会受到某种噪声污染。因此, 我们实际得到的是被扰动的值 y_i , 而非理想的 $\hat{y}_i$ 。扰动可能来源于热噪声、读出噪声、背景噪声等多种因素 [22]。某类背景噪声的问题最近被本文作者之一在 [23] 中研究。本文重点关注由探测器工作模式引起的扰动。所有现代探测器, 如 CCD 相机, 最终都是计数设备。换言之, 测量过程可以建模为计数过程, 因此可以用泊松分布的离散随机变量数学描述, 即 $\langle \text{PLACEHOLDER}_{ENV_6} \rangle$ 其中 $|\langle a_i, x \rangle|^2$ 是真实值。即在给定真实值 $|\langle a_i, x \rangle|^2$ 的条件下, 位置 i 计数到 y_i 粒子的概率为 $\frac{1}{y_i!} e^{-|\langle a_i, x \rangle|^2} (|\langle a_i, x \rangle|^2)^{y_i}$ 。为了将测量过程为泊松过程的事实纳入变分重建方法中, 必须相应调整损失函数。我们采用极大似然方法, 将最小二乘损失函数替换为泊松对数似然损失, 形式为

$$\mathcal{L}_P(z) = \sum_{i=1}^m |\langle a_i, z \rangle|^2 - y_i \log(|\langle a_i, z \rangle|^2).$$

针对泊松似然损失 alL_P 的最小化问题 (??), 已有诸多研究, 例如 [13, 24–28] 及文献中引用的资料。

我们重新考虑带泊松对数似然损失 hcalL_P 的最小化问题 (??), 动机源自特定的衍射成像装置。对于生物组织如细胞、病毒等的成像, 通常无法使用高强度辐射束, 因为此类照射会瞬间破坏物体 [29–31]。因此, 必须采用适当低强度的光束进行测量, 这反过来导致探测器接收到的信号较弱。在实际测量场景中, 计数率可能低于每像素 10 个照射粒子, 且部分像素甚至可能为零。此低计数情形对梯度下降重建过程造成严重问题, 因为它导致 $\mathcal{L}_P$ 梯度的奇异性。为应对这些问题, 必须引入正则化技术以处理这些奇异点。针对低剂量泊松噪声数据的相位恢复问题的算法方法也见 [32?, 33]。

本文结构安排如下。在 Section 2 中, 我们总结了 Wirtinger 导数相关理论以及包含导数的梯度下降算法的若干基础收敛结果。

problem formulation 讨论了针对带泊松噪声低剂量数据的

的相位恢复问题所构建优化问题中损失函数的选择。

Section 4 对涉及不同损失函数的算法进行了收敛性分析。*Section 5* 给出数值实验以

$$|\langle x, a_i \rangle|^2, \quad i = 1, \dots, m, (1)$$

$$z_{k+1} = z_k - \mu \nabla \mathcal{L}(z_k), \quad k \geq 0,$$

$$x = \arg \min_z \mathcal{L}(z), \quad (2)$$

$$y_i \sim \text{Poisson} \left(|\langle a_i, x \rangle|^2 \right), \quad i = 1, \dots, m,$$

$$\mathcal{L}(z) = \sum_{i=1}^m \left| |\langle a_i, z \rangle|^2 - \hat{y}_i \right|^2,$$

2 使用 Wirtinger 导数的梯度下降

我们首先介绍一些关于 Wirtinger 微积分的理论。考虑一个函数

$$f(z) = u(x, y) + iv(x, y), \quad z = x + iy, \quad x, y \in \mathbb{R}^n,$$

其中 u 和 v 是实值且可微的函数。利用共轭变量 $z = x + iy$ 和 $\bar{z} = x - iy$ ，函数 f 可以被视为变量 z 和 $\bar{z}$ 的函数。由于 u 和 v 是可微的，函数 $f(z, \bar{z})$ 对于固定的 $\bar{z}$ 来说是关于 z 的全纯函数，反之亦然。Wirtinger 微积分表达了函数 f 关于实变量 x 和 y 的导数，换成关于共轭变量 z 和 $\bar{z}$ ，并将它们视为独立变量。函数 f 的 Wirtinger 导数定义为

$$\partial_z f = \frac{1}{2} (\partial_x f - i \partial_y f), \quad \partial_{\bar{z}} f = \frac{1}{2} (\partial_x f + i \partial_y f).$$

这意味着以下关系成立

$$\overline{\partial_z f} = \partial_{\bar{z}} \bar{f}, \quad \text{and} \quad \overline{\partial_{\bar{z}} f} = \partial_z \bar{f}. \quad (3)$$

Wirtinger 导数 $\partial_z f$ 和 $\partial_{\bar{z}} f$ 也可以表示为

$$\partial_z f = \partial_z f(z, \bar{z}) \Big|_{\bar{z}=\text{const.}} = \left[\partial_{z_1} f(z, \bar{z}), \dots, \partial_{z_n} f(z, \bar{z}) \right] \Big|_{\bar{z}=\text{const.}},$$

$$\partial_{\bar{z}} f = \partial_{\bar{z}} f(z, \bar{z}) \Big|_{z=\text{const.}} = \left[\partial_{\bar{z}_1} f(z, \bar{z}), \dots, \partial_{\bar{z}_n} f(z, \bar{z}) \right] \Big|_{z=\text{const.}}.$$

因此，Wirtinger 梯度和 Wirtinger Hessian 定义为

$$\nabla f(z) = \begin{pmatrix} (\partial_z f)^* \\ (\partial_{\bar{z}} f)^* \end{pmatrix}, \quad \nabla^2 f(z) = \begin{pmatrix} \partial_z (\partial_z f)^* & \partial_{\bar{z}} (\partial_z f)^* \\ \partial_z (\partial_{\bar{z}} f)^* & \partial_{\bar{z}} (\partial_{\bar{z}} f)^* \end{pmatrix}. \quad (4)$$

当函数 f 是实值函数, 即 $f(z) = u(x, y)$ 时, 关系式 (3) 给出

$$\partial_{\bar{z}} f = \overline{\partial_z f}, \quad \partial_{\bar{z}}(\partial_{\bar{z}} f)^* = \overline{\partial_z(\partial_z f)^*}, \quad \partial_z(\partial_{\bar{z}} f)^* = \overline{\partial_{\bar{z}}(\partial_z f)^*}.$$

更方便的是使用以下简化符号表示

$$\nabla_z f := (\partial_z f)^*, \quad \nabla_{z,z}^2 f := \partial_z(\partial_z f)^*, \quad \text{以及} \quad \nabla_{z,\bar{z}}^2 f := \partial_z(\partial_{\bar{z}} f)^*.$$

函数 f 在点 z_0 的二阶泰勒多项式为

$$P_f(v, z_0) = f(z_0) + (\nabla f(z_0))^* \begin{pmatrix} v \\ \bar{v} \end{pmatrix} + \begin{pmatrix} v \\ \bar{v} \end{pmatrix}^* \nabla^2 f(z) \begin{pmatrix} v \\ \bar{v} \end{pmatrix}.$$

对于实值函数 f , 泰勒多项式 P_f 的二次项可以表示为

$$\begin{pmatrix} v \\ \bar{v} \end{pmatrix}^* \nabla^2 f(z) \begin{pmatrix} v \\ \bar{v} \end{pmatrix} = 2\operatorname{Re}(v^* \nabla_{z,z}^2 f(z) v) + 2\operatorname{Re}(v^* \nabla_{\bar{z},z}^2 f(z) \bar{v}). \quad (5)$$

本文中, 我们关注的是实值函数 f 。为了最小化此类函数 f , 我们应用梯度下降法

$$z_{k+1} = z_k - \mu_k \nabla_z f(z_k) \quad (6)$$

其中初始向量 $z_0 \in \mathbb{C}^n$ 是适当选择的。参数 $\mu_k > 0$ 称为步长或学习率。它可以是常数或者自适应的, 优选使得每次迭代的下降得以保证, 即对于所有 $k \geq 0$, 有 $f(z_{k+1}) \leq f(z_k)$ 。以下结果的证明可见于文献 [21]。

Proposition 1 设 $b \in \mathbb{R}$, $f : \mathbb{C}^n \rightarrow [b, \infty)$, 是一个具有一致有界 Hessian 的二次 Wirtinger 可微函数, 即

$$\begin{pmatrix} v \\ \bar{v} \end{pmatrix}^* \nabla^2 f(z) \begin{pmatrix} v \\ \bar{v} \end{pmatrix} \leq L \left\| \begin{pmatrix} v \\ \bar{v} \end{pmatrix} \right\|_2^2$$

对所有 $z, v \in \mathbb{C}^n$ 成立, 其中常数 $L > 0$ 与 z 无关。令序列 $(z_k)_{k \geq 0}$ 由带有任意初始化 $z_0 \in \mathbb{C}^n$ 的更新 (6) 生成。如果 $0 < \mu \leq L^{-1}$, 则有

$$f(z_k) - f(z_{k+1}) \geq \mu \|\nabla_z f(z_{k+1})\|_2^2$$

对所有 $k \geq 0$ 成立。然后, 若 f 具有紧致的亚水平集 $L_s(f) = \{z \in \mathbb{C}^n : f(z) \leq s\}$, 则 Wirtinger 流算法 (6) 保证收敛到 f 的一个驻点。

接下来,我们将此结果的要求具体化到在本文背景下相关的损失函数。正如前述,我们将考虑的损失函数是形如 $\ell \circ \varphi$ 的复合函数,其中 $\ell: \mathbb{R} \rightarrow \mathbb{R}$ 是平滑函数, $\varphi: \mathbb{C}^n \rightarrow [0, \infty)$, 定义为 $\varphi(z) = |\langle a, z \rangle|^2$ 。对于此类函数,我们得到关于 Hessian 的以下界。

Lemma 2 设 $\ell: \mathbb{R} \rightarrow \mathbb{R}$ 是二阶可微函数, 且 $\varphi: \mathbb{C}^n \rightarrow [0, \infty)$, $\varphi(z) = |\langle a, z \rangle|^2$, 其中 $a \in \mathbb{C}^n$ 。则有

$$\begin{pmatrix} v \\ \bar{v} \end{pmatrix}^* \nabla^2(\ell \circ \varphi)(z) \begin{pmatrix} v \\ \bar{v} \end{pmatrix} \leq \left(2\ell''(|\langle a, z \rangle|^2) |\langle a, z \rangle|^2 + \ell'(|\langle a, z \rangle|^2) \right) \|a\|_2^2 \left\| \begin{pmatrix} v \\ \bar{v} \end{pmatrix} \right\|_2^2$$

对于所有 $z, v \in \mathbb{C}^n$ 成立。

证明 函数 $(\ell \circ \varphi)(z, \bar{z}) = \ell(\bar{z}^T a a^* z)$ 的 Wirtinger 导数为

$$\begin{aligned} \partial_z(\ell \circ \varphi)(z, \bar{z}) &= \partial_z(\ell \circ \varphi)(z, \bar{z})|_{\bar{z}=\text{const.}} \\ &= \ell'(\bar{z}^T a a^* z) \bar{z}^T a a^* = \ell'(|\langle a, z \rangle|^2) z^* a a^*. \end{aligned}$$

对于二阶导数, 我们得到

$$\begin{aligned} \partial_z \left(\partial_z(\ell \circ \varphi)(z, \bar{z}) \right)^* &= \partial_z \left(\ell'(|\langle a, z \rangle|^2) a a^* z \right) \\ &= \ell''(|\langle a, z \rangle|^2) |\langle a, z \rangle|^2 a a^* + \ell'(|\langle a, z \rangle|^2) a a^*, \end{aligned}$$

类似地有

$$\partial_{\bar{z}} \left(\partial_z(\ell \circ \varphi)(z, \bar{z}) \right)^* = \partial_{\bar{z}} \left(\ell'(|\langle a, z \rangle|^2) a a^* z \right) = \ell''(|\langle a, z \rangle|^2) \langle a, z \rangle^2 a a^T.$$

结合式 (5), 我们得到

$$\begin{aligned} \begin{pmatrix} v \\ \bar{v} \end{pmatrix}^* \nabla^2(\ell \circ \varphi)(z) \begin{pmatrix} v \\ \bar{v} \end{pmatrix} &= 2 \left(\ell''(|\langle a, z \rangle|^2) |\langle a, z \rangle|^2 + \ell'(|\langle a, z \rangle|^2) \right) |\langle a, v \rangle|^2 \\ &\quad + 2 \operatorname{Re} \left(\ell''(|\langle a, z \rangle|^2) \langle a, z \rangle^2 \langle a, v \rangle^2 \right) \\ &\leq 2 \left(2\ell''(|\langle a, z \rangle|^2) |\langle a, z \rangle|^2 + \ell'(|\langle a, z \rangle|^2) \right) |\langle a, v \rangle|^2 \\ &\leq \left(2\ell''(|\langle a, z \rangle|^2) |\langle a, z \rangle|^2 + \ell'(|\langle a, z \rangle|^2) \right) \|a\|_2^2 \left\| \begin{pmatrix} v \\ \bar{v} \end{pmatrix} \right\|_2^2, \end{aligned}$$

其中我们使用了对于任意 $\alpha, \beta \in \mathbb{C}$, 有不等式 $\operatorname{Re}(\alpha^2 \beta^2) \leq |\alpha|^2 |\beta|^2$ 。□

为了应用 Theorem 1 中的收敛结果, 我们需要对 $2\ell''(x)x + \ell'(x)$ 在 $x \in [0, \infty)$ 上进行常数界定, 并且需要证明 $\ell \circ \varphi$ 的水平集是紧的。关于水平集的紧性将在下面的引理中讨论。

Lemma 3 设 $f: \mathbb{C}^n \rightarrow \mathbb{R}, z \mapsto \sum_{i=1}^m |\langle a_i, z \rangle|^2$, 其中 $a_i \in \mathbb{C}^n, i = 1, \dots, m$ 。用矩阵 A 表示其行向量为 $a_i^*, i = 1, \dots, m$ 。对于任意 $z_0 \in \mathbb{C}^n$, 函数 f 限制在 $z_0 + \text{range}(A^*)$ 上的水平集是紧的。

证明 考虑任意 $z \in z_0 + \text{range}(A^*)$ 。利用 $\sum_{i=1}^m |\langle a_i, z \rangle|^2 = \|Az\|_2^2$ 。由于 $z_0 = \hat{z}_0 + \tilde{z}_0$, 其中 $\hat{z}_0 \in \ker(A), \tilde{z}_0 \in \text{range}(A^*)$ 。向量 $\tilde{z} := z - \hat{z}_0$ 是 z 在 A^* 值域上的正交投影。由于 $\tilde{z}$ 与 A 的核正交, 有 $\|A\tilde{z}\|_2^2 \geq \sigma_{\min}^2 \|\tilde{z}\|_2^2$, 其中 $\sigma_{\min}$ 是矩阵 A 的最小非零奇异值。进一步, 因为 $\|Az\|_2^2 = \|A\tilde{z}\|_2^2$, 所以我们可以继续估计

$$\|Az\|_2^2 \geq \sigma_{\min}^2 \|\tilde{z}\|_2^2 \geq \sigma_{\min}^2 (\|z\|_2^2 - \|\hat{z}_0\|_2^2).$$

由于 $\sigma_{\min}$ 和 $\|\hat{z}_0\|_2^2$ 对所有 $z \in z_0 + \text{range}(A^*)$ 是常数, 这表明对于所有 $z \in z_0 + \text{range}(A^*)$, $\|Az\|_2^2$ 可以被 $\|z\|_2^2$ 的一个缩放和平移版本从下界约束。由于映射 $z \mapsto \|z\|_2^2$ 具有紧的水平集, 函数 f 在 $z_0 + \text{range}(A^*)$ 上的水平集是紧的。□

Remark 4 根据 Theorem 3, 如果函数 $\ell_i: [0, \infty) \rightarrow \mathbb{R}, i = 1, \dots, m$ 连续、下界有界, 且满足当 $t \rightarrow \infty$ 时 $\ell_i(t) \rightarrow \infty$, 则 $\sum_{i=1}^m \ell_i(|\langle a_i, z \rangle|^2)$ 在 $z_0 + \text{range}(A^*)$ 上具有紧致的水平集。

3 相位恢复作为一个优化问题

如上所述, 我们的目标是在对测量过程的随机性质做出一定假设的条件下, 重建相位恢复问题 (1) 的 (近似) 解。我们的关注点在于那些测量过程可以建模为泊松分布随机过程的情况。为了将这一假设与变分重建方法结合起来, 我们采用最大 (对数) 似然估计。

3.1 泊松对数似然损失

为了最大化具有真实值 $|\langle a_i, x \rangle|^2$ 的泊松分布随机变量 y_i 的 (对数) 似然函数, 我们需要确定 z 使得 $\sum_{i=1}^m (y_i \log(|\langle a_i, z \rangle|^2) - |\langle a_i, z \rangle|^2)$ 达到最大。

这等价于确定 $\arg \min_z \mathcal{L}_P(z)$, 其中

$$\mathcal{L}_P(z) = \sum_{i=1}^m |\langle a_i, z \rangle|^2 - y_i \log(|\langle a_i, z \rangle|^2). \quad (7)$$

如前所述, 我们关注的是在某些像素处计数可能为零的测量场景。在这些情况下, 我们需要考虑值 $|\langle a_i, z \rangle|^2 = 0$, 这会导致损失函数 $\mathcal{L}_P$ 中出现奇异点。处理它们的一个简单策略是通过正数常数 $\varepsilon > 0$ 对对数项进行平移, 即

$$\mathcal{L}_{P,\varepsilon}(z) = \sum_{i=1}^m |\langle a_i, z \rangle|^2 - y_i \log(|\langle a_i, z \rangle|^2 + \varepsilon). \quad (8)$$

相应的带有常数步长的梯度下降更新规则为

$$z_{k+1} = z_k - \mu \sum_{i=1}^m \left(1 - \frac{y_i}{|\langle a_i, z_k \rangle|^2 + \varepsilon} \right) \langle a_i, z_k \rangle a_i.$$

然而, 参数的合适选择并不明显。在这方面, 例如可以研究类似于 [35, 36] 的差异原则。我们则提出考虑泊松损失 (8) 的一个近似。下一节将讨论一个合适的近似方法。

3.2 高斯对数似然和方差稳定

回顾一下, 对于服从高斯分布的随机变量 y_i , 其分布为 $\mathcal{N}(|\langle a_i, x \rangle|^2, \sigma_i^2)$, $i = 1, \dots, m$, 最大对数似然损失函数表示为

$$\mathcal{L}(z) = \sum_{i=1}^m \frac{1}{2\sigma_i^2} \left(|\langle a_i, z \rangle|^2 - y_i \right)^2. \quad (9)$$

通常, 即使底层过程是计数过程, 即随机变量服从泊松分布, 该损失函数也常用于图像重建。在泊松分布 $Poisson(\lambda)$ 中, 当方差参数 λ 充分大时, 这种做法是有道理的。在这种情况下, 中心极限定理表明 $Poisson(\lambda)$ 可以被近似为高斯分布 $\mathcal{N}(\lambda, \lambda)$ 。然而, 在低剂量场景下, 该近似不再适用。

另一种将泊松随机变量近似为高斯随机变量的方法是所谓的方差稳定方法 [37–40]。该方法对泊松数据进行变换, 使得得到的随机变量具有近似恒定的方差。该方法的原理如下。设 $\lambda > 0$ 且 $X \sim Poisson(\lambda)$ 。假设函数 $f: \mathbb{R}_{\geq 0} \rightarrow \mathbb{R}$ 足够光滑。则其在方差 λ 处的一阶泰勒近似为 $f(t) \approx f(\lambda) + (t - \lambda)f'(\lambda)$, 因此有 $\mathbb{V}(f(X)) \approx \mathbb{V}(X) (f'(\lambda))^2$ 。为了获得近似恒定的方差, 将上述等式右侧设为 σ^2 , 从而得到 $f(t) = 2\sigma\sqrt{t}$ 。该方法可追溯到

[37, 38], 并由 Anscombe 在 [40] 中通过五阶泰勒近似进行了修改, 以处理方差 λ 较小时的情况。Anscombe 使用了移位平方根变换 $f(t) = \sqrt{t+c}$ 。依据上述相同的推理, 可得

$$\begin{aligned}\mathbb{V}(\sqrt{X+c}) &\approx (\lambda+c) \cdot \mathbb{V}\left[1 + \frac{1}{2} \cdot \frac{X-\lambda}{\sqrt{\lambda+c}} - \frac{1}{8} \left(\frac{X-\lambda}{\sqrt{\lambda+c}}\right)^2 + \frac{1}{16} \left(\frac{X-\lambda}{\sqrt{\lambda+c}}\right)^3 \right. \\ &\quad \left. - \frac{5}{128} \left(\frac{X-\lambda}{\sqrt{\lambda+c}}\right)^4 + \frac{7}{256} \left(\frac{X-\lambda}{\sqrt{\lambda+c}}\right)^5 \right] \\ &\approx \frac{1}{4} \cdot \left(1 + \frac{\frac{3}{8}-c}{\lambda} + \frac{32c^2-52c+17}{32\lambda^2}\right),\end{aligned}$$

这表明选择 $c = \frac{3}{8}$ 可使得 $\mathbb{V}(X) \approx 1/4$ 。

然而, 当 $\lambda \in [0, 2]$ 时, 简单的平方根变换和 Anscombe 变换均表现不佳, 因此我们寻求一种更合适的平方根型方差稳定变换 $f(t) = \sqrt{t+c}$ 。我们尝试确定参数 $c > 0$, 使得 $\mathbb{V}(\sqrt{X+c}) = 1/4$, 通过考虑

$$\begin{aligned}\mathbb{V}(\sqrt{X+c}) &= \mathbb{E}(X) + c - \left[\mathbb{E}(\sqrt{X+c})\right]^2 \\ &= \lambda + c - \left(\sum_{k=0}^{\infty} \sqrt{k+c} \cdot \frac{\exp(-\lambda)\lambda^k}{k!}\right)^2,\end{aligned}$$

并将其设为 $1/4$ 来获得一个近似最优的 c 值。通过此方法, 对于 $\lambda = 1$, 最优值为 $c \approx 0.12$, 对于 $\lambda = 2$, 最优值为 $c \approx 0.27$ 。

为了不仅覆盖单一 λ 值对应的一个最优 c , 我们建议考虑一个平均变换

$$f(z) = \frac{1}{2} (\sqrt{z+c_1} + \sqrt{z+c_2}) \quad (10)$$

其中 $c_1, c_2 \geq 0$ 。此类变换的一个例子是 Tukey-Freeman 变换 [41]

$$f(z) = \frac{1}{2} (\sqrt{z} + \sqrt{z+1}) \quad (11)$$

该变换在 λ 较小时表现良好。我们在以 1 和 2 计数为主的实验中采用 $c_1 = 0.12$ 和 $c_2 = 0.27$ 。理由是对于此类大小的观测, 底层真值很可能接近 1 或 2。该变换相较于平方根变换和 Anscombe 变换的性能可见 Figure 1。

通过 Figure 1 可观察到当 λ 接近 0 时, 平方根变换可能优于其他方差稳定变换。上述方法也表明, 当 $\lambda \rightarrow 0$ 时, 最优选择的 c 趋近于 0。




图 1 方差稳定变换。

回到合适损失函数的讨论，我们可以使用任一给出的方差稳定变换 f 并考虑损失函数

$$\mathcal{L}(z) = \sum_{i=1}^m 2 \left(g(|\langle a_i, z \rangle|^2) - f(y_i) \right)^2,$$

该损失函数表示高斯分布 $\mathcal{N}(g(|\langle a_i, z \rangle|^2), 1/4)$ 的对数似然，其中函数 g 满足 $g(X) = \mathbb{E}(f(X))$ 。

若考虑变换 $f(x) = \sqrt{x+c}$ ，其中 $c \geq 0$ ，稳定泊松随机变量的方差约为 $1/4$ ，则变换后随机变量的均值近似为

$$\mathbb{E}(\sqrt{X+c}) = \sqrt{\mathbb{E}(X+c) - \mathbb{V}(\sqrt{X+c})} \approx \sqrt{\mathbb{E}(X) + c - \frac{1}{4}}. \quad (12)$$

因此，我们可以采用损失函数

$$\mathcal{L}(z) = \sum_{i=1}^m 2 \left(\sqrt{|\langle a_i, z \rangle|^2 + c - \frac{1}{4}} - \sqrt{y_i + c} \right)^2. \quad (13)$$

此类损失函数的特例是振幅损失

$$\mathcal{L}(z) = \sum_{i=1}^m 2 \left(\sqrt{|\langle a_i, z \rangle|^2 + \varepsilon} - \sqrt{y_i} \right)^2, \quad (14)$$

其中 $\varepsilon > 0$ ，该损失函数近年来在相位恢复领域受到关注，见 [20, 21]。该损失函数基于涉及平方根变换的高斯模型，但忽略了关系 (12)，而是使用了粗略近似 $\mathbb{E}(\sqrt{X}) \approx \sqrt{\mathbb{E}(X)}$ 。

基于高斯模型的最大似然损失函数，采用 Anscombe 变换（即 $c = \frac{3}{8}$ ）的做法，之前已在例如 [42] 中考虑，并在 [43] 中研究了混合泊松-高斯噪

声情况。这些工作同样使用了近似 $\mathbb{E}(\sqrt{X+3/8}) \approx \sqrt{\mathbb{E}(X+3/8)}$ ，而非 (12)。

虽然损失函数 (13) 非常符合我们考虑的问题设置，但若 $c \leq 1/4$ ，对该损失函数应用梯度下降法存在问题。当 z 满足 $|\langle a_i, z \rangle|^2 \in [0, 1/4 - c]$ 时，损失函数未定义，且在 $|\langle a_i, z \rangle|^2 = 1/4 - c$ 不可微。因此，我们需要再次进行正则化以解决该问题。我们决定同样采用粗略近似 $\mathbb{E}(\sqrt{X+c}) \approx \sqrt{\mathbb{E}(X+c)}$ ，并考虑

$$\mathcal{L}(z) = \sum_{i=1}^m 2 \left(\sqrt{|\langle a_i, z \rangle|^2 + c} - \sqrt{y_i + c} \right)^2. \quad (15)$$

调整分布期望的思路在诸如 [16] 等工作中未被体现。这些方法意在平滑损失函数。而我们还希望损失函数接近泊松模型。然而，在低照度实验中，底层真值远小于 1，方差稳定变换后的方差接近 0，因此近似 (12) 不适用于极低剂量实验，故我们放弃在均值近似中减去 1/4，更倾向于使用 (15)。

更一般地，我们也可以使用带参数 $c_1, c_2 \geq 0$ 的平均变换 (10) 进行方差稳定。出于前述相同原因，我们采用粗略近似

$$\mathbb{E}(\sqrt{X+c_1} + \sqrt{X+c_2}) \approx \sqrt{\mathbb{E}(X)+c_1} + \sqrt{\mathbb{E}(X)+c_2},$$

并考虑形式为

$$\mathcal{L}(z) = \sum_{i=1}^m \frac{1}{2} \left(\sqrt{|\langle a_i, z \rangle|^2 + c_1} + \sqrt{|\langle a_i, z \rangle|^2 + c_2} - \sqrt{y_i + c_1} - \sqrt{y_i + c_2} \right)^2.$$

的损失函数。

所有讨论的方差稳定变换仅在分布参数 $\lambda > 0$ 时，使方差近似为 1/4。因此，当底层真值等于或接近 0 时，使用由方差稳定变换导出的损失函数可能不合适。在实验中，底层真值未知，但若 $y_i = 0$ ，相应底层真值很可能接近 0，因此我们希望避免对这些样本使用方差稳定变换。注意，对于 $y_i = 0$ ，在精确的泊松对数似然模型中无需正则化，因为损失函数简化为项 $|\langle a_i, z \rangle|^2$ 。因此，我们建议在处理以零测量为主的低剂量数据时，考虑

$$\mathcal{L}_0(z) = \sum_{i=1}^m \mathbb{1}_{y_i > 0} \cdot \frac{1}{2} \left(\sqrt{|\langle a_i, z \rangle|^2 + c_1} + \sqrt{|\langle a_i, z \rangle|^2 + c_2} - C \right)^2 \quad (16)$$

$$+ \mathbb{1}_{y_i=0} \cdot |\langle a_i, z \rangle|^2,$$

其中 $c_2 \geq c_1 > 0$, $C \geq 0$ 。

4 相位恢复梯度下降算法的收敛性分析

下面, 我们分析基于 Section 3.1 和 Section 3.2 中讨论的损失函数的优化问题的梯度下降算法的收敛性。

首先, 我们给出基于泊松对数似然损失的梯度下降算法的收敛性保证。

Theorem 5 设 $\varepsilon > 0$ 且 $\mathcal{L}_{P,\varepsilon}(z) = \sum_{i=1}^m |\langle a_i, z \rangle|^2 - y_i \log(|\langle a_i, z \rangle|^2 + \varepsilon)$ 。令矩阵 M 的行向量为 $\sqrt{1 + \frac{y_i}{8\varepsilon}} \cdot a_i^*$, $i = 1, \dots, m$, 并选取 $\mu \leq \|M\|^{-2}$ 。则由下式定义的序列 $(z_k)_{k \geq 0} \subset \mathbb{C}^n$

$$z_{k+1} = z_k - \mu \cdot \sum_{i=1}^m \left(1 - \frac{y_i}{|\langle a_i, z_k \rangle|^2 + \varepsilon} \right) \langle a_i, z_k \rangle a_i$$

收敛于 $\mathcal{L}_{P,\varepsilon}$ 的一个驻点。

证明 我们将应用 Theorem 1。由于 $\mathcal{L}_{P,\varepsilon}(z) = \sum_{i=1}^m \ell_i \circ \varphi(z)$, 其中 $\ell_i : [0, \infty) \rightarrow \mathbb{R}$, $t \mapsto t - y_i \log(t + \varepsilon)$ 且 $\varphi(z) = |\langle a_i, z \rangle|^2$, 我们计算

$$\begin{aligned} 2 \cdot \ell_i''(t) \cdot t + \ell_i'(t) &= 2 \cdot \frac{y_i}{(t + \varepsilon)^2} \cdot t + 1 - \frac{y_i}{t + \varepsilon} \\ &= 1 + \frac{y_i(t - \varepsilon)}{(t + \varepsilon)^2} \leq 1 + \frac{y_i}{8\varepsilon}, \end{aligned}$$

其中我们使用了 $\frac{s - \varepsilon}{(s + \varepsilon)^2} \leq \frac{1}{8\varepsilon}$ 对任意 $s \in \mathbb{R}$ 及任意固定 $\varepsilon > 0$ 成立。结合 Theorem 2 和该界限, 我们得到

$$\begin{aligned} \left(\frac{v}{\bar{v}} \right)^* \nabla^2 \mathcal{L}_{P,\varepsilon}(z) \left(\frac{v}{\bar{v}} \right) &\leq 2 \cdot \sum_{i=1}^m \left| \left\langle \sqrt{1 + \frac{y_i}{8\varepsilon}} \cdot a_i, v \right\rangle \right|^2 \\ &\leq 2 \|M\|^2 \|v\|_2^2 = \|M\|^2 \left\| \begin{pmatrix} v \\ \bar{v} \end{pmatrix} \right\|_2^2 \end{aligned}$$

对所有 $z, v \in \mathbb{C}^n$ 成立。剩下的工作是证明 $\mathcal{L}_{P,\varepsilon}$ 在子空间 $z_0 + \text{range}(A^*)$ 上具有紧的子平面集, 该子空间包含算法可能达到的所有迭代点。这一点由 Theorem 3 和 Theorem 4 得出。显然, 所有函数 ℓ_i 都是连续且有下界

的。此外，我们可以找到 $k_1 > 0$ 和 $k_2 \in \mathbb{R}$ ，使得对所有 $t \in [0, \infty)$ ，都有 $\ell_i(t) \geq k_1 \cdot t + k_2$ ，因此 $\ell_i(t) \rightarrow \infty$ 当 $t \rightarrow \infty$ 。然后，利用 Theorem 1，我们得出所考虑的梯度下降算法收敛到损失函数 $\mathcal{L}_{P,\varepsilon}$ 的一个驻点。 $\square$

Theorem 5 的主要结论是，保证收敛的步长必须与正则化参数 ε 同阶。如果我们希望只用很小的正则化参数来影响问题，这就要求选择很小的步长，但在所有迭代中使用恒定的小步长会导致收敛缓慢。

在文献 [13] 中，给出了一种类似算法的收敛性分析。与我们关于收敛到驻点的理论不同，[13] 的作者给出了收敛到真实解的保证。然而，这一保证仅在良好初始化且测量向量 a_i 为高斯随机向量的情况下成立，而我们的结果独立于初始化质量，适用于任意测量系统，因此对于实际应用更具意义。

接下来，我们对基于 Section 3.2 中考虑的损失函数类别的梯度下降算法进行收敛性分析。

Theorem 6 设

$$\mathcal{L}_{avg}(z) = \sum_{i=1}^m \frac{1}{2} \left(\sqrt{|\langle a_i, z \rangle|^2 + c_1} + \sqrt{|\langle a_i, z \rangle|^2 + c_2} - C \right)^2, \quad (17)$$

其中常数满足 $c_2 \geq c_1 > 0$, $C \geq 0$ 。对于任意 $z_0 \in \mathbb{C}^n$ 定义序列 $(z_k)_{k \geq 1}$ 如下

$$\begin{aligned} z_{k+1} = z_k - \mu \cdot \frac{1}{2} \sum_{i=1}^m \left(\sqrt{|\langle a_i, z_k \rangle|^2 + c_1} + \sqrt{|\langle a_i, z_k \rangle|^2 + c_2} - C \right) \\ \cdot \left(\frac{1}{\sqrt{|\langle a_i, z_k \rangle|^2 + c_1}} + \frac{1}{\sqrt{|\langle a_i, z_k \rangle|^2 + c_2}} \right) \langle a_i, z_k \rangle a_i. \end{aligned}$$

则，当步长满足 $\mu \leq 2 \left((3 + \sqrt{c_2/c_1}) \|A\|^2 \right)^{-1}$ 时，序列 $(z_k)_{k \geq 0}$ 收敛到损失函数 $\mathcal{L}_{avg}$ 的一个驻点，其中矩阵 A 是由行向量 a_i^* , $i = 1, \dots, m$ 组成的矩阵。

证明 我们按照 Theorem 5 的证明方法进行。利用 Theorem 2，对 $\mathcal{L}_{avg}$ 的 Hessian 进行界定，其中 $\ell_i : [0, \infty) \rightarrow [0, \infty)$, $t \mapsto \frac{1}{2} (\sqrt{t+c_1} + \sqrt{t+c_2} - C)^2$ 。我们有

$$\ell'(t) = \frac{1}{2} (\sqrt{t+c_1} + \sqrt{t+c_2} - C) \cdot \left(\frac{1}{\sqrt{t+c_1}} + \frac{1}{\sqrt{t+c_2}} \right)$$

$$= \frac{1}{2} \left[2 + \frac{\sqrt{t+c_1}}{\sqrt{t+c_2}} + \frac{\sqrt{t+c_2}}{\sqrt{t+c_1}} - C \cdot \left(\frac{1}{\sqrt{t+c_1}} + \frac{1}{\sqrt{t+c_2}} \right) \right],$$

由此得到

$$\begin{aligned} \ell''(t) &= \frac{1}{4} \left(\frac{1}{\sqrt{t+c_1}} + \frac{1}{\sqrt{t+c_2}} \right)^2 \\ &\quad - \frac{1}{4} (\sqrt{t+c_1} + \sqrt{t+c_2} - C) \cdot \left(\frac{1}{(t+c_1)^{\frac{3}{2}}} + \frac{1}{(t+c_2)^{\frac{3}{2}}} \right) \\ &= \frac{1}{4} \left[\frac{2}{\sqrt{t+c_1}\sqrt{t+c_2}} - \frac{\sqrt{t+c_1}}{(t+c_2)^{\frac{3}{2}}} - \frac{\sqrt{t+c_2}}{(t+c_1)^{\frac{3}{2}}} \right. \\ &\quad \left. + C \cdot \left(\frac{1}{(t+c_1)^{\frac{3}{2}}} + \frac{1}{(t+c_2)^{\frac{3}{2}}} \right) \right] \\ &\leq \frac{1}{4} C \cdot \left(\frac{1}{(t+c_1)^{\frac{3}{2}}} + \frac{1}{(t+c_2)^{\frac{3}{2}}} \right). \end{aligned}$$

在对二阶导数的界定中, 我们使用了 $\frac{2}{\alpha\beta} \leq \frac{\alpha}{\beta^3} + \frac{\beta}{\alpha^3}$, 其中 $\alpha, \beta \in \mathbb{R}$ 。因此, 我们得到

$$\begin{aligned} 2t\ell''(t) + \ell'(t) &\leq \frac{1}{2} C \cdot \left(\frac{t}{(t+c_1)^{\frac{3}{2}}} + \frac{t}{(t+c_2)^{\frac{3}{2}}} \right) \\ &\quad + \frac{1}{2} \left[2 + \frac{\sqrt{t+c_1}}{\sqrt{t+c_2}} + \frac{\sqrt{t+c_2}}{\sqrt{t+c_1}} - C \cdot \left(\frac{1}{\sqrt{t+c_1}} + \frac{1}{\sqrt{t+c_2}} \right) \right] \\ &= \frac{1}{2} \left(-C \cdot \left(\frac{c_1}{\sqrt{t+c_1}} + \frac{c_2}{\sqrt{t+c_2}} \right) + 2 + 1 + \sqrt{\frac{c_2}{c_1}} \right) \\ &\leq \frac{1}{2} \left(3 + \sqrt{\frac{c_2}{c_1}} \right), \end{aligned}$$

进而有

$$\begin{aligned} \begin{pmatrix} v \\ \bar{v} \end{pmatrix}^* \nabla^2 \mathcal{L}_{avg}(z) \begin{pmatrix} v \\ \bar{v} \end{pmatrix} &\leq \sum_{i=1}^m \left(3 + \sqrt{\frac{c_2}{c_1}} \right) |\langle a_i, v \rangle|^2 \\ &\leq \frac{1}{2} \left(3 + \sqrt{\frac{c_2}{c_1}} \right) \|A\|^2 \left\| \begin{pmatrix} v \\ \bar{v} \end{pmatrix} \right\|_2^2 \end{aligned}$$

对所有 $z, v \in \mathbb{C}^n$ 成立。这表明可以选择 $\mu = 2 \left((3 + \sqrt{c_2/c_1}) \|A\|^2 \right)^{-1}$ 。

函数 $\mathcal{L}_{avg}$ 限制在 $z_0 + \text{range}(A^*)$ 上具有紧的平面集, 根据 Theorem 3 和 Theorem 4, 因为所有函数 ℓ_i 都是连续的, 有下界, 且满足 $\ell_i(t) \rightarrow \infty$ 当 $t \rightarrow \infty$ 。由 Theorem 1, 梯度下降算法收敛到损失函数 $\mathcal{L}_{avg}$ 的一个驻点。□

由此结果, 我们也得到了使用梯度下降算法处理损失函数 (13) 或 (14) 时的步长选择规则。

Corollary 7 对于某个正则化参数 $\varepsilon > 0$, 通过使用步长 $\mu \leq \left(2 \|A\|^2 \right)^{-1}$ 的相应梯度下降算法, 可以实现对损失函数 (14) 的驻点的收敛。

这与 [20] 中的定理 A.1 相同, 这意味着我们将 [20] 对幅度损失的收敛保证推广到了损失函数类别 (17)。

该结果与 Theorem 5 中泊松对数似然损失的收敛保证的重要区别在于, 保证收敛所需的步长界限与可能较小的正则化参数无关。

Corollary 8 使用 *Tukey-Freeman* 变换 (11) 进行方差稳定化的损失函数形式为

$$\mathcal{L}(z) = \sum_{i=1}^m \frac{1}{2} \left(\sqrt{|\langle a_i, z \rangle|^2 + \varepsilon} + \sqrt{|\langle a_i, z \rangle|^2 + 1} - \sqrt{y_i} - \sqrt{y_i + 1} \right)^2,$$

其中 $\varepsilon > 0$ 用以避免导数的奇异性。根据 Theorem 6, 我们得出结论, 使用此损失函数的梯度下降算法要求步长 $\mu \leq 2 \left((3 + \sqrt{1/\varepsilon}) \|A\|^2 \right)^{-1}$ 以保证收敛。

这意味着对于这种类型的方差稳定变换, 我们同样面临与泊松对数似然损失类似的问题。

对于我们最终提出的损失 $\mathcal{L}_0$, 同样可以使用相同的固定步长, 并保证收敛到损失函数的一个驻点。

Corollary 9 通过对应的梯度下降算法, 且步长 $\mu \leq 2 \left((3 + \sqrt{c_2/c_1}) \|A\|^2 \right)^{-1}$, 可以实现对在式 (16) 中定义的损失函数 $\mathcal{L}_0$ 的驻点收敛。

5 数值实验

5.1 带有泊松噪声的低剂量数据相位恢复

我们通过数值实验验证了理论分析，即从模拟的低剂量泊松相位恢复测量中重建目标物体。我们的模拟基于测试目标 $x \in \mathbb{C}^n$ ，其中 $n = 256$ ，以及复高斯测量向量 $a_i \in \mathbb{C}^n$ ， $i = 1, \dots, m$ ，其中 $m = 10n$ 。我们将测量值归一化，使得 $\sum_{i=1}^m |\langle a_i, x \rangle|^2 = 1$ ，并将无噪声值 $|\langle a_i, x \rangle|^2$ 理解为光子到达第 i 个探测像素的概率。我们选择一个剂量 $d \in \mathbb{N}$ ，并使用测量值

$$y_i \sim \text{Poisson} \left(d \cdot |\langle a_i, x \rangle|^2 \right), \quad i = 1, \dots, m.$$

在以下实验中，我们尝试的剂量为 $d \in \{500, 1000, 1500, \dots, 4000\}$ 。图 Figure 2 中的直方图展示了剂量为 $d = 500$ 和 $d = 4000$ 时测量分布的示例实现。最低剂量对应的信噪比定义为 $SNR := \|(d \cdot |\langle a_i, x \rangle|^2)_{i=1}^m\|_2 / \|(y_i - d \cdot |\langle a_i, x \rangle|^2)_{i=1}^m\|_2$ 约为 0.6，最高剂量对应的信噪比约为 $SNR \approx 1.7$ 。




图 2 低剂量和高剂量实验的测量分布。

我们使用 [10] 中提出的幂法初始化所有考虑的算法。对于每个剂量，我们重复实验二十次，并展示重建结果的平均值。

5.1.1 带泊松对数似然的梯度下降

首先，我们比较了使用泊松对数似然损失函数 (8) 的梯度下降算法在不同正则化参数 ε 下的性能。相应的算法命名为“Poisson flow”。

Figure 3 展示了本实验中所讨论算法的性能，衡量指标为相对重构误差 $\min_{\theta \in [0, 2\pi]} \|x - e^{i\theta} \tilde{x}\|_2 / \|x\|_2$ ，其中 x 为真实信号， $\tilde{x}$ 为近似重构结果。该实验表明算法的性能明显依赖于正则化参数 ε 的选择。在高剂量实验中，算法对参数选择的敏感度较低，而在低剂量实验中则需要对 ε 的合理选择有一定了解。




图 3 泊松流在正则化参数 $\epsilon \in \{10^{-3}, 0.1, 0.25, 0.5, 1\}$ 下的性能表现。

我们想要补充说明的是，除了 (8)，我们也可以使用以下损失函数

$$\mathcal{L}(z) = \sum_{i=1}^m |\langle a_i, z \rangle|^2 - (y_i + \epsilon) \log (|\langle a_i, z \rangle|^2 + \epsilon).$$

对应的方法可以被理解为无偏的，因为该损失在满足 $|\langle a_i, z \rangle|^2 = y_i$, $i = 1, \dots, m$ 的 z 上达到最小值。因此，该方法对 ϵ 的选择不那么敏感。然而，我们在数值分析中发现，使用该损失函数对应的算法性能不如使用带有合适参数 ϵ 的 (8) 损失函数的算法。此外，建议的步长依然依赖于参数的问题仍然存在。

5.1.2 方差稳定化后的高斯对数似然梯度下降

此外，我们将泊松流与使用高斯对数似然损失的梯度下降算法进行了比较，比较内容包括是否采用方差稳定化。文献中常用“Wirtinger flow”一词表示使用损失函数 (9) 且常数方差 $\sigma_i^2 = 1/4$ 的算法。“Amplitude flow”指的是针对损失函数 (14) 的梯度下降算法。此处标记为“使用优化方差稳定化的流”的算法采用损失函数 (16)，其中 $c_1 = 0.12$, $c_2 = 0.27$ ，且 $C = \sqrt{y_i + c_1} + \sqrt{y_i + c_2}$ ；而“使用优化方差稳定化但不针对零值进行适配的流”算法则使用相同参数的损失函数 (17)。

Figure 4 中不同剂量下的相对重建误差曲线表明，采用建议的损失函数且包含针对零测量的泊松对数似然适配的优化方差稳定变换的算法，在接近最优正则化参数选择时，其表现可与泊松流相媲美。如果已知最优参数选择，合理的做法是应用泊松流；然而，如果没有相应的决策规则，建议使用含适配的正则化振幅损失函数形式。




图 4 不同讨论的损失函数下梯度下降算法的性能。灰色线对应于 Figure 3 中的泊松流。

我们注意到，对于零测量数占主导的低剂量实验，损失函数针对零测量的适配 (16) 是必不可少的。在使用振幅损失函数 (14) 的振幅流中，我们未包含此类适配。在这种特殊情况下，该适配隐含于方法中，因为振幅损失函数在零测量时对应于零测量的精确泊松对数似然损失。

除此之外，我们认识到对于非常低剂量实验，振幅流的表现与使用改进了低计数实验方差稳定变换的流同样良好。这可以通过以下事实解释：分布参数接近 0 时，平方根变换在方差稳定方面表现最佳，详见 Figure 1。

在解释重建结果时，我们必须注意处于低剂量范围内，且在数据冗余较少（即测量量较少）时，无法期望重建误差非常小。此外，我们还需考虑，在低剂量实验中，为了获得更多测量次数，每次测量的剂量必须相应降低，因为更多的测量会导致更多的损伤。

5.2 步长选择的讨论

对于使用高斯对数似然损失的 Wirtinger 流算法，我们并未找到像本文讨论的其他损失函数那样能够保证每次迭代中损失函数下降的常数步长。我们可以选择一个基于类似于本文所有证明思路的分析的迭代自适应步长，但无法消除对迭代变量的依赖。然而，这种实现计算开销较大，使得该损失函数的选择吸引力降低。实验中，我们采用了 [44] 中提出的步长，因为它在计算上更为高效。

对于所有其他算法，我们使用各自理论结果中提出的步长。

[34] 建议基于使用观测 Fisher 信息的 Hessian 近似来为泊松对数似然损失选择步长。据称，该步长加快了收敛速度，因为它比涉及因子 $1 + \frac{\mu_i}{8\epsilon}$

的倒数的步长更大。然而，与 Theorem 5 中推导的步长相比，基于 Fisher 信息的步长在每次迭代中都需进行线搜索，这导致计算开销较大。

在此，我们面临一个权衡：是采用一个独立于每次迭代中近似结果的常数步长以保证收敛，还是采用一个可以通过每次迭代中的步长优化使其独立于 ε 的步长规则。鉴于计算上的优势，我们更倾向于选择常数步长。

在数值实验中我们发现，对于较大的正则化参数 ε ，[34] 提出的步长相比我们的步长规则，并不能保证每次迭代损失的下降。虽然当 $\varepsilon \rightarrow 0$ 时我们的步长规则变得不切实际，但迭代依赖的步长规则则更有用，因为其不以 ε 的数量级减小。另一方面，实验显示极小的正则化参数 ε 并不合理。

我们得出结论：结合足够大的 ε 使用常数步长似乎是合理的。此外，我们再次强调，使用本文建议的良好方差稳定化的高斯对数似然，可以避免该权衡问题。

6 结论

本文研究了针对泊松对数似然问题的适当正则化和近似的梯度下降算法。基于低剂量成像实验的特点，我们设计了一种方法，能够更好地处理零测量值和其他小计数。对于所有讨论的算法，我们提供了包括步长规则在内的收敛性分析。

在将此类方法应用于实际数据方面，下一步是将合适的正则化项纳入优化问题，例如 [45] 或 [46] 中讨论的类型。正则化项的最佳选择高度依赖于所考虑对象的类型。未来的工作是为诸如利用低剂量照明成像的病毒等对象找到合理的问题表述。本文的一个可能的后续工作是将收敛性分析扩展到涉及此类正则化尝试的算法。

Declarations

Funding. The authors acknowledge support by the Helmholtz Association under the contracts No. ZT-I-0025 (Ptychography 4.0), No. ZT-I-PF-4-018 (AsoftXm), No. ZT-I-PF-5-28 (EDARTI), No. ZT-I-PF-4-024 (BRLEMMM). Patricia Römer was further financially supported by the German Research Foundation (DFG) grants KR 4512/1-1 and KR 4512/2-2.

References

- [1] Beinert, R., Plonka, G.: Ambiguities in one-dimensional discrete phase retrieval from Fourier magnitudes. *Journal of Fourier Analysis and Applications* **21**, 1169–1198 (2015)
- [2] Rodenburg, J., Maiden, A.: Ptychography. *Springer Handbook of Microscopy*, 819–904 (2019)
- [3] Pfeiffer, F.: X-ray ptychography. *Nature Photonics* **12**(1), 9–17 (2018)
- [4] Thibault, P., Dierolf, M., Bunk, O., Menzel, A., Pfeiffer, F.: Probe retrieval in ptychographic coherent diffractive imaging. *Ultramicroscopy* **109**(4), 338–343 (2009)
- [5] Fienup, J.R.: Phase retrieval algorithms: a comparison. *Applied optics* **21**(15), 2758–2769 (1982)
- [6] Balan, R., Casazza, P., Edidin, D.: On signal reconstruction without phase. *Applied and Computational Harmonic Analysis* **20**(3), 345–356 (2006)
- [7] Candes, E.J., Eldar, Y.C., Strohmer, T., Voroninski, V.: Phase retrieval via matrix completion. *SIAM review* **57**(2), 225–251 (2015)
- [8] Sun, J., Qu, Q., Wright, J.: A geometric analysis of phase retrieval. *Foundations of Computational Mathematics* **18**, 1131–1198 (2018)
- [9] Conca, A., Edidin, D., Hering, M., Vinzant, C.: An algebraic characterization of injectivity in phase retrieval. *Applied and Computational Harmonic Analysis* **38**(2), 346–356 (2015)
- [10] Candes, E.J., Li, X., Soltanolkotabi, M.: Phase retrieval via Wirtinger flow: Theory and algorithms. *IEEE Transactions on Information Theory* **61**(4), 1985–2007 (2015)
- [11] Zhang, H., Liang, Y., Chi, Y.: A nonconvex approach for phase

- retrieval: Reshaped wirtinger flow and incremental algorithms. *Journal of Machine Learning Research* **18**(141), 1–35 (2017)
- [12] Wang, G., Giannakis, G.B., Eldar, Y.C.: Solving systems of random quadratic equations via truncated amplitude flow. *IEEE Transactions on Information Theory* **64**(2), 773–794 (2017)
- [13] Chen, Y., Candès, E.J.: Solving random quadratic systems of equations is nearly as easy as solving linear systems. *Communications on pure and applied mathematics* **70**(5), 822–883 (2017)
- [14] Kolte, R., Özgür, A.: Phase retrieval via incremental truncated Wirtinger flow. *arXiv preprint arXiv:1606.03196* (2016)
- [15] Wang, G., Giannakis, G.B., Chen, J.: Scalable solvers of random quadratic equations via stochastic truncated amplitude flow. *IEEE Transactions on Signal Processing* **65**(8), 1961–1974 (2017)
- [16] Gao, B., Sun, X., Wang, Y., Xu, Z.: Perturbed amplitude flow for phase retrieval. *IEEE Transactions on Signal Processing* **68**, 5427–5440 (2020)
- [17] Tan, Y.S., Vershynin, R.: Phase retrieval via randomized Kaczmarz: theoretical guarantees. *Information and Inference: A Journal of the IMA* **8**(1), 97–123 (2019)
- [18] Huang, M., Wang, Y.: Linear convergence of randomized Kaczmarz method for solving complex-valued phaseless equations. *SIAM Journal on Imaging Sciences* **15**(2), 989–1016 (2022)
- [19] Römer, P., Filbir, F., Krahmer, F.: On the randomized Kaczmarz algorithm for phase retrieval. In: 2021 55th Asilomar Conference on Signals, Systems, and Computers, pp. 847–851 (2021). IEEE
- [20] Xu, R., Soltanolkotabi, M., Haldar, J.P., Unglaub, W., Zusman, J., Levi, A.F., Leahy, R.M.: Accelerated wirtinger flow: A fast algorithm for ptychography. *arXiv preprint arXiv:1806.05546* (2018)

- [21] Filbir, F., Melnyk, O.: Image Recovery for Blind Polychromatic Ptychography. *SIAM Journal on Imaging Sciences* **16**(3), 1308–1337 (2023)
- [22] Chang, H., Enfedaque, P., Zhang, J., Reinhardt, J., Enders, B., Yu, Y.-S., Shapiro, D., Schroer, C.G., Zeng, T., Marchesini, S.: Advanced denoising for X-ray ptychography. *Optics express* **27**(8), 10395–10418 (2019)
- [23] Melnyk, O., Römer, P.: Background Denoising for Ptychography via Wigner Distribution Deconvolution. *arXiv preprint arXiv:2402.15353* (2024)
- [24] Thibault, P., Guizar-Sicairos, M.: Maximum-likelihood refinement for coherent diffractive imaging. *New Journal of Physics* **14**(6), 063004 (2012)
- [25] Yeh, L.-H., Dong, J., Zhong, J., Tian, L., Chen, M., Tang, G., Soltanolkotabi, M., Waller, L.: Experimental robustness of Fourier ptychography phase retrieval algorithms. *Optics express* **23**(26), 33214–33240 (2015)
- [26] Hohage, T., Werner, F.: Inverse problems with Poisson data: statistical regularization theory, applications and algorithms. *Inverse Problems* **32**(9), 093001 (2016)
- [27] Chang, H., Lou, Y., Duan, Y., Marchesini, S.: Total variation-based phase retrieval for Poisson noise removal. *SIAM journal on imaging sciences* **11**(1), 24–55 (2018)
- [28] Fatima, G., Li, Z., Arora, A., Babu, P.: PDMM: A novel primal-dual Majorization-minimization algorithm for poisson phase-retrieval problem. *IEEE Transactions on Signal Processing* **70**, 1241–1255 (2022)
- [29] Glaeser, R.M.: Limitations to significant information in biological

- electron microscopy as a result of radiation damage. *Journal of ultrastructure research* **36**(3-4), 466–482 (1971)
- [30] Wang, J., Morin, C., Li, L., Hitchcock, A., Scholl, A., Doran, A.: Radiation damage in soft X-ray microscopy. *Journal of Electron Spectroscopy and Related Phenomena* **170**(1-3), 25–36 (2009)
 - [31] Küçükoglu, B., Mohammed, I., Guerrero-Ferreira, R.C., Ribet, S.M., Varnavides, G., Leidl, M.L., Lau, K., Nazarov, S., Myasnikov, A., Sachse, C., Müller-Caspary, K., Ophus, C., Stahlberg, H.: Low-dose cryo-electron ptychography of proteins at sub-nanometer resolution. *bioRxiv* 2024.02.12.579607 (2024)
 - [32] Pelz, P.M., Qiu, W.X., Bückner, R., Kassier, G., Miller, R.D.: Low-dose cryo electron ptychography via non-convex Bayesian optimization. *Scientific reports* **7**(1), 9883 (2017)
 - [33] Godard, P., Allain, M., Chamard, V., Rodenburg, J.: Noise models for low counting rate coherent diffraction imaging. *Optics express* **20**(23), 25914–25934 (2012)
 - [34] Li, Z., Lange, K., Fessler, J.A.: Poisson phase retrieval in very low-count regimes. *IEEE transactions on computational imaging* **8**, 838–850 (2022)
 - [35] Bertero, M., Boccacci, P., Talenti, G., Zanella, R., Zanni, L.: A discrepancy principle for Poisson data. *Inverse problems* **26**(10), 105004 (2010)
 - [36] Bevilacqua, F., Lanza, A., Pragliola, M., Sgallari, F.: Nearly exact discrepancy principle for low-count Poisson image restoration. *Journal of Imaging* **8**(1) (2021)
 - [37] Tippet, L.: 2-statistical methods in textile research. Part 2-Uses of the binomial and poisson distributions. *Journal of the Textile Institute Transactions* **26**(1), 13–50 (1935)

- [38] Bartlett, M.S.: The square root transformation in analysis of variance. Supplement to the Journal of the Royal Statistical Society **3**(1), 68–78 (1936)
- [39] Curtiss, J.H.: On transformations used in the analysis of variance. The Annals of Mathematical Statistics **14**(2), 107–122 (1943)
- [40] Anscombe, F.J.: The transformation of Poisson, binomial and negative-binomial data. Biometrika **35**(3/4), 246–254 (1948)
- [41] Freeman, M.F., Tukey, J.W.: Transformations related to the angular and the square root. The Annals of Mathematical Statistics, 607–611 (1950)
- [42] Konijnenberg, A., Coene, W., Urbach, H.: Study of cost functionals for ptychographic phase retrieval to improve the robustness against noise, and a proposal for another noise-robust ptychographic phase retrieval scheme. arXiv preprint arXiv:1703.10892 (2017)
- [43] Zhang, Y., Song, P., Dai, Q.: Fourier ptychographic microscopy using a generalized Anscombe transform approximation of the mixed Poisson-Gaussian likelihood. Optics express **25**(1), 168–179 (2017)
- [44] Chen, Z., Zhou, Y., Liang, Y., Lu, Z.: Generalized-Smooth Nonconvex Optimization is As Efficient As Smooth Nonconvex Optimization. arXiv preprint arXiv:2303.02854 (2023)
- [45] Le, T., Chartrand, R., Asaki, T.J.: A variational approach to reconstructing images corrupted by Poisson noise. Journal of mathematical imaging and vision **27**(3), 257–263 (2007)
- [46] Loock, S., Plonka, G.: Phase retrieval for Fresnel measurements using a shearlet sparsity constraint. Inverse Problems **30**(5), 055005 (2014)