

东北大学

本科毕业设计（论文）开题报告



题 目 基于检索增强与智能体协作的 LaTeX 论文

翻译系统设计与实现

学 院 计算机科学与工程

专 业 人工智能

学生姓名 徐浩淞

学 号 20226446 年 级 2022 级

指导教师 王会珍

教务处制表
二〇二五年十二月二十三日

选题意义	LaTeX 作为一种高质量的排版系统，已成为数学、物理、计算机科学等领域学术论文撰写的通用格式。据统计，arXiv 上超过 90% 的科学论文均采用 LaTeX 格式编写。然而，绝大多数顶尖学术成果均以英文发表，这给非英语母语的科研人员带来了巨大的阅读与写作障碍。 传统的机器翻译方法（如基于统计或神经网络的翻译）通常针对纯文本设计，直接应用于 LaTeX 源码时，往往会破坏复杂的文档结构（如数学公式、图表引用、宏定义），导致编译失败。虽然 PDF 文档翻译工具较为普及，但 PDF 解析过程中丢失的语义结构信息使得翻译质量大打折扣，且无法还原为可编辑的源码。 近年来，大语言模型展现出了卓越的多语言翻译能力，但在处理长篇幅、高专业度的科研文档时，仍面临两大核心挑战：一是“术语幻觉”，即无法保证垂直领域（如量子物理、深度学习）专业术语翻译的一致性；二是“上下文断层”，即无法理解跨段落的引用关系或图表语义。 针对上述问题，本课题拟设计并实现一个基于检索增强与智能体协作的 LaTeX 论文翻译系统。该系统旨在通过 RAG 技术引入外部专业知识库以确保术语准确性，利用 Multi-Agent 架构实现对文档结构、引用和图表的深层语义理解与工具调用，最终生成格式无损、术语专业、语义连贯的目标语言 LaTeX 源码，并实现编译成译文版本 pdf。本研究不仅能显著降低科研人员的语言门槛，同时也是探索 LLM 在复杂文档处理与 AI 工程化落地方面的一次有益实践。
国内外研究现状概述	随着人工智能技术的飞速发展，科学文献的机器翻译已从传统的统计机器翻译演进至神经机器翻译，并正向基于大语言模型的生成式翻译跨越。然而，针对 LaTeX 这种富含复杂排版命令、数学公式及跨模态引用（图表、文献）的结构化文档，现有的通用翻译方案容易导致结构丢失问题。本课题拟从大模型机器翻译、结构化文档处理、检索增强生成以及多智能体协作四个维度展开研究： 1.基于大语言模型的机器翻译：传统的 NMT 模型往往依赖大规模平行语料库进行训练，且在长文档翻译中容易出现上下文丢失问题。近年来，以 Transformer 为基础的预训练大语言模型（如 GPT-4, Gemini 等）展现了卓

越的零样本（Zero-shot）翻译能力。Brown 等人^[1]的研究表明，大模型仅需要通过少量示例提示即可在多种语言对上达到甚至超越监督系统的水平。Vilar 等人^[2]进一步探讨了提示工程（Prompting）对模型性能的影响，证实了通过优化提示策略可显著激活 PaLM 等模型的翻译潜力。国内学者车万翔等人^[3]在《中国科学：信息科学》的综述中指出，大模型时代自然语言处理的研究范式已从“预训练+微调”转向“预训练+提示学习”，赋予了模型强大的语义理解能力。针对科技文本领域，李银玲^[15]通过实证研究发现，在设计恰当的交互指令下，大语言模型在科技文本翻译的完整性、准确性和科学性上表现优异，但同时也存在译文略显冗长等局限性。此外，Jiao 等人^[4]的对比研究发现，虽然 ChatGPT 等模型在高资源语言对上的翻译质量已媲美顶级商业系统，但在处理低频术语及特定文化背景内容时仍存在不稳定性。Hendy 等人^[12]的研究也证实，在医学、法律等高精度要求的领域，未经专业微调的通用大模型在术语准确性上往往不及专用系统。

2.结构化文档与 LaTeX 解析技术研究：科学论文的翻译不仅是语言的转换，更是格式与结构的保持。LaTeX 作为一种图灵完备的排版语言，其嵌套的宏定义和数学公式给翻译带来了巨大障碍。LaTeX 翻译必须解决公式、图表等非语言符号的各种技术难题，以保持文本的逻辑严密性。现有的开源工具（如 MathTranslate）大多基于正则表达式或简单的规则替换，鲁棒性较差。Khan^[5]在结构化文本翻译研究中尝试了基于规则的转换，但难以适配 LaTeX 的灵活性。正如朱梓鸣等人^[6]在前期原型研究中验证的，缺乏对 LaTeX 抽象语法树（AST）的深层解析，直接将源码作为纯文本输入模型，会导致公式环境被错误翻译或宏命令丢失，因此基于 AST 的结构化解析与重构是实现无损翻译的关键。

3.检索增强生成（RAG）技术研究：为解决大模型的“幻觉”问题，检索增强生成技术应运而生。RAG 通过在生成过程中引入外部知识库，显著提升了内容的真实性和准确性。Lewis 等人^[7]提出的 RAG 架构通过联合训练检索器和生成器，成为该领域的开山之作。Gao 等人^[8]在关于 RAG 的综述中详细梳理了技术演进，指出当前的 RAG 已从朴素检索发展为包含“检索前预处理、检索后重排”的高级架构。在术语管理方面，冯志伟^[16]指出大

	语言模型时代为术语学发展提供了重要机遇，强调应将术语的民族化与国际化相结合，这为利用外部知识库规范术语翻译提供了理论依据。Pan 等人^[13]进一步提出将知识图谱与大模型融合（Unifying LLMs and KGs），这种结构化的知识增强方式对于解决科研论文中复杂的术语一致性问题提供了新的思路。然而尽管 RAG 发展迅速，但在处理 LaTeX 这种包含大量非自然语言符号（公式）的文档时，传统的文本切分策略往往会破坏语义单元，目前尚缺乏针对科研文档结构的专用 RAG 切分方案。 4.多智能体协作系统（Multi-Agent）研究：面对长篇幅、高复杂度的科研论文翻译任务，单一智能体往往难以兼顾全局规划、精准翻译和格式校对。多智能体系统通过角色分工与协作，展现了解决复杂任务的巨大潜力。Li 等人^[9]提出的 CAMEL 框架通过角色扮演机制，展示了交际智能体在复杂任务规划中的协作能力。Yang 等人^[14]在对 AutoGPT 的基准测试中，验证了智能体在在线决策制定方面的自主性与有效性。针对长文档翻译中常见的遗忘问题，Wang 等人^[10]提出的 Delta 代理通过引入多级记忆机制（Multi-level Memory），有效提升了文档级翻译的上下文连贯性。此外，针对大模型在特定领域能力的不足，Qin 等人^[11]提出的“工具学习”（Tool Learning）范式论证了大模型作为控制器，通过调用外部工具（如编译器、搜索引擎）来弥补自身短板的可行性，这为构建具备编译修复能力的智能体提供了理论支撑。 综上，尽管现有技术在各个单点上已取得进展，但将 AST 级文档解析、面向术语一致性的 RAG 技术以及具备编译修复能力的 Multi-Agent 架构有机整合，构建一个端到端的 LaTeX 论文翻译系统，仍具有重要的研究意义与应用价值。
主要研究内容	本课题旨在设计并开发一套面向科研场景的智能编译翻译系统。主要研究内容包括以下四个方面： 1.LaTeX 文档结构化解析与重构算法研究。针对 LaTeX 文档语法复杂、宏定义多样的特点，研究高鲁棒性的文档解析与重构方案，这是系统的基石。主要包括解析算法设计，研究基于抽象语法树的文档解析技术，设计专用的遍历算法，精准识别并剥离文档中的自然语言文本、数学公式、图表

	代码及宏命令；占位符保护机制，设计占位符替换还原策略，在翻译过程中对非文本元素进行掩码保护，防止大模型破坏文档结构；文档重构研究，研究译文与原始结构的回填算法，确保翻译后的文档能够保留原始排版格式并成功编译。 2.面向术语一致性的自适应 RAG 算法设计。为了解决垂直领域论文翻译中术语不一致、不准确的问题，将研究并实现一套高级检索增强生成流程。主要包括多源知识库构建，研究针对非结构化 PDF 文献及结构化术语表的自适应切分与向量化策略，构建多模态领域知识库；混合检索策略研究，设计基于查询转换的预处理机制，并研究语义向量检索与关键词精确检索相结合的混合检索算法，以提高术语召回率；重排机制设计，研究引入 Cross-Encoder 重排模型，对多路检索结果进行相关性精排，筛选注入提示词，从算法层面保障翻译的专业性。 3.基于多智能体的深度语义理解机制研究。利用 LangChain 框架，研究如何通过多智能体协作来解决翻译中的上下文依赖与多模态理解问题。主要包括智能体架构设计，设计包含规划者、翻译者、校验者的多智能体协同工作流；设计引用解析工具，研究通过 arXiv API 或 BibTeX 解析技术，实现对命令的语义链接，辅助模型理解引用背景；视觉理解工具，探索性研究调用多模态大模型，实现对图表内容的视觉识别，以提升图表标题的翻译准确度；自修正机制研究，设计基于编译器反馈的自动修正回路，当译文导致编译错误时，智能体能够自主分析日志并修复 LaTeX 语法错误。 4.系统全栈架构设计与工程化实现。主要包括微服务后端设计，基于 FastAPI 设计高性能的 RESTful API，研究任务队列管理机制以支持长文档的异步翻译处理；交互式前端设计，设计支持双栏对照预览、实时编译反馈的 Web 前端界面，提升用户体验；容器化部署研究，研究 Docker 容器化技术与编排方案，实现系统服务的一键部署与高可用交付。
--	---

本课题拟采用“基于 AST 的结构化解析 + 混合检索增强 (Hybrid RAG) + 多智能体协作 (Multi-Agent)”的技术路线，构建端到端的 LaTeX 论文翻译系统。系统架构如图 1 所示，主要包含输入层、处理核心层（解析模组、RAG 模组、Agent 核心）及输出层。




图 1 系统架构图设计

拟采用的研究思路如下：

1. 基于抽象语法树 (AST) 的文档结构化解析：针对 LaTeX 翻译中格式破坏的难题，不采用纯文本处理方式，而是基于 pylatexenc 库开发深度解析算法。对于 AST 构建与剥离，将 LaTeX 源码解析为抽象语法树，精准识别并分离自然语言文本节点与非翻译节点（如公式、宏定义、TikZ 绘图代码）；设计智能切分算法 (Intelligent Chunking)，在保持段落语义完整性的前提下，对长文档进行切分，为后续的大模型处理做准备。
2. 面向术语一致性的混合检索增强：为解决垂直领域术语翻译不准确的问题，设计“查询转换-混合检索-重排”的三阶段 RAG 流程。摄入 PDF 参考文献及 CSV 术语表，利用向量数据库构建领域多源知识库；通过并行执行基于语义的向量检索和基于关键词的 BM25 检索，同时捕获语义相关性与精确术语定义，解决单一检索召回率低的问题；引入 Cross-Encoder 重排

	模型对检索结果进行二次精排，筛选出 Top-N 高相关性上下文注入 Prompt，强约束大模型遵循特定术语规范。 3. 基于工具学习（Tool Learning）的多智能体协作：基于 LangChain 框架构建 Multi-Agent 系统，将翻译任务分解为规划、执行、校验三个环节，通过调用外部工具解决深层语义理解问题。主要包括设计引用解析工具，针对 <code>\cite{...}</code> 命令，开发工具调用 arXiv API 或解析本地 BibTeX 文件，获取参考文献摘要，辅助模型理解引用背景；设计视觉理解工具，针对 <code>\includegraphics{...}</code> 命令，集成多模态大模型识别图表内容，确保图表标题（Caption）翻译与图像内容语义相符；设计编译自修正逻辑，设计反馈回路，当翻译结果导致编译失败时，Agent 能够自主分析 LaTeX 编译器日志并修正语法错误。 4. 系统服务化与工程实现：使用 FastAPI 重构后端逻辑，实现 RESTful API，引入任务队列管理机制以支持长文档异步翻译；编写 Dockerfile 及 Docker Compose 编排文件，将应用服务、向量数据库与模型服务打包，实现跨平台的一键部署与交付。			
工 作 进 度 安 排	序号	起止日期	任务	提交的阶段成果
	1	12月1日—12月7日 (1周)	调研	调研报告
	2	12月8日—12月29日 (2-4周)	查阅文献资料	开题报告
	3	1月1日—3月1日 (5-7周)	原型系统实现	系统代码
	4	3月2日—3月16日 (8-9周)	系统后端服务化实现	系统代码
	5	3月17日—4月1日 (10-13周)	系统前端实现及容器化部署	完整系统模型代码
	6	4月1日—5月1日 (14-15周)	系统集成测试、对比实验及数据分析、 撰写论文	实验数据分析报告、论 文全文
	7	5月2日—5月9日 (16-16周)	整理、修改、审核论文	论文全文
	8	5月10日—5月30日 (17-20周)	准备答辩	各种答辩材料

- [1] Brown T B, Mann B, Ryder N, et al. Language models are few-shot learners[C] // Advances in Neural Information Processing Systems 33 (NeurIPS 2020). New York: Curran Associates, Inc., 2020: 1877–1901.
- [2] Vilar D, Freitag M, Cherry C, et al. Prompting PaLM for translation: Assessing strategies and performance[C] // Proceedings of the 61st Annual Meeting of the Association for Computational Linguistics. Toronto: Association for Computational Linguistics, 2023: 15406–15427.
- [3] 王健, 王健, 王健, 王. 大模型在机器翻译中的应用: 挑战、机遇与发展[J]. 计算机学报, 2023, 53(9): 1647-1668.
- [4] Jiao W, Wang W, Huang J T, et al. Is ChatGPT a good translator? A preliminary study[R]. arXiv preprint arXiv:2301.08745, 2023.
- [5] Khan I A. XML and JSON translator[D]. Helsinki: Haaga-Helia University of Applied Sciences, 2023.
- [6] Zhu Z, Wang C. LaTeXTrans: Structured LaTeX Translation with Multi-Agent Coordination[R]. arXiv preprint arXiv:2508.18791, 2025.
- [7] Lewis P, Perez E, Piktus A, et al. Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks[C] // Advances in Neural Information Processing Systems 33. New York: Curran Associates, Inc., 2020: 9459-9474.
- [8] Gao Y, Xiong Y, Gao X, et al. Retrieval-augmented generation for large language models: A survey[R]. arXiv preprint arXiv:2312.10997, 2023.
- [9] Li G, Hammoud H, Itani H, et al. CAMEL: Communicative agents for "mind" exploration of large language model society[C] // Advances in Neural Information Processing Systems 36 (NeurIPS 2023). New York: Curran Associates, Inc., 2023: 51991–52008.
- [10] Wang Y, Zeng J, Liu X, et al. Delta: An online document-level translation agent based on multi-level memory[R]. arXiv preprint arXiv:2410.08143, 2024.
- [11] Qin Y, Liang S, Ye Y, et al. Tool learning with foundation models[R]. arXiv preprint arXiv:2304.08354, 2023.
- [12] Hendy N, Mohamed M, Saleh M, et al. How good are GPT models at translation? A comprehensive evaluation in a low-resource scenario[J]. arXiv preprint arXiv:2302.09210, 2023.
- [13] Pan S, Luo L, Wang Y, et al. Unifying large language models and knowledge graphs: A roadmap[J]. IEEE Transactions on Knowledge and Data Engineering, 2024, 36(7): 3580-3599.

	[14] Yang H, Yue S, He Y. AutoGPT for online decision making: Benchmarks and additional opinions[R]. arXiv preprint arXiv:2306.02224, 2023. [15][J]. , 2025, 38(4): 5-10. [16][J]. , 2024, 26(4): 3-8.
--	---